密级：公开

北京郵電大學

硕士学位论文(学术学位)



题目：基于深度学习的镍板表面缺陷检测算法研究

学　　号：2020110824

姓　　名：任 明 金

学科专业：控制科学与工程

培养方式：全 日 制

导　　师：杨 辉 华

学　　院：人工智能学院

2024 年 3 月 28 日



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Master Thesis

Research on Nickel Plate Surface Defect Detection Algorithm Based on Deep Learning

Student ID： 20201108204

Author： MingJin Ren

Subject： Control Science and Engineering

Supervisor： Huihua Yang

Institute： School of Artificial Intelligence

28 March 2024

答辩委员会名单

职务	姓　名	职　称	工　作　单　位
主席			
委员			
委员			
委员			
委员			
秘书			
答辩日期			

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

摘　要

金属镍由于其优越的特性，在航空航天、船舶、化工等多个领域都有广泛的应用。对电解镍板进行质量评估和缺陷检测，是生产中必要的一个环节。传统的人工目视检测方法，存在着速度慢、效率低和准确率低等问题。因此快速、高效地对电解镍板进行表面质量检测是生产企业亟需解决的问题。

本文研究使用深度学习分类方法与目标检测方法对镍板进行表面质量评估和缺陷检测。通过搭建工业现场图像采集实验平台，采集了 419 张电解镍板表面图片，经过图像处理和标注，本文分别构建了电解镍板表面质量等级分类数据集和电解镍板表面缺陷目标检测数据集。

对于电解镍板表面质量等级分类任务，针对分类训练数据量较少导致的模型训练不充分问题，本文提出了基于 ResNet-18 的双分支交叉熵-监督对比学习联合损失训练方法。通过引入监督对学习机制，对特征空间中各类别特征向量的分布进行优化，提升特征表示的有效性，使得分类性能显著提升。

对于电解镍板表面缺陷识别和定位任务，为使模型能够更好地处理电解镍板表面形态复杂的缺陷，本文提出了基于 YOLOv5 改进的电解镍板缺陷目标检测算法。将原本的耦合检测头替换为解耦头，并在解耦头中添加具有不同膨胀系数的空洞卷积和残差连接模块进行改进，增强解耦头的感知能力，使得检测性能有了较大的提升。

关键词：电解镍板；表面质量；等级分类；目标检测

ABSTRACT

Because of its superior characteristics, nickel is widely used in aerospace, shipping, chemical and other fields. Quality evaluation and defect detection of electrolytic nickel plate is a necessary link in production. The traditional manual visual detection methods have some problems, such as slow speed, low efficiency and low accuracy. Therefore, it is an urgent problem for production enterprises to inspect the surface quality of electrolytic nickel plate quickly and efficiently.

In this thesis, deep learning classification method and target detection method are used to evaluate the surface quality and detect defects of nickel plate. By building the industrial field image acquisition experimental platform, 419 surface pictures of electrolytic nickel plate were collected, and after image processing and marking, the classification data set of electrolytic nickel plate surface quality grade and the target detection data set of electrolytic nickel plate surface defects were constructed respectively.

For the classification task of surface quality grade of electrolytic nickel plate, aiming at the problem of insufficient model training caused by the small amount of classification training data, a joint loss training method of double-branch cross-entropy-supervised comparative learning based on ResNet-18 is proposed in this thesis. By introducing the supervised pair learning mechanism, the distribution of feature vectors in each category in the feature space is optimized, the effectiveness of feature representation is improved, and the classification performance is significantly improved.

For the task of surface defect identification and location of electrolytic nickel plate, in order to make the model better deal with the complex surface defects of electrolytic nickel plate, an improved defect target detection algorithm based on YOLOv5 is proposed in this thesis. The original coupling detection head is replaced by the decoupling head, and hole convolution and residual connection modules with different expansion coefficients are added to the decoupling head to enhance the perception of the decoupling head, so that the detection performance has been greatly improved.

KEY WORDS: electrolytic nickel plate; surface quality; grade classification; object detection

目 录

摘 要.....I
ABSTRACT.....II
第一章 绪论.....1
1.1 研究背景.....1
1.2 国内外研究现状.....1
1.2.1 传统金属表面缺陷检测.....2
1.2.2 基于机器视觉的金属表面缺陷检测.....2
1.2.3 基于深度学习的金属表面缺陷检测.....4
1.3 研究意义.....8
1.4 本文主要内容及结构安排.....9
1.4.1 本文主要内容.....9
1.4.2 本文结构安排.....9
第二章 基础理论和图像采集.....11
2.1 深度学习起源发展过程.....11
2.2 深度学习基本组件.....11
2.2.1 卷积层.....11
2.2.2 激活函数.....13
2.2.3 池化层.....16
2.2.4 全连接层.....17
2.2.5 归一化层.....17
2.3 深度学习模型训练方法.....18
2.3.1 梯度下降法.....18
2.3.2 反向传播算法.....19
2.4 图像采集.....20
2.4.1 图像采集实验平台.....20
2.4.2 数据处理.....21
2.5 本章小结.....22
第三章 电解镍板表面质量等级分类.....23
3.1 ResNet-18 分类模型.....23
3.1.1 残差连接.....23
3.1.2 网络结构.....24
3.1.3 损失函数.....25

3.1.4 性能评估.....26
3.2 监督对比学习.....26
3.2.1 介绍.....26
3.2.2 损失公式.....27
3.3 交叉熵-监督对比学习联合训练.....28
3.3.1 交叉熵-监督对比学习双分支网络.....28
3.3.2 监督对比学习损失改进.....29
3.3.3 交叉熵-监督对比学习联合损失.....30
3.4 实验数据集.....31
3.5 实验环境.....32
3.6 实验结果对比与分析.....32
3.7 本章小结.....34
第四章 电解镍板表面缺陷检测.....35
4.1 YOLOv5 目标检测模型.....35
4.1.1 YOLOv5 网络整体结构.....35
4.1.2 自适应锚框计算.....39
4.1.3 Mosaic 数据增强.....39
4.1.4 后处理.....39
4.1.5 损失函数.....40
4.1.6 性能评估.....41
4.2 YOLOv5 检测头改进.....43
4.2.1 原 YOLOv5 检测头.....43
4.2.2 检测头替换为解耦头.....43
4.2.3 解耦头改进.....44
4.3 实验数据集.....45
4.4 实验环境.....51
4.5 实验过程和结果分析.....51
4.6 本章小结.....52
第五章 总结与展望.....54
5.1 总结.....54
5.2 工作展望.....55
参考文献.....56
致 谢.....61
攻读学位期间取得的“创新成果”目录.....62

第一章　绪论

1.1　研究背景

镍金属是一种在现代工业制造中被广泛采用的材料之一，其具有出色的机械强度和抗腐蚀性，因此备受青睐，并在航空、机械、电池等多个行业中得到广泛应用。在金属镍的生产中，采用硫化镍阳极隔膜电解法生产的电解镍占据了全国镍产量的 90%，在电子、电力、化工和冶金等领域中发挥着重要作用。电解镍的纯度和晶体形态对产品质量至关重要，直接影响到其在市场上的竞争力和应用范围。

随着电解镍板的广泛用途和生产需求的增加，如何提高其生产质量和效率已成为镍金属生产企业和整个行业共同关注的焦点。其中，对电解镍板表面缺陷进行检测和及时处理则成为确保其质量和可靠性的重要环节之一。

目前，电解镍的出厂质检中，对其表面缺陷的检测是确保产品质量的必要手段。然而，电解镍生产企业仍依赖于人工检测，尚未实现镍板等级分类和缺陷识别的自动化、智能化。电解镍板通常具有较大的长宽尺寸（80cm 到 90cm），重量也相对较大（60kg 至 80kg），这使得检测工人面临着巨大的劳动强度和安全风险。现行的人工检测方法效率低下，无法满足不断增长的生产需求和严格的品质控制要求。此外，长时间的工作会导致工人视觉疲劳，而且不同工人之间的判断标准存在差异，个人主观因素影响较大，从而导致了判断结果的不确定性和误差增加，进而对镍板的质量评定带来了一定的经济损失。

传统的人工质检方法存在一系列问题，包括效率低、准确率低、人力成本高、容易疲劳等。随着生产工艺的不断提升和生产规模的扩大，传统的人工质检方法已经无法满足大规模生产的需求。因此，研究和开发一种自动、快速、准确的电解镍板表面缺陷检测方法成为了企业迫切的需求。

1.2　国内外研究现状

目前对电解镍板表面缺陷检测的研究和应用相对较少。在这一领域，研究仍处于起步阶段，相关文献数量有限，仅有两篇相关文献进行了探索。这些研究主要采用传统的图像处理和机器学习技术，尚未涉及到深度学习等新兴技术的应用。因此，电解镍板表面缺陷检测领域的研究仍有待进一步的深入和探索。

2020 年电子科技大学的崔增波等人[1]设计了一套电解车间电解镍阴极板和电解液状态视觉检测系统。对于电解镍阴极板的缺陷检测，该系统采用滑动窗口的方式去检测整张阴极板图像，使用传统图像处理技术分别提取窗口内的灰度、纹理等特征，使用主成分分析法（PCA）对特征进行压缩，使用支持向量机（SVM）

得到缺陷的种类，从而完成对电解镍阴极板表面是否含有缺陷的判断。2021 年昆明理工大学的王鑫等人[2]为检测电解镍板表面存在的气孔和结粒（凸起）两类缺陷，设计了电解镍表面缺陷视觉检测系统。该系统采用暖黄色 LED 灯照明方式拍摄图片，采用滤波降噪、线性变换以突出缺陷的轮廓特征，以此来检测电解镍板表面的气孔和结粒缺陷。

目前，尚未有相关研究文献探讨基于深度学习的镍板表面缺陷检测方法，本文是首次尝试利用深度学习方法对电解镍板进行表面缺陷检测。鉴于此，本文将重点介绍金属表面缺陷检测技术的研究和发展情况，为本研究提供一定的借鉴和启发意义，金属表面缺陷检测的研究方法如图 1-1 所示：

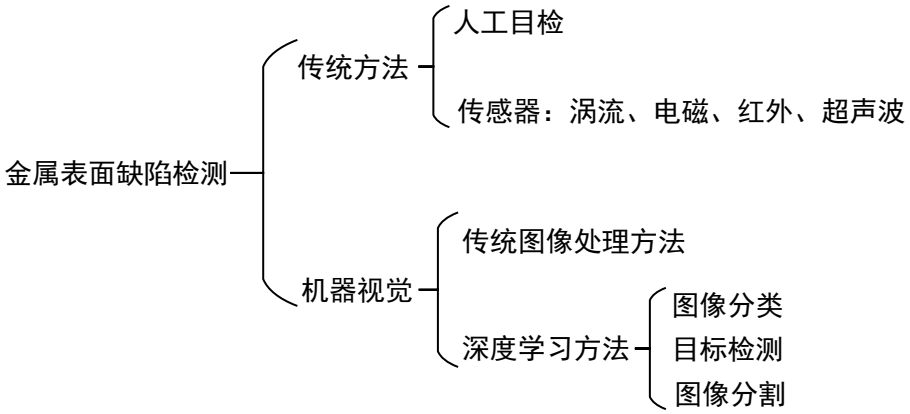


图 1-1 金属表面缺陷检测方法分类图

1.2.1 传统金属表面缺陷检测

传统金属表面缺陷检测方法根据检测原理的不同，主要分为人工目视检测方法、涡流检测技术[3]、电磁检测技术[4]、红外检测技术[5]和超声波检测技术[6]。在最原始的人工检测方法中，工人使用肉眼去辨别生产流水线上钢材的缺陷。然而，由于现场光线昏暗、噪声大、流水线速度较快，工人为了跟上流水线速度，需要保持高强度的精神集中。这容易导致用眼疲劳，无法仔细辨别缺陷，从而产生大量的错误检测和漏检情况。此外，判别过程存在着很强的个人主观性，标准模糊，导致了人工检测效率低下、准确度低的特点。涡流、漏磁、红外等检测技术虽然不再受工人生理上的影响，相对提高了检测效率，但是这些专业设备的使用有很高的环境要求。检测结果受金属表面状态及环境因素的影响较大，并且系统复杂、维护困难，适用范围小，难以满足企业对金属表面检测的需要。

1.2.2 基于机器视觉的金属表面缺陷检测

随着自动化检测技术和计算机图像处理技术的发展，机器视觉技术开始逐渐替代传统的检测方法。基于机器视觉的检测方法通常包括图像采集和图像处理两个步骤。首先，图像采集阶段使用光学图像采集设备获取金属材料表面图像。通

常有两种获取图像的方案。一种是通过激光对金属板进行扫描，激光接收器接收反射激光获取金属板表面的高度信息图像；另一种是使用可见光发光源和工业相机搭配来获取金属板的彩色图像或灰度图像。然后，在图像处理阶段，采用传统图像处理技术对图像进行预处理。包括滤波去噪和图像增强技术，以削弱或滤除图像中的噪声干扰，突出需要检测缺陷的特征。接着，使用边缘检测和阈值分割等方法提取出待检测缺陷的区域。最后，采用特征提取技术获取缺陷的特征信息，并根据需要调整适当的阈值或应用机器学习方法对特征进行分类，从而完成对表面缺陷的检测任务。机器视觉技术不需要与物体接触，具有广泛的适用范围，受环境条件影响较小，在复杂的工业环境中能够稳定运行。因此，在钢铁、纺织、交通等许多领域都得到了广泛的应用。

该方面的研究国外发展较早，在 20 世纪 70 到 80 年代时期，基于激光扫描方法获取金属板图像并进行表面缺陷检测的装置就已经出现。在 1971 年英国钢铁公司[7]开发出使用 He-Ne 激光器对钢材表面进行扫描的光学检测系统。在 20 世纪 70 中期，日本川崎公司[8]开发出镀锡板的表面缺陷检测装置，其装置采用激光三角测量方法，分别采用斜交激光和平行激光进行扫描，通过分析激光信号得到镀锡板表面缺陷情况。在 1988 年美国 SICK 公司[9]使用低功率 He-Ne 激光器对冷轧钢表面进行扫描，然后接收反射光线并进行转换得到冷轧钢表面图片信号，经过后续信号处理完成缺陷检测任务。

与此同时，由于 CCD 传感器拍摄技术的进步，基于 CCD 相机的机器视觉缺陷检测方法开始使用并逐渐发展。1983 年美国的 Honeywell 公司[10]采用 CCD 相机成像并结合边缘检测和阈值分割数字图像处理算法研制出了热轧钢表面缺陷实时检测装置，可以检测出热轧钢表面的裂纹和结粒缺陷。1986 年美国 Westinghouse 公司[11]基于 CCD 线扫摄像机和线光源，将三种明域、暗域和微光域照明方式进行组合，实现了在最高带速和最大带宽情况下的毫米级缺陷检测。1998 年芬兰 Rautaruukki 公司[12]研制出 Smart-Vis 表面检测系统，该系统使用使用机器学习方法决策树来对缺陷进行分类。美国 Cognex 公司[13]研发出自学习分类器软件并应用于自研的带钢自动检测系统，相比同时期的其他检测系统，检测精度有很大的提高。德国 Parsytec 公司[14]使用人工神经网络(ANN)构建分类器，研制出了 HTS-2 冷轧带钢表面检测系统，该系统可以在 300 m/min 的轧制速度下检测精度达到 0.5 mm。

相对于国外，国内基于机器视觉的表面检测研究起步相对较晚。1994 年罗志勇等人[15]研制出针对钢带表面缺陷的检测系统，该系统使用激光扫描和线扫 CCD 传感器拍摄相结合，通过对获得的脉冲信号进行分析，完成对带钢的边裂、重皮和空洞缺陷的检测。2000 年徐科等人[16]研制出冷轧钢板表面缺陷检测系统，

该系统使用面阵 CCD 相机，采用明场和暗场两种照明方式进行图片采集以适应不同性质的缺陷，对获得的图像进行边缘检测和区域分割并提取特征，最后使用基于 BP 网络的分类器进行缺陷分类，成功实现了对乳化液斑痕、锈痕、氧化铁皮、边裂、辊印和划痕这 6 种常见的冷轧钢板的表面缺陷的检测，平均识别率达到了 88.66%。2008 年 Wu 等人[17]设计了一种热轧带钢表面在线检测系统，主要对划痕、凹坑、疤痕、裂四种缺陷进行检测，该系统使用 20 台 CCD 相机同时采集热轧带钢不同区域的图像，通过特殊的照明方式，根据图片灰度级的变化可以将将缺陷区域与背景区分开，采用快速图像处理技术和并行技术实时处理图像，开发了模式识别算法对缺陷进行分类，四种缺陷的检出率都在 90%以上，各种缺陷的识别率在 85%以上。2010 年 Wei 等人[18]提出了亮场照明和暗场照明相结合的亮暗场缺陷识别新方法，亮暗场缺陷同时检测增加了缺陷的信息量，基于图像融合技术提出了一种适用于明暗场模式的缺陷检测新算法，缺陷的检出率达到 95%以上，而缺陷的识别率达到 85%以上。2016 年徐科等人[19]提出了一种基于 Tetrolet 变换的特征提取方法对冷轧钢板表面进行缺陷检测。该方法不对图片进行滤波去噪预处理，而是直接使用 Tetrolet 变换进行特征提取，以捕获不同尺度和不同方向上的信息，然后使用支持向量机对缺陷进行分类，在自建的数据集上的识别率达到了 97.38%。Zhao 等人[20]提出了一个将线阵列 CCD 平面扫描成像和面阵列 CCD 激光三维扫描成像相结合的多源成像系统，将 2D 特征和 3D 信息进行融合，从而对 3D 形状进行重建，基于三维图像深度值进行感兴趣区域（ROI）定位，使用模糊粗糙集模型来自适应检测缺陷边界。2020 年 Liu 等人[21]提出了一种对钢板表面的微变形缺陷进行检测分析的方法，使用 CCD 相机采集钢板表面的衍射纹理，通过对纹理图像进行灰度变换、二值化处理和梯度计算进行特征提取，使用支持向量机进行缺陷判断。

1.2.3 基于深度学习的金属表面缺陷检测

虽然基于机器视觉和图像处理方法在金属表面缺陷检测任务上得到了广泛应用并取得了一定成果，但仍存在一些问题。传统的图像处理方法和步骤需要专业人员进行精心设计，仅能检测出容易分辨特征明显的缺陷。在缺陷形态颜色变化较大或缺陷种类多的情况下，传统方法的检测效果往往不尽如人意。此外，这些方法对工作环境的稳定性要求较高。一旦图像采集设备的光照角度和强度发生变化，缺陷特征也会发生变化，导致传统算法无法适应，检测性能急剧下降甚至无法正常工作。

工业现场存在光照、背景、位置等不确定性因素的干扰，以及金属表面本身的复杂缺陷，传统的机器视觉技术难以有效处理这些情况。近年来，随着深度学习技术的不断发展和突破，在各种计算机视觉任务上取得了显著的进展。深度学

习技术具有较强的泛化性和适应性，逐渐成为金属表面缺陷检测研究的主流。

1.2.3.1　基于深度学习图像分类方法

金属表面缺陷检测的深度学习图像分类方法可以分为有监督分类器、半监督分类器和无监督分类器。目前最常见和广泛使用的方法是有监督学习方法，它需要收集大量含有标记的数据样本进行训练，即需要人工标注每个样本的缺陷类别信息。半监督学习方法需要大量未标记样本和少量的标记样本。它利用未标记的数据和部分标记的数据进行训练，从而提高模型性能。无监督学习方法只需要使用未标记样本进行训练，不需要任何标记样本，模型通过自主学习数据中的模式和结构来进行分类。每种方法都有其优缺点，选择适合具体需求的方法取决于数据的可用性、标记成本和分类性能要求等因素。

在有监督学习方法方面，Natarajan 等人[22]使用卷积神经网络（CNN）提取图像特征，然后使用支持向量机分类器进行判别，在 NEU 数据集上实现了 99.5%的分类准确率。Liu 等人[23]采用 GoogLeNet 作为主干网络，在网络主干中添加恒等映射，使用数据增强技术扩充数据集，在自建的冷轧钢带表面缺陷数据集上分类准确率达到了 98.57%。He 等人[24]使用 Inception-V4 卷积神经网络对热轧钢表面缺陷进行分类。使用多尺度卷积来提取图片的不同尺度信息，然后使用自编码器进行特征降维，分类率达到 97%以上。Yi 等人[25]采用端到端 CNN 网络对七种类型的带钢表面缺陷进行分类，使用对称的周围显著性图对缺陷区域进行分割，将缺陷区域的裁剪，图像作为输入，经过 CNN 网络对缺陷类别进行识别，在自建的数据集上实现了 99.29%的缺陷识别精度。Huang 等人[26]提出了深度注意残差卷积神经网络（DARCNN）来对六种热轧带钢表面缺陷进行分类，在网络中使用通道注意机制与残差块相结合，使得网络可以在没有信息丢失的情况下关注重要的特征通道，在 NEU 数据集上检测的精确率和召回率都达到了都达到了 99%以上。Kim 等人[27]采用 CNN 孪生神经网络，在只使用少量缺陷样本的情况下对的钢板表面缺陷进行分类，在 NEU-CLS-64 数据集上对九种缺陷分类准确率达到了 86.5%。

一些研究人员已经开始探索使用半监督学习和无监督学习方法进行金属表面缺陷检测的研究。这些方法的主要目标是解决深度学习有监督学习方法需要大量标注数据的问题。通过半监督和无监督方法，可以充分利用未标记的数据进行训练，以及生成新的数据以扩充数据集。目前，半监督和无监督深度学习方法主要应用于缺陷的分类任务中。

Gao 等人[28]提出了一种基于 CNN 的半监督学习方法，用于有限标记样本下的钢表面缺陷识别，先使用有限的标记样本进行训练，然后使用 CNN 网络对没有标签的样本生成伪标签，并结合伪标签样本与真实标签样本一起训练，在 NEU

数据集上分类准确率达到了 90.7%。Zheng 等人[29]提出了一种基于 MixMatch 的用于带钢表面检测的通用半监督方法，使用 Cutout 数据增强方法，对没有标签的数据经过多次数据增强通过 CNN 网络进行标签预测，然后进行平均、锐化得到伪标签。使用 MixUp 方法将标记样本和未标记样本混合从而产生新的图像样本，并且设计了新的损失函数和残差 CNN 网络进行训练，在 NEU 数据集上分类准确率达到了 100%。Di 等人[30]提出了一种新的半监督学习方法，基于卷积自动编码器（CAE）和半监督生成对抗网络（SGAN）对钢表面缺陷进行分类，首先使用未标记数据训练卷积自动编码器（CAE），以提取钢铁表面缺陷的特征，然后保留 CAE 的编码器网络作为 GAN 网络的鉴别器的特征提取器，引入 GAN 来生成钢表面缺陷的伪图像，以训练鉴别器从而对缺陷进行分类，在自建的数据集上实现了 97.2%的分类准确率。Liu 等人[31]一种新的基于 GAN 的带钢表面缺陷检测方法，该方法首先使用无缺陷图像训练 GAN 网络，并将其用于提取图像的特征，然后将训练特征放入 OC-SVM 中进行训练，从而对是否是无缺陷图片进行判别，通过该方法在自建的数据集中检测的精确率和召回率都达到了都达到了 93%。

1.2.3.2　基于深度学习目标检测方法

目标检测方法与分类方法不同，它需要检测出缺陷的类别、位置和大小。基于深度学习的目标检测方法通常分为两种类型：一种是基于区域建议的两阶段网络，如 Faster R-CNN[32]。这种方法将检测问题分为两个阶段：首先生成候选区域，然后对候选区域进行分类和位置回归。这种方法通常在精度上有所优势，因为它能够更准确地定位目标，但速度较慢；另一种是以 SSD[33]和 YOLO[34]及其系列为代表的一阶段网络，这种方法直接使用从网络中提取的特征来预测缺陷的位置和类别。相比两阶段方法，一阶段方法在速度上更有优势，因为它将检测和分类合并到一个阶段，但在精度上可能略有降低。在目标检测算法中，如何更好地平衡精度和速度一直是一个重要的研究方向。不同的应用场景可能需要不同的权衡，有些场景可能更注重精度，而有些场景则更注重速度。因此，选择合适的目标检测算法需要根据具体的需求来进行评估和选择。

顾佳晨等人[35]在两阶段 Faster R-CNN 模型中加入多尺度特征金字塔进行特征融合和可变形卷积，在对冷轧钢板的 10 类表面缺陷检测中，平均精确率和召回率分别达到了 93.8%和 95.8%。Wei 等人[36]提出了一种基于 Faster R-CNN 的缺陷检测方法，在网络中加入可变形卷积、多尺度特征融合技术，以及使用加权 RoI 池化层来缓解区域错位问题，在自建的钢筋数据集上平均召回率达到了 97%。Ren 等人[37]使用可分离卷积来对 Faster R-CNN 模型进行轻量化处理，在损失函数中添加类内中心损失项，在自建的带钢表面缺陷数据集上平均召回率和 mAP

分别达到了 97.02%和 98.32%。王艳玲等人[38]提出了基于 SSD 目标检测模型的钢带表面缺陷检测系统，使用灰度变换和小波变换进行图像增强，在 NEU-DET 数据集上 mAP 达到了 85.59%。Lin 等人[39]提出了一种检测钢坯表面缺陷的深度学习方法，该方法分为两个阶段，首先使用 SSD 模型进行缺陷的检测和定位，然后使用 ResNet 网络检测出的缺陷进行分类，在自建的钢坯表面缺陷数据集上实现了 100%的精确率和 97.9%的召回率。

Li 等人[40]针对冷轧带钢表面缺陷检测改进了 YOLO 算法，可实现端到端的自动化缺陷检测，使用卷积核大小为 3 步长为 2 的卷积替代原始网络的最大池化函数，为了提升检测小缺陷的性能，将 26×26×512 的特征图转换为 13×13×2048 的特征图，并与原始的 13×13 乘以 1024 的特征图连接，在自建的冷轧带钢六种表面缺陷数据集上实现了 97.55%的 mAP 和 95.86%的召回率。Zhang 等人[41]基于 YOLOv3 提出了一种分类优先的 CP-YOLOv3-dense 神经网络模型，先训练一个线性分类器对图像进行分类，然后再进行缺陷检测。将 YOLOv3 中的残差网络模块代替为密集网络模块，从而增强特征的重用和融合，改进后的网络在 NEU-DET 数据集上的 mAP、平均精确率和平均召回率分别达到了 82.73%、85.7%和 82.3%。Kou 等人[42]在 YOLOv3 的基础上将原本的锚点框结构使用自由框特征选择机制替代，并且使用密集卷积块提高特征提取能力，在 GC10-DET 数据集上的 mAP 达到了 71.3%，在 NEU-DET 数据集上的 mAP 达到了 72.2%。Ning 等人[43]基于 YOLOv3 模型，采用移位、改变亮度、添加噪声、旋转角度和剪裁五种方式对数据集进行扩展，在网络结构中增加了一个对浅层特征图的检测层并进行特征融合，以提高网络对小目标的检测能力。改进后的 YOLOv3 算法在 NEU-DET 数据集上的 mAP 达到 89.5%。李一鸣[44]等采用 YOLOv5s 模型对热轧钢表面缺陷进行检测，使用已经在 COCO 数据集上训练好的模型作为预训练模型，然后继续在 NEU-CLS 数据集上进行训练。在 NEU-CLS 数据集上 mAP@0.5 和平均召回率都达到了 77%。

1.2.3.3　基于深度学习图像分割方法

深度学习图像分割方法相对于目标检测方法的检测要求更加精确。它不仅需要检测出缺陷的种类和位置，还需要对图像上的各种缺陷和正常区域进行区域分割，即对图像上的所有像素点都进行类别判断，以完成缺陷区域和正常区域的分割。然而，在实际工业应用中，通常只需要检测缺陷是否存在，或者更进一步，检测出缺陷的种类和位置信息即可满足绝大部分的应用需求。因此，对于图像分割的需求并不是很大。

另外，图像分割算法需要消耗大量的计算资源，很难满足目前工业应用的实时性要求。此外，建立一个大型缺陷分割数据集也十分困难。要使用深度学习图

像分割方法，需要大量的标注数据，而且分割数据的标注是对每一张图片的每一个像素进行的，因此需要投入极大的人力、财力和时间成本。考虑到这些因素，目标检测方法在工业应用中更为实用和高效。

Zhang 等人[45]提出了一种基于对抗性学习的半监督分割网络来自动检测钢材上的缺陷，该网络由分割网络和全卷积鉴别器网络两个子网络构成，分割网络用于进行缺陷分割，全卷积鉴别器网络用于对没有标签的数据生成置信度标签，然后使用生成的标签数据和有标签数据联合训练分割网络，在 Severstal 数据集上实现了平均 IOU 为 81.8%的性能。Huang 等人[46]提出了一种深度可分离的 U 形网络对热轧钢带进行缺分割，采用深度可分离卷积来代替传统的卷积层，采用多尺度模块来获得多尺度上下文信息，以降低模型模型复杂度并提高分割性能，在 SD-saliency-900 数据集上分割精度和 Dice 分别达到了 95.42%和 80.8%。Qian 等人[47]提出一种基于 U-Net 与特征金字塔 FPN 和几种先进的预训练分类网络相结合的神经网络集成模型对钢板表面缺陷进行语义分割，在 U-Net 的编码和解码网络中集成多种分类网络主干，在 Severstal 数据集上 Dice 达到了 91.5%。Neven 等人[48]基于 U-Net 分割模型提出了具有两个分支的多任务模型，一个分支用来进行缺陷的像素级分割，另一个分支对缺陷的严重程度进行像素级分割，并且在 U-Net 网络中间加入生产工艺参数进一步提升了网络性能，在自建的钢材表面数据集上缺陷分割的平均 IOU 达到了 40.2%。

1.3 研究意义

传统的人工质检方法存在效率低、准确率低、安全性差等问题，无法满足大规模生产的需求。在国内外现状调研中发现，基于机器视觉的自动化检测技术在质量检测领域得到广泛应用。然而，传统的图像处理算法面对种类多、形态复杂的缺陷时，很难构造出有效的缺陷目标特征，需要专业知识和大量时间投入，且易受外界环境因素干扰，检测不稳定、鲁棒性不强。

近年来，深度学习技术的快速发展在图像分类、目标检测、视频理解和自然语言等任务上取得了大量优秀成果，成为研究热点和主流。深度学习技术通过端到端的训练学习过程，自动从数据中学习到优秀的特征表示，无需手动设计，使得模型能够更好地适应不同的数据和任务，具有较强的鲁棒性。在金属表面缺陷检测领域，深度学习技术已经取得了较好的性能，并得到了广泛的研究和应用。

考虑到企业对检测设备组成简单、易于维护的要求，以及对算法具有较强的抗干扰性和稳定性的需求，本文选择了深度学习方法来处理镍板表面缺陷的多样性和复杂性，使用深度学习分类算法和目标检测算法完成对镍板表面质量的等级评估和缺陷检测任务，填补了电解镍板表面缺陷检测领域深度学习方法研究的空白，对企业保障产品质量、推动企业转型升级和高质量发展、优化生产结构和提

高生产经营效益具有重要意义。

1.4　本文主要内容及结构安排

1.4.1　本文主要内容

本研究旨在利用深度学习方法对电解镍板表面质量进行等级评估和缺陷检测。主要分为两个方向：深度学习分类算法和目标检测算法。研究使用深度学习图像分类算法对电解镍板表面质量进行等级分类，研究使用深度学习目标检测算法，实现对电解镍板表面缺陷的识别和定位。

本文主要的研究内容如下：

首先构建实验数据集。设计了镍板表面图像采集方案，并在工人的帮助下在生产现场搭建了图像采集实验平台，采集了 419 张电解板表面图片，经过图像的转正处理和数据标注，分别构建了电解镍板表面质量等级分类数据集和电解镍板表面缺陷目标检测数据集，完成了算法研究需要的数据准备。

提出了基于 ResNet-18 的电解镍板表面质量等级分类算法。在原本的 ResNet-18 模型基础上，新增了对比学习分支和监督对比学习损失，并对原有的监督对比学习损失进行改进，与交叉熵分类损失结合，形成了交叉熵-监督对比学习联合损失并进行训练，该方法对比原有的方法获得了显著的性能提升。

提出了基于 YOLOv5 的电解镍板表面缺陷目标检测算法。分析了 YOLOv5 模型耦合检测头存在的不足，将模型上的耦合检测头替换为解耦头，并在解耦头中添加具有不同膨胀系数的空洞卷积和残差连接模块，以更好地适应电解镍板表面复杂的缺陷形态，使得缺陷检测性能有了较大的提升。

1.4.2　本文结构安排

根据本文的研究内容，论文分为五章，论文的相关章节安排如下：

第一章为绪论部分，主要介绍了镍板表面缺陷检测的研究背景和研究意义，介绍了镍板表面缺陷检测和金属材料表面缺陷检测方面的相关研究工作，分析了传统图像处理方法存在的问题，总结了当前主流的深度学习图像分类、目标检测和图像分割算法在金属表面缺陷检测方面相关的研究和应用。面对工业实际应用需求，提出了基于深度学习分类算法和目标检测算法的镍板表面缺陷检测方法。

第二章介绍了深度学习相关的基础理论知识和实验数据的采集。主要包括深度学习的发展过程和网络模型基本构成组件、深度学习模型训练方法。介绍了电解板表面图像采集实验平台和图像转正处理方法，为数据集的构建做准备。

第三章研究了基于 ResNet-18 改进的电解镍板表面质量等级分类算法。介绍了 ResNet-18 分类模型的网络结构、损失函数、分类性能评估指标和监督对比学相关知识，以及电解镍板表面质量等级分类数据集的构建。针对实验数据较少的情况，提出了交叉熵-监督对比学习联合损失并进行训练，在电解镍板表面质量

等级分类数据集上取得了显著的性能提升。

第四章研究了基于 YOLOv5 模型改进的电解镍板表面缺陷目标检测算法。介绍了 YOLOv5 模型的网络结构组成、自适应锚点框计算、数据增强方法和后处理过程等相关知识，以及电解镍板表面缺陷目标检测数据集的构建。对 YOLOv5 模型耦合检测头存在的问题，使用解耦头代替并对其结构加以改进，使其更好地适应电解镍板表面缺陷复杂的形态，提升了其对电解镍板表面缺陷检测的性能。

第五章，对基于深度学习 ResNet-18 模型的电解镍板表面质量等级分类和基于深度学习 YOLOv5 模型的电解镍板表面缺陷目标检测研究工作进行总结，以及将来对这两方面研究工作的展望。

第二章　基础理论和图像采集

2.1　深度学习起源发展过程

深度学习技术在当今社会的许多方面发挥着重要作用，从医疗辅助诊断到自动驾驶，再到智能助手和智能家居设备，从网络信息搜索到智能推荐系统，从图片生成和视频制作。它的应用范围越来越广，已经渗透到我们的日常生活中的多个方面，为我们带来了诸多便利和创新。

深度学习是一种特征学习方法，深度学习起源于人工神经网络的研究，最早可以追溯到 20 世纪 40 年代[49]。当时，神经科学家们对人脑中神经元之间的信息传递过程进行研究，试图将其应用于计算机科学领域。在 20 世纪 50 年中期到 70 年代，来源于模拟人脑神经网络的人工神经网络取得了一定的发展[50-52]。然而，由于硬件和算法的限制，神经网络的性能受到了限制，很难处理复杂的任务。在 20 世纪 80 年代神经网络的研究逐渐停滞。到 1986 年，Rumelhart 等人[53]提出了神经网络最基本的训练方法——BP 误差反向转播算法，使得浅层神经网络得以有效训练。之后随着硬件的发展，计算机算力的提升，神经网络的研究在不断进行，相继出现了双向联想记忆（BAM）网络[54]、卷积神经网络[55]、循环神经网络[56]等经典网络。2006 年，Hinton 等人[57]发表了一篇重要的论文，提出了一种新型的神经网络模型——深度信念网络（DBN），提出了深度神经网络学习算法，使神经网络的能力得到很大的提高。自此以后，深度学习开始成为热门的研究领域。2012 年，Hinton 的团队提出 AlexNet 深度学习网络[58]，在 ImageNet 视觉识别比赛中取得第一名的成绩。自此由于深度学习方法的突出表现，吸引了众多研究者投入精力进行研究，深度学习开始飞速发展，成为热门的研究领域。

2.2　深度学习基本组件

2.2.1　卷积层

深度学习中的卷积层是一种核心组件，广泛应用于处理图像、视频、语音等多维数据。它通过卷积操作有效地捕捉输入数据的局部特征，具有局部连接和权重共享的特点，能够高效地提取输入数据的空间结构信息，并实现对复杂数据的高效处理与分析。

传统神经网络采用的是全连接的工作方式，参数量庞大，容易过拟合。而在卷积层中，每个神经元只与输入数据的局部区域（称为感受野）相连接，这样能够大大减少参数数量。此外，卷积层中的权重共享机制也能够提高模型的稳健性和泛化能力。因为在卷积操作中，每个卷积核都与输入数据的不同区域进行卷积，但是所有区域都使用相同的卷积核，这意味着同一个特征在不同位置可以使用相

同的特征提取器，从而实现对输入数据的有效特征提取。

卷积操作通过滑动窗口的方式进行数据运算，输出大小取决于输入数据的大小、卷积核的大小和步长等参数。在卷积操作中，常见的卷积核包括边缘检测器、模糊滤波器、锐化滤波器等，它们能够有效地提取输入数据的不同特征。

一个卷积核对图片进行卷积操作可以提取某一种特征，深度学习卷积网络就是在每一层都应用大量的卷积核，通过学习训练这些卷积核的参数以此提取各种各样的丰富特征，对模型的性能起着最基本的支撑作用。

在图像领域，卷积神经网络（CNN）利用卷积层和池化层来提取图像的局部特征，实现图像的分类和识别。在视频领域，3D 卷积层能够有效地提取视频中的时空特征，从而实现视频的动作识别和行为分析。在语音领域，卷积神经网络也被广泛应用于语音识别和语音合成等任务中，能够有效地提取语音数据中的时域和频域特征。因为我们获取到的图像数据是二维的，因此通常使用的二维卷积来对图像进行操作。卷积操作包括下面三个基本几个参数，卷积核的大小和形状、卷积步长以及边缘数据的填充。卷积层的学习参数包含卷积核的参数和一个偏置参数。

2.2.1.1　卷积核

一个卷积核通常是一个小的矩阵，它与图像中的每个位置进行卷积操作，从而得到一个特征图。一个大小为 2×2 的卷积核和步长为 1 的卷积操作如图 2-1 所示：

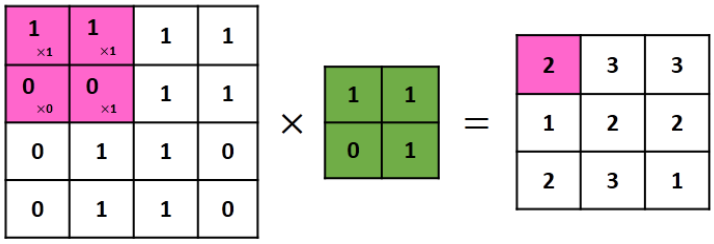


图 2-1 卷积操作示意图

卷积核的大小和形状决定了每一次卷积操作进行特征提取的视野的形状和大小，也称为卷积操作的感受野。

有一种特殊的空洞卷积，可以在不增加卷积核参数数量的情况下增加感受野，也被称为扩张卷积或膨胀卷积。膨胀系数 dilated=2 的空洞卷积操作如图 2-2 所示。

空洞卷积的卷积核中的每个元素都会与图像中的间隔元素相乘，然后将相乘的结果相加得到卷积操作的结果，就好像将卷积核进行了膨胀一样。通过这种方式，空洞卷积可以在不增加参数数量的情况下增加感受野，恰当地使用可以提高网络性能。但是如果膨胀系数设置过大则会导致原始数据不连续，缺失细节，而

起到相反的效果。

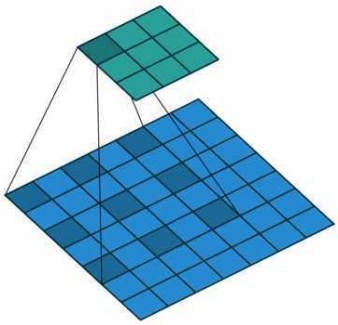


图 2-2 空洞卷积操作示意图

2.2.1.2　卷积步长

卷积步长控制着卷积核在一个位置做运算后，做下次运算位置在图像像素上移动的距离。因此步长大小会影响输出特征图的大小，当步长为 1 时，输出特征图的大小不会改变，当步长为 2 时，输出特征图的宽度和高度会分别是输入特征图宽度和高度的一半。

2.2.1.3　边缘填充

由于卷积操作过程中，卷积核是在图片或特征图里面进行移动和运算，如果不对图像或特征图的边缘进行数值填充，每次完整的卷积操作得到的特征图大小都会缩小，随着网络的加深，这种信息丢失会越来越严重，导致最外层边缘信息没有得到有效利用，从而会导致边缘特征的丢失，影响学习性能。因此，在进行卷积操作时对图片或特征图边缘进行适当的填充，可以确保当卷积步长为 1 时，输入输出的大小不变，维持中间特征图大小不变，以及卷积步长为 2 时输出大小减半的关系，方便计算网络每一层输出的大小。

2.2.2　激活函数

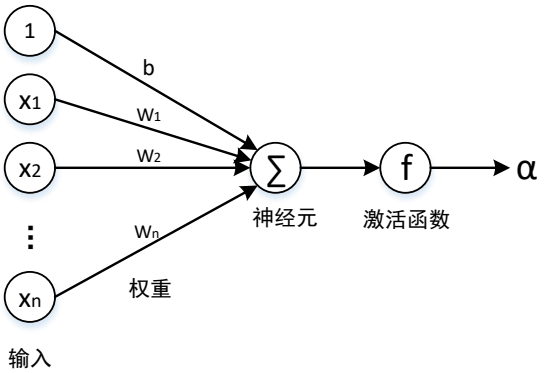


图 2-3 激活函数作用位置示意图

激活函数是深度学习网络中的重要组成部分，通过作用于神经网络中的每个神经元，将神经元的输出经过非线性激活函数处理后再输出，其作用在于在神经元的线性计算后引入非线性变换，使得神经网络可以拟合更加复杂的函数关系，

提高网络的表达能力。

在卷积神经网络中，上一层的卷积操作加权求和完成后都需要经过激活函数进行非线性变换后传递到下一个卷积层。激活函数作用位置如上图 2-3 所示。

当选择激活函数时，有四种常用选项，每种都有其独特的特点，适用于不同的任务和需求。

2.2.2.1 Sigmoid 激活函数

Sigmoid 激活函数是一种常用的激活函数，它将输入值映射到 0 到 1 之间，具有平滑的曲线特性。然而，当输入值较大或较小时会出现梯度消失问题，导致训练过程中梯度更新变得非常缓慢。此外由于经过该函数处理后的输出可以看做概率值，它也常用于二分类问题正类概率的计算。

Sigmoid 激活函数计算公式如下：

$$Sigmoid(x) = \frac{1}{1+e^{-x}} \tag{2-1}$$

函数图像如图 2-4 所示：

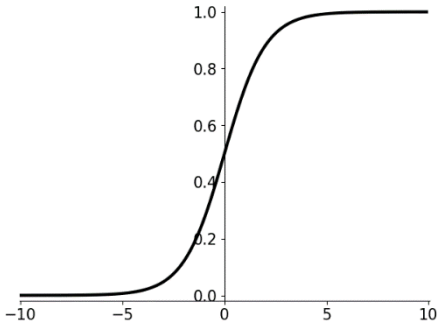


图 2-4 Sigmoid 激活函数图像

2.2.2.2 ReLU 激活函数

ReLU 激活函数是目前深度学习中最常用的激活函数之一。函数在输入为正时，保持不变，而在输入为负时，输出值为 0。相比于 Sigmoid 函数，ReLU 激活函数在计算上更加简单，当 x≥0 时导数等于 1，一定程度上可以效缓解梯度消失问题，加速网络的训练过程。但由于当 x<0 时导数等于 0，也会存在梯度消失导致参数无法更新的情况。

ReLU 激活函数计算公式如下：

$$ReLU(x) = max(0,x) = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases} \tag{2-2}$$

函数图像如图 2-5 所示：

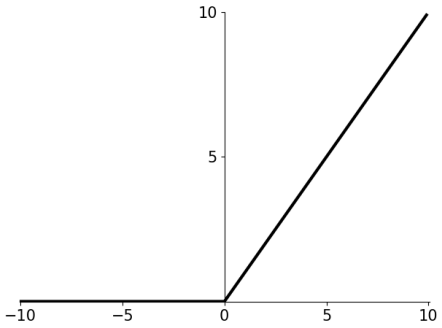


图 2-5 ReLU 激活函数图像

2.2.2.3　Leaky ReLU 激活函数

Leaky ReLU 激活函数是对 ReLU 函数的改进，该函数在输入为负时，不再完全置零，而是引入一个小的斜率，梯度不再是 0，有助于缓解 ReLU 函数中可能出现的梯度消失现象，提高模型的稳定性。

Leaky ReLU 激活函数计算公式如下：

$$Leaky\ ReLU(x) = max(\alpha x, x) = \begin{cases} x & x \geq 0 \\ \alpha x & x < 0 \end{cases} \tag{2-3}$$

其中，α 是一个小的正数，通常取 0.01。函数图像如图 2-6 所示：

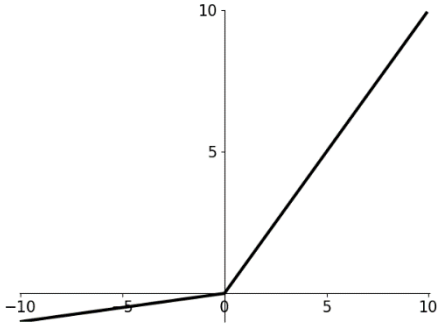


图 2-6 Leaky ReLU 激活函数图像

2.2.2.4　Tanh 函数激活函数

Tanh 激活函数也是一种常用的激活函数。该函数将输入值映射到-1 到 1 之间，与 Sigmoid 激活函数相比，它具有与 Sigmoid 激活函数一样平滑的形状，但输出值的范围包含负值，范围更广。Tanh 激活函数在输入为 0 时，输出值接近于 0，不改变原有数据的正负号，有利于中心化数据。但同样存在与 Sigmoid 函数一样的梯度消失问题。

Tanh 激活函数计算公式如下：

$$Tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}} \tag{2-4}$$

函数图像如图 2-7 所示：

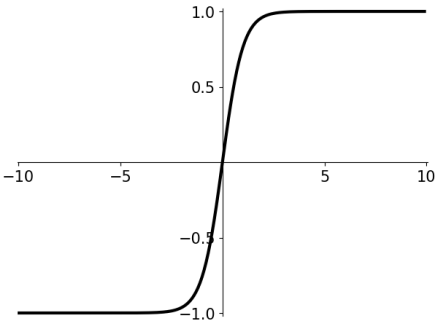


图 2-7 Tanh 激活函数图像

2.2.2.5 Softmax 激活函数

Softmax 激活函数是一种常用的激活函数，但是它有一些特殊。上面介绍的激活函数的输入只有一个，而 Softmax 激活函数的输入有多个。该激活函数将多个输入值分别映射到 0 到 1 之间，且所有输出值的和为 1。因此常用于多分类任务中。

给定一个包含 n 个元素的向量 $\boldsymbol{x} = [x_1, x_2, \ldots, x_n]$，Softmax 激活函数的输出计算公式如下：

$$Softmax(x_i) = \frac{e^{x_i}}{\sum_{j=1}^{n} e^{x_j}} \tag{2-5}$$

其中，x_i 是向量 $\boldsymbol{x}$ 中的第 i 个元素，e 是自然对数的底，而分母则是向量 $\boldsymbol{x}$ 中所有元素的指数函数之和。这样，Softmax 激活函数将向量 $\boldsymbol{x}$ 中每个元素转换为一个概率值，使得所有概率之和为 1。

在多分类任务中，Softmax 激活函数通常和交叉熵损失函数一起使用。它将原始得分进行指数化，然后进行归一化处理，从而得到概率分布。通过指数函数的作用，Softmax 激活函数会放大原始得分中的差异，使得概率分布更加明显，有利于区分不同类别之间的得分差异。

然而 Softmax 激活函数也存在一定的局限性。当输入的原始得分较大或较小时，Softmax 激活函数的输出概率会接近 1 或 0，导致梯度消失或梯度爆炸的问题。

2.2.3 池化层

池化操作是卷积神经网络中常用的一种操作，通常与卷积层交替使用，主要用于减小特征图的尺寸，减少模型参数和计算量以提高计算效率，同时减少模型对位置的敏感性，增强模型的鲁棒性和泛化能力。池化操作通常在卷积和激活的操作后进行，是一种降采样技术，通过聚合邻近区域的特征来减少特征图的尺寸。池化操作不涉及权重参数，而是通过一种固定的函数来计算输入特征图的输出值。典型的池化操作包括最大池化和平均池化。

最大池化（Max Pooling）：最大池化通过选取邻域内的最大值来减少特征图

的尺寸。最大池化的主要优点是可以提取出特征图中最显著的特征，通过保留最显著的特征来提高鲁棒性和抗扰动能力，同时具有一定的平移不变性。

平均池化（Average Pooling）：平均池化通过计算邻域内像素值的平均值来减少特征图的尺寸。平均池化的主要优点是可以保留更多的细节信息，有助于提高模型的稳定性。

平均池化取邻域内的平均值，有助于保留更多的局部信息，适用于提取图像中的平滑特征，如纹理等。最大池化取邻域内的最大值，适用于提取图像中的突出特征，如边缘、角点等信息。

池化操作的参数包括池化核、步长和填充，类似于卷积操作但是池化核不包含需要学习的参数，步长和填充用以调整输出特征图的大小和形状。

2.2.4　全连接层

全连接与卷积一样都属于线性变换，全连接层的每个神经元都与前一层的所有神经元相连，每个连接都有一个权重，用于学习输入和输出之间的线性关系。在全连接层中，需要学习的参数主要包括连接权重和偏置项。

全连接的主要作用在于变换特征的维度到固定的维度，用在网络的中间可以进行特征的压缩或者扩张，在卷积神经网络中经常用在网络的末尾，作为线性分类器使用，把提取到的图片特征进行线性加权求和，计算各类别的得分，然后经过 Sigmoid 激活函数或 Softmax 激活函数处理，得到各个类别的概率得分。

2.2.5　归一化层

深度学习中的归一化层是一种重要的技术，它通过将输入的中间特征进行归一化处理，使得其均值为 0，方差为 1，保持深度神经网络每一层的输出在一个较稳定的范围内，有利于梯度的传播，缓解深度神经网络训练过程中的梯度消失和梯度爆炸等问题，也降低了神经网络对学习率和初始化的敏感性，从而使深度神经网络在训练中更加稳定和更快的收敛。同时归一化在训练过程中引入了一定的噪声，有助于提升模型的泛化能力，抑制过拟合的发生。

深度学习中常用的归一化方法有如下三种。

(1) 批量归一化（Batch Normalization）

批量归一化方法是对于训练过程中一个 mini-batch 的所有输入数据而言的，对于每个 mini-batch 中的每个样本的每个特征维度，计算该维度在 mini-batch 上的均值和方差，然后再通过一个可学习的缩放参数和平移参数进行调整，使得网络学习出适合的分布，以恢复数据的表达能力。

批量归一化使得网络对输入数据的规模变化更加稳健，即使输入数据的分布发生变化，网络也能够更好地适应，从而增强了网络的鲁棒性。

(2) 层归一化（Layer Normalization）

层归一化是在层级上对数据进行归一化，对于一个输入样本神经网络会提取多个不同的特征，按照层级排布构成不同的特征通道，归一化的范围只限制在一个样本的所有特征层上，而不包含同一批次的其他数据。相比于批量归一化，层归一化对批量大小不敏感，因此更适用于小批量训练或者序列数据（如 RNN、Transformer 等）。在一些非卷积网络结构（如循环神经网络）中，批量归一化可能会引入一定的噪声，影响网络的性能，而层归一化可以避免这个问题。

(3) 组归一化（Group Normalization）

组归一化是将特征通道分为多个组，然后在每个组内对数据进行归一化处理。它跟层归一化更加接近，同样不受批量大小的影响，因此在一些特定场景下有着较好的表现。

2.3 深度学习模型训练方法

2.3.1 梯度下降法

梯度下降法（Gradient Descent）是一种常用的优化算法，被广泛应用于机器学习、深度学习以及其他优化问题中。其核心思想是利用损失函数对模型参数的梯度信息来指导参数更新，通过不断地迭代更新模型参数，以最小化（或最大化）损失函数（目标函数）的值。

目标函数或损失函数用于衡量模型预测与真实值之间的差距。目标函数的形式可以根据具体问题而定，常见的有均方误差损失、交叉熵损失等。在深度学习中，通常使用梯度下降法来调整神经网络中的权重和偏置参数，以最小化损失函数。损失函数表示了深度学习模型预测值与真实标签之间的差异，通过对损失函数求梯度并对参数进行更新，使模型更好的拟合训练数据。

假设有一个目标函数 $J(\theta)$，θ 表示模型的参数，梯度下降法的更新规则可以表示为：

$$\theta = \theta - \alpha \cdot \nabla J(\theta) \tag{2-6}$$

其中，α 是学习率，控制着参数更新的步长，$\nabla J(\theta)$ 是目标函数 $J(\theta)$ 关于参数 θ 的梯度，表示目标函数在当前参数值处的变化率。

算法步骤如下：

(1) 初始化参数：首先需要对模型的参数进行初始化，可以使用随机初始化或预训练的方式。

(2) 计算损失函数的梯度：对于当前参数值，计算损失函数关于参数的梯度，即目标函数在当前参数值处的斜率。

(3) 更新参数：沿着梯度的反方向，以一定的步长（学习率）更新参数值，使得目标函数值逐步减小。

(4) 重复迭代：重复步骤 2 和步骤 3，直到达到预定的迭代次数或损失函数

收敛到某个阈值。

梯度下降法的性能和效率受到多种因素的影响，包括学习率的选择、停止条件的设置、初始参数的初始化方法等。为了获得更好的训练效果，通常需要对这些参数进行调优和优化。梯度下降法根据训练时使用数据量的不同，可以分为三种：

(1) 批量梯度下降（Batch Gradient Descent）

批量梯度下降是指在每次迭代更新参数时，使用所有的训练样本的梯度信息来更新模型参数。这种方法计算量大，但是可以保证每次迭代都是朝着全局最优解的方向前进。因此，批量梯度下降通常用于小型数据集上。

(2) 随机梯度下降（Stochastic Gradient Descent）

随机梯度下降是指在每次迭代更新参数时，只使用一个随机的训练样本的梯度来更新模型参数。由于每次更新只需要计算一个样本的梯度，计算量相对较小，因此计算速度很快，但是每次参数的优化方向不稳定，有可能导致收敛到局部最优解。

(3) 小批量梯度下降（Mini-batch Gradient Descent）

小批量梯度下降法在计算梯度时不是使用全部训练数据，而是将训练数据集划分为若干个小批量（mini-batch），每次使用一个小批量数据来计算梯度并更新模型参数。这种方法可以降低每次迭代的计算复杂度，提高算法的效率，保证更新的方向相对稳定，有助于加速收敛和提高模型的泛化能力，因此是深度学习中最常用的优化算法之一。

梯度下降法作为深度学习中最基本、最重要的优化算法之一，为神经网络的训练提供了可靠的方法，促进了深度学习领域的快速发展和应用。

2.3.2　反向传播算法

反向传播算法（Backpropagation）是深度学习中最重要的算法之一，由 Hinton 等人[53]在 1986 年提出。其基本原理是反向逐层地计算损失函数对每一层参数的梯度，然后使用下降法来更新参数，以最小化损失函数。正式有了反向传播算法深度神经网络才得以有效训练，它使得神经网络能够通过训练数据自动学习和调整参数，从而实现对复杂模式的学习和泛化能力。

反向传播算法主要包含两个步骤：

(1) 前向传播（Forward Propagation）

反向传播算法的第一步是前向传播。在前向传播过程中，输入数据经过神经网络的每一层，通过各层的权重和激活函数，逐步得到输出结果。具体而言，前向传播的计算过程如下：

对于输入层，将输入数据送入神经网络。每一层的神经元将输入信号与其连

接的权重相乘，并加上偏置项，然后通过激活函数计算输出。将每一层的输出作为下一层的输入，直至到达输出层，得到最终的输出结果。

(2) 反向传播（Backward Propagation）

在前向传播得到输出后，反向传播算法通过计算损失函数对网络参数的梯度来更新参数。首先是计算损失函数对最后输出层的梯度，然后通过链式求导法则沿着网络的反方向逐层计算梯度，将输出层的梯度传递给每一层，然后使用损失函数的梯度对每一层的参数进行更新。

然而反向传播算法并不完美，在实际应用中随着神经网络的加深，梯度在反向传播过程中可能会指数级地减小或增大，导致参数无法正确更新，从而影响模型的训练效果，面临梯度消失和梯度爆炸等问题。当网络层数较深时，为了缓解这些问题，可以采用一些方法，如合适的激活函数选择、权重初始化方法、批量归一化等。

2.4 图像采集

2.4.1 图像采集实验平台

为了构建实验数据集，本文设计了电解镍板表面图像采集方案，并在企业工人的帮助下在生产现场搭建了电解镍板表面图像采集实验平台，在工业生产现场采集到了 419 张电解镍板表面图片。电解镍板表面图像采集方案如图 2-8 所示：

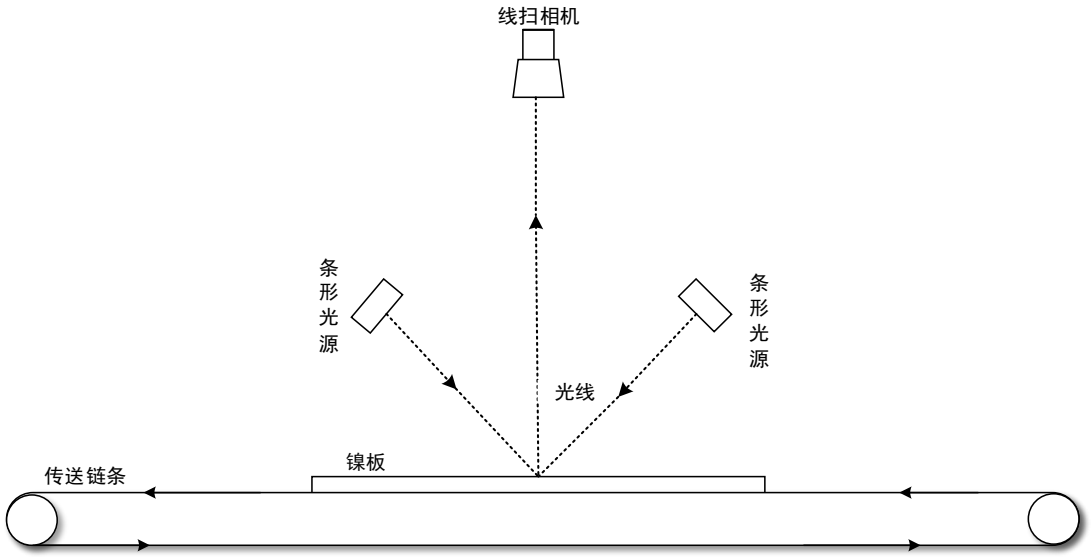


图 2-8 电解镍板表面图像采集方案示意图

为对在运动速度为 200mm/s 的传送带上拍摄电解镍板图片，实验采集平台采用线阵相机进行拍摄。因为电解镍板的长宽尺寸约为 90cm×90cm，并且留有一定的视野裕量，将拍摄视场宽度定为 1200mm。考虑电解镍板表面缺陷是有颜色的，以及后续研究的可能需要，现场采集图片的像素精度尽可能的高，以免精度不够而需要重新拍摄，因此最终选择使用型号为 Teledyne Dalsa Linea GigE 4k

的线阵 CMOS 彩色工业相机。该工业相机行输出图片每一行可以达到 4096 个像素，在宽度为 1200mm 的视场下，在相机安装高度为 1000mm，镜头焦距为 25.3mm 时，像素精度可以达到 0.29mm。

在拍摄过程中在相机两边分别使用大功率白色 LED 条形光源进行打光，以减轻工业现场外界光线的干扰。为在 200mm/s 运动速度下拍摄到正常图片，防止图像变形，线扫相机的拍摄行频设置为 710Hz，曝光时间为 45 μs。通过图像采集实验平台可以得到像素高宽大小为 3554×4096 的 RGB 三通道彩色图像。

工业现场图像采集实验平台如图 2-9 所示：

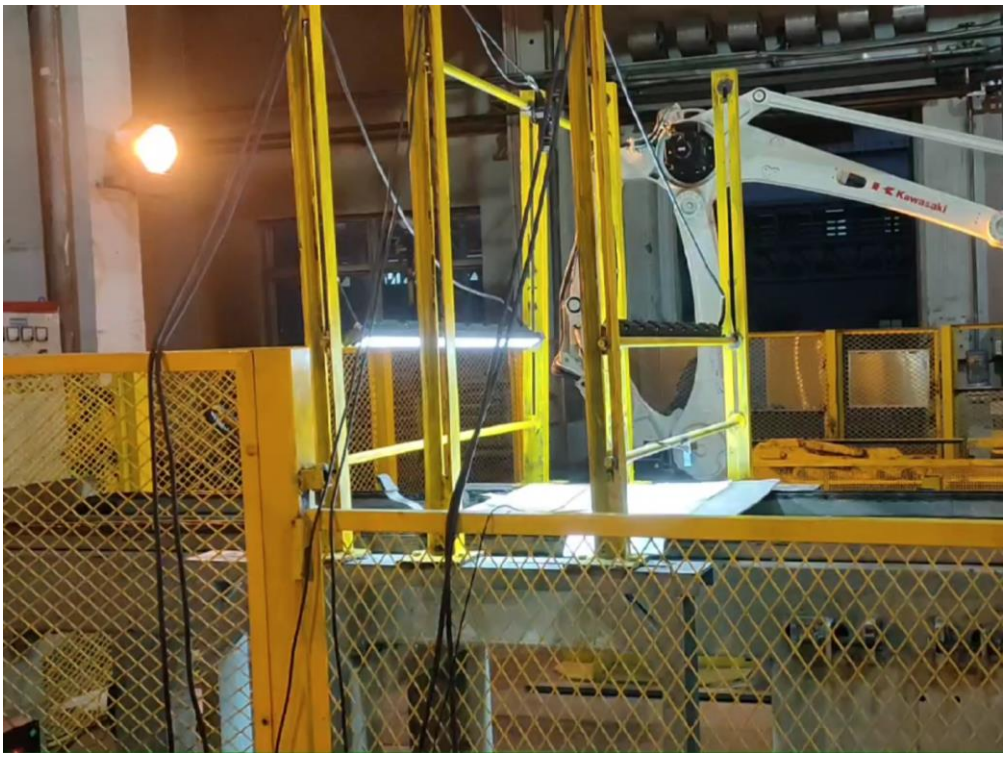


图 2-9 工业现场图像采集实验平台

2.4.2 数据处理

生产现场使用机械臂将镍板抓取并放置到传送链条上。然而，在放置过程中，无法保证镍板的上边缘与链条的运动方向垂直对齐，导致镍板存在一定程度的歪斜，拍摄的图片未能达到预期的放正姿态。

对于电解镍板表面质量等级分类任务而言，模型的训练应重点关注电解镍板表面的整体质量情况。由于采集到的图片数量有限，对图片进行转正可以消除镍板不同旋转角度的干扰，使模型能够更好地聚焦于学习镍板表面的综合质量特征，从而减轻模型训练的难度。对于电解镍板表面缺陷目标检测任务而言，如果镍板存在不同的旋转角度，为了精确检测缺陷的位置和大小，标注过程中除了需要框出缺陷的矩形区域，还需要标注缺陷矩形框的旋转角度，模型还需要额外学习检测框的旋转角度参数，这无疑会增加数据标注和模型训练的难度。

转正后的图片能够让标注人员更好地观察镍板表面的情况，从而更快地完成分类和缺陷检测的标注工作。企业也要求在检测结果显示时图片为转正状态，以便工人能够更轻松地观察和对比结果。综合考虑以上情况，对现场采集到的电解镍板表面图片进出转正处理，为构建数据集和标注做准备。

转正算法的主要思想是先找到图片中电解镍板的边缘轮廓，然后绘制边缘轮廓的最小外接矩形，从而得到电解镍板的位置和旋转角度。算法用 Python 语言编写，使用了 OpenCV 库提供的图片操作函数，具体步骤如下：

(1) 彩色图片转换为灰度图，缩小图片尺寸，减少计算量，提升处理速度。

(2) 设置合适阈值，把灰度图转换成黑白二值化图片。

(3) 对二值化图片使用 7×7 大小的核进行形态学开运算操作，去除背景和镍板剪耳的干扰。

(4) 把经过滤波处理的二值化图片作为输入，计算获得图像轮廓顶点信息。

(5) 根据轮廓顶点信息，使用计算包含所有轮廓顶点的最小外接矩形，从而确定电解镍板的中心点位置、高宽长度和偏移角度。

(6) 根据电解镍板的中心点和偏移角度计算旋转矩阵，然后对原图进行旋转，获得转正后的图片。

转正操作流程效果图 2-10 所示：

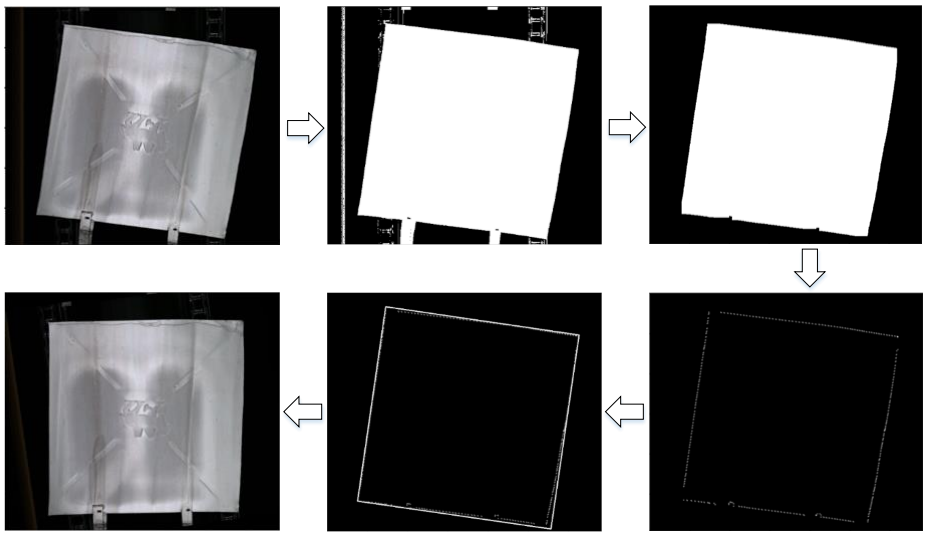


图 2-10 转正操作流程效果图

2.5 本章小结

本章首先介绍了深度学习基础理论，包括构成深度学习模型的卷积层、激活函数、池化层等基本组件，以及用于深度学习模型训练的梯度下降和误差反向传播算法。然后介绍了电解板表面图像采集方案和工业现场图像采集实验平台，以及对采集到图像的转正预处理算法，为数据集的构建做好准备。

第三章　电解镍板表面质量等级分类

对电解镍板表面质量进行等级分类有助于生产厂家根据不同的产品要求选择合适的材料，从而确保产品质量和性能的稳定性和可靠性。而传统人工质检存在易疲劳、效率低的缺点。为克服工人质检的缺点，提升效率，实现自动、快速地对电解镍板表面质量等级进行分类，本章提出了基于 ResNet-18 的电解镍板表面质量等级分类算法，构建了电解镍板表面质量等级分类数据集，并且提出了双分支交叉熵-监督对比学习联合损失训练方法，在数据量较少的情况下进一步提升表面质量等级分类性能。

3.1　ResNet-18 分类模型

ResNet（Residual Neural Network）是由 Kaiming He 等人[59]于 2015 年提出的一种深度神经网络模型，在当年的 ImageNet 图像分类比赛上获得了冠军。它通过引入残差学习的概念，有效解决了深度神经网络训练中的梯度消失问题，使得网络可以更轻松地训练成百上千层，成为深度学习领域的重要里程碑。由于其优越的网络性能和泛化能力，被广泛应用于各种计算机视觉任务中。

ResNet 根据模型参数量的大小分为不同的版本，如 ResNet-18、ResNet-34、ResNet-50 等，后面的数值表示网络的层数，层数越多网络的参数量越大。电解镍板表面质量分类实验的基础模型使用的是 ResNet-18，是 ResNet 中参数量最小的版本，总共约 11.7M 的参数量，以适应自建的小规模电解镍板表面质量分类数据集。

3.1.1　残差连接

ResNet 的核心思想是残差学习，即网络的每一层并不是学习输出与输入之间的映射关系，而是学习残差。传统的网络结构是通过堆叠多个非线性层来学习复杂的映射关系，而 ResNet 通过在这些层之间引入跨层连接，让网络直接学习残差，即网络的输出与输入之间的差异。因为网络只需学习残差的微小调整而不是整个映射关系，从而减轻了训练的难度。

残差块（Residual Block）是 ResNet 中的基本构建模块，一个典型的残差块包含两个分支，即主分支和残差分支。ResNet-18 中的残差块主分支由两个连续的 3×3 卷积层组成，第一个卷集层后使用批量归一化和 ReLU 激活函数处理，第二个卷积层输出后接使用批量归一化处理。

ResNet-18 中使用的残差块有两种变体。第一种残差块的输出特征图形状大小与输入相同，不会改变输入特征的长宽尺寸大小和通道数目，因此在主分支中的两个卷积层都是卷积核大小 3×3、步长为 1 的卷积，残差分支使用的是恒等

变换跳跃连接；第二种是残差块的输入特征图的长宽尺寸是输入的一半，通道数是输入特征图的两倍，因此主分支的第一个卷积层使用卷积核大小为 3×3、步长为 2 的卷积，第二层为卷积核大小 3×3、步长为 1 的卷积，对应的残差分支使用的是卷积核大小为 1×1、步长为 2 的卷积。第二种类型的残差块一方面进行下采样操作，缩小了特征图的长宽尺寸，用来减少网络计算的参数量；另一方面特征通道翻倍，是为了抵消参数量减少导致特征减少的负面影响，增加更多的特征。两种残差块结构如图 3-1 所示：

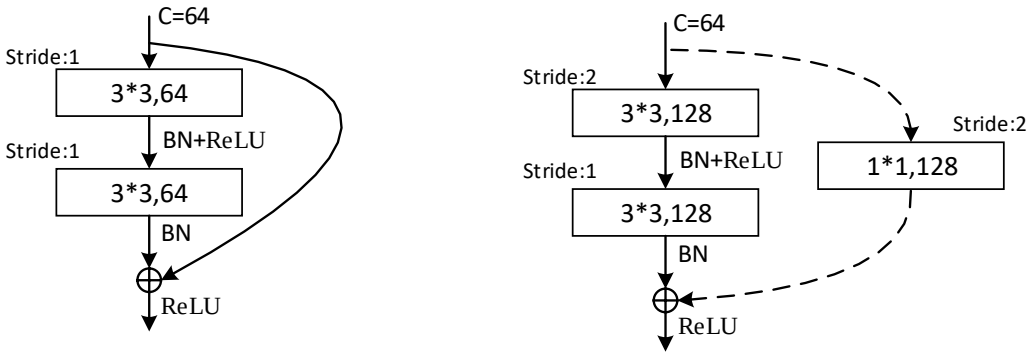


图 3-1 ResNet-18 两种残差块结构图

3.1.2 网络结构

ResNet-18 网络包含了 17 个卷积层，一个最大池化层和一个全连接层，包含训练参数是的 17 个卷积层和最后的一个全连接层以及在中间使用的批量归一化（Batch Normalization）层，因此命名为 ResNet-18。整个网络结构使用了四个步长为 2 的下采样卷积和一个步长为 2 下采样最大池化，逐级缩小特征图的尺寸。

ResNet-18 的输入层是一个卷积核大小为 7×7、步长为 2 的卷积层，主要用来减小输入图像尺寸和提取图像最初的特征。

第二层是一个最大池化层（MaxPooling），采用池化核为 3×3、步长为 2 的池化操作，用于降低特征图的尺寸，增加网络的感受野。

接下来是由四个阶段组成。每个阶段由两个残差块（Residual Block）堆叠而成。第一个阶段的两个残差块都使用第一种变体，来对上一步的特征进行提取和处理。第二个到第四个阶段，每个阶段的第一个残差块使用第二种变体，来减少特征图的尺寸、增加通道数，第二个残差块使用第一种残差块，不改变特征图的尺寸和通道数，进行更丰富的特征提取。这四个阶段堆叠在一起，一共 8 个残差块 16 个卷积层，构成了 ResNet-18 残差网络的主要部分。

接着是一个全局平均池化层（Global Average Pooling），对最后一个阶段的特征图进行全局平均池化，将特征图的尺寸降至 1×1。

最后将 1×1 尺寸、512 个通道的特征图变换成具有 512 维度的特征向量，再接一个全连接层（Fully Connected Layer），将特征向量映射为分类的各个类别得分。ResNet-18 网络结构如图 3-2 所示：

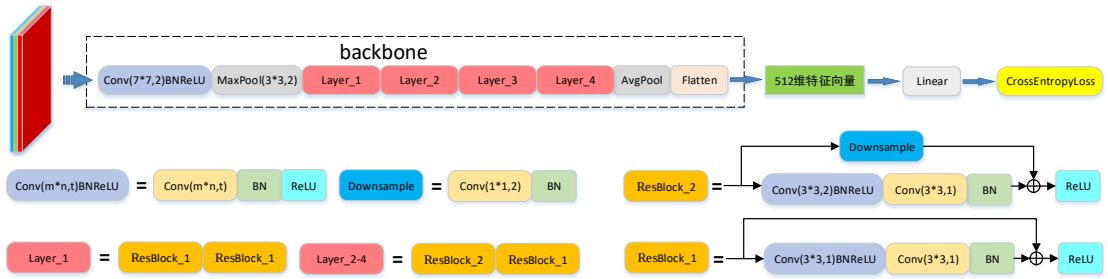


图 3-2 ResNet-18 网络结构图

3.1.3　损失函数

ResNet-18 分类网络模型的损失函数使用交叉熵损失（Cross-Entropy Loss），它衡量了模型输出的概率分布与真实标签之间的差异，是一种常用的分类损失函数。

在分类任务中，假设模型的输出为一个概率分布，表示每个类别的预测概率，而真实标签则是一个 one-hot 向量，表示样本的真实类别。交叉熵损失函数通过比较模型预测的概率分布和真实标签的分布，来评估模型的预测准确程度。对于一个样本，假设其真实标签为 $\boldsymbol{y}$，模型的输出概率分布为 $\boldsymbol{p}$，则交叉熵损失可以表示为：

$$\mathcal{L}^{CE} = CrossEntropyLoss(\boldsymbol{y},\boldsymbol{p}) = -\sum_{i=1}^{n} y_i \, log(p_i) \qquad (3-1)$$

其中

$$p_i = Softmax(x_i) = \frac{e^{x_i}}{\sum_{j=1}^{n} e^{x_j}} \qquad (3-2)$$

$\boldsymbol{y} = (y_1, y_2, \ldots, y_n)$，是具有 n 个维度的 one-hot 向量，n 表示分类的类别数。如果这个样本的真实样本类别是第 j 类，那么

$$y_k = \begin{cases} 1, & k = j \\ 0, & k \neq j \end{cases} \qquad (3-3)$$

$\boldsymbol{x} = (x_1, x_2, \ldots, x_n)$，是输入图片经过 ResNet-18 网络处理后得到的各类别的得分。$\boldsymbol{p} = (p_1, p_2, \ldots, p_n)$，是得分 $\boldsymbol{x}$ 经过 Softmax 函数处理后得到的各类别预测的概率分布。

3.1.4 性能评估

对于分类任务，常用的性能评估指标有精确率（Precision）、召回率（Recall），和准确率（Accuracy）。对于某一个类别其分类结果的混淆矩阵如表 3-1 所示：

表 3-1 某一个类别分类结果混淆矩阵

真实	预测	
	正例	反例
正例	TP	FN
反例	FP	TN

其中，TP（True Positive）表示实际是正例且模型预测为正例的数目。FP（False Positive）表示实际是反例而模型预测正例的数目。FN（False Negative）表示实际是正例而模型预测为反例的数目。TN（True Negative）表示实际是反例而模型也预测为反例的数目。

精确率 Precision，简写为 P，是指对于该类别，模型预测为正例且实际也为正例的数目占模型预测为正例总数的比例，计算公式如下：

$$P = \frac{TP}{TP + FP} \tag{3-4}$$

召回率 Recall，简写为 R，是指对于该类别，模型预测为正例且实际也为正例的数目占该类别实际正例总数的比例。计算公式如下：

$$R = \frac{TP}{TP + FN} \tag{3-5}$$

准确率 Accuracy 是指对于该类别，模型正确分类数目占所有分类样本数的比例。其计算公式如下：

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \tag{3-6}$$

3.2 监督对比学习

3.2.1 介绍

监督对比学习（Supervised Contrastive Learning）旨在利用数据样本之间的相似性和差异性来改善模型的表示学习能力。其灵感来源于无监督学习中的对比学习思想，即通过比较不同样本之间的相似性来学习有意义的表示。然而，无监督学习往往受到表示质量和稳定性的限制。监督对比学习结合了监督学习和对比学习的思想，通过有效利用标签信息来引导学习过程，从而提升模型性能。

2020 年 Khosla 等人[60]首次将自监督对比学习方法扩展到监督对比学习方法，提出并分析了监督对比损失的两种可能形式，确定了两种可能形式中最好的一种，在 ImageNet 数据集上实现了 81.4%的 top-1 准确度，比原有使用 Cross-Entropy 损失模型性提升了 0.8%。2021 年 Gunel[61]在自然语言理解分类任务上引入了监督对比学习损失，用以对预训练好的语言模型进行微调，使模型对数据中的噪声更具鲁棒性，在少镜头学习任务中性能得到了显著的提高。Zeng 等人[62]在聊天对话的域外检测任务中使用了有监督对比学习目标，以最小化各类文本的类内方差和最大化类间方差，并采用对抗性增强机制来增加伪正样本数量，帮助模型捕捉更广泛的特征，在域外检测公开数据集上证明了该方法的有效性。2022 年 Pinitas 等人[63]在多模态情感建模任务中使用监督对比学习方法进行融合学习，利用情感注释来构建对比标签，以训练多模式情感模型学习到更通用的情感特征表示，结果显示监督对比学习方法有效地提高了情感模型的有效性。Yang[64]在推荐系统任务中使用监督对比学习方法，以使相似节点在特征空间中更接近、差异大的节点相互远离，以提高推荐系统的性能。Chen 等人[65]在文本情感分类任务中提出了一个新的弱监督抗噪声对比学习情感分类框架 WACL。该框架在模型的预训练阶段采用了有监督对比训练策略，充分挖掘弱标记数据的潜在对比模式，以学习分类特征的稳健表示。

对于小规模电解镍板表面质量分类数据集来说，由于训练数据有限，即使使用 ResNet-18 这个最小参数量模型，仍然存在着训练不充分的问题，为改善该问题引入了监督对比学习机制，提高模型在少样本的情况下的特征表示能力。

3.2.2　损失公式

监督对比学习损失由无监督对比学习损失改进而来，在无监督对比学习损失中，由于没有类别标签，通常使用数据增强后的图片与原图片互为正例，与其他图片互为反例。而监督对比学习是在有真实的分类标签下进行的，因此在训练的一个批次中，具有相同类别标签图片样本的互为正例，不同类别标签图片样本的互为反例，监督对比学习损失在论文[60]中首次提出，其计算公式如下：

$$\mathcal{L}^{sup} = \frac{1}{2N}\sum_{i=1}^{2N}\mathcal{L}_i^{sup} \tag{3-7}$$

$$\mathcal{L}_i^{sup} = \frac{-1}{2N_{y_i}-1}\sum_{j=1}^{2N} l_{[i\neq j]}\cdot l_{[y_i=y_j]}\cdot log\frac{exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{2N} l_{[k\neq i]}\cdot exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_k}{\tau}\right)} \tag{3-8}$$

在一个训练批次中，有 N 个样本，然后通过数据增强后扩充到 $2N$ 个数据样本，$\boldsymbol{z}_i$ 表示经过正则化处理的第 i 个样本对应的特征，$\boldsymbol{z}_i\cdot\boldsymbol{z}_j$ 是两个正则化样本特征做内积求取特征的相似度。y_i 表示第 i 个样本的类别标签，N_{y_i} 表示 N 个样

本中 y_i 类别的样本个数。在一个批次中，监督对比损失 $\mathcal{L}^{sup}$ 是每个样本的监督对比损失 $\mathcal{L}_i^{sup}$ 的总和再求均值。

对于第 i 个样本的监督对比损失 $\mathcal{L}_i^{sup}$，是在 $2N$ 个样本批次中，需要计算所有与 i 具有相同类别标签的正样本对之间的监督对比损失，但是除去 i 样本本身。然后求和再取均值。例如第 i 与 j 个样本与互为正样本对，先计算该样本与除去自身的所有其他样本的正则化特征的内积，然后将内积相似度除以温度缩放因子 τ，进行特征相似度的缩放。再用类似与 Softmax 的计算方式对特征相似度进行计算，其分母包含样本 i 与所有其他样本的归一化特征的相似项求和，里面包含了所有与 i 具有相同类别标签的正样本（除去自己）和其他不同类别的负样本。分子中只包含 i 与 j 的归一化特征相似度项，最后将这个结果取负自然对数，样本对 i 与 j 之间的对比损失计算完成。

3.3 交叉熵-监督对比学习联合训练

对于电解镍板表面质量分类任务，在自建的小规模数据集的基础上进行实验和改进。实验基线基于 ResNet-18 分类网络模型，原模型使用多分类交叉熵损失函数。对于小规模数据集存在的模型训练学习不充分的问题，引入监督对比学习机制，在原来的 ResNet-18 模型上增加对比学习分支，形成了一个交叉熵-监督对比学习双分支网络。修改监督对比损失函数形式，适应电解镍板表面质量分类的需要。然后对原来的监督对比学习损失进行改进，结合交叉熵损失提出了交叉熵-监督对比学习联合损失并进行训练，使得电解镍板表面质量分类性能有了显著的提高。

3.3.1 交叉熵-监督对比学习双分支网络

在 ResNet-18 网络的主干后面添加监督对比学习分支，形成双分支网络。监督对比学习分支用来计算监督对比学习损失（SupConLoss），优化 ResNet-18 网络主干的类别特征表示。基于 ResNet-18 的交叉熵-监督对比学习双分支网络如图 3-3 所示：

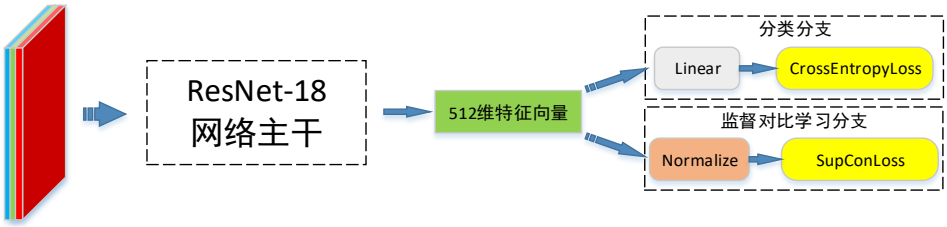


图 3-3 基于 ResNet-18 的交叉熵-监督对比学习双分支网络结构图

分类分支把 ResNet-18 网络主干提取的 512 维特征向量经过线性层映射为各类别得分，然后计算交叉熵分类损失。监督对比学习分支先把这 512 维特征向量

进行归一化处理，然后计算监督对比学习损失。

3.3.2　监督对比学习损失改进

原来的监督对比损失虽然发挥了一定的作用，但是仍然存在一定的缺陷，监督对比损失引入的目的是为了优化各个类别在特征空间中分布，尽可能拉大不同类别特征的距离并缩小相同类别特征的距离。这种特征之间的距离衡量是通过特征的内积计算得到的，计算公式如下所示：

$$log\frac{exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{2N}l_{[k\neq i]}\cdot exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_k}{\tau}\right)} \tag{3-9}$$

要使监督对比学习损失最小，那就需要上式中自然对数的参数为 1，这样负自然对数才能取值为 0，达到最小值。这就要求分子的正样本对之间的相似度值 $\boldsymbol{z}_i\cdot\boldsymbol{z}_j/\tau$ 相较于分母中的其他项的相似度值大很多，这样才能使得整个结果约等于 1。然而，分母中的计算除了与 i 类别不同的负样本，还存在除了 j 之外的正样本，而在训练过程中正样本之间的相似度较高，无法达到 i 和 j 样本之间的相似度远大于 i 和其他正样本的相似度，就存在着优化方向的矛盾。基于此便有了下面对于原本监督对比损失的改进版本，并且已经在论文[65]中使用，公式如下：

$$\mathcal{L}^{sup_1}=\frac{1}{2N}\sum_{i=1}^{2N}\mathcal{L}_i^{sup_1} \tag{3-10}$$

$$\mathcal{L}_i^{sup_1}=\frac{-1}{2N_{y_i}-1}\sum_{j=1}^{2N}l_{[i\neq j]}\cdot l_{[y_i=y_j]}\cdot log\frac{exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{2N}l_{[y_i\neq y_k]}\cdot exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_k}{\tau}\right)+exp\left(\boldsymbol{z}_i\cdot\frac{\boldsymbol{z}_j}{\tau}\right)} \tag{3-11}$$

上式中的每一个样本的监督对比损失项，分母中的正样本对只保留了分子中的那一项，去除了其他正样本对的干扰，负样本对没有没改变。这样在优化每一项的时候就可以只考虑 i 和 j 正样本对的相似度和 i 和其他负样本对的相似度，使得 i 与其他同类正样本的特征更加接近，与其他不同类的负样本之间的特征相离地更远。该监督对比学习损失改进了正负样本对之间的选择计算策略，使得特征优化方向更加明确。

在电解镍板表面质量等级分类任务中，使用 ResNet-18 双分支网络训练，由于在数据集构建过程中，已经使用图像增强算法对训练集进行了四倍的扩充，所以在训练中一个批次的样本无需同上面的监督对比学习一样进行训练样本的 2 倍扩充，因此需要将上面原来的监督对比损失和改进后的监督对比损失公式改写，以应用在电解镍板表面质量等级分类任务中。

训练的一个批次中样本大小为 N，那么就使用这 N 个数据的特征进行监督对比学习的训练，对原来的监督对比损失进行改写，改写后的公式如下所示：

$$\mathcal{L}^{sup} = \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}_i^{sup} \tag{3-12}$$

$$\mathcal{L}_i^{sup} = \frac{-1}{N_{y_i}-1}\sum_{j=1}^{N} l_{[i\neq j]} \cdot l_{[y_i=y_j]} \cdot log\frac{exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{N} l_{[k\neq i]} \cdot exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_k}{\tau}\right)} \tag{3-13}$$

对改进后的监督对比损失进行改写，改写公式如下：

$$\mathcal{L}^{sup_1} = \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}_i^{sup_1} \tag{3-14}$$

$$\mathcal{L}_i^{sup_1} = \frac{-1}{N_{y_i}-1}\sum_{j=1}^{N} l_{[i\neq j]} \cdot l_{[y_i=y_j]} \cdot log\frac{exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{N} l_{[y_i\neq y_k]} \cdot exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_k}{\tau}\right) + exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_j}{\tau}\right)} \tag{3-15}$$

然而改写后的监督对比损失会存在一些问题。原监督对比损失中，在训练时使用一个训练批次样本的 2 倍扩充，可以确保每一个样本至少都有一个正样本对来计算监督对比损失。改写后的损失中，只使用了一个训练批次的样本，在训练中无法保证每一个样本都至少有一个正样本对来计算监督对比损失，当一个批次中出现某一个类别的样本只有一个的时候，该样本作为正样本应贡献的损失项就会丢失。在样本数量较少的情况下，这种问题会更加突出。

针对改写后的监督对比损失存在的样本利用不充分问题，在改写的 $\mathcal{L}^{\mathrm{sup_1}}$ 损失基础上再进行改进，在损失项中把样本自身与自身也算作一个正样本对，加入到所有的正样本对中，这样就得到改进后的版本 ${\mathcal{L}_1}^{\mathrm{sup_1}}$，公式如下：

$${\mathcal{L}_1}^{sup_1} = \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}_i^{sup_1} \tag{3-16}$$

$$\mathcal{L}_i^{sup_1} = \frac{-1}{N_{y_i}}\sum_{j=1}^{N} l_{[y_i=y_j]} \cdot log\frac{exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_j}{\tau}\right)}{\sum_{k=1}^{N} l_{[y_i\neq y_k]} \cdot exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_k}{\tau}\right) + exp\left(\boldsymbol{z}_i \cdot \frac{\boldsymbol{z}_j}{\tau}\right)} \tag{3-17}$$

3.3.3 交叉熵-监督对比学习联合损失

最终结合交叉熵分类损失和监督对比学习损失，将两者相加得到交叉熵-监督对比学习联合损失，公式如下：

$$Uloss_1 = \mathcal{L}^{CE} + \mathcal{L}^{sup} \tag{3-18}$$

$$Uloss_2 = \mathcal{L}^{CE} + \mathcal{L}^{sup_1} \tag{3-19}$$

$$Uloss_3 = \mathcal{L}^{CE} + {\mathcal{L}_1}^{sup_1} \tag{3-20}$$

$Uloss_1$ 损失是交叉熵损失项加上改写的原监督对比学习损失项，$Uloss_2$ 损失是交叉熵损失项加上改写的改进监督对比学习损失项，$Uloss_3$ 损失是交叉熵损失项加上为适应小规模数据集而改进的监督对比学习损失项。

3.4　实验数据集

电解镍板表面质量等级分类数据集包含 419 张图片，将电解镍板表面质量分为 0、1、2 和 3 四个等级类别进行打标，数值越小代表的表面质量越好，然后按照 4:1 的比例进行随机分层抽样完成训练集和测试集的划分，其中训练集中包含 336 张图片，测试集中包含 83 张图片。

由于训练样本数较少，考虑使用图像增强方法对训练集进行扩增。为了避免引入额外的不同旋转角度信息干扰，使模型能够更好地聚焦于学习镍板表面的综合质量特征，无法使用常用的随机角度旋转的数据增强方法。为了平衡数据增强的效果和引入的旋转角度信息干扰，选择只使用 90°、180°和 270°三个旋转角度进行数据增强操作。

经过这三个角度的旋转操作得到的图片镍板看起来仍然是正的，可以尽可能少的引入干扰。这样就把训练集图片扩充到了原来的四倍。电解镍板表面质量等级分类数据集中各类别分布情况如表 3-2 所示：

表 3-2 电解镍板表面质量等级分类数据集统计表

等级类别	0	1	2	3	总计
Train	84	292	484	484	1344
Test	5	18	30	30	83
总和	89	310	514	514	1427

经过训练集数据扩充后，第 0 类，表示表面质量最好的一类，整个板面颜色均匀正常，只存在少量轻微缺陷，一共有 89 张图片；第 1 类，板面绝大部分为正常区域，存在小面积的水渍、烧板导致的发黄发黑和分散的表面凸起，一共有 310 张图片；第 2 类，存在较大面积的水渍、烧板发黄发黑、密集凸起和气孔，一共有 514 张图片；第 3 类，板面情况最严重的等级，烧板、水渍、表面凸起或气孔等缺陷几乎占据整个板面，一共有 514 张图片。各等级电解镍表面图片如图 3-4 所示：

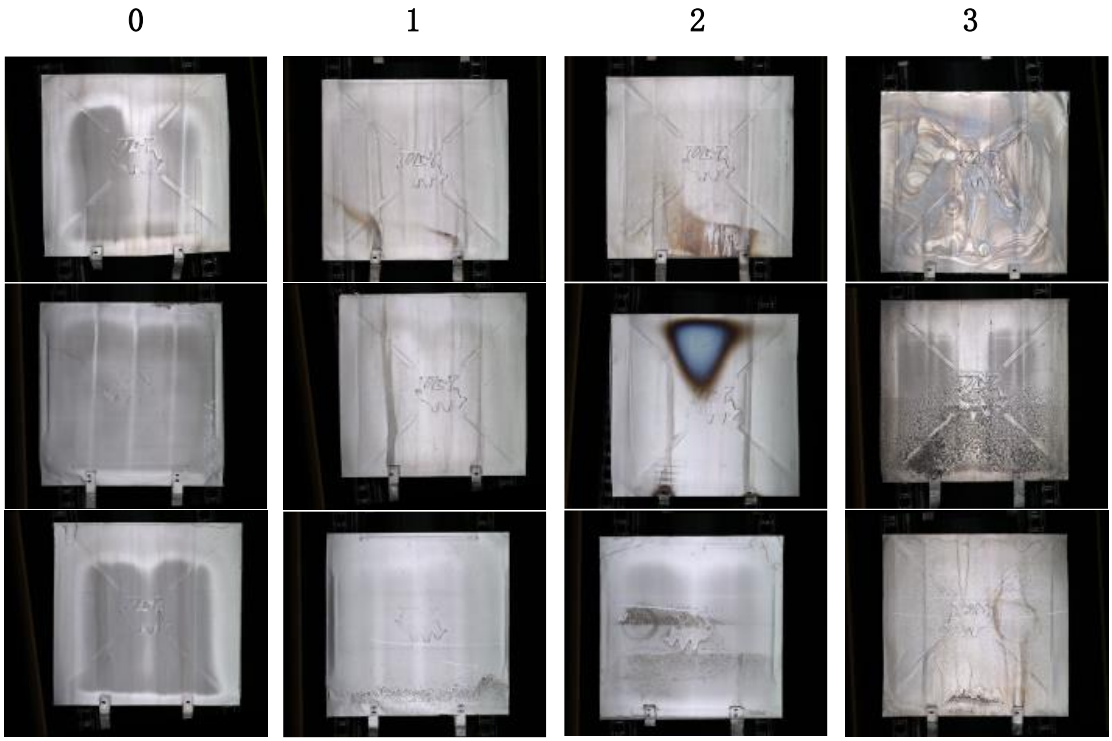


图 3-4 电解镍板表面质量各等级样例图

3.5 实验环境

实验环境的搭建是进行算法研究的基础，算法基线和算法的改进对比需要保持环境的一致性，来保障实验结果的有效性，主要包括使用的系统平台、深度学习框架、GPU 型号软件版本等，电解镍板表面质量等级分类实验环境如下表 3-3 所示：

表 3-3 电解镍板表面质量等级分类实验环境信息表

实验环境	具体信息
系统平台	Ubuntu 22.04.2 LTS
深度学习框架	Pytorch-1.13.1
编程语言	Python-3.9.16
GPU 显卡型号	NVIDIA GeForce RTX 3090, 24260MiB
显卡驱动	NVIDIA Linux Driver 535.161.07
Cuda 版本	CUDA Toolkit Driver 11.7

3.6 实验结果对比与分析

实验是在基于 ResNet-18 修改的交叉熵-监督对比学习双分支网络模型，使用 ResNet-18 预训练模型初始化，分别使用交叉熵损失 $\mathcal{L}^{CE}$、三种交叉熵-监督对

比学习联合损失 Uloss_1、Uloss_2、Uloss_3 在自建的电解镍板表面质量等级数据集上进行训练。其中只使用交叉熵损失 $\mathcal{L}^{CE}$ 是对比的实验基线，此时交叉熵-监督对比学习双分支网络模型退化为原本的 ResNet-18 网络模型。

实验相关参数设置：随机数种子参数 seed=3，监督对比损失中的温度缩放因子 $\tau = 0.07$，总训练轮数 epoch=90。实验结果如下表 3-4 所示：

表 3-4 各损失实验对比

损失函数	分类准确率（Accuracy）
$\mathcal{L}^{CE}$（基线）	72.29 %
$Uloss_1 = \mathcal{L}^{CE} + \mathcal{L}^{sup}$	72.29 %
$Uloss_2 = \mathcal{L}^{CE} + \mathcal{L}^{sup_1}$	73.49 %
$Uloss_3 = \mathcal{L}^{CE} + \mathcal{L}_1{}^{sup_1}$	78.31 %

实验结果显示，在只使用交叉熵损失的情况下，分类准确率为 72.29 %。使用交叉熵-监督对比学习联合损失 Uloss_1，分类准确率为 72.29 %，分类准确率没有得到预期的提升。使用联合损失 Uloss_2 的情况下，分类准确率为 73.49 %，性能跟基线和 Uloss_1 相比，分类准确率提高了 1.2%。使用联合损失 Uloss_3，分类准确为 78.31 %，性能跟基线和 Uloss_1 相比，分类准确率提高了 6.02%，与 Uloss_2 相比分类性能提高了 4.82%，分类性能得到了显著的提升。

可以看到，对比的实验结果与 3.3 章节的理论分析结论基本一致。联合损失 Uloss_1 的分类性能没有提高可能的主要原因就是 Uloss_1 使用的是改写后的最原始版本的监督对比损失，其中损失计算项的分母包含了所有的正样本对和所有的负样本对，使得特征优化方向存在冲突，因此导致了结果的不理想。因为数据量较少，加上监督对比学习损失优化方向存在冲突和矛盾，导致在小数据集上基本起不到明显作用，性能基本与只使用交叉熵的情况下相同。

联合损失 Uloss_2 的性能相较基线和 Uloss_1 相比，分类准确率提高了 1.2%。联合损失 Uloss_2 能起到作用的原因是改善了 Uloss_1 中监督对比学习损失中特征优化存在的冲突，监督对比学习损失项的分母中只使用单个正样本对和其他负样本对，这样正、负样本对之间的特征对比和优化方向更加的明确，从而使性能有了提升。

联合损失 Uloss_3 的分类性能最好，达到 78.31 %。相较基线和联合损失 Uloss_1，分类准确率有了 6.02%的巨大提升，相较联合损失 Uloss_2，分类性能有 4.82%的较大提升。证明了针对小规模数据集上的监督对比学习损失的分析和改进方向是正确的，在监督对比学习损失基础上加上样本自身与自身构成的正样本对并计算损失，在小规模数据集上，可以充分利用每一张图片的特征进行优化，使得性能

取得了明显的提升。

3.7 本章小结

本章对于电解镍板表面质量等级分类任务，首先介绍了 ResNet-18 分类模型的网络结构、多分类交叉熵损失函数和分类准确率性能评估指标相关理论知识。然后引入监督对比学习机制，提出了基于 ResNet-18 模型的双分支交叉熵-监督对比联合损失训练方法，以对样本和标签信息进行有效利用，优化特征空间中各类别特征的分布，缓解数据量较少而导致的训练不充分问题。

构建了研究使用的电解镍板表面质量等级分类数据集，该数据集将电解镍板表面质量分为 4 个等级，为了平衡数据增强的效果和引入的旋转角度信息干扰，选择只使用 90°、180°和 270°三个旋转角度进行数据增强操作，来缓解数据量少的问题。

在自建的数据集上，原有的单分支交叉熵损失分类准确率为 72.29 %，而提出的双分支交叉熵-监督对比联合损失分类准确率达到了 78.31 %，分类性能取得了 6.02%的显著提升。

第四章　电解镍板表面缺陷检测

传统人工质检只是将电解镍板进行大致的等级分类，并未对所含缺陷的种类、大小和数目等信息做统计，要得到这些信息，依靠人工处理的话需要耗费大量的时间和精力。为了实现自动、快速地检测到电解镍板表面所含缺陷的种类、位置以及大小信息，弥补工人质检的不足，本章提出了基于 YOLOv5 的电解镍板表面缺陷目标检测算法，构建了电解镍板表面缺陷目标检测数据集，并对 YOLOv5 模型的检测头进行改进，进一步提升表面缺陷检测性能。

4.1　YOLOv5 目标检测模型

YOLOv5 是一个基于锚点框（Anchor-based）深度学习的单阶段（One-stage）目标检测模型，它是由 Ultralytics 团队[66]开发的一种快速、准确的实时目标检测框架。YOLOv5 在 2020 年发布，是对之前版本（如 YOLOv3[67]和 YOLOv4[68]）的改进和优化。该模型具有较高的检测准确性和较快的检测速度，广泛应用于图像处理、自动驾驶、视频监控等领域。

4.1.1　YOLOv5 网络整体结构

YOLOv5 模型网络结构主要由网络主干（Backbone）、颈部（Neck）和检测头（Head）三个部分组成，如下图 4-1 所示。图片经过网络主干将进行特征提取，然后网络颈部对主干特征进行不同层次的融合，得到三个层次的融合特征，最后将融合后的特征送入检测头，计算出不同层次上包含的目标位置、置信度和目标类别信息。

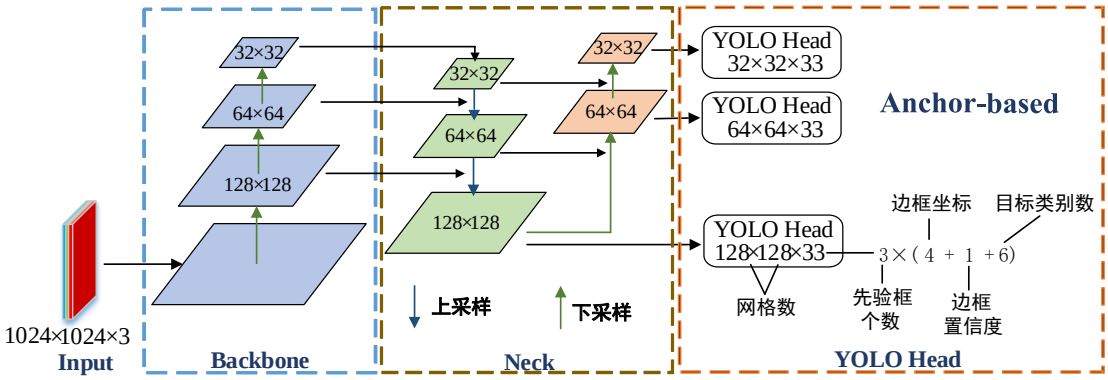


图 4-1 YOLOv5 模型网络结构图

4.1.1.1　网络主干

网络主干的作用是对图像进行特征提取，为实现从图像中检测出目标的位置和类别提供必要的特征信息。网络主干主要由卷积操作、残差连接、池化操作、批量归一化和激活函数组成，通过卷积层的不断堆叠，由浅到深，逐步对特征进

行处理。浅层的网络由于感受野小，特征的尺寸大，包含更多的纹理、轮廓和小目标的信息。深层网络的感受野范围大，特征的尺寸小，包含更多的复杂组合、抽象性的概念和大目标信息。以 yolov5l 为例，网络主干结构如图 4-2 所示：

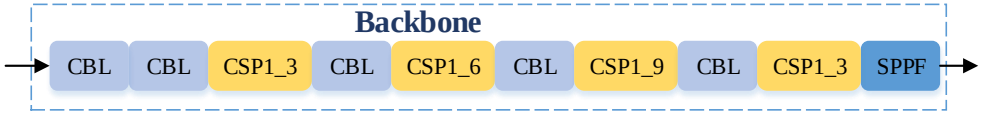


图 4-2 YOLOv5 模型网络主干结构图

网络主干整体由三个模块构成，分别是 CBL、CSP1_X 和 SPPF。

CBL 是由卷积 Conv、批归一化 BN 和激活函数 SiLU 三个组件组合在一起构成，是构成该网络的基本模块，结构如图 4-3 所示：



图 4-3 CBL 模块结构图

CBL 模块在主干网络中单独使用时主要作用是通过使用不同大小的卷积核，扩大感受野。卷积步长 stride 为 2，把输入特征图的长宽尺寸缩小两倍，起到下采样的作用，减少网络的参数量，同时将输入特征图的通道数增大两倍，增加更多种类的特征提取。比如网络主干中的第一个 CBL 模块，使用的是卷积核大小为 6×6、步长 stride 为 2、输出通道数为 64，起到的作用就是将输入大小 1024×1024×3 的图片，在较大感受野下进行特征的提取，同时降低网络的参数和计算量。将通道数从 3 扩充到 64，来丰富特征的种类。之后在网络主干中单独使用的 CBL 也起着相似的作用。

当在 CSP1_X 组件中使用时，通常是卷积核大小为 3×3、步长 stride 为 1 以及保持输入输出通道数不变，主要目的是进行特征的处理和变换，通过不断级联提取更加复杂的特征信息。

CSP1_X 是 CSP 网络模块的变体，主要由多个 CBL 组件堆叠在一起构成，中间加上残差连接，在尾部将相同尺寸、不同层级的特征在通道维度上进行合并，最后再加上一个 CBL 模块对特征做一次融合。结构如图 4-4 所示：

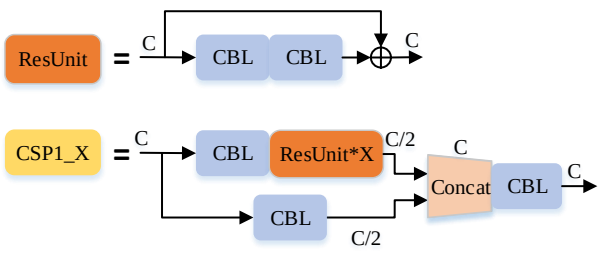


图 4-4 CSP1_X 模块结构图

CSP1_X 中的 X 代表该模块中包含的残差单元的个数，数目越大，提取的特征就包含信息越丰富，但同时也会增加网络的计算量。残差单元中有连续的两个

CBL 组件构成，然后将输入输出相加。由于多个残差单元的使用，使得 CSP1_X 模块中的计算量增大，为了减小计算量的增加同时保留特征的提取效果，CSP 模块中会先用两个 CBL 模块，分别将输入 C 通道转换成 C/2，进行特征通道的减半，在其中一个分支后接多个残差单元进行特征提取，然后再将两个分支的特征合并起来。

SPPF（Spatial Pyramid Pooling - Fast）模块是 SPP[69]（Spatial Pyramid Pooling）的改进版本，全称为快速空间金字塔池化。它被用在 YOLO 网络主干的最后一层，目的是对提取到最深层次的图像特征再进行一次不同尺度上的特征融合，同时进一步扩大了特征图的感受野。其结构如图 4-5 所示：

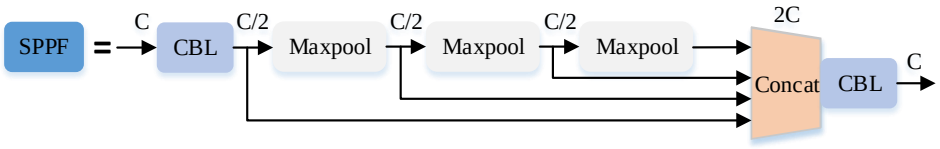


图 4-5 CSP1_X 模块结构图

对于输入 C 通道的特征图，先经过 CBL 模块处理，将通道数减半，然后连着使用三个核为 5×5、步长为 1 的最大池化 Maxpool 进行处理，每一层最大池化处后的特征感受野都会变大，就如同卷积的堆叠也会增加感受野。使用最大池化，是为了不对将特征再进行变换，而只是在不同范围上去突出最大的特征值，同时减少网络参数减少计算量。通过三个核为 5×5、步长为 1 的最大池化的堆叠，分别达到了 5×5、9×9、13×13 范围的感受野，然后将这些具有不同范围感受野的特征进行通道维度的合并，最后再由一个 CBL 模块进行融合，变换为原来的通道数。

4.1.1.2　网络颈部

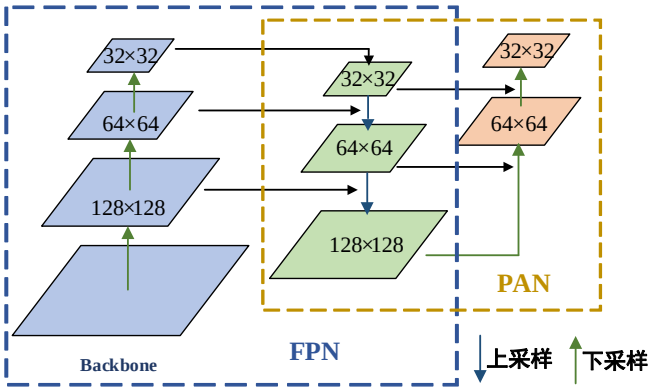


图 4-6　网络颈部 Neck：FPN+PAN 结构图

网络颈部结构如上图 4-6 所示，其作用是对网络主干提取到的特征做进一步的处理，更好地利用网络主干所提取的特征信息。将网络主干不同层次提取到的特征，使用 FPN+PAN 结构对不同层次的特征进行融合，使得深层次的语义信息

和浅层次的纹理轮廓信息相互融合，为检测头提供更丰富的特征。

FPN（Feature Pyramid Network）由 Lin 等人[70]于 2017 年提出，旨在解决传统的卷积神经网络在处理多尺度目标时存在的问题。FPN 在神经网络中构建多尺度的特征金字塔，进行不同尺度特征的融合，以更好地应对不同大小和形状的目标。

FPN 通过自底向上和自顶向下的路径来构建多尺度的特征金字塔。自底向上的路径用于从原始图像中提取信息，通过卷积或池化操作逐步降低特征图的分辨率，逐层向上进行特征提取。低层次特征包含更多的细节、小目标信息，高层次特征包含更多的高层语义、大目标信息；自顶向下的路径用于向下传播高层特征的语义信息，先通过上采样提升高层特征的分辨率，然后与自底向上路径中下一层的具有相同分辨率的特征图进行融合。

PAN（Pyramid Attention Network）也是一种用于解决目标检测和语义分割中多尺度信息融合的深度学习模型。它由 Peng 等人[71]在 2018 年提出，旨在解决传统的深度学习模型在处理多尺度信息时的不足。PAN 通过引入 FPN 特征金字塔和注意力模块来实现特征图的多尺度信息融合，从而提高了模型在多尺度目标检测和语义分割任务中的性能。

PAN 在 FPN 特征金字塔的后面又加了一个自底向上的路径，目的在于对 FPN 特征金字塔进行特征融合后的特征再进行一次处理。通过池化操作或者卷积操作进行下采样，缩小大尺度分辨率特征图，然后与 FPN 特征金字塔中高一层级的特征图进行融合，自底向上的提取不同层次的更加关注的信息，进一步提升目标检测或语义分割的性能。

4.1.1.3　检测头

检测头的作用是使用卷积操作对网络颈部提供的融合特征进行信息提取，得到可能包含目标的目标框、置信度和类别信息。

经过网络主干和网络颈部的处理，YOLO 模型对输入的图片整体上进行了 5 次的下采样操作，逐层地将尺寸缩小为原来的 2、4、8、16 和 32 倍，然后在融合后的尺寸为输入图片的 1/8、1/16、1/32 特征图上进行目标的检测。假设输入图片的大小为 1024×1024×3，那么待检测特征图尺寸、通道数分别为 128×128×256、64×64×512、32×32×1024 大小，然后通过检测头的卷积操作进行信息提取，分别得到 128×128×33、64×64×33、32×32×33 三个尺寸的检测结果矩阵。每个检测结果矩阵的长宽尺寸代表在不同尺寸检测网格数，每个网格位置检测 3 个目标框，每个框包含 4 个元素的位置信息、1 个元素的置信度信息和 6 个元素的类别概率信息，每个位置的检测信息维度就是(4+1+6)×3=33，三个不同尺寸的检测结果一共有 128×128×3+64×64×3+32×32×3 = 64512 个检测框，

然后经过后处理步骤，得到最终的检测结果。

4.1.2　自适应锚框计算

YOLO 系列的模型是基于锚点框（Anchor-based）的目标检测模型。其基本思想是将图像划分为网格，并对每个网格单元进行目标检测，每个网格单元负责预测与其位置相对应的目标。为了提高目标检测的准确性，每个网格单元通常会预测多个边界框（bounding box），每个边界框包含了相对于当前网格单元的位置偏移和锚框的相对尺寸。而为了应对检测目标的多尺度问题，YOLO 给锚框预先设置了不同尺寸和长宽比例，不同的大小和形状的目标分别跟不同大小的锚框进行匹配，以提高多尺度检测的性能。

传统的 YOLO 模型通常使用手动设定的锚框，这种方法不够灵活，会导致模型对目标的定位不准确。为了解决这个问题，YOLOv5 引入了自适应锚框计算技术，使得模型能够自动学习适应于数据集特点的锚框，从而提高检测的准确性和泛化能力。自适应锚点框先使用 k-means 聚类算法在目标数据集上聚类出 9 个尺寸大小的锚点框，然后使用遗传算法随机迭代 1000 次对锚点框的宽高进行变异，每次迭代后评估锚点框和数据集的适应度，选择具有最好的适应度的锚点作为参考锚点框。

4.1.3　Mosaic 数据增强

Mosaic 数据增强由 Yolov5 团队的成员提出，是一种在计算机视觉领域广泛应用的数据增强技术，它通过将多个图像拼接成一个新的图像来增加训练数据的多样性和数量。

Mosaic 数据增强的核心思想是创建一个新的训练样本，该样本由四个原始图像拼接而成，新的样本包含四个不同区域的图像。这样做的目的是引入更多的变化和复杂性，从而增加模型对不同场景和条件的鲁棒性。由于由四张图片组合成一张图片，使得原来图片中的目标变小了，可以使得使模型在小目标的检测上有更强的适应性，有利于提升小目标检测性能。

4.1.4　后处理

后处理过程是对网络检测头输出的检测信息进行进一步的处理，得到最终的检测结果。当输入图片的大小为 1024×1024×3 时，输出三个不同尺寸的检测结果一共有 128×128×3+64×64×3+32×32×3 = 64512 个检测框，首先将三个不同尺度上检测到的检测框都还原到相对于原输入图片的大小，然后将每个检测框的框置信度信息与 6 个元素的类别概率信息相乘，得到检测框中的目标属于某一个类别的置信度得分（confidence score）。

由于在目标检测任务中，通常会有多个检测框同时检测到同一个目标，存在大量的冗余，需要使用非极大值抑制 NMS（Non-Maximum Suppression）算法来

消除冗余的检测结果，从而得到最终的准确结果。

NMS 的基本原理是在一组检测结果中，按照检测框的各个类别的置信度得分对检测结果进行排序，首先去除类别置信度得分低于置信度阈值（confidence threshold）的框，因为置信度得分过低，说明该检测框包含目标的概率很小，应当排除。然后从得分最高的检测框开始，逐个遍历所有检测框，并去除与当前检测框重叠度高于重叠度阈值（IoU threshold）的检测框。当根据最高置信度得分的检测框过滤完一遍后，从剩下的框中再选出置信度得分最高的框，然后去除与当前检测框重叠度高于阈值的其他检测框。不断重复以上步骤，直到所有检测框都处理完毕。得到最终的具有高置信度且重叠度低于阈值的一组检测框。

4.1.5 损失函数

目标检测损失函数主要由类别预测损失和边界框回归损失组成。在 YOLOv5 模型中损失函数除了这两项，还包括一个目标置信度损失，用来衡量预测框包含目标的准确性。

4.1.5.1 类别预测损失（Class Prediction Loss）

类别预测损失用于衡量模型对该预测框中目标类别的分类准确性。在 YOLOv5 中分类损失采用的是二值交叉熵 BCE（Binary Cross-Entropy）损失函数，只有当该检测框包含检测目标时，才进行计算。先对各个类别得分经过 Sigmoid 激活函数处理，转换为各类别的概率，然后每个类别概率分别求取二值交叉熵，最后所有类别的损失相加求均值，每一个检测框类别预测损失计算公式如下：

$$\mathcal{L}_{cls} = \frac{1}{N}\sum_{i=1}^{N} \mathcal{L}_i^{BCE} \tag{4-1}$$

$$\mathcal{L}_i^{BCE} = y_i \cdot log\,\sigma(x_i) + (1 - y_i) \cdot log\big(1 - \sigma(x_i)\big) \tag{4-2}$$

其中 $\sigma(x)$ 是 Sigmoid 激活函数，

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{4-3}$$

N 表示目标类别数目，x_i 表示当前检测框的目标属于第 i 类的得分，y_i 表示当前检测框的目标属于第 i 类的标签，如果真实类别是第 i 类，则 $y_i = 1$，否则 $y_i = 0$。

4.1.5.2 边界框回归损失（Bounding Box Regression Loss）

边界框回归损失用于衡量模型的预测框和真实目标框之间的准确性。YOLOv5 采用 CIoU[72]损失（Complete Intersection over Union Loss）损失衡量，只有当该检测框包含检测目标时，才进行计算。CIoU 损失函数不仅考虑了预测框和真实框之间的交并比，还考虑了它们中心点的距离以及宽高比，从而能更全

面地评估预测框的质量。CIoU 损失的计算公式如下：

$$\mathcal{L}_{Bbox} = \mathcal{L}_{CIOU} = 1 - IOU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \tag{4-4}$$

CIoU 损失包含了三个部分：预测框与真实框的重叠损失、中心点距离损失和高宽之比损失。其中，IoU（Intersection over Union）表示预测框和真实框的交并比，用于衡量目标检测中预测框与真实框的重叠程度。假设预测框为 A，真实框为 B，则 IoU 的表达式为：

$$IoU = \frac{A \cap B}{A \cup B} \tag{4-5}$$

$\rho(b, b^{gt})$ 表示 A、B 的中心点距离，c 是包含 A、B 的最小外接框的对角线距离。v 是衡量 A、B 两框宽高比一致性参数，计算公式如下：

$$v = \frac{4}{\pi^2}(arctan\frac{w^{gt}}{h^{gt}} - arctan\frac{w}{h})^2 \tag{4-6}$$

α 是一个权重参数，用于平衡 v 对损失函数的贡献，计算公式如下：

$$\alpha = \frac{v}{(1 - IoU) + v} \tag{4-7}$$

4.1.5.3　目标置信度损失（Object Confidence Loss）

目标置信度损失是对预测框中包含目标的可信度的衡量。在 YOLOv5 模型中，当该预测框包含检测目标时，将预测框与真实框的交并比IoU作为是否包含检测目标的衡量标准，预测框与真实框的交并比 IoU 值越大，说明目标的可信度越高；当该预测框不包含检测目标时，则令 IoU 值为 0。目标置信度 obj_{conf} 的训练目标就是拟合 IoU 的值，使用二值交叉熵 BCE（Binary Cross-Entropy）损失函数计算损失，损失计算公式如下：

$$\mathcal{L}_{obj} = IoU \cdot log\, obj_{conf} + (1 - IoU) \cdot log\big(1 - obj_{conf}\big) \tag{4-8}$$

4.1.5.4　总损失

YOLOv5 最终的损失是由类别预测损失 $\mathcal{L}_{cls}$、边界框回归损失 $\mathcal{L}_{Bbox}$ 和目标置信度损失 $\mathcal{L}_{obj}$ 分别乘以相应的权重，然后求和得到，公式如下：

$$\mathcal{L} = w_{cls} \cdot \mathcal{L}_{cls} + w_{Bbox} \cdot \mathcal{L}_{Bbox} + w_{obj} \cdot \mathcal{L}_{obj} \tag{4-9}$$

其中 w_{cls}、w_{Bbox}、w_{obj} 分别表示类别预测损失、边界框回归损失和目标置信度损失项的权重，用于平衡各项损失。

4.1.6　性能评估

目标检测模型的性能评价指标用于衡量模型在识别和定位目标方面的准确

性和鲁棒性。

评价指标主要包括精确率（Precision）、召回率（Recall）、平均精度（AP，Average Precision）和平均检测精度（mAP，mean Average Precision）。将这些评价指标按照各类别计算，然后所有类别求和取平均值，就可以得到模型在所有类别上相应的平均指标。

对于某一个类别而言，根据检测结果可以得到该类别的混淆矩阵如表 4-1 所示：

表 4-1 某一个类别检测结果混淆矩阵

真实	**预测**	
	正例	反例
正例	TP	FN
反例	FP	TN

TP（True Positive）表示该类别目标被模型正确检测出来的数目。FP（False Positive）表示模型将其他类别目标或者不存在的目标检测为该类别的数目。FN（False Negative）表示该类别目标没被模型正确检测出来的数目。TN（True Negative）在目标检测模型中没有意义，因为未模型检测出来的目标，可以有无数个，无法统计，而不是该类别的目标可以有无数个，也无法统计。

精确率 Precision，简写为 P，是指对于该类别，模型正确检测出来的目标数目占模型检测为该类别目标数目的比例。计算公式如下：

$$P = \frac{TP}{TP + FP} \tag{4-10}$$

召回率 Recall，简写为 R，是指对于该类别，模型正确检测出来的目标数目占该类别实际目标数目的比例。计算公式如下：

$$R = \frac{TP}{TP + FN} \tag{4-11}$$

平均精确度 AP，是一种综合性评价指标。它计算 P-R 曲线下的面积作为该类别的平均精度。P-R 曲线以精确率 P 和召回率 R 作为纵、横轴坐标的曲线，通过选取不同的类别置信度阈值时对应的精度和召回率画出。平均精确度 AP 计算公式如下：

$$AP = \int_0^1 P(r)d(r) \tag{4-12}$$

当对模型检测出来的目标判定是不是 TP 的时候，是根据预测框与真实框的 IoU 值和预测框的类别置信度得分进行判断的。当预测框与真实框的 IoU 值超过

IoU 阈值，并且预测框的类别置信度得分超过置信度阈值时，选择满足该条件的最大类别置信度的检测框为 TP，否则就为 FP。因此设置不同的 IoU 阈值，就会有不同的结果，IoU 阈值越大，则检测框检测得越准。根据不同的 IoU 阈值设置，可以得到不同的 AP 值。如常用的 AP50 和 AP50-95。

AP50 是指 IoU 阈值设置为 0.5 时的 AP 值。AP50-95 是先分别计算 IoU 阈值分别设置为 0.5、0.55、0.6、0.65、0.7、0.75、0.8、0.85、0.9、0.95 下的 AP，然后求和再取平均值得到，是一个平均性的 AP 指标。

多类别平均精确度 mAP，是指多个类别的 AP 的均值，反应的是多个类别的平均检测性能。与 AP50 和 AP50-95 相对应，mAP 也有 mAP50 和 mAP50-95，求取方式是多个类别的 AP50 和 AP50-95 求均值所得。mAP 计算公式如下，其中 N 表示检测目标种类数：

$$mAP = \frac{1}{N}\sum_{i=1}^{N} AP_i \tag{4-13}$$

4.2　YOLOv5 检测头改进

4.2.1　原 YOLOv5 检测头

YOLOv5 中的检测头在网络颈部提供的特征上通过一个卷积层直接提取预测框坐标、预测框置信度和目标类别这三类信息，是一种耦合头，YOLOv5 中的检测头在某一个检测层的分支结构如图 4-7 所示：

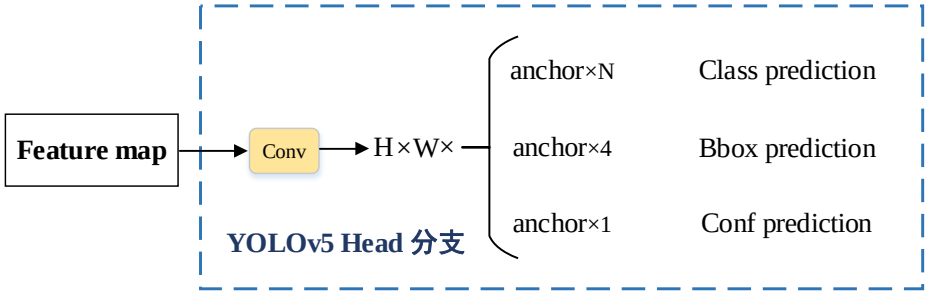


图 4-7　原 YOLOv5 检测头 Head 分支结构图

然而在目标检测的定位和分类任务中，两个大任务所聚焦和侧重的地方是不同的。分类任务更关注所提取的各类别特征的差异性，而定位任务更加关注检测框与真实目标框之间的位置坐标和长宽尺寸的差异。因此如果同一个特征图直接进行分类和定位两个任务的识别，明显难度比较高，以至于检测的效果不好。因此，针对 YOLOv5 中的耦合检测头的缺陷，将 YOLOv5 检测头 Head 换成解耦头进行改进。

4.2.2　检测头替换为解耦头

解耦头（Decoupled Head）是由 YOLOX[73]论文提出并使用，主要的思想就

是将目标检测中的分类和定位任务分开处理，将颈部提供的特征分为分类分支和定位分支，分别进行特征转换和提取，分类和定位任务使用各有侧重不同的特征图进行识别，提升模型性能。使用的解耦头在某一个检测层中的分支结构如图 4-8 所示：

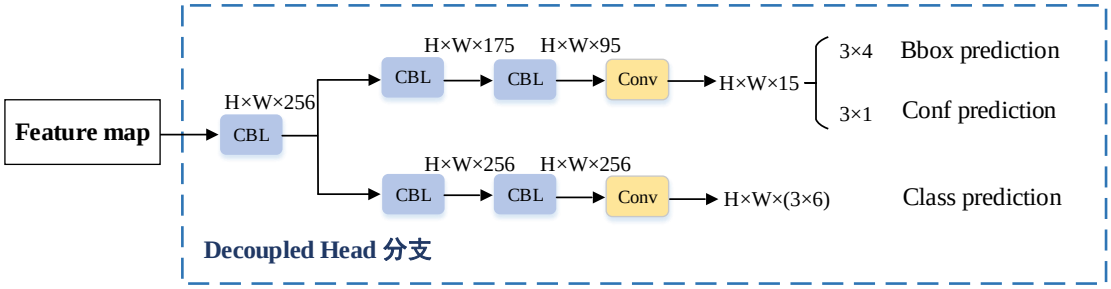


图 4-8 解耦头（Decoupled Head）分支结构图

解耦头中先对颈部网络提供的特征先使用一个卷积层进行处理，将特征通道数转换为 256，然后分为 Bbox 加 Conf 预测分支和分类预测分支。Bbox 加 Conf 预测分支中，使用三个卷积层对 256 通道的特征进行处理，并将特征图的通道数从 256 逐步缩小，最终输出通道数为 3×(4+1)，数字 3 表示特征图上每个检测位置都有三个检测框，数字 4 表示预测框的四个参数，数字 1 表示置信度的预测。分类预测分支也使用三个卷积层进行处理，不过前两个卷积层不改变特征图的通道数都为 256，最后一个卷积层输出特征图通道数为 3×6=18，数字 6 是电解镍板表面缺陷的种类数。

4.2.3 解耦头改进

针对电解镍表面缺陷的种类多、形态复杂和大小尺度变化多样的问题，在原有的解耦头上加以改进，以提升缺陷检测性能。在解耦头中对网络颈部提供的特种的 CBL 模块后增加更多的卷积层处理，然后再分为两个分支。改进后的结构如图所 4-9 所示：

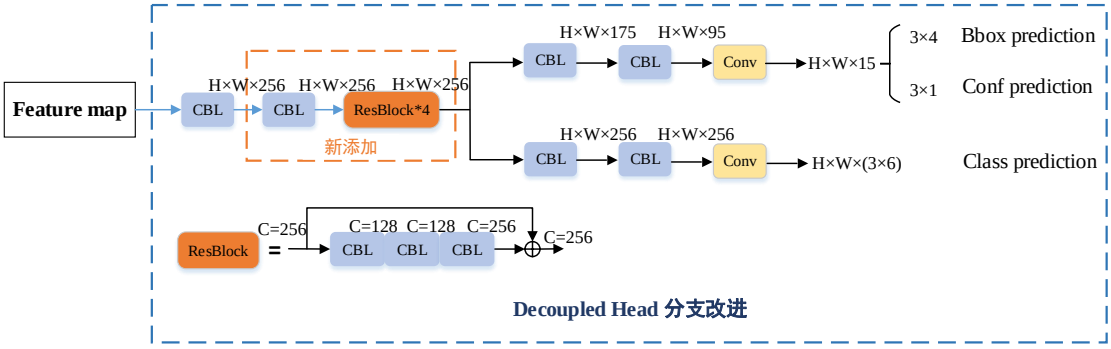


图 4-9 解耦头分支改进结构图

改进后的解耦头第一个 CBL 模块后加了一个 CBL 模块，然后接着使用了 4 个 ResBlock 残差连接模块，每个 ResBlock 残差连接模块里包含三个 CBL 模块。新添加的卷积层会导致计算量的增加，为了不让计算量增加太多，ResBlock 中第

一个 CBL 模块使用核为 1×1 卷积，并将特征通道数减半为 128；第二个 CBL 模块使用核为 3×3 的空洞卷积，保持特征通道数不变；第三个 CBL 模块使用核为 1×1 卷积，将特征通道数恢复到 256。

四个 ResBlock 模块中包含的第二个 CBL 模块依次使用膨胀系数 dilated=[2, 4, 6, 8]的空洞卷积，以增加感受野，使用残差连接使得不同感受野的信息融合在一起。新添加的模块，进行了更多的特征变换和提取，同时将具有更大感受野的特征进行融合，以提取更丰富的特征，以此达到提升检测性能的效果。

4.3　实验数据集

电解镍板表面缺陷目标检测数据集包含 419 张图片，与镍板表面质量等级分类数据集共用图片。使用 LableImg 标注工具对发黄（yellowstain）、水渍（waterstain）、点渍（waterpoint）、烧板（overfire）、结瘤（nodule）和凸起（bubble）六种主要表面缺陷进行标注。按照 5:1 的图片比例进行随机抽取划分训练集和测试集，在电解镍板表面缺陷检测数据集中，训练集中一共包含 350 张图片，测试集中一共包含 69 张图片，训练集和测试集中各类缺陷数目统计如表 4-2 所示：

表 4-2 电解镍板表面缺陷目标检测数据集统计表

缺陷类别	点渍	发黄	烧板	结瘤	水渍	凸起	总计
Train	5908	988	159	263	3345	552	11215
Test	1258	183	16	31	766	81	2335
总和	7166	1171	175	294	4111	633	13550

(1) 点渍缺陷（waterpoint）

点渍是液体滴溅到镍板表面风干后留下的印记，有着较为清晰的轮廓边界。与水渍缺陷不同之处在于点渍缺陷主要是圆形或椭圆形，面积较小。既有分散的单独存在，也有密集的聚集在一起形成一片，主要发生在电解镍板边缘位置。点渍缺陷样例如图 4-10 所示。

(2) 发黄缺陷（yellowstain）

发黄缺陷是在电解镍板在电解槽中进行电解生成的过程中，当电解电流过大时，阴极电解镍板由于热阻效应，产生大量的热，温度过高导致金属镍被氧化所致，氧化程度轻微而使局部区域呈现为黄色和淡黄色。氧化发黄范围会覆盖一定的表面区域，面积有大有小，位置随机，没有像水渍那样清晰地边界，而是渐变式的颜色逐渐变淡到消失。发黄缺陷样例如图 4-11 所示。

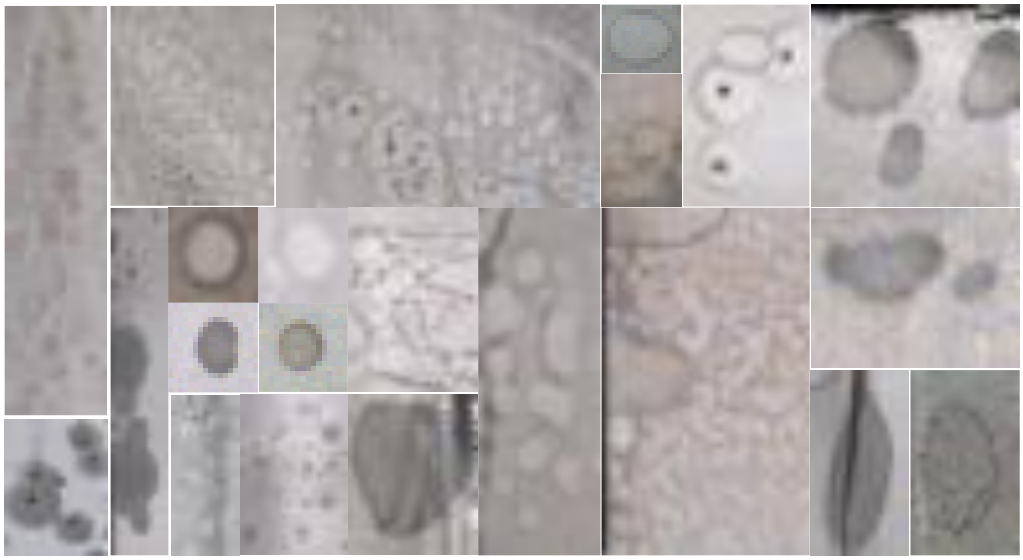


图 4-10 电解镍板表面点渍缺陷样例图



图 4-11 电解镍板表面发黄缺陷样例图

(3) 烧板缺陷（overfire）

烧板缺陷与发黄缺陷一样是由于电解过程中氧化导致，但氧化程度更严重，呈现出黑色或灰青色。烧板缺陷也没有明显的边界轮廓，氧化的位置随机出现在镍板表面，形状和大小不固定，小的可以只有一小片区域，大的可以覆盖整个板面，呈片状分布。烧板缺陷样例如图 4-12 所示。



图 4-12 电解镍板表面烧板缺陷样例图

(4) 边部结瘤（nodule）

边部结瘤缺陷特指发生在电解镍边缘的一种缺陷，是由于电解过程中边缘吸附了电解溶液中的杂质（尘埃、灰渣和阳极泥等），造成了镍板边缘形成了大小不同的结粒和凸起，外观表现为边缘坑坑洼洼，凹凸不平，通常情况下呈现出密集的瘤状形态。边部结瘤缺陷样例如图 4-13 所示。



图 4-13 电解镍板表面边部结瘤缺陷样例

(5) 水渍缺陷（waterstain）

水渍缺陷是表面电解酸液残留风干后在电解镍板表面留下的水印。水渍缺陷形态多样，大小不一，有的水渍可以横穿板面，有的只占一小块面积。既有单个面积较大的圆形水渍，也有面积较小的条状水渍。水渍颜色有深有浅，在正常颜色的镍板上有较为清楚的灰黑色轮廓边界，轮廓外形主要为长条形和椭圆形，位置多分布于电解镍板的边缘附近。水渍缺陷样例如图 4-14 所示。

(6) 表面凸起（bubble）

表面凸起缺陷的形成原因与边部结瘤类似，是由于电解液中的杂质附着在镍板表面所致，在镍板表面形成凸起。其形态大小不一，位置随机，往往较为密集地聚集在一起成片分布，成片区域有大有小，有的可以几乎占据整个板面，有的只占据较小的区域。表面凸起缺陷样例如图 4-15 所示。

可以看到，电解镍板这六种主要缺陷呈现出不同的颜色、大小的形态变化，缺陷情况复杂多样，尺度变化大，缺陷相互之间还存在重叠，加上不同的电解镍板基色存在差异，传统的图像处理算法无法对如此复杂多变的缺陷形态进行有效处理，因此研究使用鲁棒性更好、适应性更强的深度学习算法对电解镍板表面缺件进行检测。



图 4-14 电解镍板表面水渍缺陷样例图

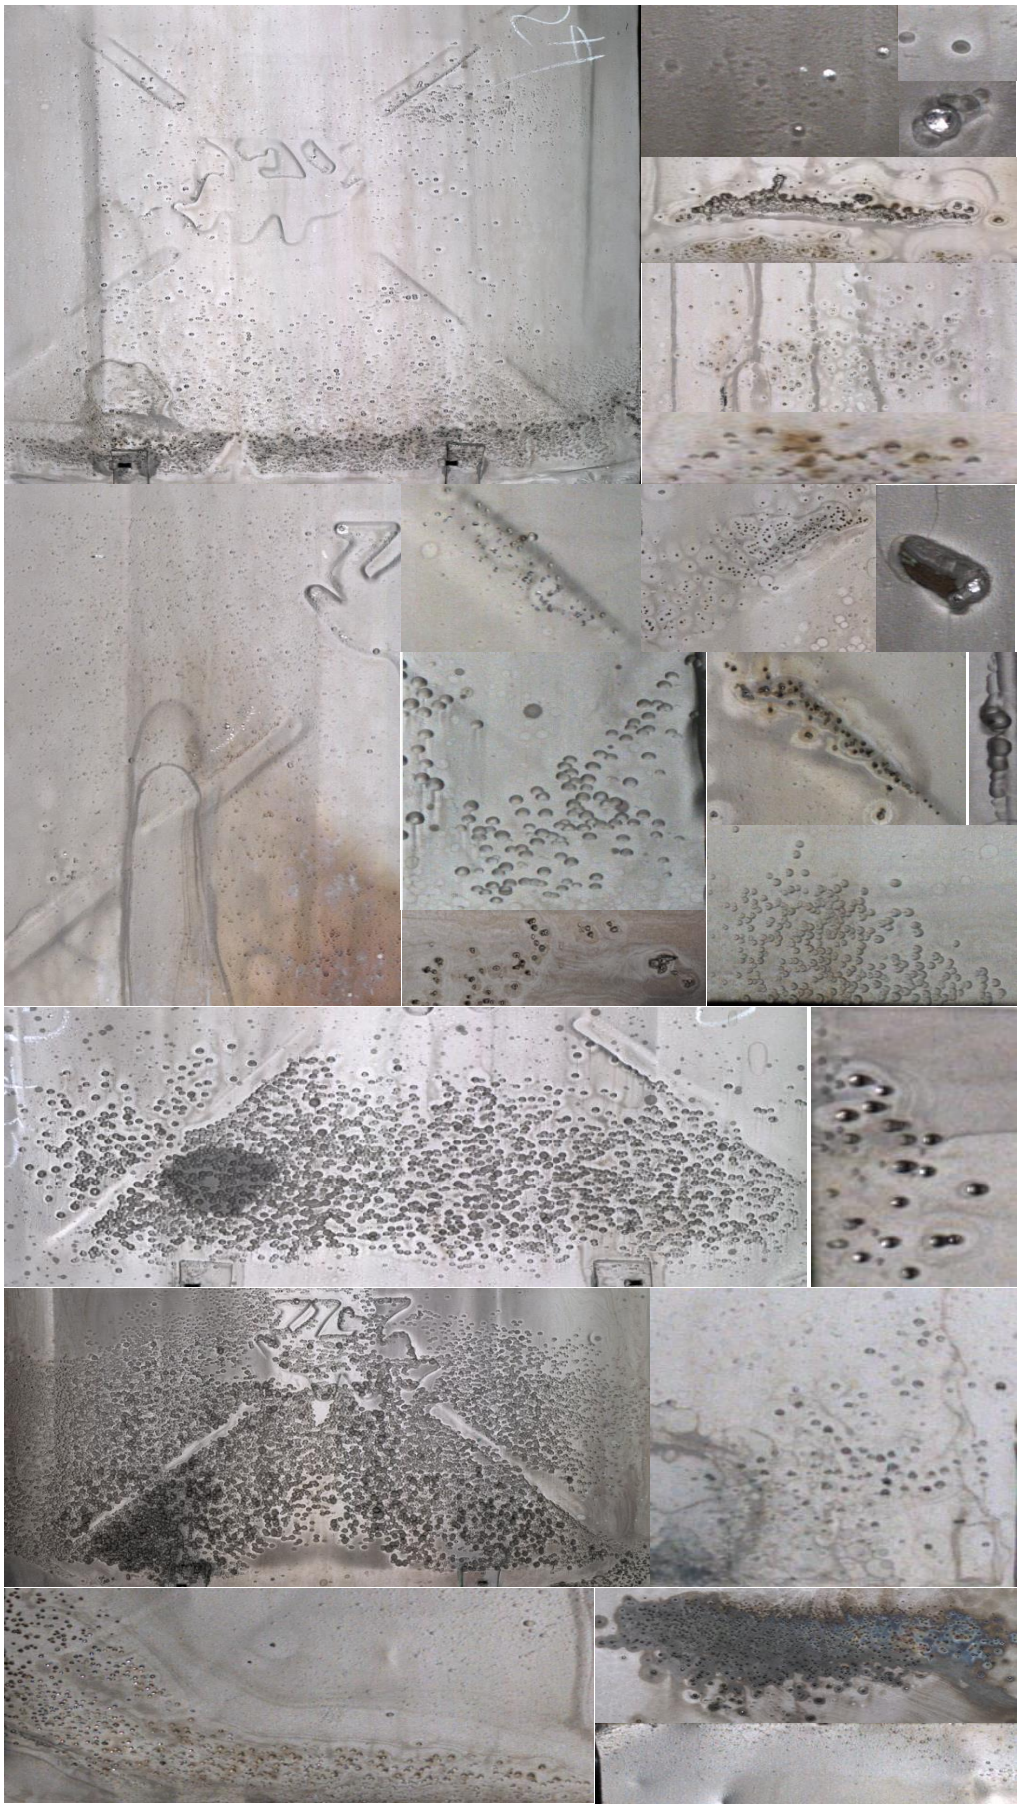


图 4-15 电解镍板表面凸起结瘤缺陷样例图

4.4　实验环境

电解镍板表面缺陷检测的使用的实验环境与 3.5 章节相同，不再复述。

4.5　实验过程和结果分析

由于电解镍板表面存在的缺陷形态变化多样，比较复杂，首先分别在 YOLOv5l 和 YOLOv5x 这两个较大的预训练模型上训练 900 个 epoch 并测试，根据 mAP50 性能指标选择出性能最好的模型。实验结果如表 4-3 所示：

表 4-3 不同大小模型实验结果

模型	模型大小	平均精确率	平均召回率	mAP50	mAP50-95
YOLOv5l	93.1 MB	77.8%	52.8%	0.588	0.356
YOLOv5x	173.4 MB	71.3%	54.3%	0.573	0.355

可以看到 YOLOv5l、 YOLOv5x 的模型大小逐渐增大，然而并不是模型越大检测的效果越好，可能是由于 YOLOv5x 模型参数量过大，导致了模型的过拟合所致。YOLOv5l 的 mAP50 性能指标最好，因此选取在该模型的基础上进行解耦头的改进实验和对比，使用 YOLOv5l 预训练模型初始化，其他参数保持不变，实验结果如表 4-4 所示：

表 4-4 YOLOv5l 使用解耦头实验结果

模型	模型大小	平均精确率	平均召回率	mAP50	mAP50-95
YOLOv5l	93.1 MB	77.8 %	52.8 %	0.588	0.356
YOLOv5l_ Decoupled Head	98.1 MB	76.0 %	51.3 %	0.589	0.380

通过实验对比可以看到，在 YOLOv5l 模型上使用解耦头在 mAP50 和 mAP50-95 的性能上都比原来的好，尤其 mAP50-95 性能由 0.356 提升到 0.38，说明解耦头的使用的确起到了效果。然而在 mAP50 上的性能只提升了 0.01，未能达到想要的效果。为了寻找原因，将解耦头应用到 YOLOv5x 模型上进行实验，看看模型参数量的变化会不会影响解耦头的检测效果，使用 YOLOv5x 预训练模型初始化，其他参数保持不变，实验结果如表 4-5 所示：

表 4-5 YOLOv5x 使用解耦头实验结果

模型	模型大小	平均精确率	平均召回率	mAP50	mAP50-95
YOLOv5x	173.4 MB	71.3 %	54.3 %	0.573	0.355
YOLOv5x_ Decoupled Head	178.6 MB	75.9 %	49.7 %	0.591	0.385

可以看到，在 YOLOv5x 模型上使用解耦头在 mAP50 和 mAP50-95 的性能都有了较大的提升。mAP50 由原来的 0.573 提升到了 0.591，提升幅度为 0.18，mAP50-95 由原来的 0.355 提升了 0.385，提升幅度为 0.3。两者性能提升的幅度都超过了 YOLOv5l 模型上使用解耦头的效果。

YOLOv5l 模型的实验说明了解耦头本身的使用是有效果的，但是 mAP50 提升的效果较小。而 YOLOv5x 模型网络结构在深度、广度上分别是 YOLOv5l 模型的 1.33、1.25 倍，可以提供较 YOLOv5l 模型更多更丰富的特征，使用解耦头的检测效果也更好。

为了取得更好的效果，在解耦头中加入了更多的卷积层进行改进，将改进后的解耦头应用在 YOLOv5l、YOLOv5x 模型上，分别使用 YOLOv5l、YOLOv5x 预训练模型进行初始化，其他参数保持不变，改进后的解耦头实验结果如表 4-6 所示：

表 4-6 改进后的解耦头实验结果

模型	模型大小	平均精确率	平均召回率	mAP50	mAP50-95
YOLOv5l_ Decoupled Head	98.1 MB	76.0 %	51.3 %	0.589	0.380
YOLOv5l_ Decoupled Head_Pro	107.0 MB	79.9 %	50.5 %	0.586	0.381
YOLOv5x_ Decoupled Head	178.6 MB	75.9 %	49.7 %	0.591	0.385
YOLOv5x_ Decoupled Head_Pro	187.4 MB	73.6 %	52.4 %	0.601	0.39

可以看到，改进后的解耦头在预训练的 YOLOv5l 模型上 mAP50 性能较原来的解耦头没有提升反而还下降了 0.03 个点。在预训练的 YOLOv5x 模型上 mAP50 性较原来的解耦头性能上升了 0.1 个点，mAP50-95 也上升了 0.05 个点，获得了较好的性能提升。解耦头将目标定位任务和分类任务分开来检测，因而可能需要模型提供更丰富的特征来支持，因此需要更大参数量的模型或者更多的卷积层提供更丰富的特征。

4.6 本章小结

本章对于电解镍板表面缺陷目标检测任务，首先介绍了 YOLOv5 目标检测模型的网络结构、自适应锚框计算方法、Mosaic 数据增强方法以及后处理过程、损失函数和性能评估指标相关目标检测基础知识。然后将 YOLOv5 模型的检测头替换为解耦头，并在解耦头中加入具有不同膨胀系数的空洞卷积和残差连接模块，以使模型可以更好地适应电解镍板表面缺陷的复杂形态。

实验结果显示，在 YOLOv5x 上使用解耦头，mAP50 指标达到了 0.591，原始 YOLOv5x 版本 mAP50 为 0.573，整体 mAP50 性能提升了 0.18，取得了较好的性能提升。改进版本的解耦头在 YOLOv5x 上使用，mAP50 指标达到了 0.601 最好结果，相较于使用原解耦头的 YOLOv5x 模型，mAP50 性能提了 0.1 个点，相较于原始的 YOLOv5x 版本，mAP50 性能提了 0.28 个点，取得了良好的性能提升。然而无论是原解耦头还是改进后的解耦头在 YOLOv5l 模型上并未取得性能的提升。

通过对比 YOLOv5l、YOLOv5x 模型的实验结果可以发现，解耦头将目标检测的分类、识别和定位任务进行解耦，使用两个分支进行处理的机制，对于电解镍板表面复杂的缺陷检测有不同的效果，需要较大的模型给解耦头提供更多更丰富的特征来支持，才能取得更好的效果。

第五章　总结与展望

5.1　总结

由于金属镍在各个领域的广泛应用其需求量不断增长，金属镍生产企业需要增加生产能力并确保产品质量。其中，采用硫化镍阳极隔膜电解法生产的电解镍占据了镍金属生产的绝大部分。因此，如何提高电解镍板的质量和可靠性成为了生产企业关注的焦点。在保障电解镍板质量和可靠性方面，对其表面缺陷进行检测和处理尤为重要。

目前，金属镍生产厂家仍然依赖工人对电解镍板的表面质量进行检测，存在效率低下、易疲劳和高度依赖工人经验等问题。随着图像处理技术的进步，一些用于电解镍板表面缺陷检测的方法开始涌现，但由于电解镍板表面缺陷形态复杂，传统图像处理方法难以有效处理。近年来，人工智能技术的迅速发展和卓越表现为电解镍板表面复杂缺陷的检测提供了新的解决方案。针对企业的实际需求，本研究对电解镍表面质量等级评估和表面缺陷检测任务进行了深度学习算法的研究。以下是本文的主要研究内容：

(1) 在工业现场搭建了图像采集实验平台，用于获取电解镍板表面的图片。经过图像处理和数据标注，构建了两个数据集：电解镍板表面质量等级分类数据集和电解镍板表面缺陷目标检测数据集。质量等级分类数据集包含 4 个类别等级，测试集包含 83 张图片，训练集包含 336 张图片。为了缓解训练数据不足的问题，我们对训练集图片进行了三个不同角度的旋转变换，将训练集图片扩充到了 1344 张。表面缺陷目标检测数据集包含 6 种主要缺陷，测试集中包含 2335 个缺陷目标，训练集中包含 11215 个缺陷目标。

(2) 对于电解镍板表面质量等级分类任务，针对分类训练数据量较少的问题，本文提出了基于 ResNet-18 的双分支交叉熵-监督对比学习联合损失训练方法。通过引入监督对学习机制，通过拉大不同类别特征之间的距离和拉近相同类别特征的距离来优化特征分布，在训练数据有限的情况下，提高模型学得的特征的有效性。实验结果显示，改进前的 ResNet-18 分类模型的 72.29 %分类准确率，使用交叉熵-监督对比学习联合训练方法达到了 78.31 %的分类准确率，分类准确率提升了 6.02%，取得了显著的分类性能提升。

(3) 对于电解镍板表面缺陷目标检测任务，为应对电解镍板表面缺陷的复杂形态，本文提出了基于 YOLOv5 改进的电解镍板表面缺陷目标检测算法。首先将模型的耦合头替换为解耦头，并在解耦头中添加具有不同膨胀系数的空洞卷积和残差连接模块进行改进。实验结果显示，未使用解耦头的 YOLOv5x 模型

mAP50 为 0.573，使用解耦头 mAP50 为 0.591，使用改进后的解耦头 mAP50 为 0.601，mAP50 性能分别提升了 0.18 和 0.28，取得了较大的性能提升。

5.2　工作展望

本文虽然在基于深度学习的电解板表面缺陷检测方法中取得了一些研究成果，但是由于个人知识水平和时间等因素的限制，本文的研究中还存在许多不足之处，在以下几个方面还可以进一步的研究与完善：

(1) 对于自建的电解镍板表面质量等级分类数据集和电解镍板表面缺陷检测数据集两个数据集的规模还可以进一步扩大。由于在工业现场采集图片需要大量的时间，以及数据标记需要耗费大量的人力和时间，限于目前的条件，只能够建立一共有 419 张图片的小规模数据集。目前的表面质量等级分类和表面缺陷检测算法的研究和改进，都是在小规模数据集上进行的，难免会有一定的限制。

(2) 电解镍板表面缺陷检测数据集的标注质量还需提高。由于电解镍板表面缺陷的颜色深浅变化，形态大小多种多样，并且判断是否是缺陷的标准比较模糊，缺陷的标注存在个人的主观判断影响，而且数据标注过程费时费力且枯燥，导致缺陷的漏标、错标现象的发生，从而影响到深度学习算法的性能。

(3) 本文提出的电解镍板表面质量等级分类方法和表面质量检测方法都还处在实验研究阶段，还没有在生产现场进行部署、使用和测试。为了更好地应对电解镍板表面复杂的缺陷，进一步提升检测性能，算法上还需要更全面和深入的研究，以满足实际应用的需要。

参考文献

[1] 崔增波. 镍电解状态视觉检测与分析方法研究[D]. 电子科技大学, 2020. DOI: 10.27005/d.cnki.gdzku. 2020. 003412.

[2] 王鑫. 电解镍表面缺陷视觉检测系统的研究[D]. 昆明理工大学, 2021. DOI: 10.27200/d.cnki.gkmlu. 2021. 000266.

[3] 胡学雄, 陶军, 黎润民, 董小明. 涡流检测技术在宝钢热轧轧辊上的应用[J]. 轧钢, 2004(05): 65-67.

[4] Eisenmann D J, Enyart D, Lo C, et al. Review of progress in magnetic particle inspection[C]//AIP Conference Proceedings. American Institute of Physics, 2014, 1581(1): 1505-1510.

[5] Okamoto Y. Detection of surface flaws by infrared radiation sensor[C]//Technical Digest of the 7th Sensor Symposium. 1988: 107-110.

[6] 何轶. 超声波传感器在宝钢钢卷检测中的应用[J]. 电工技术, 2003(10): 64-65.

[7] Norton-Waynel L, Hill W J, Brook R A. Automatic Visual Inspection of Moving Steel Surfaces[J]. British Journal of NDT, 1977, (09): 242-258.

[8] Hazem R. Salem T. An integrated robotic and machine vision system for surface flaw detection and classification [J]. Computers and Engine, 1996, 30(1): 27-40.

[9] Treiber F. On-line automatic defect detection and surface roughness measurement of steel strip[J]. Iron and Steel Engineer, 1989: 26-33.

[10] Suresh B R, Fundakowski R A, Levitt T S, et al. A real-time automated visual inspection system for hot steel slabs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1983(6): 563-572.

[11] Canella G, Falessi R. Surface inspection and classification plant for stainless steel strip[J]. Non-Destructive Testing, 1992, 4: 1185-1189.

[12] Badger J C, Enright S T. Automated surface inspection system[J]. Iron and Steel Engineer, 1996, 73(3): 48-51.

[13] Carisetti C. iLearn self-learning defect classifier[J]. Iron and Steel Engineer(USA), 1998, 75(8): 50-53.

[14] Rodrick T J. Software controlled on-line surface inspection[J]. Steel Times Int, 1998, 22(3): 30.

[15] 卢益民, 翁虹, 罗志勇. 钢带表面缺陷检测信息实时处理方法的研究[J]. 华中理工大学学报, 1994(11): 109-113.

[16] 徐科, 徐金梧, 鹿守理, 郭芳. 冷轧带钢表面自动监测系统的研究[J]. 钢铁, 2000(10):

63-66.

[17] Wu G, Kwak H, Jang S, et al. Design of online surface inspection system of hot rolled strips[C]//2008 IEEE International Conference on Automation and Logistics. IEEE, 2008: 2291-2295.

[18] Wei Y L, Yan Y H, Li B, et al. Development of a surface defect inspection system for cold rolled strip based on bright-dark filed mode[J]. Advanced Materials Research, 2010, 118: 762-766.

[19] 徐科, 王磊, 王璟瑜. 基于 Tetrolet 变换的热轧钢板表面缺陷识别方法[J]. 机械工程学报, 2016, 52(04): 13-19.

[20] Zhao L, Zhang Y, Xu X, et al. Defect inspection in hot slab surface: Multi-source CCD imaging based fuzzy-rough sets method[C]//Applications of Digital Image Processing XXXIX. SPIE, 2016, 9971: 958-964.

[21] Liu X H, He Z Y, Sun Y. On study of a method for detecting micro-deformation defects of steel plate surface[C]//AOPC 2020: Optics Ultra Precision Manufacturing and Testing. SPIE, 2020, 11568: 133-142.

[22] Natarajan V, Hung T Y, Vaikundam S, et al. Convolutional networks for voting-based anomaly classification in metal surface inspection[C]//2017 IEEE International Conference on Industrial Technology (ICIT). IEEE, 2017: 986-991.

[23] Liu Y, Geng J, Su Z, et al. Real-time classification of steel strip surface defects based on deep CNNs[C]//Proceedings of 2018 Chinese Intelligent Systems Conference: Volume II. Springer Singapore, 2019: 257-266.

[24] He D, Xu K, Wang D. Design of multi-scale receptive field convolutional neural network for surface inspection of hot rolled steels[J]. Image and Vision Computing, 2019, 89: 12-20.

[25] Yi L, Li G, Jiang M. An end-to-end steel strip surface defects recognition system based on convolutional neural networks[J]. steel research international, 2017, 88 (2): 1600068.

[26] Huang Z, Wu J, Xie F. Automatic recognition of surface defects for hot-rolled steel strip based on deep attention residual convolutional neural network[J]. Materials Letters, 2021, 293: 129707.

[27] Kim M S, Park T, Park P G. Classification of steel surface defect using convolut-ional neural network with few images[C]//2019 12th Asian Control Conference (ASCC). IEEE, 2019: 1398-1401.

[28] Gao Y, Gao L, Li X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition[J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.

[29] Zheng X, Wang H, Chen J, et al. A generic semi-supervised deep learning-based approach for automated surface inspection[J]. IEEE Access, 2020, 8: 114088-114099.

[30] Di H, Ke X, Peng Z, et al. Surface defect classification of steels with a new semi-supervised learning method[J]. Optics and Lasers in Engineering, 2019, 117: 40-48.

[31] Liu K, Li A, Wen X, et al. Steel surface defect detection using GAN and one-class classifier[C]//2019 25th international conference on automation and computing (icac). IEEE, 2019: 1-6.

[32] Faster R. Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 9199(10.5555): 2969239-2969250.

[33] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.

[34] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.

[35] 顾佳晨, 高雷, 刘路璐. 基于深度学习的目标检测算法在冷轧表面缺陷检测中的应用[J]. 冶金自动化, 2019, 43(06): 19-22+27.

[36] Wei R, Song Y, Zhang Y. Enhanced faster region convolutional neural networks for steel surface defect detection[J]. ISIJ international, 2020, 60(3): 539-545.

[37] Ren Q, Geng J, Li J. Slighter Faster R-CNN for real-time detection of steel strip surface defects[C]//2018 Chinese Automation Congress (CAC). IEEE, 2018: 2173-2178.

[38] 王艳玲, 苏盈盈, 罗妤, 唐霞. 基于 SSD 模型的钢带表面缺陷检测系统设计[J]. 重庆科技学院学报(自然科学版), 2021 ,23(03): 95-98.

[39] Lin C Y, Chen C H, Yang C Y, et al. Cascading convolutional neural network for steel surface defect detection[C]//Advances in Artificial Intelligence, Software and Systems Engineering: Proceedings of the AHFE 2019 International Conference on Human Factors in Artificial Intelligence and Social Computing, the AHFE International Conference on Human Factors, Software, Service and Systems Engineering, and the AHFE International Conference of Human Factors in Energy, July 24-28, 2019, Washington DC, USA 10. Springer International Publishing, 2020: 202-212.

[40] Li J, Su Z, Geng J, et al. Real-time detection of steel strip surface defects based on improved yolo detection network[J]. IFAC-PapersOnLine, 2018, 51(21): 76-81.

[41] Zhang J, Kang X, Ni H, et al. Surface defect detection of steel strips based on classification priority YOLOv3-dense network[J]. Ironmaking & Steelmaking, 2021, 48(5): 547-558.

[42] Kou X, Liu S, Cheng K, et al. Development of a YOLO-V3-based model for detecting defects on steel strip surface[J]. Measurement, 2021, 182: 109454.

[43] Ning Z, Mi Z. Research on surface defect detection algorithm of strip steel based on improved YOLOV3[C]//Journal of Physics: Conference Series. IOP Publishing, 2021, 1907(1): 012015.

[44] 李一鸣, 王潇. 基于 YOLOv5s 模型的轧钢表面缺陷检测[J]. 制造业自动化, 2021, 43(11): 117-119.

[45] Zhang G, Pan Y, Zhang L. Semi-supervised learning with GAN for automatic defect detection from images[J]. Automation in Construction, 2021, 128: 103764.

[46] Huang Z, Wu J, Xie F. Automatic surface defect segmentation for hot-rolled steel strip using depth-wise separable U-shape network[J]. Materials Letters, 2021, 301: 130271.

[47] Qian K. Automated detection of steel defects via machine learning based on real-time semantic segmentation[C]//Proceedings of the 3rd International Conference on Video and Image Processing. 2019: 42-46.

[48] Neven R, Goedemé T. A multi-branch U-Net for steel surface defect type and severity segmentation[J]. Metals, 2021, 11(6): 870.

[49] McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The bulletin of mathematical biophysics, 1943, 5(4): 115-133.

[50] Hebb D O. The organization of behavior: A neuropsychological theory[M]. Psychology press, 2005.

[51] Rosenblatt F. The perceptron: a probabilistic model for information storage and organization in the brain[J]. Psychological review, 1958, 65(6): 386.

[52] Minsky M, Papert S. An introduction to computational geometry[J]. Cambridge tiass, HIT, 1969, 479(480): 104.

[53] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.

[54] Kosko B. Bidirectional associative memories[J]. IEEE Transactions on Systems, man, and Cybernetics, 1988, 18(1): 49-60.

[55] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural computation, 1989, 1(4): 541-551.

[56] Elman J L. Finding structure in time[J]. Cognitive science, 1990, 14(2): 179-211.

[57] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural computation, 2006, 18(7): 1527-1554.

[58] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.

[59] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[60] Khosla P, Teterwak P, Wang C, et al. Supervised contrastive learning[J]. Advances in neural information processing systems, 2020, 33: 18661-18673.

[61] Gunel B, Du J, Conneau A, et al. Supervised contrastive learning for pre-trained language model fine-tuning[J]. arXiv preprint arXiv:2011.01403, 2020.

[62] Zeng Z, He K, Yan Y, et al. Modeling discriminative representations for out-of-domain detection with supervised contrastive learning[J]. arXiv preprint arXiv: 2105.14289, 2021.

[63] Pinitas K, Makantasis K, Liapis A, et al. Supervised contrastive learning for affect modelling[C]//Proceedings of the 2022 International Conference on Multimodal Interaction. 2022: 531-539.

[64] Yang C, Zou J, Wu J H, et al. Supervised contrastive learning for recommendation[J]. Knowledge-Based Systems, 2022, 258: 109973.

[65] Chen L, Wang F, Yang R, et al. Representation learning from noisy user-tagged data for sentiment classification[J]. International Journal of Machine Learning and Cybernetics, 2022, 13(12): 3727-3742.

[66] Glenn J. YOLOv5 [CP/OL]. https://github.com/ultralytics/yolov5, 2020.

[67] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv: 1804. 02767, 2018.

[68] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv: 2004. 10934, 2020.

[69] He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.

[70] Lin T Y, Dollár P, Girshick R, et al. Feature pyramid networks for object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2117-2125.

[71] Li H, Xiong P, An J, et al. Pyramid attention network for semantic segmentation[J]. arXiv preprint arXiv:1805.10180, 2018.

[72] Zheng Z, Wang P, Liu W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 12993-13000.

[73] Ge Z, Liu S, Wang F, et al. Yolox: Exceeding yolo series in 2021[J]. arXiv preprint arXiv: 2107. 08430, 2021.

致 谢

在我即将完成硕士学位论文的时刻，我想要向所有在我学业生涯中给予帮助和支持的人们致以最诚挚的感谢和敬意。

我要感谢我的家人。感谢你们一直以来对我的支持和鼓励，是你们的爱和理解让我坚持了下来。

我要感谢我的导师杨辉华教授。您在学术上给予的指导，让我受益匪浅，在生活上给予的帮助，让我能够顺利完成学业。您的言传身教将成为我人生道路上宝贵的财富，我会倍加珍惜。

我还要感谢实验室的赵文义博士师兄，感谢他在论文的研究方向、方法上对我的指导，以及在论文写作上的帮助和鼓励。感谢实验室的刘文涛博士师兄和李威博士师兄对我的关心和帮助。感谢实验室的侍掠飞师弟、母征岩师弟和何琪在数据集标注上提供的帮助。

最后，我要向所有未被提及到的人们表示最诚挚的感谢。感谢每一个曾经给予我启示和帮助的人，没有你们的帮助和支持，我的论文也不可能完成，谢谢大家！

攻读学位期间取得的“创新成果”目录

[1] 任明金, 金岩, 白翔, 等. 基于ResNet的电解镍板质量等级分类[EB/OL].北京:中国科技论文在线[2024-04-15]. http://www.paper.edu.cn/releasepaper/content/202404-180.