密级：公开

北京郵電大學

硕士学位论文(专业学位)



题目：基于深度学习的电积镍智能分拣算法研究

学　　号：2021141148

姓　　名：侍掠飞

学科专业：计算机技术

培养方式：全日制

导　　师：杨辉华

学　　院：人工智能学院

2024 年 3 月 7 日



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Master Dissertation

Research on intelligent sorting algorithm of electrodeposition nickel based on deep learning

Student ID： 2021141128

Author： Lvefei Shi

Subject： Computer technology

Supervisor： Huihua Yang

Institute： School of artificial Intelligence

7th March 2024

答辩委员会名单

职务	姓 名	职 称	工 作 单 位
主席			
委员			
委员			
委员			
委员			
秘书			
答辩日期			

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：

导师签名：_____ 日期：

摘　要

在电积镍板的生产过程中，因化学反应不稳定或人工操作失误，镍板表面会产生起泡、烧板等表面缺陷。这些缺陷影响了产品质量，企业需根据缺陷情况，将其分拣为不同等级的镍板进行销售。目前企业采用的分拣方法仍是通过现场人工目检，翻起每张镍板检查正反两面的缺陷。由于镍板面积大（约 0.8 平方米）并重达100kg，通过观察上下表面人工分拣不仅费时费力、危险程度高，而且准确率较低，企业急需要一种更准确、有效的自动化镍板分拣系统。

近年来深度学习技术的迅速发展，为传统工业、制造业的难题提供了高效成熟的解决方案。本文通过在质检现场搭建图像采集系统，使用线扫相机扫描运动的镍板，获取镍板正反两面的图像进行检测。

本文针对电积镍板的分类问题，为更好的提取电积镍板色彩纹理特征，提出了一种加入改进通道注意力的 ResNet18 模型。基于电积镍板在不同图层间的特征信息量不同，引入 SE 模块进行更好的层间特征提取；基于镍板板面像素值高于背景像素值，使用最大池化对 SE 模块进行优化，优化后的 SE+模块可以在提取层间特征时关注到更多的层间高频分量，从而更好的学习到各类镍板典型特征，提高分类准确率。

本文针对电积镍板的缺陷检测问题，提出了一种融合 CBAM 及 ASFF 模块的 YOLOv5s 多尺度目标检测模型。针对镍板各类缺陷位置分布广泛、尺寸多变的问题，引入 CBAM 模块，提升网络对位置分布广泛的小目标检测能力。引入 ASFF 模块，提升网络对多尺度目标的检测能力。优化后的 YOLOv5s 在污渍、水渍这两类位置、尺寸多变的缺陷检测达到了更高的准确率。

经现场测试，电积镍智能分拣系统算法达到了 90%的准确率。通过图像采集系统及划线剪切算法的配合，实现了镍板的自动采集、分类、缺陷检测、剪切与展示。解决了企业人工分拣镍板效率低、准确率低的问题。

关键词：图像分类；目标检测；电积镍

ABSTRACT

In the production process of electrodeposition nickel plate, due to the unstable chemical reaction or manual error, the surface defects such as foaming and burning will occur on the surface of nickel plate. These defects affect the quality of the product, and the enterprise needs to sort it into different grades of nickel plate for sale according to the defect situation. At present, the sorting method adopted by the enterprise is still through the field manual eye inspection, turn up each nickel plate to check the defects on both sides. Due to the large nickel plate area (about 0.8 square meters) and up to 100kg, manual sorting by observing the upper and lower surfaces is not only time-consuming and laborious, high danger, but also low accuracy, enterprises urgently need a more accurate and effective automatic nickel plate sorting system.

In recent years, the rapid development of deep learning technology has provided efficient and mature solutions to the problems of traditional industry and manufacturing. In this thesis, an image acquisition system is set up in the quality inspection site, and the images of the front and back sides of the nickel plate are obtained by scanning the moving nickel plate with a line scan camera for detection.

Aiming at the classification of electrodeposited nickel plates, a ResNet18 model with improved channel attention is proposed in order to better extract the color texture features of electrodeposited nickel plates. Based on the different feature information between layers of electrodeposited nickel plate, SE module is introduced to extract better feature between layers. Based on the fact that the pixel value of the nickel plate surface is higher than that of the background pixel value, the SE module is optimized using maximum pooling. After optimization, the SE+ module can pay attention to more interlayer high-frequency components when extracting interlayer features, so as to better learn various typical features of the nickel plate and improve the classification accuracy.

Aiming at the defect detection problem of electrodeposited nickel plates, a YOLOv5s multi-scale target detection model based on CBAM and ASFF modules is proposed in this thesis. Aiming at the problems of wide location distribution and variable size of various defects in nickel plate, CBAM module is introduced to improve the detection ability of small targets with wide location distribution. The ASFF module is introduced to improve the detection ability of multi-scale targets. The optimized YOLOv5s achieves a higher accuracy in the detection of stains and water stains, two types of defects with varying location and size.

After field test, the algorithm of electrodeposition nickel intelligent sorting system reaches 90% accuracy. Through the combination of the image acquisition system and the scribing and cutting algorithm, the automatic acquisition, classification, defect detection, cutting and display of the nickel plate are realized. The problems of low efficiency and low accuracy of manual sorting of nickel board are solved.

KEY WORDS: Image classification; Object detection; Electrode--posited nickel plate

目 录

摘　要.....I
ABSTRACT.....II
第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 基于传统图像处理方法的金属产品表面缺陷检测.....2
1.2.2 基于深度学习方法的金属产品表面缺陷检测.....4
1.3 论文主要工作.....5
1.4 论文结构与章节安排.....6
第二章 相关技术.....7
2.1 传统数字图像处理算法.....7
2.1.1 图像变换几何算法.....7
2.1.2 高斯滤波算法.....8
2.1.3 灰度阈值分割算法.....9
2.1.4 形态学处理算法.....9
2.2 对比学习.....10
2.3 基于深度学习的图像分类算法.....11
2.3.1 卷积神经网络.....11
2.3.2 深度卷积神经网络.....14
2.4 基于深度学习的目标检测算法.....15
2.4.1 双阶段目标检测算法.....16
2.4.2 单阶段目标检测算法.....17
2.5 本章小节.....19
第三章 基于改进 ResNet18 模型的电积镍板分类.....20
3.1 引言.....20
3.2 针对电积镍分类问题的改进 ResNet18 模型.....21
3.3 实验设计和结果分析.....24
3.3.1 数据集与实验环境.....24
3.3.2 评价指标.....25
3.3.3 基准实验与消融实验.....25
3.3.4 与其他分类模型的对比实验.....28
3.4 本章小节.....29

第四章 基于改进 YOLOv5s 模型的电积镍板缺陷检测 30
4.1 引言 30
4.2 针对电积镍板表面缺陷改进的 YOLOv5s 模型 31
4.2.1 基于注意力机制的改进 32
4.2.2 基于多尺度特征融合的改进 34
4.3 实验设计和结果分析 36
4.3.1 数据集及实验环境 36
4.3.2 评价指标 36
4.3.3 基准实验与消融实验 37
4.3.4 和其他检测模型的对比实验 40
4.4 本章小节 40
第五章 智能分拣系统实现 41
5.1 电积镍板智能分拣系统设计方案 41
5.2 图像采集系统 41
5.3 镍板图像矫正与划线算法 42
5.3.1 矫正算法 42
5.3.2 划线算法 45
5.4 可视化系统实现 46
5.5 本章小节 47
第六章 总结与展望 48
6.1 工作总结 48
6.2 工作展望 49
参考文献 52
附 录 57
致 谢 58
攻读学位期间取得的“创新成果”目录 59

符号说明

符 号	代表意义	单 位
W、H	图片宽高	px
x、y	像素点横纵坐标	px
θ	角度	°
$Gray$	灰度图像灰度值	
R、G、B	RGB 三色通道分量	
σ	Sigmoid 激活函数	

第一章 绪论

1.1 研究背景及意义

镍是一种银白色带光泽的金属，因为其具有良好的硬度、耐腐蚀性及延展性，而被广泛应用于建筑业、军工业、镍基合金及电镀工业等产业。随着近年来新能源产业的发展，对不锈钢、特钢及动力电池需求的增长，金属镍作为其重要的制作原料，需求量也在逐渐增加。电积镍板的生产过程中，含有镍盐和其他添加剂的溶液，在电解槽内电解，通过电流的作用让金属镍沉积到工件表面，形成电积镍板。但因为电解液化学成分复杂，其他金属或杂质附着于金属镍板表面；工件电镀处理不彻底或水洗不干净，在进入镍槽时表面有残留的氧化皮等杂物；添加剂的添加配比失调等因素，会导致电积镍板表面出现起泡、烧板等表面缺陷。这些缺陷不仅会影响产品外观，也会影响镍合金的硬度。作为重要的工业原理，不合格的电积镍板可能会被用于建筑、汽车，存在着安全隐患。为此需要将电积镍板划分等级，对不合格的电积镍进行降号或二次烫洗处理，保障电积镍板的产品质量。

目前企业对电积镍板的分拣方法依然是在生产车间进行人工分拣。生产现场环境昏暗，需要顶部白炽灯照明，而镍板表面反光率较高，可能会因为板面过暗或反光导致缺陷漏检。此外电积镍板尺寸与重量较大，人工分拣时需要将不合格及需要二次烫洗的镍板抬出放在一起，再通过叉车运送，长时间的工作容易产生疲劳，导致误检。不同质检员的合格标准存在差异，导致即使是分拣出的同种镍板个体质量也会参差不齐。现场环境噪音较大，有时会有有毒气体排出，影响质检员身体健康。对专业人员的技术培训也影响着企业的发展。人工分拣费时费力，需要有一种更高效准确的分拣方法代替人工分拣。

随着中国制造 2025 及工业 4.0 的提出，越来越多的大型冶金企业开始与高校联合研究基于计算机视觉的表面缺陷检测算法及系统。2022 年虞佳佳等提出了一种基于机器视觉的铝镍钴磁棒材料缺陷检测的方法，通过 Canny 边缘检测算法提取图像轮廓，基于轮廓信息计算出端面圆，通过计算轮廓点到端面圆的距离确定材料表面缺角及崩角缺陷[1]。2023 年刘广鹏针对镍板表面结粒与气泡这些凸起类缺陷，使用梯度增强算子及分水岭算法对 Otsu-Canny 算法进行改进，实现了对镍板表面结粒与气泡的准确检测[2]。

以上为近些年来针对镍产品表面缺陷检测的研究，这些研究主要使用了传统图像处理算法，通过对图像进行开闭运算，边缘提取等操作进行缺陷检测。但在电积镍板质检问题中，板面缺陷类型复杂，存在水印，油污，烧板等多种

类型的缺陷，部分类别的缺陷个体特征差别过大，使用传统图像处理算法可能难以获得其典型特征，近些年迅速发展的深度学习技术为此提供了解决方案。深度学习通过大量的训练集，自动提取各类镍板与缺陷的典型特征，与传统的机器视觉缺陷检测相比，避免了人工提取特征的局限性，达到了更高的检测精度和效率。相较于传统机器视觉缺陷检测算法，深度学习可以更加全面地检测出复杂工业场景下产品表面的各种缺陷，从而将产品准确分级。本文首次将深度学习算法应用于电积镍板质检问题，通过图像采集系统获取镍板正反双面的图像，编写图像预处理算法对镍板进行图像矫正操作，使用图像分类模型及目标检测模型对镍板图像进行分类及缺陷检测，设计划线算法确定镍板的剪切线位置，搭建可视化系统展示质检结果。针对现有分类模型与目标检测模型在电积镍分拣问题中的不足，本文对其进行了改进，研究包括：

1. 基于优化残差模块的电积镍板分类算法

电积镍板存在多种类型不同的缺陷，不同缺陷特征不同，因而在各图层中的特征分类也不同。传统的残差模块并没有关注到不同特征图层中的信息分量。使用 SE 模块对残差模块进行改进，使网络更有效的提取不同特征图层中的信息。针对镍板图像板面灰度值高于背景灰度值的特点，设计加入最大池化的 SE+模块来提取特征图层中的局部高频分量，使用 SE+模块对 ResNet18 网络进行改进，改进后的 ResNet18 网络电积镍板分类的准确率取得了显著的增长。

2、基于多尺度特征提取与注意力机制优化的电积镍表面缺陷检测算法

电积镍板图像尺寸较大，各种缺陷在板面分布位置广泛，坐标跨度大。为此模型需要充分的学习到图像各位置上的特征信息。在 YOLOv5 网络中加入 CBAM 模块，给特征图层间与空间中的各个像素分配注意力，使模型更好的学习空间与通道中的关键特征。电积镍板的各类缺陷大小不同，如烧板缺陷常遍布整个板面，污渍缺陷有时是面积仅几平方厘米的小点，为解决多尺度缺陷检测问题，在 YOLOv5 网络的基础上引入 ASFF 模块优化网络，提取多尺度特征，以检测不同尺度的缺陷。

通过搭建现场图像采集系统，使用深度学习算法对电积镍板进行等级分拣，基于缺陷确定剪切位置，搭建可视化系统进行结果展示，完成了电积镍板图像的自动采集、分类、缺陷检测、剪切与展示。实现了电积镍分拣的自动化、智能化。

1.2 国内外研究现状

1.2.1 基于传统图像处理方法的金属产品表面缺陷检测

基于传统图像处理方法的表面缺陷检测通常基于人工设计的特征提取器，使用色彩直方图、图像滤波、边缘提取、形态学操作等方法进行缺陷检测，能

够准确检测到边缘、色彩等特征明显的缺陷。随着自动化等技术的发展，国外一些公司开始使用传统图像处理方法代替人工目检，进行自动化、智能化的金属产品表面缺陷检测。美国 Westinghouse 公司通过使用高强度的线性光源及线阵相机 CCD 采集带钢图片，并提出使用明域、微光域与暗域三路联合灯光进行检测的方法[3]。意大利 CSM 公司设计了针对不锈钢表面空洞缺陷的检测系统。这些系统虽然实现了图像的自动采集与检测，却无法检测到周期性的缺陷，能够检测出的缺陷类型也比较少。针对此问题，美国 Cognex 公司研制了 iLearn 自学习分类器软件系统及 iS-2000 自动检测系统[4]。通过其配合，传统自学习分类方法在训练集样本规模、数据吞吐量以及模式特征的自动选择等方面的不足得到了有效改善。随着图像处理技术的发展及实际生产中产品质量检测的需要，国内也展开了针对金属产品表面缺陷检测的研究。屈尔庆等针对传统带钢表面缺陷检测方法在实际生产过程中检测精度低、实时性差的问题，提出一种基于复合差分进化的 Gabor 滤波器优化方法，极大的提升了带钢表面缺陷检测效率，且降低了非缺陷的误检率[5]。安宗权等提出了一种非线性扩散与图像差分的金属表面缺陷检测方法，使用图像梯度的倒数对传统 P-M 非线性扩散模型中的扩散因子进行改进，将金属表面的原始图像与经过非线性扩散后的图像进行图像差分运算，通过差分图像差构造自适应二值化模型，实现对金属表面缺陷的准确检测[6]。王进峰等提出了一种基于 HALCON 的四光源光度立体法金属表面缺陷检测方法，使用 CCD 相机采集 4 个不同空间角度的打孔金属试样图像，基于四光源的光度立体技术原理计算得到表面梯度图像进行缺陷检测[7]。厉荣宣等提出一种基于 Canny 算子的轴类零件表面裂纹检测算法，通过 Canny 算子和形态学操作提取裂纹区域，基于裂纹连通域的曲度及长宽比检测裂纹[8]。黄文涛等针对锂电池极片表面存在低对比度微小缺陷难以检测的问题，提出了一种基于改进 Canny 算子的锂电池极片表面缺陷检测方法，使用双边滤波算法级及 Otsu 算法对 Canny 边缘检测算法进行改进，改进后的算法可以更好的保留图像边缘特征并检测出锂电池表面暗纹、划痕、破损等缺陷[9]。马忠平提出了一种基于机器视觉的轴承环形表面缺陷检测算法，通过对图像进行傅里叶变换、差分处理及中值滤波，基于图像灰度值，使用修正后的自适应双阈值算法计算图像阈值，之后通过形态学处理与二值化操作检测缺陷[10]。崔焱等提出了一种手机盖板表面缺陷检测算法，使用 Canny 边缘检测与高斯滤波进行数据预处理，针对手机不同缺陷的特点，采用最小二乘法计算 IR 孔圆度以对 IR 孔缺陷进行检测；使用图像差分算法对油墨点缺陷进行检测[11]。刘飞飞等提出了一种基于改进 Canny 边缘检测算法的铜箔表面缺陷检测方法，通过使用中值滤波的 Canny 边缘检测算法，避免原 Canny 算法中的高斯核会造成缺陷边缘模糊

的问题；通过自适应双阈值算法确定合适的缺陷分割阈值，准确的检测出了铜箔表面裂口、污渍及划印缺陷[12]。

1.2.2 基于深度学习方法的金属产品表面缺陷检测

传统视觉方法基于图像的色彩与纹理特征，使用人工设计的特征提取器，对特征明显的缺陷取得了较好的检测效果，但对于特征信息复杂，形状、位置及尺寸大小多变的缺陷检测效果较差；而且当图像分辨率较大时、算法的检测速度会大幅下降。2009 年斯坦福大学教授李飞飞团队发布了 ImageNet 数据集，并基于 ImageNet 举办了数次 ILSVRC 竞赛[13]。大批量的训练集为性能更好的模型提供了数据基础。由此诞生了众多性能优异的卷积神经网络。2012 年，Krizhevsky 等提出基于深度学习的 AlexNet 网络 [14]。相较于先前手写数字分类这类较简单的图像分类任务，AlexNet 对 ImageNet 数据集中高达 1000 个类别的图像取得了较好的检测效果，引发了深度学习研究的热潮。随着工业智能化的发展，一些研究人员开始将深度学习应用于产品表面缺陷检测，以弥补传统数字图像处理方法需手工提取特征、对多尺度缺陷检测能力不足的缺点。2014 年 RossB.Girshick 等设计了 RCNN 模型，首次将卷积神经网络引入目标检测领域，相较于此前目标检测领域常用的手工设计特征方法大幅提高了检测准确率[15]。2015 年， Ross Girshick 独自提出了更快、更强的 Fast RCNN 算法，通过先计算特征图再获得 RoI 区域，实现了端到端的训练模型，大幅提升了 RCNN 网络的检测速度及准确率[16]。之后人们继续对 RCNN 模型进行改进，设计出了 Faster RCNN[17]、Mask RCNN[18]、Cascade RCNN 等网络[19]。改进后的 RCNN 网络具有更高的检测速度与精度，被人们广泛用于各类金属产品表面缺陷检测。孔思曼等针对金属板材表面缺陷，使用可变形卷积、RoI Align 及 Kmeans++算法对 Faster RCNN 网络进行优化，提升了网络检测小目标及不规则缺陷的能力[20]。杜志虎等针对传统管道焊缝缺陷检测方法的实用性差、准确率低的问题，使用空洞卷积对 Mask RCNN 网络进行优化，实现了管道焊缝缺陷的准确检测[21]。陆尧等通过引入空洞卷积及 PANet 特征聚合算法对 Cascade RCNN 网络进行改进，提高了热轧带钢各类表面缺陷的检测精度[22]。双阶段目标检测算法首先产生候选区域，再处理候选区域进行分类，检测精度较高，但产生候选区域的过程会造成检测时间增加，在实际生产中产品的检测速度需达到产量的要求，为此速度更快的单阶段目标检测算法将是一个更好的选择。2016 年 W. Liu et al.提出了 SSD 网络[23]，不同于 RCNN 网络基于像素特征聚类产生候选区域的方式，SSD 通过在特征图上的数个像素预设锚点产生候选区域，从而不再像两阶段检测模型一样需要在图像中先产生选区，再通过分类损失及 Bounding box 调整选框，从而大幅缩短了检测时间。除 SSD 网络外，单阶

段目标检测模型的另一个代表为 YOLO 系列网络。就在 SSD 诞生的同一年，Juan R. Terven 等人提出了 YOLOv1 网络[24]，与 SSD 相似，YOLOv1 将特征图划分为多个部分，对每部分产生数个检测框，之后通过 Bounding box 回归损失函数及分类损失函数调整网络参数，从而检测出待检目标。因 YOLO 网络优异的检测精度与速度，稳定的性能，人们在 YOLO v1 网络的基础上不断进行改进，研究出了各种版本的 YOLO 网络[25-33]。 YOLO 网络具有优异的检测精度与速度，稳定的性能。因其方便快捷的部署，为不同的设备需求及应用场景提供了不同大小的网络，YOLO 网络被广泛用于工业界缺陷检测。王勇强等针对导地线缺陷检测问题，提出了一种基于 LSD 与深度学习的轻量化导地线缺陷检测方法，通过 LSD 及 RANSAC 拟合出分割基线，剔除导线图像的背景；最后通过修改 YOLO V5 网络的 Backbone，减少计算量，使其更适合在边缘计算设备上部署[34]。谢昆等针对铝材表面缺陷检测问题，提出一种基于改进 YOLO V5s 的铝材表面缺陷检测方法，通过使用 ShufflenNetv2，SE 注意力机制及 SIoU 损失函数对 YOLO V5 进行优化，提高了检测准确度，有效改善了先前的错检漏检问题[35]。

除了使用有监督学习的方式进行缺陷检测外，近些年自监督学习也被被越来越多的人关注，而广泛用于缺陷检测。自监督学习是一种无监督学习方法，其使用无标注的数据，基于聚类算法设计类别标签，再使用此标签进行有监督学习。因工业场景中一些缺陷形态、尺寸位置多变，标注工作较为复杂，近些年自监督方法也被一些研究人员用于表面缺陷检测。杨景崙等针对输电线路螺栓螺母异常检测中标注数据集较少的问题，使用自监督学习，通过无标签螺栓数据集对预训练大模型进行训练，获取螺栓注意力图并检测上面的缺陷[36]。刘华峰等提出一种基于自监督模型 SimSiam 的改进缺陷检测算法，通过使用空间注意力模块及全卷积网络，使模型在提取目标深层特征的同时保留浅层的局部特征；通过平均池化操作计算特征图特征向量，再将特征向量归一化计算欧氏距离，以此来优化损失函数[37]。

1.3 论文主要工作

论文针对电积镍板智能分拣问题，设计自动化检测方案，使用图像处理算法进行电积镍智能分拣，搭建可视化系统进行分拣结果展示。相关工作流程如下图所示，首先于现场搭建图像采集系统，采集镍板图像，之后使用图像预处理算法检测镍板轮廓，确定镍板中心后对镍板图像进行平移与旋转，使镍板位于图片中央且垂直显示。之后调用图像分类算法，若分类为合格板或为烫洗板直接进行镍板图像及判定类别展示；若分类为不合格板则调用缺陷检测算法，检测镍板表面缺陷，之后根据缺陷面积及位置确定合适的剪切线，以供之后剪

板机切除缺陷部分。展示镍板图像，缺陷检测结果与划线结果。

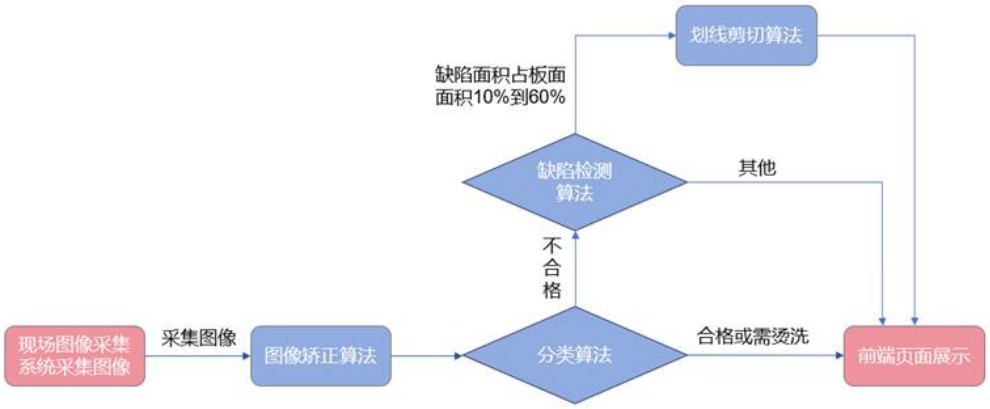


图 1-1 镍板智能分拣流程图

Figure 1-1 Intelligent sorting flow chart of nickel plate

1.4 论文结构与章节安排

本论文按研究内容分五个章节进行研究，各章节内容安排如下：

第一章介绍了论文研究内容的研究背景及意义；针对金属产品表面缺陷检测问题，国内外使用传统方法，传统数字图像处理算法及深度学习算法进行的研究；论文的工作内容；各章节内容安排。

第二章介绍了本文使用的相关算法的背景知识，包括数字图像处理、卷积神经网络、对比学习及目标检测算法。

第三章介绍电积镍板分类任务、分类算法的实现与优化。首先介绍了电积镍分类的问题背景及任务难点，结合现场任务需求及设备条件，使用 ResNet18 进行分类实验。基于镍板图像特征，提出加入最大池化操作的 SE+模块以提取特征图中的高频分量，通过数据增强提升模型对过暗、混入图像噪音的异常图片的判别能力。使用改进残差结构后的 ResNet18 网络进行电积镍板分类实验，并与 AlexNet、SqueezeNet、监督对比学习分类模型等网络对比实验效果。

第四章介绍电积镍板缺陷检测任务背景与问题难点，电积镍缺陷数据集的建立。针对镍板表面缺陷位置分布多变，同类缺陷的个体间特征差异较大的问题，通过 CBAM 注意力机制提升 YOLOv5s 对图像上不同位置及不同层间的特征自适应提取的能力，通过 ASFF 模块优化 YOLOv5s 的 Neck 部分，优化 YOLOv5 对不同层特征进行自适应融合的能力，使用改进后的 YOLOv5s 网络进行分类实验。与 SSD、YOLOv4 等缺陷检测模型的对比实验结果。

第五章介绍电积镍板智能分拣系统设计与实现，包括图像采集系统、镍板图像矫正与划线算法的实现、可视化系统的实现的实现。

第二章 相关技术

2.1 传统数字图像处理算法

2.1.1 图像变换几何算法

在数字图像处理中，通过变换矩阵，对图像进行平移、旋转、翻转等几何变化。平移变换指按指定偏移量对图像进行水平及垂直方向上的平移操作，平移后图像坐标变为$(x_1,y_1)=(x,y)+(t_x,t_y)$，其中$t_x$与$t_y$表示水平及垂直方向的平移量，写作矩阵表达式即：

$$\begin{bmatrix}x_1\\y_1\\1\end{bmatrix}=\begin{bmatrix}1&0&t_x\\0&1&t_y\\0&0&1\end{bmatrix}\begin{bmatrix}x\\y\\1\end{bmatrix} \tag{2-1}$$

$\begin{bmatrix}1&0&0\\0&1&0\\t_x&t_y&1\end{bmatrix}$即平移变换矩阵，通过其可实现对图像的任意平移操作。

旋转变换指以某固定点对图像进行旋转操作。当图像绕原点旋转时，如下图中，v点绕原点逆时针旋转θ角得到v'点。有v点坐标表达式$x=r\cos\Phi$，$y=r\sin\Phi$，v'点坐标表达式$x'=r\cos\theta\cos\Phi-r\sin\theta\sin\Phi$，$y'=r\sin\theta\cos\Phi+r\cos\theta\sin\Phi$，将v点坐标表达式代入到$v'$点坐标表达式得$x'=x\cos\theta-y\sin\theta$，$y'=x\sin\theta+y\cos\theta$。

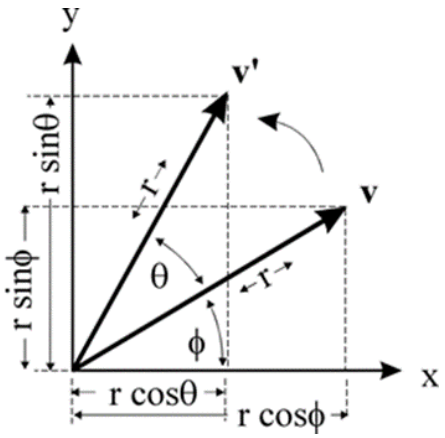


图 2-1 旋转变换坐标图

Figure 2-1 Rotation transform coordinate diagram

同理可推出图像绕其他任意点(x_a,y_a)旋转θ角的表达式。将旋转点

(x_a, y_a)平移至原点，求图像绕原点旋转θ角的坐标，再将原点平移至旋转点，求绕其他点旋转的坐标问题就转换为了求绕原点旋转加平移的问题，以上的变换中，图像点经过了平移-t_x ,-t_y，绕原点旋转θ角，平移t_x ,t_y的操作，写作矩阵表达式即：

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} cos\theta & -sin\theta & t_x \\ sin\theta & cos\theta & t_y \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 0 & -t_x \\ 0 & 1 & -t_y \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2\text{-}2)$$

可得变换矩阵：

$$\begin{bmatrix} cos\theta & -sin\theta & x_c(1-cos\theta)+y_c sin\theta \\ sin\theta & cos\theta & y_c(1-cos\theta)-x_c sin\theta \\ 0 & 0 & 1 \end{bmatrix} \quad (2\text{-}3)$$

翻转变换指以图像水平或垂直对称轴为轴线，对图像进行翻转处理。对宽度为 w，高度为 h 的图像，以左上角为坐标原点，水平翻转的矩阵表达式为:

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 & w \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2\text{-}4)$$

垂直翻转矩阵表达式为:

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & h \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} \quad (2\text{-}5)$$

2.1.2 高斯滤波算法

在图像采集、处理、传输的过程中，可能会因为信号不稳定而产生图像噪音。图像滤波通过对图像进行卷积操作，达到平滑图像，去除噪音的效果。常见的图像滤波算法有线性滤波、均值滤波、中值滤波、高斯滤波、双边滤波等，这里对本文使用的高斯滤波算法进行详细介绍。

高斯滤波通过高斯卷积核，与图像做卷积运算进行滤波，适用于处理高斯噪声。高斯卷积核中各行（列）的数据权重服从二维高斯分布：

$$G(x,y) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2} \quad (2\text{-}6)$$

通过二维高斯分布热力图能看出高斯卷积核中心点的权重较大，从中心到四周点的权重逐渐降低，即在进行卷积时让临近的像素点具有较大的权重值，起到模糊图像，消除噪音点的作用。

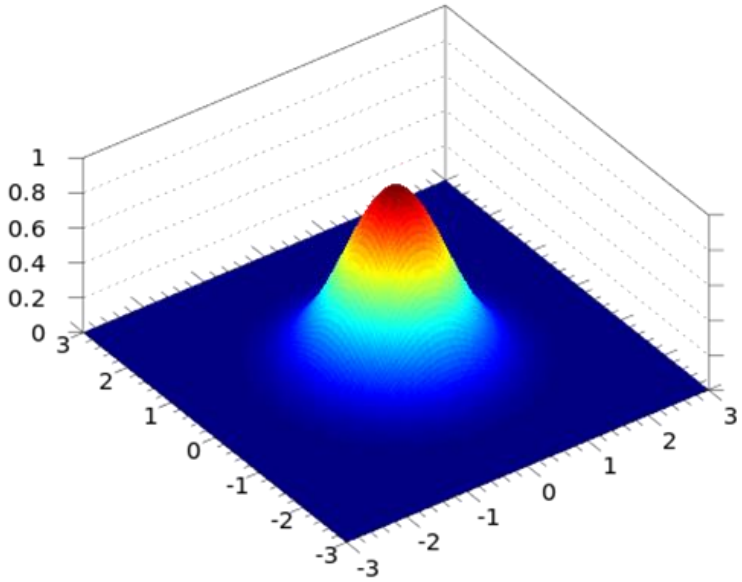


图 2-2 二维高斯分布热力图

Figure 2-2 Two-dimensional Gaussian heat map

2.1.3 灰度阈值分割算法

灰度阈值分割算法基于灰度值对图像进行分割，达到剔除噪音，保留感兴趣的目标，提取图像边缘等效果。计算机中的彩色图像多为基于 RGB 色彩空间，由红、绿、蓝三色通道组成。在对彩色图像进行阈值分割时，首先需将彩色图像转换为灰度图像。因人眼对不同频率的光敏感度不同，计算机视觉中模拟人眼视觉效果进行灰度图转换，转换后的灰度值表达式为：

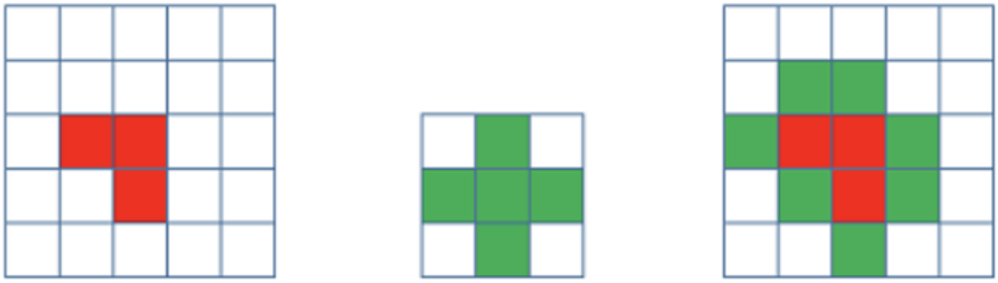
$$Gray = 0.2989R + 0.5879G + 0.1140B \quad (2\text{-}7)$$

通过灰度转换，将原来三通道的彩色图像，转换为单通道的，灰度值 0~255 的灰度图，设定灰度范围，保留设置区间内的像素，完成图像分割

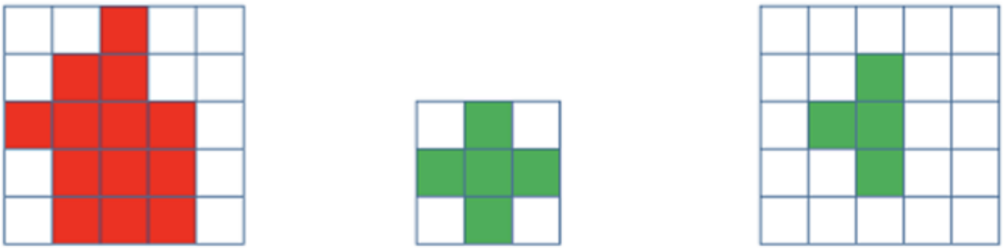
2.1.4 形态学处理算法

形态学操作基于图像形状进行运算处理，常被用于提取图像特征、消除噪声、改变图像的形状。常用的形态学操作有膨胀、腐蚀、开运算与闭运算。

膨胀操作使用一个结构元素扫描图像中的所有像素，进行或运算，若该点及其周围像素与结构元素间有重叠，即有一点在结构元素及图像上均为 1，则将该点设为 1，否则为 0。腐蚀操作为使用结构元素与图像做与运算，若结构元素及图上的对应位置均为 1，则该点为 1，否则为 0。膨胀操作可以对图像边缘进行填充，常被用于图像边缘平滑，消除目标内空洞点。腐蚀操作保留了目标中心位置内的像素，可以消除图像边缘毛刺，剔除图像噪音。



(a) 膨胀操作



(b) 腐蚀操作

图 2-3 膨胀与腐蚀操作示意图

Figure 2-3 Expansion and corrosion operation diagram

开运算对图像先进行腐蚀操作，剔除噪音信息，保留目标信息，再进行膨胀操作平滑图像边缘。闭运算对图像先进行膨胀操作，扩充前景信息，再进行腐蚀操作消除边缘毛刺。开运算可以在保留目标信息的基础上剔除背景噪音，闭运算常被用来消除目标内部空洞。

2.2 对比学习

对比式学习着重于学习同类实例之间的共同特征，区分非同类实例之间的不同之处，它无需数据标注就能完成学习，适用于数据量较大、标准困难的任务。在自监督对比学习中，正样本I^+与锚点I^a组成一个正样本对，负样本I^-与锚点I^a组成一个负样本对，通过编码器进行编码，模型使正样本对编码特征间的度量$\delta(f^a, f^+)$尽可能减小，负样本对编码特征$\delta(f^a, f^-)$间的度量尽可能增大，从而无需依赖大规模的数据标签，通过对比样本间的相似度完成分类。有监督学习通过从标定类别的样本间学习类别特征，再基于类别特征进行分类；对比学习基于样本间的相似度进行分类，因此在处理特征明显，相似度较高的同类样本时具有较好的泛化性能。

在对比学习中，对一个包含 N 张图片的 MiniBacth，随机对每张图片进行两次数据增强，得到 2N 张图片。将其通过特征提取网络产主 2N 个特征向量，进行标准化处理，产生归一化特征向量$\{z_1, z_2, z_3 \dots z_i \dots z_{2N}\}$，对其中任意一张图片 i，其他图片中有且只有另一张图片 j，和其来源于同一张图片的数据增强，自监督对比学习通过拉近其距离，疏远其与其他特征的距离完成训练。其

损失函数表达式为：

$$L^{self} = \sum_{i=1}^{2N} L_i^{self} \tag{2-8}$$

$$L_i^{self} = -log\frac{\exp(z_i \cdot z_{j(i)}/\tau)}{\sum_{k=1}^{2N} 1[k\neq i]*\exp(z_i \cdot z_{j(i)}/\tau)} \tag{2-9}$$

上式中 1[k≠i]为指示函数，当且仅当 k=i 时取 0，否则为 1。$z_i \cdot z_{j(i)}$ 表示对向量z_i与$z_{j(i)}$进行内积运算，以此表征其之间的距离。τ是进行优化的温度参数，取值大于 0。该损失函数的作用为对来源于正样本对图片 i 与图片 j 的特征，使其余弦相似度越大越好，对来源于负样本对的特征使其余弦相似度越小越好。自监督对比学习基于样本特征相似度进行分类，从而无需类别标签就可以完成训练，降低了标注工作量，且在处理类别特征明显的样本时性能较好，但其缺乏标签的缺点也很明显。当样本与该类的其他样本相似度较低时，对比学习会基于类间度量将该样本划分为其他样本。为解决对比学习缺乏标签而导致类别判断完全依赖于样本间相似度的缺点，有监督的对比学习将标签引入对比学习，首先通过自监督对比学习使相似的样本接近，差异较大的样本疏远，再使用标签信息进行有监督的学习。

从而在原自监督对比学习通过学习样本对间的特征度量进行分类的基础上，进一步的通过标签避免同类样本对特征度量较远。为此有监督学习的损失函数在自监督对比学习损失函数的基础上进行改进，变为：

$$L^{sup} = \sum_{i=1}^{2N} L_i^{sup} \tag{2-10}$$

$$L_i^{sup} = -\frac{1}{2N_{\tilde{y}_i}-1}\sum_{j=1}^{2N} 1[i\neq j] * 1[\tilde{y}_i \neq \tilde{y}_j] log\frac{\exp(z_i \cdot z_{j(i)}/\tau)}{\sum_{k=1}^{2N} 1[k\neq i]*\exp(z_i \cdot z_{j(i)}/\tau)} \tag{2-11}$$

在上式中，相较于自监督对比学习损失函数，有监督对比学习损失函数添加了指示函数$1[\tilde{y}_i \neq \tilde{y}_j]$，$\tilde{y}_i$表示第 i 张图片的类别信息，即当两个特征来源于同一类别的图片时，通过让指示函数为 0，使其不参与损失函数的计算，从而利用标签信息，解决了自监督模型会让来源同类别不同图片的特征疏远的问题。

2.3 基于深度学习的图像分类算法

2.3.1 卷积神经网络

1958 年 Frank Rosenblatt 提出了由两层神经元组成的感知机模型，用于简单图像的分类实验，引发了人们对神经网络的研究。感知机可视为最简单的一种前馈神经网络，其将多个信号加权相加，通过调整模型权重完成训练。下图表示了一个感知机的基本结构，将输入 x 加权相加，加上偏移量 b，通过激活函数 f 引入非线性变换。

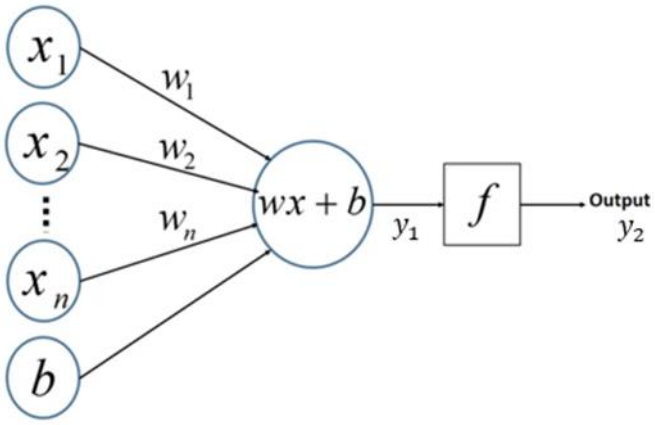


图 2-4 感知机模型结构

Figure 2-4 Perceptron model structure

虽然感知机结构简单，易于实现，但其只能提取的特征有限，只能用于手写数字识别之类的简单任务。GPU 算力的提高，让结构更加复杂的神经网络也能够被实现，其中卷积神经网络取得了飞速发展，在图像分类、检测、定位等任务上取得了当时远超其他神经网络的优异性能，下面以经典神经网络 AlexNet 为例讲解卷积神经网络的相关内容。AlexNet 是 2012 年 Alex Krizhevsky 等人提出的卷积神经网络，由五个卷积层与三个全连接层组成。对输入为 224*224*3 的图像，网络通过五个卷积层输出 13*13*256 的特征图，再将其拉平为一维向量，经过三个全连接层输出长度为 1000 的一维向量，表示分类任务中 1000 个类别对应的概率。

AlexNet 的卷积层由卷积、ReLU 激活函数及最大池化组成。卷积是卷积神经网络最基本的操作，对输入图像，使用卷积核（通常为 n*n 的方形矩阵）滑动扫描图片的各个像素做内积运算，将卷积核及图片中对应位置的元素相乘后再相加，起到聚合图像特征的作用。通常卷积运算会让提取的特征图相较于图像尺寸减小，通道数增多。卷积运算后特征图的通道数等于卷积核的通道数，尺寸 o 由输入尺寸 n、卷积核的大小 f、图像填充 p（进行卷积运算时在图像边缘填充 p 个像素）、步长 s（卷积运算时卷积核每次平移 s 像素）决定，其计算公式为：

$$o = \left\lfloor \frac{n+2p-f}{s} \right\rfloor + 1 \qquad (2\text{-}12)$$

式中⌊⌋表示向下取整，实际也可使用向上取整等其他取整方式。

池化是神经网络中常用的下采样操作，在不改变图片通道数的情况下降低图片尺寸，用以提取图像特征，减少后续处理的计算量。池化操作将图像分为 n*n 部分，对每一部分输出一个像素值，从而将 f*f*c 的特征图转化为 n*n*c 的特征图。通常池化操作采用最大池化或平均池化，最大池化输出区域内的最大

像素值，适用于提取图像纹理信息；平均池化输出区域内像素值的平均值，可以保留更多的图像背景信息。

激活函数用于帮助模型拟合更复杂的函数关系，在卷积、池化与全连接运算中，除最大池化引入了少量非线性关系外，其余操作都是在进行线性组合，纯粹的线性组合无法解决更复杂的问题，为此卷积神经网络通过激活函数引入非线性组合，去拟合更复杂的关系。在 AlexNet 的卷积层中使用了 ReLu 激活函数，其表达式为：

$$h(x) = \begin{cases} x\ (x > 0) \\ 0\ (x \leq 0) \end{cases} \tag{2-13}$$

ReLu 激活函数逻辑简单，计算速度快，且对所有大于 0 的值其梯度为 1，不容易出现因梯度消失而导致模型学习缓慢的问题，而成为了最常用的激活函数之一。不过当像素值不大于 0 时 ReLU 激活函数将其直接降为 0，导致此处梯度为 0，网络无法再学习到对应的权重及偏置更新。针对 ReLu 激活函数的梯度消失问题一些激活函数做了改进，其中常用的有 Leaky ReLu。Leaky ReLu 的输出在正半轴上与 ReLu 的输出相同，但在负半轴上并非取 0，而是乘以系数 α，由此使小于零的部分也有梯度。

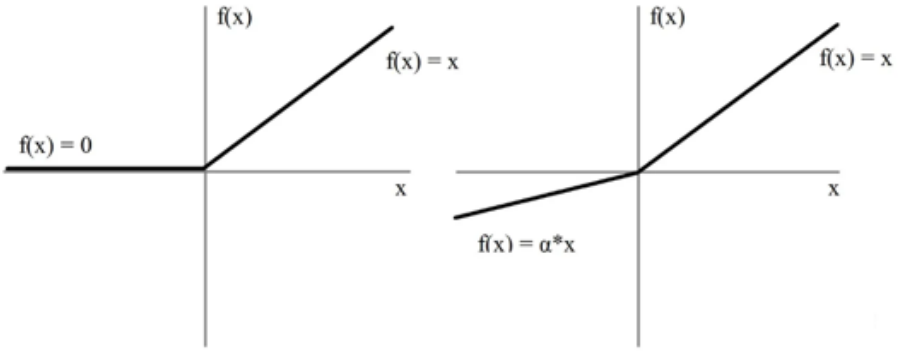


图 2-5 ReLu 与 Leaky ReLu 激活函数

Figure 2-5 ReLu and Leaky ReLu activation function

AlexNet 通过五个卷积层提取特征得到 13*13*256 的特征图后，使用全连接层进行类别判断。全连接结构就是前文中提到的感知机结构，将一维向量中的所有元素进行线性运算，通过 ReLu 激活函数。AlexNet 的最后两个全连接层中使用了 Dropout 策略，即通过使全连接结构中的一些神经元失活，防止模型过拟合，提升模型的泛化性能。在最后一个全连接层输出长度 1000 的一维向量后，使用 softmax 函数将表示各类的 logits 值转换为和为 1 的概率分布，softmax 函数的表达式为：

$$f(x_i) = \frac{e^{x_i}}{\sum_{i=1}^{N} e^{x_i}} \tag{2-14}$$

式中 N 表示分类任务的类别数，i 表示第 i 个类别，通过 softmax 函数，原来表示对应各类别的 logits 指数就转换为了[0,1]间的概率。训练过程中使用损失函数让预测的概率分布逐渐接近于实际类别的 one-hot 编码，就完成了模型训练。

2.3.2 深度卷积神经网络

卷积神经网络的性能不仅受网络结构本身影响，也会受到数据的影响，数据量越大，标注的越准确，则通常网络可以学习到更多深层特征，具有更好的泛化性与鲁棒性。2009 年斯坦福大学教授李飞飞团队发布了 ImageNet 数据集，并基于 ImageNet 举办了数次 ILSVRC 竞赛，大批量的训练集为性能更好的模型提供了数据基础，由此诞生了众多性能优异的卷积神经网络。上文中的 AlexNet 就是 2012 年 ILSVRC 图像分类任务的冠军网络，此后围绕着 ILSVRC 竞赛，诸多结构更复杂，性能更优异的卷积神经网络被提出，因其层数众多，所以被称作深度卷积神经网络。

VGG 是是由牛津大学计算机视觉组于 2014 年提出的深度卷积神经网络[38]。VGG 结构沿用了 AlexNet 简明的结构设计，前五层是卷积层，之后是三层全连接层。不过 VGG 中只使用了 3*3 卷积核，将一个大卷积核分解为多个小卷积核，是 VGG 的重要创新点。一个 7*7 的卷积核的感受野范围与三个 3*3 卷积核的感受野相同，但对于输入为 C 通道，输出为 C 通道的特征图，使用 7*7 卷积核的需要的参数数为$49C^2$，而连续使用 3 个 3*3 卷积核所需的参数数为$27C^2$，降低了模型参数量，使模型训练更快。此外使用多个小卷积核代替大卷积核，可以加入更多的激活函数，从而更好的去拟合非线性关系。

同一年的 GoogLeNet 提出了 Inception 结构[39]，让输入经过多个通道的卷积再合并，Inception 的创新点主要有两个：使用 1*1 的卷积核进行降维及使用多尺度卷积运算再聚合特征。1*1 卷积核可以在保持感受野的同时降低通道数，从而起到数据降维的作用，在一些卷积网络中就不使用池化，而通过 1*1 卷积进行降维，以减少图片空间维度上的信息损失；此外与 VGG 使用多个小卷积核的好处相同，通过添加 1*1 卷积可以加入更多的激活函数，提高网络的非线性拟合能力。使用多个尺度的卷积核做分支，以其求和为输出，可以提取到不同尺度的特征，使网络对不同尺度特征的学习能力更强。

除 Inception 结构外，GoogLeNet 另一个巨大贡献是提出了批归一化。如下图所示，对特征信息的原分布，当其通过激活函数 f(x) = tanh(x)，仅中间段的函数输出对输入变化比较敏感，当输入值过大或过小时，tanh(x)的输出趋近于 1 或-1，此时即使输入产生了较大的变化，因为激活函数特性，输出也只是产生了微小的改变。将输入的图像分为多批，对每一批进行批标准化，可以使得新

的分布更符合数据的真实分布，保证模型的非线性表达能力，加速模型收敛。

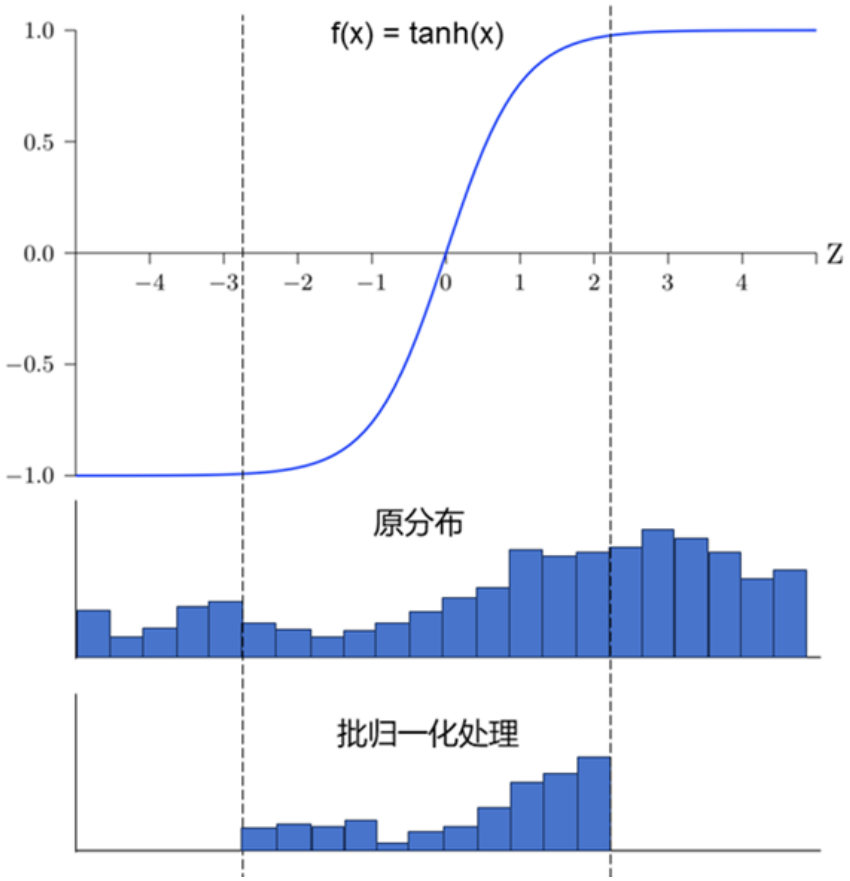


图 2-6 使用批归一化处理优化样本分布

Figure 2-6 Optimizing sample distribution using batch normalization

以上是一些经典深度卷积神经网络模型，其中使用 1*1 卷积核降维、批标准化等设计思想，至今仍被各卷积神经网络沿用与进行模型改进。之后提出的深度卷积神经网络有诸如 DenseNet[40]这类朝着层数更多、结构更复杂方向发展的，也有 MobileNet[41]、ShuffleNet[42]这类向轻量化网络，兼顾速度与精度。即便今天最先进的神经网络已能在 ImageNet 等数据集上取得极高的准确率，但深度卷积神经网络的轻量化、泛化性、可解释性等问题，依旧是需要大量研究与突破的关键点。

2.4 基于深度学习的目标检测算法

基于深度学习的目标算法从模型结构上可以分为双阶段目标检测算法与单阶段两种，双阶段算法先通过 Selective Search 等方法产生候选框，再对各候选框进行特征学习与检测；单阶段算法将图像分为 n*n 份后直接送入网络处理。通常双阶段目标检测算法会因产生候选框而训练及测试时间长于单阶段目标检测算法，但准确率也会高一些。下文将通过介绍一些单阶段及双阶段目标检测的经典模型，阐明其处理流程及设计思想。

2.4.1 双阶段目标检测算法

卷积神经网络在分类任务上的优异表现，也让人们开始思考能否将其用于其他任务。2014 年 Ross Girshick 等人提出的 RCNN 首次将卷积神经网络用于目标检测任务，将 PASCAL VOC 数据集检测准确率从 35.1%提高到了 53.7%，让目标检测由此前的手工提取特征转向卷积神经网络的研究。RCNN 在 AlexNet 的基础上进行改进，首先通过 Selective Search 算法，基于图像中的色相、纹理等信息产生约 2000 个推荐区域，将其变换到 227*227 的尺寸后送入网络。经过前五个卷积层提取图像特征后，一个分支使用两个全连接层及 SVM 分类器进行类别的预测，另一个分支进行目标框位置的预测，结合两分支输出目标检测框与类别信息。

RCNN 前的图像分类模型使用交叉熵等分类函数损失函数训练模型，进行类别预测，RCNN 通过加入位置预测的分支，使用 Bounding box 回归损失训练模型，来让模型具有预测目标框位置的能力，实现目标检测。如上图所示，对 Selective Search 产生的目标框 P，应使其通过模型后的预测框 G^尽可能接近于目标的实际选框 G，选框的信息使用列表{x, y, w, h}表示，其中 x、y 表示选框中心点的横纵坐标，w、h 表示选框宽高。模型预测的偏移量应满足：

$$\hat{G}_t = P_s d_t(P) + P_t \qquad t = x\ or\ y, s = w\ or\ h \tag{2-15}$$

$$\hat{G}_s = P_s exp\,(d_s(P)) \qquad s = w\ or\ h \tag{2-16}$$

上式中 d(p)表示模型对待处理的目标框 P 预测的 x、y、w、h 变化量，其中d_x与d_x是横纵方向上位移相对于选框 P 的的系数，d_w与d_h是选框 P 宽高的缩放系数，取 e 的指数以保证其为正值，由该式，可求得模型应预测的偏移量 O：

$$O_t = (G_t - P_t)/P_s \qquad t = x\ or\ y, s = w\ or\ h \tag{2-17}$$

$$O_s = log\,(G_s/P_s) \qquad s = w\ or\ h \tag{2-18}$$

RCNN 通过 Selective Search 产生推荐区域后，需要将其变为 227*227 尺寸，这是因为网络的全连接层要求有固定尺寸输入，但粗暴的将不同尺寸，宽高比的推荐框变换为固定尺寸会很大程度的破坏图像特征。为解决此问题，何凯明等提出了 SPP 结构，SPP 将 RCNN 原固定感受野的池化替换为几个固定输出尺寸的全局池化操作，从而无论输入的图片尺寸是多少，通过 SPP 都可以得到固定尺寸的输出，而使用多个尺度的池化可以提取到图片多尺度特征，丰富特征图语义信息。

通过 SPP 结构，RCNN 不再要求 Selective Search 算法产生的图片输入检测网络前必须变换到固定尺寸，从而提高了检测准确率。但对每张图片，模型需处理其产生的大量推荐框，极大的降低了模型的时间性能。针对此问题，Fast RCNN 将所有图片先输入卷积层提取特征，之后在特征图上通过 Selective

Search 算法产生推荐框，实现了模型端到端的结构，极大的提升了模型的时间速度。除此外，Fast RCNN 还提出了相较于 SPP 更快的 RoI 池化。先前的目标检测模型使用 Bounding box 回归损失函数及分类损失函数进行类别预测及检测框位置预测，但这两个孤立的损失可能存在冲突，而在优化一方面性能的同时降低了另一方面的性能。Fast RCNN 中使用了多任务损失函数以平衡网络的分类性能与定位性能。

Faster RCNN 在 Fast RCNN 的基础上，继续针对网络的时间性能进行改进，将产生推荐框的 Selective Search 算法改为全卷积结构的 RPN 网络。RPN 通过滑动窗口在每个 Anchor 上产生数个不同尺寸宽高比的预选框，之后通过两个卷积核分别对预选框进行类别预测与定位预测，相较于基于传统图像特征提取的 Selective Search 算法，基于固定位置锚点做卷积运算的 RPN 网络极大的提升了网络速度。

2.4.2 单阶段目标检测算法

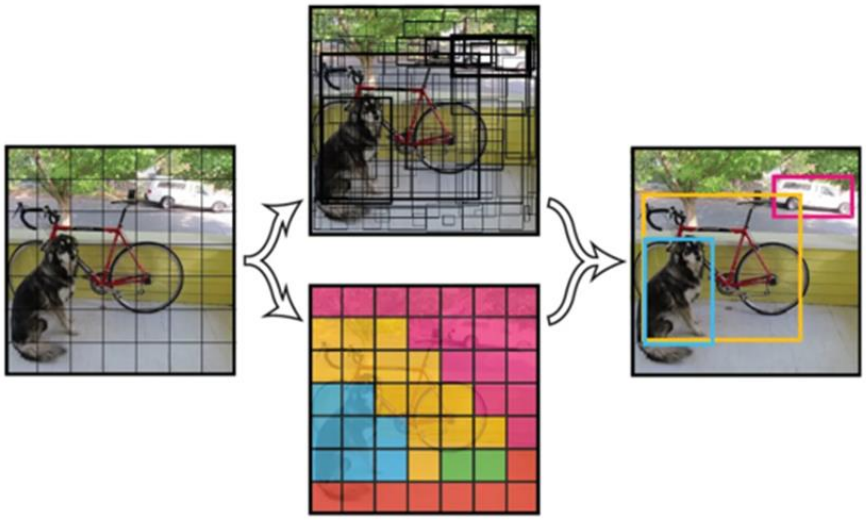


图 2-7 双阶段与单阶段目标检测流程

Figure 2-7 The flow of two-stage and single-stage object detection

2015 年 Joseph Redmon 等人提出了首个单阶段的目标检测模型 YOLOv1，开启了单阶段目标检测算法的研究热潮。双阶段检测模型通常使用单独的一个网络结构去产生数个尺寸，长宽比不同的目标框，单阶段检测模型通过将图片划分为几个网格或使用 Anchor，省去了产生预选框的过程，实现了更快的检测速度。如上图所示， YOLOv1 通过将整张图片划分为 7*7 的网格，每个网格产生两个 Bounding box，目标框与哪个网格的 IoU 值最大，就使用该网格的 Bounding box 预测此目标。YOLOv1 使用了损失函数：

$$L = \lambda_{coord}\sum_{i=0}^{s^2}\sum_{j=0}^{B}1_{ij}^{obj}[(x_i-\hat{x_i})^2+(y_i-\hat{y_i})^2$$
$$+\lambda_{coord}\sum_{i=0}^{s^2}\sum_{j=0}^{B}1_{ij}^{obj}\left[\left(\sqrt{w_i}-\sqrt{\hat{w_i}}\right)^2+\left(\sqrt{w_i}-\sqrt{\hat{h_i}}\right)^2\right]$$
$$+\sum_{i=0}^{s^2}\sum_{j=0}^{B}1_{ij}^{obj}\left(C_i-\hat{C_i}\right)^2+\lambda_{noobj}\sum_{i=0}^{s^2}\sum_{j=0}^{B}1_{ij}^{noobj}\left(C_i-\hat{C_i}\right)^2$$
$$+\sum_{i=0}^{s^2}1_{i}^{obj}\sum_{c\in classes}(p_i(c)-\hat{p_i}(c))$$

（2-19）

该损失函数预测框的坐标误差，有无包含物体的置信度误差以及网格预测类别的误差三部分组成。λ_{coord}与λ_{noobj}分别表示损失函数中坐标预测及该网格不属于预测目标两个分量的系数，S 表示将图片划分为 S*S 的网格，B 表示需预测的目标框个数，公式中1_{ij}^{obj}表示第 i 个网格是否负责预测第 j 个目标框，满足条件时取 1，否则取 0；1_{ij}^{noobj}与之相反，表示网格是否不负责预测此目标框。考虑到相同的 w 与 h 偏移量对大目标的影响小，而对小目标的影响大，式中使用了$\sqrt{w}$及$\sqrt{h}$去表示这个关系。

因 YOLOv1 的每个网格只有两个选框负责预测，当图中存在多个位置接近的目标时，模型可能会漏检或检测结果偏差过大。YOLOv2 仿照 Faster RCNN 引入了 Anchor Boxes，且优化了位置预测的损失函数。当时大多数的目标检测模型，如 Faster RCNN 是预测目标框与预测框中心横纵坐标的距离，但针对图像中位置、尺寸各不相同的目标，坐标偏差距离分布范围较广，直接预测偏移量的话模型可能需要较长时间才能收敛。YOLOv2 改为预测 Bounding box 中心相对于对应网格左上角位置的偏差，预测公式为：

$$b_t = \sigma(d_t)+c_t \qquad t = x\ or\ y, s = w\ or\ h \qquad (2\text{-}20)$$
$$b_s = P_s exp\,(d_s) \qquad s = w\ or\ h \qquad (2\text{-}21)$$

式中 b 表示网络预测出的 Bounding box，c_t表示该选框对应网格左上角的横纵坐标，σ函数将位移量约束在了 0 到 1 之间，使网格负责预测的目标框中心位于网格内。

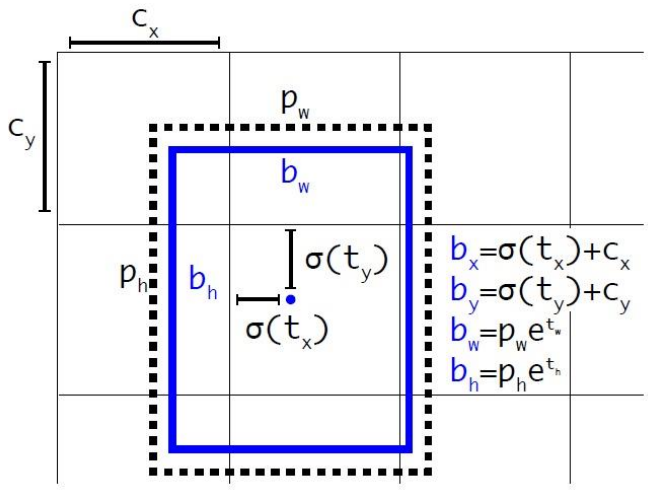


图 2-8 YOLOv2 基于网格尺寸的损失函数优化

Figure 2-8 YOLOv2 loss function optimization based on mesh size

之后提出的各版本的 YOLO 进行了损失函数优化、多尺度融合、网络轻量化等多方面的改进，前不久 Chien-Yao Wang 等人刚刚提出了最新的 YOLOv9 网络，因 YOLO 网络易于修改部署及优异的检测性能，其也被广泛应用于现实中的各类检测任务。

2.5 本章小节

本章介绍了文章使用的相关技术的技术背景，包括传统图像处理算法中的几何变换、高斯滤波、灰度阈值分割及形态学处理算法，自监督与有监督的对比学习算法，卷积神经网络 AlexNet、VGG 及 GoogleNet，经典两阶段目标检测网络 RCNN、Faster RCNN 与单阶段目标检测 YOLO 网络。

第三章 基于改进 ResNet18 模型的电积镍板分类

3.1 引言

企业生产的电积镍板，根据其表面缺陷情况需将其划分为合格板、不合格板、及表面只有大面积水渍等可烫洗掉的缺陷，需经过二次烫洗的镍板。目前行业内对镍板分类的方法为人工目检，需要检测员现场判定每块镍板品级、码放、再运输到产品车间，且因为不同质检员的评判标准不同、现场作业环境和质检员的疲劳状态影响，容易导致判别错误。卷积神经网络通过学习图像特征，建模表征图像的代表特征，随着 ImageNet 等大数据集的提出及计算设备算力的提升，卷积神经网络的精度与速度性能大幅增长，逐渐代替传统人工目检方法，被广泛用于工业界各类产品分类。使用卷积神经网络，对电积镍板进行分类，可以避免因质检员疲劳及个人判定标准不同产生的人为误差，配合图像采集系统，实现电积镍板分拣的智能化、自动化。

电积镍板图像来源于检测车间现场的图像采集系统，受现场环境等因素影响，存在以下问题需要解决：

1）生产现场作业环境复杂，受环境光、图像噪音等因素影响成像，模型很有可能判断错误。如下面两张镍板表面水渍与污渍缺陷较多，属于需要进行二次烫洗的镍板，但左边的图片因环境光影响整体偏暗，导致模型将其错误判定为不合格镍板。



图 3-1 偏暗的需要二次烫洗镍板被模型错误判定为不合格板

Figure 3-1 The darker nickel plate is wrongly judged by the model as unqualified plate

2）因生产的镍板多数为合格板，仅少量为不合格板与需要二次烫洗的镍板，训练集中各类镍板分布不均衡，模型学习到的合格板类别特征较多，不合格板与需要二次烫洗的镍板特征较少，导致模型在不合格板与需要二次烫洗的

镍板两个类别上准确率较低。

针对电积镍分类任务存在的问题，本文提出了基于特征图层全局特征与高频局部特征、进行特征图层间自适应特征融合的残差结构。具体的，使用添加最大池化操作的改进的 SE+模块，提取特征图中的局部高频信息，让模型在图片较暗的情况下也能学习到较多的镍板板面特征。通过图像滤波、色相变换等数据增强手段扩充样本数，提升模型对过曝、过暗、混入噪音的图像的判别能力，均衡各类样本分布。使用改进后的 ResNet18 模型进行实验，在电积镍分类任务中达到了 90.85%的准确率，较原 ResNet18 模型提高了 4.93%的准确率。在对比实验中效果优于 AlexNet、SqueezeNet1_0[43]等分类网络，优于有监督对比学习的对比学习网络。

3.2 针对电积镍分类问题的改进 ResNet18 模型

ResNet 是由残差模块组成的图像分类网络，针对不同的分类任务，ResNet 提供了 ResNet18、ResNet101、ResNet152 等不同大小的 ResNet 网络[44]。因电积镍板图片样本相较于 ImageNet 等大数据集样本少、分类类别少、类别特征明显，本文使用规模最小的 ResNet18 模型进行实验。ResNet18 主要由四个卷积模块组成，每个卷积模块含有两个残差模块，在每个残差模块中输入经过两次 3*3 的卷积运算后与原输入相加。图片输入经过每一层后尺寸缩小两倍，通道数增加两倍。以 224*224*3 的图片输入为例，图片先通过一个步长为 2 的卷积核变为 112*112*64，再经过下采样变为 56*56*64，通过四个卷积模块，图片尺寸缩小 2*4 倍，通道增加 2*4 倍，得到 7*7*512 的输出，经过全局平均池化得到 512 的一维向量，最后通过全连接层输出维度为类别数的一维向量，表示输入图片对应各类别的概率。

ResNet 中提出了残差模块，此前的卷积神经网络通常采用一层接一层的多层结构，网络越深，深层图像中每个像素覆盖的原图感受野越大，越能拟合出复杂的关系式，表征更深层的语义特征，但因为反向传播的链式法则，当网络层数过深时，很容易出现梯度消失或梯度爆炸，导致网络退化。实际上如果前面的网络已拟合了图像特征的函数关系，此时再继续加深网络，之后的网络就是在学习恒等映射。但让网络去拟合恒等映射函数 H(x) = x 比较困难，可能会导致深层网络难以训练。如果把网络的输出设计为 H(x) = F(x) + x，网络需要学习的映射就转换为学习残差函数 F(x) = H(x) – x，只需要 F(x)=0，就构成了一个恒等映射 H(x) = x，显然拟合残差 F(x)，使其等于 0 对模型来说更加容易。残差结构通过将原来的输出 H(x)与输入 x 相加，使深层网络更容易去拟合成需求出的目标函数，捕捉到网络小的扰动。

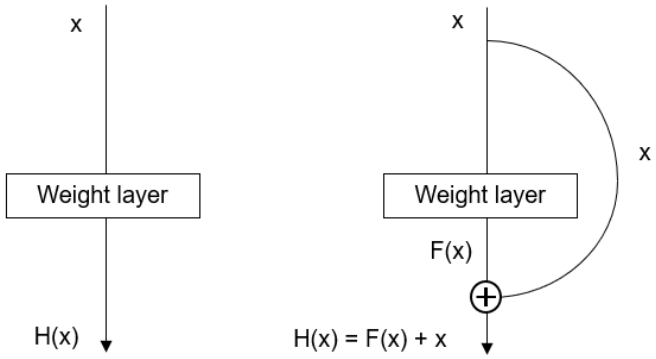


图 3-2 残差模块的改进

Figure 3-2 Improvement of residual module

从特征图来看，残差模块将卷积后的特征图与原特征图进行融合，在卷积操作后加入原特征图信息，以避免网络性能退化时损失大部分有效信息。卷积神经网络通过缩小图片尺寸，增加通道数以在尽可能少损失图像特征信息的前提下减少计算量，提升网络速度。越深层的网络，特征图的层数越多，特征信息在不同层上的分布方差越大。观察电积镍三色通道的图像，可以发现不同通道上缺陷部分的特征信息也有所不同，中间的绿色通道较另外两个通道包含更多缺陷的细节纹理特征。类似于彩色通道，在特征图中，缺陷也会在各层上表现缺陷信息残差结构将卷积后的特征图与原输入直接相加，保留输入信息以缓解网络退化，但不同通道上包含的有效信息量不同，直接相加可能会造成无用信息冗余，而有效的特征信息产生损失。

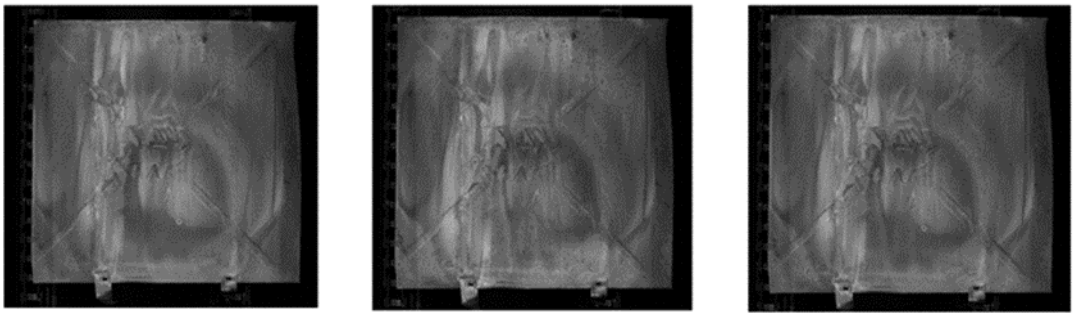


图 3-3 电积镍板三色通道图片

Figure 3-3 Three-color channel picture of electrodeposition nickel plate

针对卷积池化操作未注意到特征图中不同通道包含的有效信息量不同造成的特征信息损失问题，SE 模块通过对不同层做加权拼接，以表示特征图不同通道对目标特征提取的重要性[45]。对大小为 H*W*C 的特征图，SE 模块首先通过全局平均池化，基于图像特征信息得到各层粗略的权重，接着通过两个全连接层，首先经过第一个全连接层及 ReLu 激活函数，降低特征图通道数以减少计算量，再通过一个全连接层及 Sigmoid 激活函数，计算出各层归一化权重。

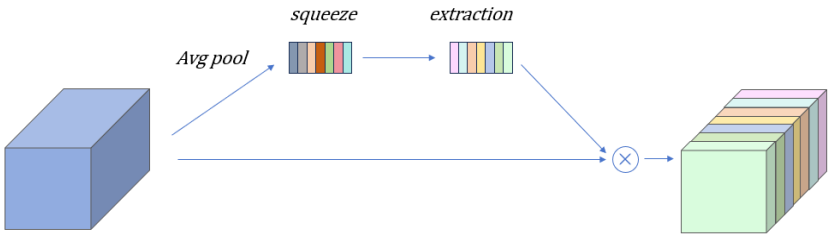


图 3-4 SE 模块结构

Figure 3-4 SE module structure

SE 模块通过全局平均池化，基于各图层整体像素均值决定其在特征提取中的权重。但在一些图层上，可能其局部有重要的特征信息，却因为整图整体特征相较于其他层不明显而被分配一个较低的权重，造成信息损失。镍板板面部分相较于背景较亮，因此在特征图中的像素值也相对较高，使用最大池化操作可以从图像中提取较多板面特征，剔除背景信息。基于此设计了改进的 SE+模块，在 SE 模块中增加一个最大池化分支，以提取位于整体权重较小的特征图层中的高频分量，改进后的 SE+模块结构为：

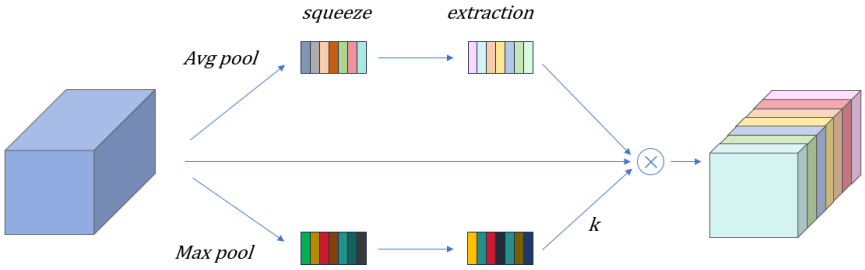


图 3-5 改进后的 SE+模块结构

Figure 3-5 Improved SE+ module structure

其公式表达为：

$$z_{ca} = F_{sq}(u_c) = \frac{1}{H*W}\sum_{i=1}^{H}\sum_{j=1}^{W} u_c(i,j) \quad (3\text{-}1)$$

$$z_{cm} = F_{sq}(u_c) = max\sum_{i=1}^{H}\sum_{j=1}^{W} u_c(i,j) \quad (3\text{-}2)$$

$$s_a = F_{ex}(z_a, W) = \sigma\big(W_2\delta(W_1 z_a)\big) \quad a = ca\ or\ cm \quad (3\text{-}3)$$

$$V = s_{ca} * U + k * s_{cm} * U \quad (3\text{-}4)$$

上式中z_{ca}表示对各层特征图做平均池化的输出结果，z_{cm}表示对各层特征图做最大池化的输出结果，s_{ca}与s_{cm}表示通过 Squeeze 操作计算出的基于各层平均像素值及最大像素值的图层权重。对输入特征图U，通过 squeeze 及 excitation 操作计算各层基于全局特征与局部高频特征分量的权重s_{ca}与s_{cm}，将其与特征图

U 相乘，因相较于局部高频分量仍是全局特征较为重要，使用参数 k 调节局部高频分量对特征图层权重的影响，实验中 k 取 0.3 时达到了最好的效果。

使用 SE+模块对残差结构进行改进，下图为改进后的残差结构。输入通过 residual 模块后，由 SE+模块，计算出特征图各层的权重，基于各层特征信息的重要性与输入加权相加，因最大池化的影响局部位置的高频分量得以保留，再通过一个卷积层将其与邻近信息进一步进行信息融合，丰富其特征，提升模型对特征的识别能力。



图 3-6 改进后的残差模块结构

Figure 3-6 Improved Residual module structure

3.3 实验设计和结果分析

3.3.1 数据集与实验环境

实验使用的数据集为现场采集的电积镍图片组成的电积镍分类数据集，数据集有 1423 张电积镍板图像，包括 792 张合格板、248 张需二次烫洗的镍板、433 张不合格板，按 8：1：1 的比例划分训练集，测试集与验证集，分别包含 1139、142、142 张各类电积镍板图片。

实验基于 Ubuntu 系统完成。操作系统为 Ubuntu 20.04.4 版本，编程语言使用 Python3.10.9，使用深度学习框架 Pytorch2.1.2，配备 Nvidia 推出的并行运算架构 CUDA12.1 版本进行 YOLOv5 模型及其改进模型搭建。使用 GPU 加速库 CuDNN 8.9.2，加速深度学习运算。CPU 使用 Intel Xeon Platinum 8358P 处理器（频率 2.60GHz），GPU 使用英伟达 GeForce RTX 3090，显存 24GB。实验环境配置如下表所示:

表 3-1 实验环境配置

Table 3-1 Experimental environment configuration

模块名称	版本配置
操作系统	Ubuntu 20.04.4
编程语言	Python 3.10.9
深度学习框架	Pytorch2.1.2
CPU 中央处理器	Intel Xeon Platinum 8358P
GPU 图形处理器	NVIDIA GeForce RTX 3090
CUDA	12.1
CUDNN	8.92

3.3.2 评价指标

1. 准确率、查准率与召回率

在分类任务中，模型的预测会产生预测正确的正负样本 TP 与 TN，预测错误的正负样本 FP 与 FN 四种结果。准确率为预测准确的样本数占总样本数的比例。其表达式为：

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \tag{3-5}$$

查准率为模型预测正确的正样本占所有被模型预测为正的正样本的比例：

$$Precision = \frac{TP}{TP+FP} \tag{3-7}$$

召回率为预测准确的正样本占原正样本的比例：

$$Recall = \frac{TP}{TP+FN} \tag{3-8}$$

2. PR 曲线

对不同的类别阈值会产生不同的准确率与召回率，以召回率作为横坐标，准确率作为纵坐标轴绘制的曲线就是 PR 曲线。通过 PR 曲线可以直观的分析各阈值下模型的准确率及召回率情况，通过平衡点获得模型准确率及召回率综合最优的结果。如果一个模型的 PR 曲线完全被另一个模型的 PR 曲线覆盖，则可以认为后一个模型的性能优于前者。

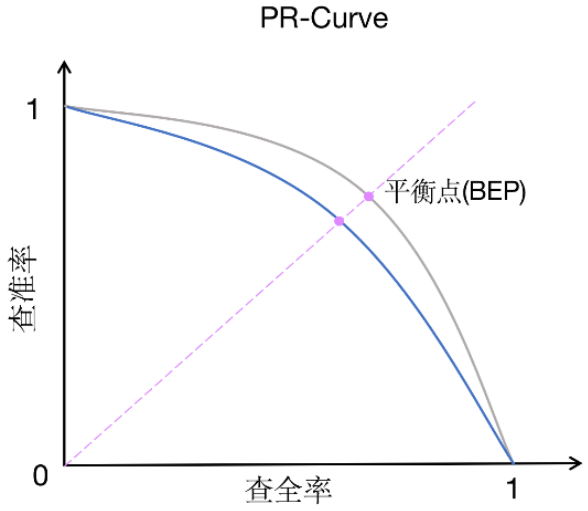


图 3-7 PR 曲线

Figure 3-7 PR curve

3.3.3 基准实验与消融实验

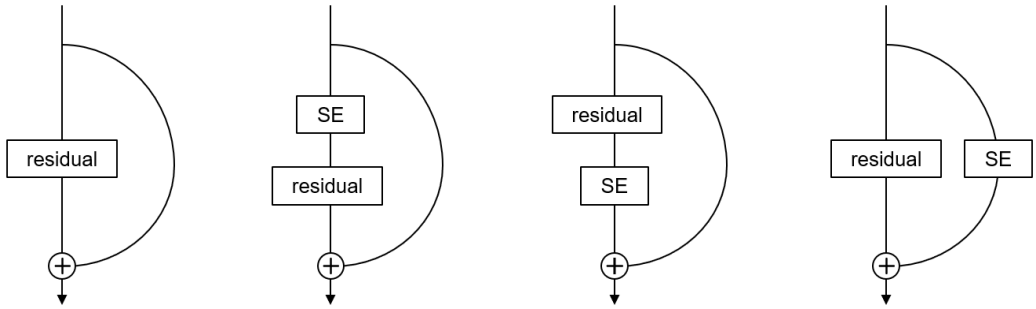
实验使用电积镍分类数据集，训练 100 轮次，图片的 batch size 设为 8，优化器采用 SGD，初始学习率为 0.01，权重衰减系数为 1e-4，使用交叉熵损失函数进行网络优化。原 ResNet18 网络与添加 SE 模块的 ResNet18 效果对比如下：

表 3-2 加入 SE 模块效果对比

Table 3-2 Add SE effect comparison

网络	Acc/%
原 ResNet18 模型	85.92
添加 SE 模块的 ResNet18 模型	**88.73**

可以观察到使用 SE 模块后模型的精度有了较大的提升，相较于原来的 ResNet18 网络提升了 2.81%的准确率。实验进行了在残差结构中多个不同位置添加 SE 模块的尝试，其中将 SE 模块加于 Residual 操作后取得了最好的实验效果。



(a) (b) (c) (d)

图 3-8 在残差模块不同位置添加 SE 模块

Figure 3-8 Add SE effect comparison in different positions

表 3-3 不同位置添加 SE 效果对比

Table 3-3 Add SE effect comparison in different positions

SE 添加位置	Acc%
无添加[(a)]	85.92
residual 模块前[(b)]	88.03
residual 模块后[(c)]	**88.73**
原输入上[(d)]	87.32

在各位置添加 SE 模块，模型的准确率均有所提升。分析是因为 SE 模块分配了对各特征图层的权重，让模型更好的提取到了图像的特征信息。基于效果最好的在 residual 模块后添加残差结构，使用 SE+模块对网络进行改进，进行了多个控制最大池化分类权重的系数 k 取值的实验，实验结果如下：

表 3-4 不同系数 k 的实验

Table 3-4 Experiments with different k

池化权重系数 k 取值	Acc%
0	90.14
0.3	**90.85**
0.6	87.32
0.9	85.92

当 k 取 0.3 时，模型达到了最好的准确率，分析是因为通过在 SE 模块中添

加最大池化分支，模型学习到了更多与背景相比像素值较高的镍板板面特征，而提升了分类准确率。当 k 取值较大时模型的准确率相对较低，可能是因为相较于局部高频特征，图层中整图的特征更为重要，因此最大池化分量的系数 k 取值应比较低，避免对全图特征提取产生较大影响。



图 3-9 使用数据增强平衡样本分布

Figure 3-9 Balanced sample distribution by data augmentation

此外，本文还通过旋转、高斯滤波、亮度调整进行数据增强，将数据由原来的 1423 张镍板图像扩充到 3000 张，其中各类别镍板图像均有 1000 张，以使其分布均衡，继续以 8：1：1 划分训练集，验证集与测试集，实验结果如下：

表 3-5 数据增强实验

Table 3-5 Experiments with data augmentation

数据集	Acc%（好板）	Acc%（烫洗板）	Acc%（不合格板）	Acc%（总）
原数据集	**97.23**	72.00	90.70	**90.85**
数据增强后	95.00	**78.00**	**93.00**	88.67

虽然使用数据增强平衡各样本分布后总的准确率有所降低，但在二次烫洗板与废板这两类上的准确率有所提升。未使用数据增强时更高的准确率因为在合格镍板这一类别上的准确率较高，但训练集中合格镍板的数量本就远多于另外两种镍板，导致模型容易将烫洗板与不合格板错检为烫洗板。通过数据增强实现

样本分布均衡，可以提高模型在二次烫洗板与废板这两个在原分布中占比较少的类别上的准确率。此外生成的图片也能模拟现场环境光、图像噪声的干扰效果，提升模型的鲁棒性。

3.3.4 与其他分类模型的对比实验

使用经典分类网络 AlexNet、VGG、SqueezeNet1_0 进行对比实验，结果如下：

表 3-6 和其他模型的对比实验

Table 3-6 Comparative experiments with other models

网络	Acc/%
改进的 ResNet18	**90.85**
AlexNet	83.10
VGG	84.51
SqueezeNet1_0	85.21

作为早期提出的卷积神经网络 AlexNet 与 VGG，尽管其结构简单，参数相对较少，仍有 83.1%及 84.51%的准确率，由此可见卷积网络强大的特征提取能力。SqueezeNet 作为轻量化模型也达到了 85.21%的准确率，与原 ResNet18 网络准确率接近。

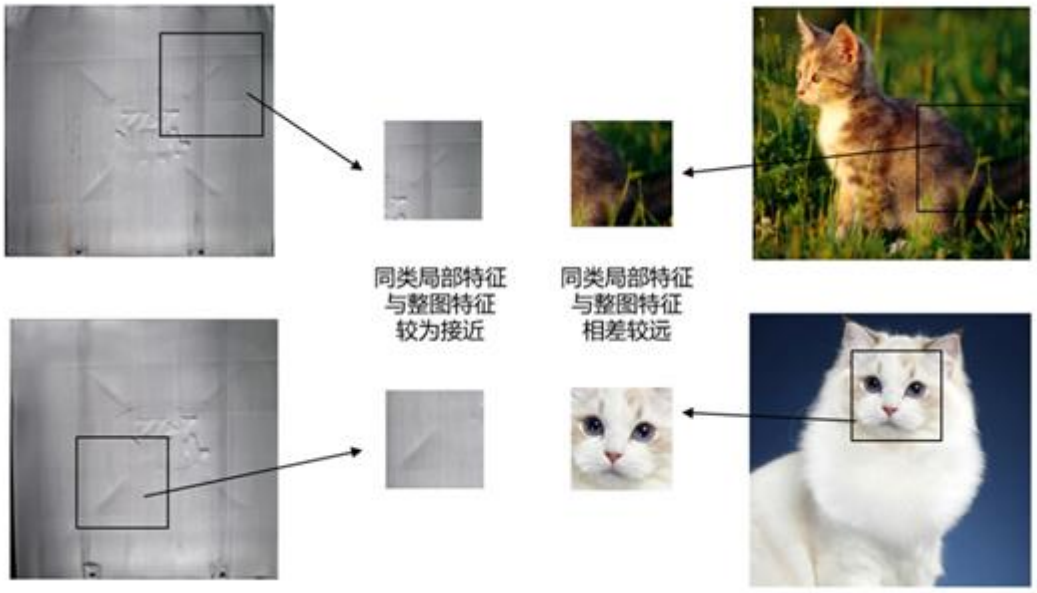


图 3-10 镍板同类局部特征与全图特征接近

Figure 3-10 Local features of nickel plate are close to the global features

除使用基础的卷积神经网络进行分类外，实验还使用了有监督的对比学习方法进行分类。有监督的对比学习改进了对比学习损失函数，通过类别标签，使属于同类别的样本不参与度量计算，避免了同类中离群点的产生。在对比学习中，因电积镍板图像的特征，由其图像产生的样本对与同类的整张图片间也

应有较多的相似特征。因此尝试通过添加交叉熵损失的有监督对比学习进行实验，在修改损失函数后模型的准确率有所增长，但相较于基础分类网络差距过大，推测是因为对比学习需要较多的样本，而电积镍样本数较少，不适合使用对比学习方法。

表 3-7 监督对比学习实验

Table 3-7 Supervised constrative learning experiments

网络	Acc/%
监督对比学习	69.01
监督对比学习+分类损失函数	69.72

3.4 本章小节

针对电积镍分类任务中现场环境复杂、影响成像的因素较多、各类样本不平衡等技术难题，本文设计了一种基于 SE+模块优化后的残差网络。通过在 SE 模块中添加最大池化分支提取镍板特征图中的高频分量，使用改进后的 SE+模块对 ResNet18 网络残差结构进行优化，并与经典图像分类网络 AlexNet、VGG、SqueezeNet 及监督对比学习分类网络进行对比实验，优化后的 ResNet18 网络精度显著优于其他网络。

第四章 基于改进 YOLOv5s 模型的电积镍板缺陷检测

4.1 引言

在电积镍板的生产过程中，含有镍盐和其他添加剂的溶液，在电解槽内电解，通过电流的作用让金属镍沉积到工件表面，形成电积镍板。但因电解反应不稳定、运送过程中人工操作不当等因素，电极镍板表面可能会出现水渍，凸起疙瘩等缺陷。因电解液成分复杂，化学反应不受人为控制。导致电积镍表面缺陷同类别间特征差别过大、尺寸不均、且可能出现在镍板上的任何位置。如下图中的污渍缺陷有时呈密集的点状，有时呈条形的波纹状，对此类缺陷特征信息，先前的图像分类模型很难基于全图提取到其典型特征。

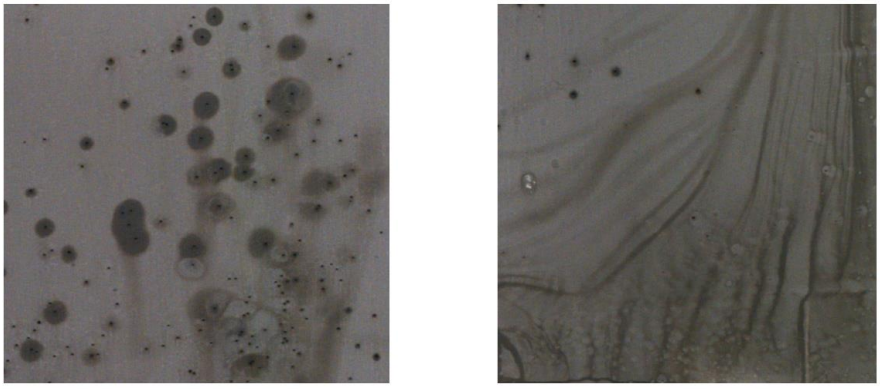


图 4-1 特征不同的污渍缺陷

Figure 4-1 Different characteristic of stain

此外，分类模型只是简单的将镍板分为合格板、需要二次烫洗板与不合格板，但在不合格板中，有时缺陷可能只占板面的一小部分，而大部分板面并没有缺陷。对缺陷较少的镍板，企业希望切除缺陷部分作为废板，剩余部分作为合格板输出（详见于 5.3.2 划线算法）。此时只靠分类模型就无法满足企业的需求了，而需要精确的检测各个缺陷，再对镍板进行剪切。YOLO 模型作为最早被提出的单阶段目标检测模型之一，因其模块化的结构设计、优异的速度与精度性能，一经提出后就被人们投入了大量的研究与应用，各种新版本的 YOLO 模型层出不穷，其也被广泛用于各类工业缺陷检测任务[46-58]。

对电积镍表面缺陷检测问题，存在以下难点：

1）在多数用于深度学习的数据集中，通常目标是图片的主体，会在图片相对较为固定的位置出现，模型除了目标特征外也可以靠位置特征检测到目标。但镍板尺寸较大，缺陷分布位置广泛，特别是对一些尺寸比较小的缺陷，其可

能出现的位置坐标覆盖了整个板面，模型需要对缺陷大量位置特征进行学习，具有对目标较强的的定位能力。

2）不同缺陷尺寸分布范围较广，镍板上既有覆盖整个板面的烧板缺陷，也有只是一小点的污渍缺陷。特别是对小目标，其相较于大目标特征信息较少，且因为面积小而需要更准确的定位。模型需要学习到从大到小各尺度缺陷的特征。

针对电积镍表面缺陷检测存在的问题，本文设计了改进的 YOLOv5s 模型进行缺陷检测实验。通过在模型中添加 CBAM 模块，让模型具有空间注意力及通道注意力，以对出现在图像各位置的缺陷进行充分的学习。在 Neck 部分添加 CBAM 模块，对不同尺度的特征图进行多尺度自适应特征融合，提升模型对不同尺度特征的学习能力。改进后的 YOLOv5s 较原网络在镍板缺陷检测任务中提升了 1.06%的准确率，且优于 SSD、YOLOv7 等目标检测网络。

4.2 针对电积镍板表面缺陷改进的 YOLOv5s 模型

YOLOv5 是 Ultralytics 公司研发的第五代 YOLO 模型，针对不同数据量的任务，YOLOv5 提供了 YOLOv5n、YOLOv5s、YOLOv5m、YOLOv5l、YOLOv5x 五个版本的网络，因 YOLOv5 兼顾检测精度与速度、易于部署的优点，其被广泛用于各类缺陷检测任务。

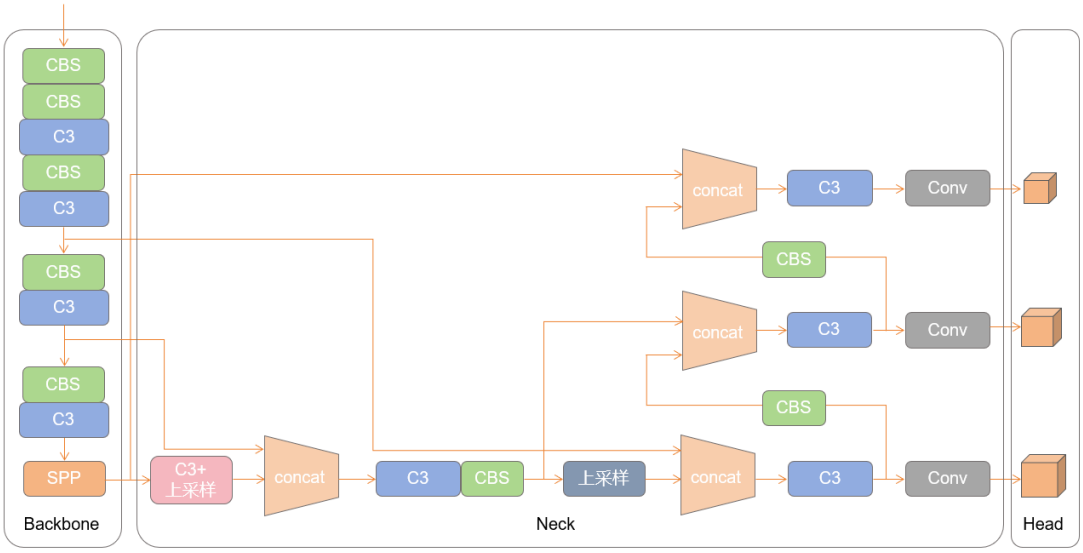


图 4-2 YOLOv5s 网络结构

Figure 4-2 YOLOv5s structure

上图为 YOLOv5s 模型的网络结构，网络包括用于多尺度特征提取的 Backbone、用于多尺度特征融合的 Neck 及用于多尺度目标检测的 Head 三部分。Backbone 部分使用 Focus、CBS、C3 等模块进行特征聚合，得到多个尺度

的特征图，Neck 部分使用上采用与拼接操作对不同尺度的特征图进行融合，Head 部分含有三个不同尺寸的检测头，完成对多尺度目标的检测。以输入 640*640*3 尺寸的图像为例，Backbone 通过卷积及下采样，得到 160*160、80*80、40*40 与 20*20 尺寸的特征图，Neck 部分选用 80*80、40*40 与 20*20 的特征图进行多尺度特征融合， Head 部分以这三个尺寸为基准进行目标检测。

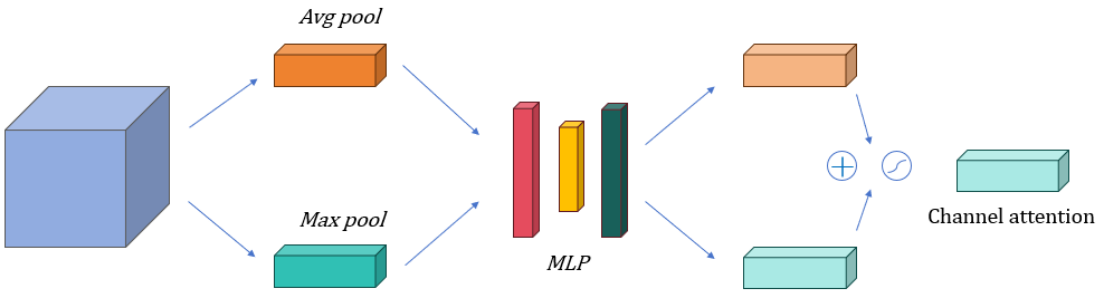
本文使用 YOLOv5s 进行电积镍板表面缺陷检测实验，且结合缺陷特征，对 YOLOv5s 进行了注意力机制及多尺度特征融合两方面的改进。

4.2.1 基于注意力机制的改进

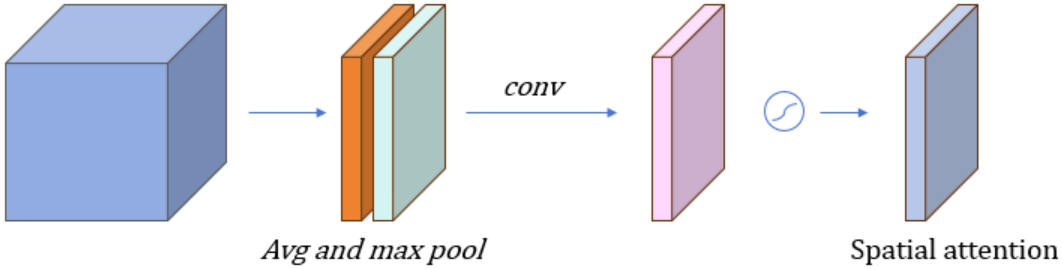
虽然相较于 AlexNet、VGG 等早期提出的神经网络，YOLOv5 网络通过 CBS、C3 等模块组建了更庞大、复杂的网络，但这些模块仍是由卷积、池化、激活函数与批归一化这些基本运算构成。因此 YOLOv5 网络可以看作是一个由更多卷积层、池化层组成的模块化神经网络。在上一章中提到卷积运算中未注意到不同层间有效特征信息量的不同，给计算出的各图层分配了相同的权重进行组合，造成了有效信息的损失。在 YOLOv5 网络中也存在相同的问题，缺乏注意力机制对层间有用信息进行更高效的提取。

相较于镍板缺陷在各图层间的不均衡分布，镍板缺陷在空间上的不均衡分布更为显著。如上图中的污渍缺陷，图片中大片区域都是合格的板面，只有一小片地方存在污渍，在进行缺陷检测时，模型应只关注污点这一小片区域的特征信息，而忽略大部分区域的合格板面信息。为此需要一种有效的注意力机制，特别是在空间位置上的注意力机制，使模型基于空间与通道两个维度对特征图层分配注意力，以更好的提取镍板图片上位置分布广泛的缺陷特征。

CBAM 模块通过通道注意力与空间注意力，使模型更加关注空间与通道中目标存在的部分，更好的提取到特征信息，提升检测精度[59]。CBAM 使用最大池化与平均池化计算通道中各图层权重，再通过多层感知机计算出模型调整后的各层自适应权重。最大池化与平均池化共用一个多层感知机以降低模型参数，加速运算。空间注意力的计算与通道注意力原理类似，通道注意力通过池化操作在空间维度上压缩图像，计算出各层的权重，空间注意力则在通道维度上进行池化操作，将多个特征图层压缩为一个图层后，计算空间上个位置的注意力权重。



(a) 通道注意力



(b) 空间注意力

图 4-3 CBAM 的通道与空间注意力机制

Figure 4-3 Channel and Spatial Attention Module of CBAM

通道注意力与空间注意力权重计算公式为：

$$M_C(F) = \sigma\left(MLP(AvgPool(F)) + MLP(MaxPool(F))\right)$$

$$= \sigma(W_1(W_0(F^C_{avg})) + \sigma\left(W_1\left(W_0(F^C_{max})\right)\right) \quad (4\text{-}1)$$

$$M_s(F) = \sigma(f^{n*n}[AvgPool(F), MaxPool(F)]) = \sigma(f^{n*n}([F^S_{avg}; F^S_{max}])) \quad (4\text{-}2)$$

上式中$M_c(F)$表示通道注意力，AvgPool 与 MaxPool 表示平均池化与最大池化，MLP 为多层感知机，σ为 Sigmoid 激活函数。将特征图通过全局池化及平均池化进行降维运算，使用多层感知机进行全连接计算，将两种池化的权重结果相加，得到各层的线性注意力权重，再经过激活函数引入非线性关系，使模型自适应为各层特征图分配注意力。$M_s(F)$表示空间注意力，首先进行通道维度上的最大池化与平均池化，得到两个特征图进行拼接， W*H*C 的特征图变为了 W*H*2 的特征图，f^{n*n}表示通过 n*n 的卷积核进行卷积运算，再通过 Sigmoid 激活函数引入非线性关系，计算出空间注意力权重。本文使用 3*3 的卷积核进行实验。

通过 CBAM 注意力机制，模型可以更好的学习到缺陷在不同图层中的有效特征，以及图片各种位置上的缺陷特征。针对颜色与板面区别较大、位置多变

的电积镍板缺陷，使用 CBAM 注意力机制对 YOLOv5s 进行改进，进行 YOLOv5s 模型不同位置添加 CBAM 模块的实验，其中添加于最大尺寸的检测头时模型取得了最好的效果。

4.2.2 基于多尺度特征融合的改进

早期提出的 RCNN、YOLOv1 等目标检测网络只使用最深度层的特征图进行检测。深层特征图的感受野较大，且大目标尺寸大，包含更多可供目标学习的特征信息，因而模型学习到的更多是大目标的特征信息，在小目标检测上表现较差。在卷积网络的各层特征图中，浅层的特征图尚未经过多个的卷积与池化操作，图像局部信息丰富，包含较多的目标位置信息，而特征信息较少。深层的特征图经过多层卷积与池化，聚合了大量特征信息，但此时目标的位置信息比较少。为了使模型检测到多尺度目标，需将多尺度特征融合，使特征图既有深层的目标特征信息，也有浅层的目标位置信息。

针对小目标、多目标检测问题，FPN[60]及 PANet[61]通过将不同尺度的特征图进行融合，使模型充分学习到浅层位置信息及深层特征信息，YOLOv5 的网络就是使用了 FPN+PANet 的结构设计。在 Backbone 中使用 FPN 构建图像自顶向下不同尺度的特征图，经过 FPN 的多层网络后，最底层的目标信息已变得非常模糊，为此 PANet 又加入了自底向上的路线，对底层的特征图进行上采样后与上层的特征图融合，从而弥补底层特征图位置信息不足的缺陷。虽然 YOLOv5 的 Neck 对不同尺度特征图使用上采样及 concat 操作进行了信息融合，但不同尺度的特征图中存在的目标特征信息量不同，对于大目标，大尺寸的特征图中可能包含更多有效特征，对于小目标，目标范围较小，此时大尺度的特征图中可能较多的是的无效特征，而小尺寸特征图中包含的特征有效率更高。因此在进行多尺度特征融合时，不应只是简单的特征组合，而应根据目标，自适应分配各特征图的权重进行加权组合。在电积镍板板面缺陷检测问题中，各种缺陷尺寸分布极为广泛，小到几平方厘米以内的污点，大到覆盖了大半个板面的烧板缺陷，对尺寸相差巨大的各类缺陷，网络须充分融合多层特征，从中提取到跨幅巨大的各尺度缺陷位置及特征信息特征，模型需具有强大的从多尺度特征间提取信息的能力。

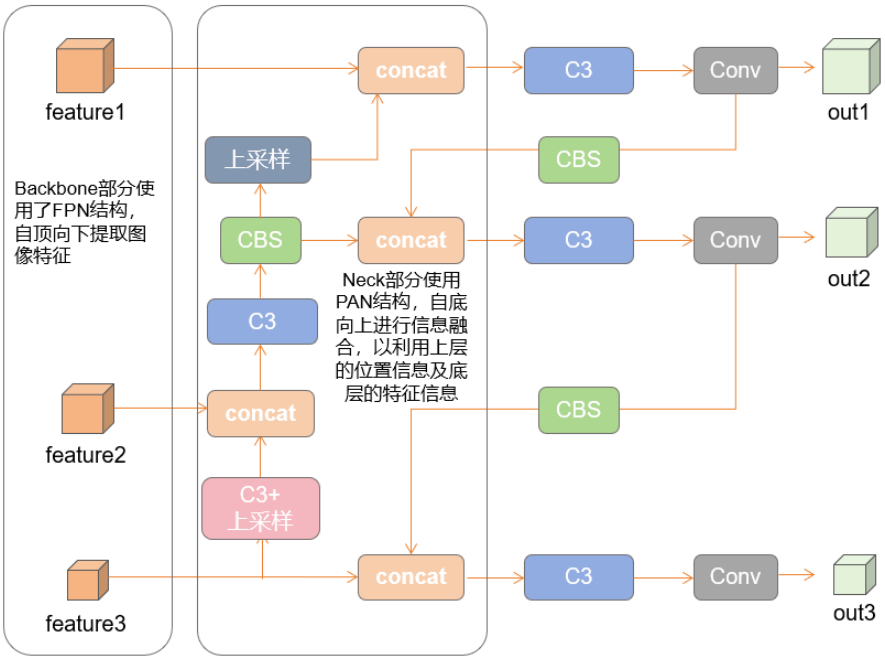


图 4-4 YOLOv5s 网络 Neck 结构

Figure 4-4 YOLOv5s Neck structure

ASFF 设计了空间特征自适应融合方法[62]。其网络结构如上图所示，通过全连接结构计算出各层特征图的权重，使用 softmax 计算归一化权重，让模型自适应分配各尺度特征图的权重，浅层位置信息与深层特征信息在多尺度特征融合过程中应占多少，从而更好的学习到多尺度目标信息。

ASFF 的特征融合公式表达如下:

$$y_{ij}^{l} = \alpha_{ij}^{l} * x_{ij}^{1\to l} + \beta_{ij}^{l} * x_{ij}^{2\to l} + \gamma_{ij}^{l} * x_{ij}^{3\to l} \tag{4-3}$$

$$\alpha_{ij}^{l} = \frac{e^{\lambda_{\alpha_{ij}}^{l}}}{e^{\lambda_{\alpha_{ij}}^{l}} + e^{\lambda_{\beta_{ij}}^{l}} + e^{\lambda_{\gamma_{ij}}^{l}}} \tag{4-4}$$

上式中$x_{ij}^{1\to l}$、$x_{ij}^{2\to l}$、$x_{ij}^{3\to l}$表示来自 Level1 到 Level3 的三个尺度的特征图，$\lambda_{\alpha_{ij}}^{l}$表示三个特征图的权重，由全连接计算得到，$\alpha_{ij}^{l}$、$\beta_{ij}$、$\gamma_{ij}$表示由 softmax 函数计算得到的归一化权重，l 表示 ASFF 的第 l 层。以 ASFF-3 为例，首先将 Level1 到 Level3 的特征图进行上采用或下采样，变换到 ASFF-3 检测所需的尺寸，得到特征图$x_{ij}^{1\to 3}$、$x_{ij}^{2\to 3}$、$x_{ij}^{3\to 3}$；使用归一化权重α^{3}、β^{3}、γ^{3} 将其加权相加，得到 ASFF-3 层的自适应融合特征。

4.3 实验设计和结果分析

4.3.1 数据集及实验环境

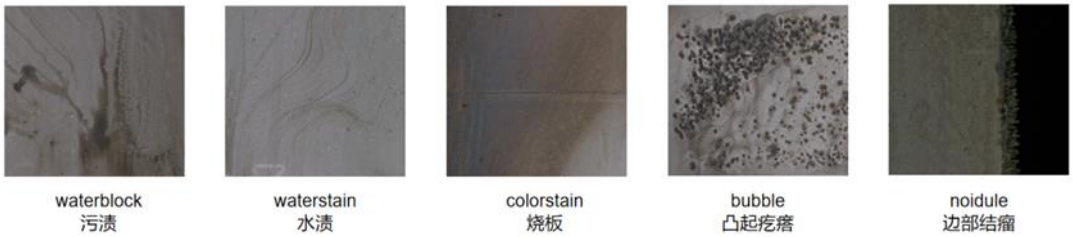


图 4-5 电积镍板标注意缺陷类型

Figure 4-5 Defect type of electrodeposition nickel plate

本文使用 Labelimg 软件，对水渍（waterstain）、污渍（waterblock）、烧板（colorstain）、边部结瘤（nodule）与凸起疙瘩(bubble)这五类电积镍板表面典型缺陷进行标注，建立电积镍缺陷数据集。数据集包括 961 张电积镍板图片，各类缺陷实例分布如下图所示，其中水渍与污渍占比较多，在 YOLO 模型实验中取得了相对较好的实验结果。

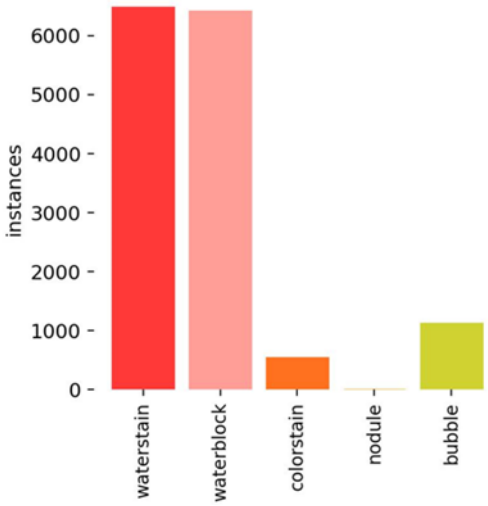


图 4-6 各类缺陷分布

Figure 4-6 Distribution of various defects

电积镍缺陷检测的实验环境与电积镍分类的实验环境相同，详见于 3.4.1。

4.3.2 评价指标

1. IoU

IoU 是目标检测中用于衡量预测框相对于检测目标的位置是否准确的评价指标，使用预测框与目标框的交集除以并集，判断其重叠程度。

$$IoU = \frac{A \cap B}{A \cup B} \tag{4-5}$$

2. mAP（mean Average Precision）与 FPS

与分类任务的准确率和召回率的定义有所不同，目标检测任务中不仅要考

虑目标被检出，还要考虑预测框的位置区域是否准确，使用目标框与检测框的交集与检测框面积的比值作为准确率，以衡量检测框是否准确的框选了目标区域；使用目标框与检测框的交集与检测框面积的比值作为召回率，以衡量目标范围是否都被有效检出。mAP 就是计算出一类目标在多个召回率下的准确率 AP，再计算出各类别的平均准确率，用以衡量检测精确程度。FPS 代表模型 1s 处理的图片张数，用以衡量模型推理速度。

3．混淆矩阵

目标检测任务的混淆矩阵表示预测的各类目标与实例的对应情况，其横轴表示标注实例对应的各类别，纵轴表示预测出的各类别。通过混淆矩阵能看出模型的预测结果在各类别上的准确性，其对角线上各点表示各类别检测准确的概率，纵向上的其他点表示此类预测结果其实是其他类别的概率，由此也能看出模型对哪几类目标的预测容易产生混淆，以对模型进行针对性的改进。

4.3.3 基准实验与消融实验

本文按 9：1 的比例随机划分训练集与测试集进行缺陷检测实验，训练 500 个 epoch，图片尺寸设为 1024，batch size 设置为 8。实验结果如下：

首先尝试在 YOLOv5 的 Backbone 及 Neck 中加入 CBAM 模块进行实验，在 Backbone 部分中于 Neck 直接进行特征融合的 CSP1_3 及 CBS 模块的输出后加入 CBAM 模块进行特征提取，在 Neck 部分中于三个尺度的输出后加入 CBAM 模块进行信息融合。CBAM 模块的添加位置及实验结果如下表所示。

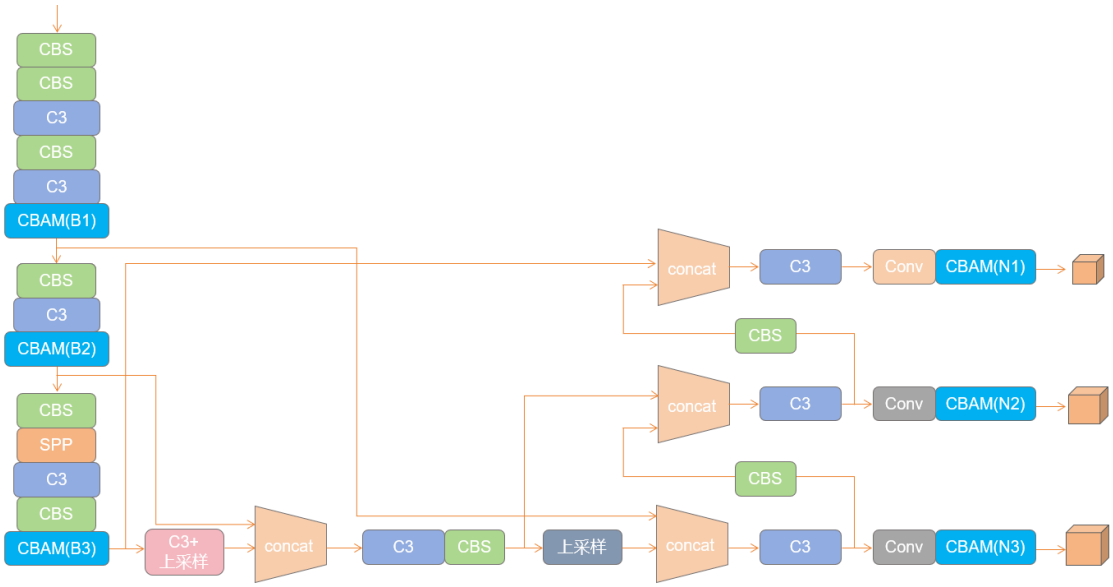


图 4-7 CBAM 添加位置

Figure 4-7 CBAM Add Location

表 4-1 不同位置加入 CBAM 实验结果

Table 4-1 Experimental results of adding CBAM in different positions

添加位置	P/%	R/%	mAP50/%
未添加	41.79	37.35	32.23
B1	36.16	35.11	28.10
B2	37.04	34.92	29.63
B3	36.60	35.00	29.50
B1,B2,B3	35.96	34.71	28.74
N1	40.66	38.84	31.38
N2	40.51	38.34	31.71
N3	41.57	38.79	**32.32**
N1,N2,N3	41.42	39.74	31.93

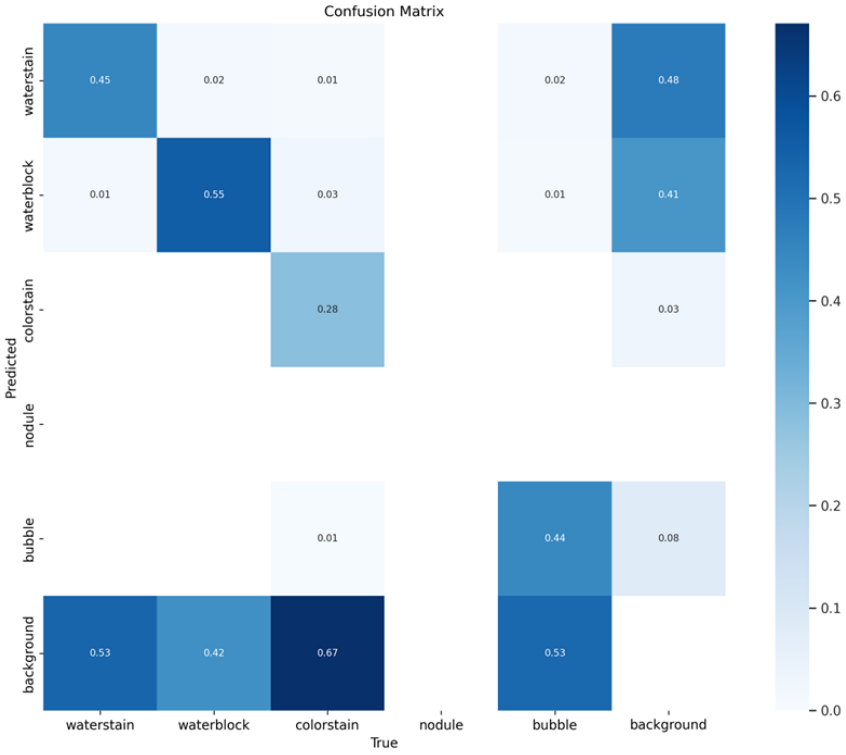
从以上实验结果可以看出，在 N3 位置加入 CBAM 的效果较好，而加在其他位置时模型准确率不仅没有提升，反而有所下降，特别是在 Backbone 加入 CBAM 时模型准确率下降了许多，由此可见对于电积镍缺陷检测任务，CBAM 不太适合加入 Backbone 中提取特征。在 N3 加入 CBAM 后模型准确率有所增长，可能是因为 N3 处特征图尺寸较大，包含较多的位置信息，而特征信息提取不足，加入 CBAM 模块后模型从空间与通道上充分学习目标特征信息，提高了准确率。N1 及 N2 位置中，特征图尺寸小，覆盖的感受野大，已经包含了较多深层的语义信息，此时再添加注意力机制损失了其中的有效信息，导致模型退化。

在 YOLOv5s 的检测头前加入 ASFF 模块，实验结果如下图所示，相较于原本的 YOLOv5s 网络，加入 ASFF 后水渍及污渍类型缺陷检测准确率提升较高，烧板类型缺陷检测准确率有所下降，整体缺陷准确率有所增长。分析可能是因为烧板缺陷通常面积较大，提供了较多特征。加入自适应特征融合模块后，模型通过自适应分配不同尺度特征图的权重，而提升了对水渍、污渍这类小面积缺陷的检测能力，达到了更高的准确率。

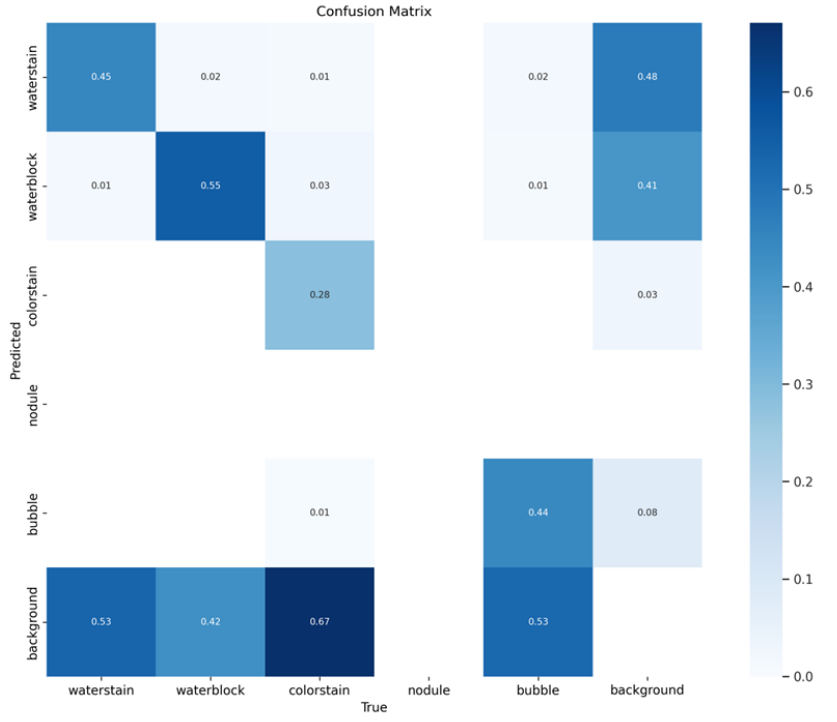
表 4-2 加入 ASFF 实验结果

Table 4-2 Experimental results of adding ASFF

模型	P/%	R/%	mAP50/%
YOLOv5s	41.79	37.35	32.23
YOLOv5s+ASFF	42.17	38.48	**32.64**



(a) 加入 ASFF 的 YOLOv5s 混淆矩阵



(b) YOLOv5s 混淆矩阵

图 4-8 混淆矩阵结果

Figure 4-8 Results of confusion matrix

使用位于 N3 处添加 CBAM 模块的 YOLOv5 网络、只添加 ASFF 模块的 YOLOv5s 网络、位于 N3 处添加 CBAM 模块及 ASFF 模块的 YOLOv5s 网络网

络进行消融实验，结果如下：

表 4-3 消融实验结果

Table 4-3 Ablation experiment results

模型	P/%	R/%	mAP50/%
YOLOv5s	41.79	37.35	32.23
YOLOv5s+ ASFF	42.17	38.48	32.64
YOLOv5s + CBAM	41.57	38.79	32.32
YOLOv5s + CBAM + ASFF	43.50	38.19	**33.29**

通过消融实验发现添加 CBAM 模块后模型增长的准确率较低，添加 ASFF 模块后模型增长的准确率较高，同时添加时模型达到了最好的效果。分析是因为位于 N3 处加入 CBAM，模型只能从检测头中最大的特征图上提取空间与图层上的有用信息，而整体检测结果受多尺度目标，三个检测头共同影响。加入 SFF 模块后，CBAM 于一个检测头中提取的有效信息被 ASFF 自适应分配权重放大，提高了在多尺度目标上的检测准确率。从以上结果也能看出自适应特征融合对模型性能提升起到了较大作用，说明对多尺度目标的检测是电积镍缺陷检测中的关键问题，应通过多尺度特征融合、平衡样本中各尺度缺陷的分布等手段提升模型对多尺度缺陷的检测能力。

4.3.4 和其他检测模型的对比实验

使用改进后的 YOLOv5s 网络与其他模型进行对比实验，结果如下：

表 4-4 和其他检测模型的对比实验结果

Table 4-4 Compared with other detection models

模型	P/%	R/%	mAP50/%
YOLOv5s + CBAM + ASFF	43.50	38.19	**33.29**
YOLOv5m	34.10	29.18	23.85
YOLOv7-tiny	33.56	34.27	28.17
YOLOv9-c	37.23	30.07	26.70

通过对比实验发现，相较于 YOLOv5s 模型，更大的 YOLOv5m、YOLOv7 及 YOLOv9 模型的效果反而不好，推测是因为数据样本较少，大模型在学习中欠拟合。而参数更少，速度更快的改进 YOLOv5s 反而取得了更好的效果，说明实验中应结合数据量选择合适的模型，且结合数据特征采用合适的优化方法。

4.4 本章小节

针对电积镍表面缺陷位置与尺寸分布广泛问题，本文从注意力机制与多尺度特征融合两方面对 YOLOv5s 进行改进。使用 CBAM 模块提升模型对空间、通道中有效信息的提取能力，使用 ASFF 模块进行自适应特征融合提升模型对多尺度目标的检测能力，使用改进后的 YOLOv5s 模型与 YOLOv5m、YOLOv7 等网络进行对比，改进后的模型效果显著优于这些参数更多的检测网络。

第五章 智能分拣系统实现

5.1 电积镍板智能分拣系统设计方案

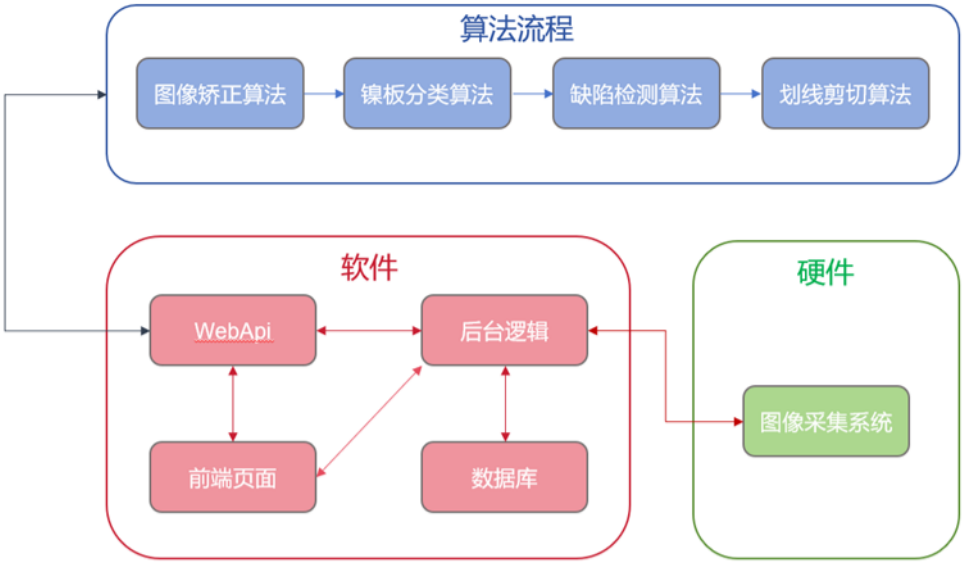


图 5-1 电积镍板智能分拣系统架构

Figure 5-1 Architecture of intelligent sorting system for electrodeposition nickel plate

电积镍板智能分拣系统由图像采集设备、客户端软件及图像处理算法三部分组成。客户端软件与采集设备通信，控制设备开始采集图像，通过 WebApi 调用算法接口，展示镍板检测结果，并存储采集的图像与算法处理结果。前文已介绍了镍板分类算法及缺陷检测算法，本章将介绍图像采集系统主要器材与工作原理、镍板图像矫正算法与缺陷部分划线算法及软件实现。

5.2 图像采集系统

镍板在电解过程中会存在轻微形变问题，形变问题会在 CCD 采集图像时产生随机图像失真，会严重影响图像预处理的质量。镍板表面表面不平整、板面卷曲，预处理操作时镍板堆放较高等因素，都会影响相机成像。为保证成像清晰，需要妥善设计视觉检测系统，解决分辨率、光照、景深和标定等问题，防止环境光干扰，防止失焦、欠曝及过曝等问题产生。

电积镍板图像采集系统由线扫相机，LED 条形照明灯，光电传感器，触发器、控制器、电源线等器材组成，采集图像的工作流程为：首先机械臂抓取镍板，移动镍板经过光电传感器，传感器在收到光电信号后将信号发送给控制器，让照明灯开启，位于传送带底部的相机完成镍板下表面图像的采集。之后

机械臂将镍板放于传送带，镍板通过传送带移动至下一个光电传感器，照明光开启，顶部相机完成对镍板上表面图像的采集。



图 5-2 现场图像采集系统

Figure 5-2 Field image acquisition system

通过线扫相机与照明灯三路灯光交替照明配合，获得了三种照明情况下的镍板图像（两张单侧灯光照明及一张双侧灯光照明）。对比三张图片的成像效果，第一种打光条件下的图片较亮，缺陷与合格部分对比明显，但少数区域过曝，导致图像细节缺失；第二种打光条件下的图片整体较暗，缺陷与合格部分的区分度不够明显；第三种打光条件下的图片光照均匀，没有过曝或过暗的区域，也能明显的区分缺陷与合格板面，因此选定第三种光照条件下的电积镍板图片构建实验数据集。



图 5-3 三种光照下的成像

Figure 5-3 Imags of three types of lighting

5.3 镍板图像矫正与划线算法

5.3.1 矫正算法

在机械臂抓取镍板到传送带的过程中，机械臂可能会发生一定角度的转动，导致镍板在图片中斜向显示。为了软件展示界面的美观，以及让分类与检

测模型更好的学习到各平类镍板及缺陷特征，需要使用矫正算法矫正镍板在图像中的位置，使镍板位于图片中央且正向显示。

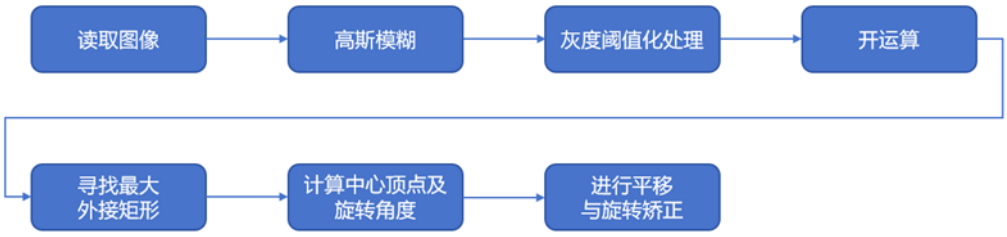


图 5-4 图像矫正算法流程

Figure 5-4 The flow of image correction algorithm

镍板图像矫正算法首先将镍板图像放缩为 1024*888 尺寸的图片（相机采集原图尺寸为 4096*3554，进行 1/4 的下采样）；接着进行高斯模糊，消除图像噪音，避免其对镍板轮廓检测产生干扰，接着进行灰度图阈值化处理，将图片灰度化，设置灰度阈值，保留图像中的镍板主体信息，剔除背景；使用开运算消除背景中的孤立点，平滑镍板轮廓；再计算图像中的最大外接矩形，得到镍板四个顶点坐标，由顶点坐标计算出镍板中心点坐标及旋转角度，从而对镍板进行矫正，使镍板位于图像中央且垂直显示。

输出中间过程的图像，可以观察到高斯模糊对图像进行了模糊操作，接着二进制阈值化处理保留了镍板信息和部分背景噪音，开运算滤除了大部分的背景噪音，平滑了镍板边缘。实验中高斯滤波和开运算使用 5*5 的卷积核，阈值化保留灰度值[150,180]范围内的像素。



图 5-5 高斯模糊、阈值化、开运算的处理结果

Figure 5-5 The processing results of Gauss filter, thresholding and open operation

找出镍板的四个顶点后，计算镍板的中心及旋转角度。中心点坐标及旋转角度的计算公式为：

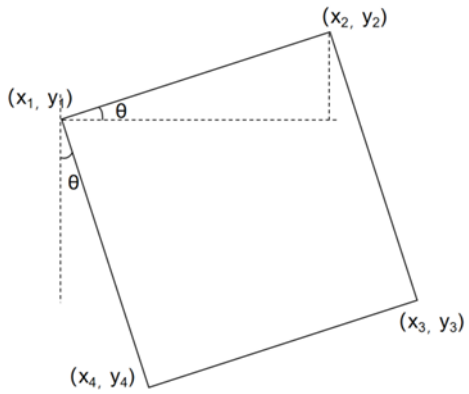


图 5-6 中心点及旋转角计算

Figure 5-6 Calculation of center point and rotation angle

$$(x,y) = \left(\frac{x_1+x_2+x_3+x_4}{4}, \frac{y_1+y_2+y_3+y_4}{4}\right) \quad (5\text{-}1)$$

$$\theta = \arctan\left|\frac{y_2-y_1}{x_2-x_1}\right| \quad (5\text{-}2)$$

式中(x_1,y_1)，(x_2,y_2)，(x_3,y_3)，(x_4,y_4)表示以左上角顶点为起点，按顺时针方向旋转镍板的四个顶点坐标。旋转角度为镍板与垂直方向的夹角，当$y_2 > y_1$时镍板按逆时针方向产生角度偏差，机械臂抓取镍板后需按顺时针方向旋转 θ 度使镍板在图中垂直显示，当$y_2 < y_1$时镍板按顺时针方向产生角度偏差，机械臂抓取镍板后需按逆时针方向旋转θ度使镍板在图中垂直显示。

得到镍板的中心坐标及旋转角度后，对镍板图像先平移，再旋转。计算镍板中心坐标与图像中心坐标的偏差，以此偏差值对图像进行平移，之后对镍板进行旋转矫正，使用黑色像素填充位移后图像中空缺的像素点，得到镍板位于图片中央，且垂直显示的镍板图像。

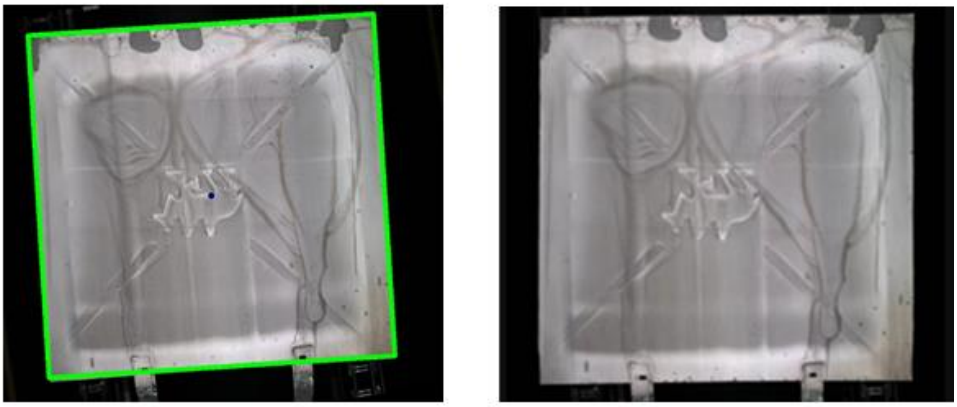


图 5-7 镍板边缘检测及矫正

Figure 5-7 Nickel plate edge detection and correction

5.3.2 划线算法

在分类模型判断为不合格板的镍板上，有时缺陷只是在镍板的一小块区域。企业希望切除缺陷部分作为废板，剩余部分作为合格板输出。镍板长860～920mm，宽 860～900mm，对缺陷较多的镍板切五刀，获得 6 个尺寸约900mm*150mm 尺寸的镍条，或对缺陷较少的镍板切一刀，获得尺寸约900*600、 900*300 的镍条，比较容易码放与运输。为此设计以下的划线方案：

1）缺陷面积大于板面面积 60%的镍板，将此类镍板降级为废板。

2）缺陷面积大于板面面积 1/3，小于 60%的镍板，将镍板平均切五刀分为六个镍条，计算各镍条上的缺陷面积，若缺陷面积大于镍条面积 40%，该镍条不合格，否则镍条合格，保存切五刀的坐标信息及六个镍条的合格状况。

3）缺陷面积大于板面面积 10%，小于 1/3 的镍板，将此镍板从板长或板宽 1/3 初的位置切一刀以切除缺陷，计算镍板四边的四条切割线内的缺陷面积，选择缺陷面积最大的一边进行切除。

4）缺陷面积小于板面面积 10%的镍板，尽管此类镍板上有缺陷，但缺陷面积较少，将其判定为合格板，不进行剪切。

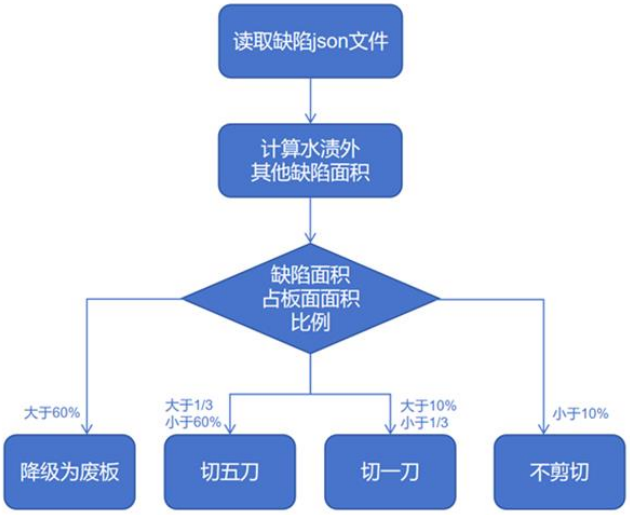


图 5-8 划线算法流程

Figure 5-8 The flow of cutting algorithm

镍板划线算法流程如上图所示，首先读取检测模型生成的缺陷 json 文件，得到表示镍板双面缺陷的坐标列表，每个缺陷以左上角加右下角坐标(x_1,y_1,x_2,y_2)的的形式表示。接着计算上下表面缺陷的总面积，使用 1024*888 的 0/1 二维数组记录缺陷信息，以防对上下表面重叠的缺陷部分重复计算。根据缺陷面积占板面面积比例对镍板进行剪切。

经现场测试，电积镍缺陷检测+划线算法输出结果的准确率达到了 90%，在缺陷检测准确的情况下，划线算法可以准确的确定电积镍板缺陷部分的剪切

线。如下图所示，对缺陷较少的镍板，划线算法准确的确定了一条剪切线，切除掉了存在较大水渍、污渍、凸起疙瘩的一边。对存在大面积烧板缺陷的镍板，确定了五条切割线切并获得了最上方两个几乎没有缺陷的镍条。基于电积镍缺陷检测结果，使用划线算法确定剪切线，切除缺陷部分，可以避免因为板面部分位置存在缺陷就将镍板当作废板，帮助企业提高了生产效益。

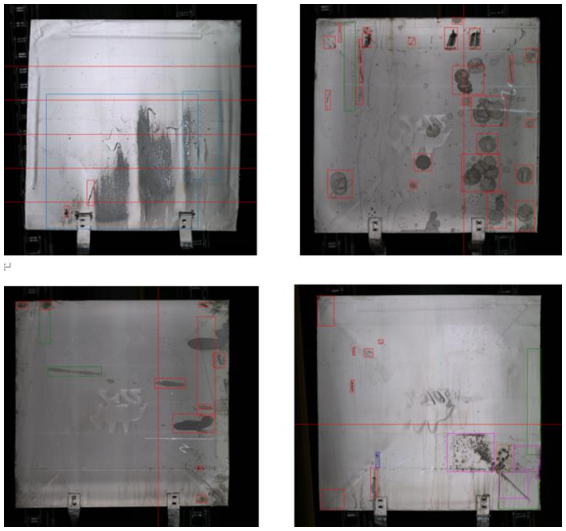


图 5-9 划线算法处理结果

Figure 5-9 Results of cutting algorithm

5.4 可视化系统实现

可视化系统需展示电积镍分拣结果，包括镍板图像、分类结果、检测的缺陷信息、划线信息及剪切后各镍条的合格状态。此外还应有控制相机是否开始采集图像、查看上一张/下一张镍板的检测结果、查看存储的镍板图像功能。使用 C#完成软件系统开发，通过相机控制软件完成与相机间的通信，通过 WebApi 完成对算法接口的调用。

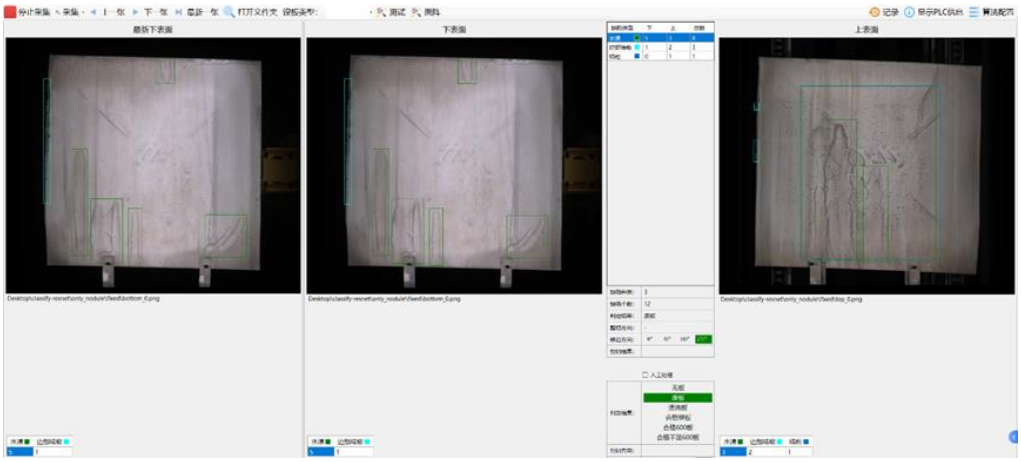


图 5-10 可视化系统界面

Figure 5-10 Visual system interface

5.5 本章小节

本章介绍了电积镍智能分拣系统的实现。包括系统设计方案，客户端软件控制图像采集系统开始或停止采集图像，通过 WebApi 调用算法接口，展示镍板检测结果，并存储采集的图像与算法处理结果。图像采集系统设计中应注意的问题，本文使用的图像采集系统主要器材的型号及工作原理；算法部分介绍了图像矫正算法及划线算法的算法流程与处理结果；软件系统介绍了软件的功能与实现。

第六章 总结与展望

6.1 工作总结

在电积镍生产行业中，企业仍采用传统的人工目检方法对电积镍板进行分拣，人工分拣不仅费时费力，而且会因为现场环境、质检员疲劳状态等因素影响准确率。针对电积镍分拣问题，本文基于深度学习，设计了一套电积镍智能分拣算法，配合图像采集设备与可视化系统，实现了电积镍分拣的智能化、自动化。论文的主要内容与相关工作总结如下：

1. 通过与企业技术专家多次讨论，到生产现场实地考察，了解电积镍生产的行业背景、工艺流程与企业需求，设计电积镍智能分拣技术方案。结合现场环境与专家意见，设计电积镍图像采集系统方案。为了采集到清晰、没有过曝、过暗与色彩失真的电积镍板图像，搭建图像采集系统并对器械进行调整，包括相机的焦距、行频与帧延时等参数调整、平场矫正与色彩矫正；编码器分辨率及精度等参数调试；照明灯光的触发延时与光照时间等参数调整、三路灯光设置、位置与旋转角度调整；集成控制器与照明灯、相机间的通信调试。搭建好的图像采集系统可以进行控制器内信与编码器外信两种方式的图像采集，配合现场的传送带与机械臂，实现自动且连续的无过曝、过暗、色彩失真的高分辨率（4096*3554）镍板图像采集。

2. 通过现场采集电积镍板图像，分析采集的图像样本，企业一天生产的镍板数量有多少，合格率应控制在多少。同质检员讨论镍板的分类判断依据以及各类缺陷特征、范围的定义，建立电积镍板分类及缺陷检测数据集。为使同类电积镍板、同类缺陷间具有较多的相似特征，使模型更好的学习到各类镍板与缺陷的典型特征，通过分析目标特征及模型检测结果，结合企业需求，同质检员多次改进分类数据集的划分与镍板各类表面缺陷的标注方式，如将多条相邻的水渍按每一条进行标注，深色、呈片状的水渍标注为污渍，凸起疙瘩缺陷只标注凸出较明显、且分布较密的部分。通过不断优化标注方式，使缺陷检测模型的准确率从最开始的不到 1%，提升到了 30%以上。

3. 使用 AlexNet、VGG、ResNet、SqueezeNet、监督对比学习分类模型进行电积镍板分类实验，选用其中效果最好的 ResNet18 网络进行分类与改进。基于镍板缺陷类型多样、在不同特征图层间的特征分量不同，使用 SE 模块对残差结构进行改进。因镍板板面特征像素值高于背景像素值，加入最大池化分支，对 SE 模块进行改进，改进后的模型可以注意到图层中的局部高频分量，为通道中的各层特征图自适应分配权重。改进后的网络较原网络提升了的 4.93%准确

率。此外还尝试使用数据增强的方式进行各类样本分布平衡，虽总的准确率较未使用数据增强有所下降，但在二次烫洗板及缺陷板这两类原分布中占比较少的类别上准确率有所增长。

4. 使用 YOLOv5、YOLOv7 进行电极镍缺陷检测实验，选用其中效果最好的 YOLOv5s 网络进行检测与改进。因镍板面积较大，表面缺陷尺寸多变、部分缺陷面积极小，需要模型对小目标、多尺度目标有较强的学习能力。为此从空间、通道注意力及多尺度特征融合两个方面对 YOLOv5s 网络进行改进，使用 CBAM 优化 YOLOv5s 网络的注意力，提升其对空间中不同位置、通道中不同层上的特征信息提取能力；在 Neck 部分加入 ASFF 模块进行自适应多尺度特征，使浅层特征图包含更多来自深层的特征信息，深层特征图包含更多来自浅层的位置信息，以此提升网络对多尺度缺陷的检测能力。通过 CBAM 的空间通道注意力与 ASFF 模块配合，提升了网络检测准确率。

5. 完成镍板图像矫正算法及划线算法。通过对图像进行高斯模糊、灰度图阈值化处理、开运算、求最大外接矩形，求得到镍板四个顶点坐标，之后通过几何关系求出镍板的中心坐标及旋转角度，以对镍板图像进行矫正处理。通过大量测试确定合适的分割阈值区间，以确保板面较亮的合格板及偏暗的废板各种类型镍板图像均能被准确矫正。为提升企业的生产效益，通过和企业专家探讨，确定了将缺陷镍板切一刀或切五刀，获得 150、300、600 三种不同宽度镍条的划线方案，以便于将切割后的镍条码放成摞。划线算法读取缺陷检测算法存储的镍板双面缺陷的 Json 文件，计算缺陷总面积，根据缺陷占板面面积比例确定划线条数，由各区域内缺陷位置确定划线位置。在检测结果准确无误的情况下，划线算法可以切除掉缺陷部分，获得表面没有缺陷或缺陷较少的镍条，在保障产品质量的前提下帮助企业实现了生产效益最大化。

6.完成可视化系统开发，通过前端页面展示矫正后的双面镍板图像、分类类别、各板面及总共检测出的缺陷类别、个数、位置信息、划线位置；通过 WebApi 完成对图像算法的调用；通过后端逻辑完成软件与采集系统间的通信、算法处理结果的存储与读取。通过图像采集系统、客户端软件及图像处理算法的配合，实现了电积镍板图像的自动采集、分类、缺陷检测、剪切、展示。通过与现场机械臂、传送带配合，实现了电积镍分拣过程的智能化、自动化。

6.2 工作展望

虽然目前已实现了电积镍图像采集、分类检测、划线剪切流程的自动化，算法在现场测试中取得了较好的测试结果，但依然存在一些问题值得深入研究，总结如下：

1. 电积镍板种类及缺陷类别判断依据。对不同类型的缺陷，企业主要依据

其产生原因划分类别，但电解过程中，化学反应复杂，即使是相同原因产生的缺陷特征差别也可能较大。深度学习算法主要依据图像特征进行分类，因此存在一些缺陷，企业认为属于一类，但在特征上更接近于其他类别的缺陷。比如深色的水渍，尽管其是因板面烫洗不干净留下的水印，但只是从图片来看的话其特征更接近于污渍缺陷。烧板缺陷可能表现为发黄的条状、发黑的片状以及中间发紫、周围伴有发黑发黄的片状缺陷。为此不仅应根据缺陷成因划分缺陷类别，也应基于缺陷特征划分缺陷类别，使模型更好的提取缺陷典型特征。其次考虑到企业生产效益，不同质检员的标准有所差异，缺陷特征的标准也难以确定。比如凸起疙瘩缺陷，当其凸出不明显，分布比较分散的时候，企业认为其对板面品相影响较小，不构成缺陷。但凸出程度、密集程度多少的疙瘩缺陷才构成缺陷，企业间难以给出一个固定的阈值标准；因当日产品合格率、生产绩效、不同质检员的严格程度，构成缺陷的判别阈值也有所差异。导致在数据集中，一些缺陷被认为特征不明显、影响程度较小而没有标注，但在其他图片中特征相近的缺陷却被标注，导致缺陷的漏检误检。何种程度才构成缺陷，需要一个尽可能统一的标准，按照此标准进行标注及测试。此外如何标注缺陷，才能让模型学习到更多特征也是一个需继续研究的问题。本文已进行了许多标注改进的工作，比如对范围较大，但疏密程度不同的疙瘩缺陷，与使用一个大框框选所有的凸起疙瘩范围相比，使用几个小框只标出上面密集的疙瘩部分可以达到更好的检测效果。在深度学习中，有时数据集的质量会比模型产生更大的影响。因本研究与实际生产质检结合，目前采集的电积镍板图像较深度学习的大数据集规模还比较小，通过继续采集镍板图像、优化标注方法、以统一标准进行标注，相信可以达到更高的准确率。

2. 数据集中各类别样本分布不均衡。因企业生产的镍板多数为合格板，采集系统在生产现场采集镍板图像，导致数据集中多数样本为合格板。与各类镍板分布不均衡相同，各缺陷类别分布也严重不均，比如边部结馏类别缺陷在数据集中数量极少，导致无法检出。应通过继续采集图像，平衡各类别样本分布。当样本较少的类别达到一定规模后使用 VAE、GAN 等生成网络扩充其数量，进行研究。

3. 在实际生产中，镍板质量是否合格多方面决定，用户、生产、质检等不同部门对产品质量的接受度各不相同。针对不同的应用场景，企业对镍板类别及缺陷的判断标准有所差异，为此企业希望通过动态可调的阈值控制产品合格率。比如合格阈值设置较低时，合格镍板表面可以有较为密集、但面积较小的凸起疙瘩缺陷存在，当合格阈值较高时，无论面积大小，合格镍板表面不允许有密集的凸起疙瘩缺陷。深度学习依靠学习到的特征进行检测，为此若要实现

不同标准的分类与检测，需要建立多个不同标准的训练集，得到不同标准的参数，再调用其进行检测，多标准数据集的建立与训练需要消耗大量时间。深度学习模型学习到的是图像深层语义特征，而非颜色、纹理、边缘这些浅层特征。因此很难像我们直观理解的通过设置阈值，就可以区分出疏密程度、边缘凹凸不同的同类缺陷。不止是电积镍板的质检，其他许多生产制造业中也一样，针对不同的应用场景，存在多个产品合格标准。如何让深度学习实现这个阈值，使用相同的学习参数进行不同标准的检测，是一个值得深入思考与研究的问题。

参考文献

[1] 虞佳佳,张耀,何勇.基于机器视觉的铝镍钴磁性材料外观缺陷检测的研究[J].浙江工业大学学报,2022,50(02):143-148.

[2] 刘广鹏. 基于机器视觉的有色金属镍板材表面缺陷检测技术研究[D].兰州理工大学,2023.DOI:10.27206/d.cnki.ggsgu.2023.000442..

[3] Suresh B R，Fundakowski R A,Levitt T S,et al. A real-time automated visual inspection system for hot steel slabs[J].IEEE Transactions on Pattern Analysis and Machine Intelligence,1983, PAMI-5(6): 563-572. [DOI:10.1109/TPAMI.1983.4767445]

[4] Badger J C,Enright S T.Automated surface inspection system [J].Iron and Steel Engineer,1996,73(3):48-51.

[5] 屈尔庆,崔月姣,徐森等.改进的 Gabor 滤波器带钢表面缺陷显著性检测[J].华中科技大学学报(自然科学版),2017,45(10):12-17.DOI:10.13245/j.hust.171003.

[6] 安宗权,王匀.一种非线性扩散与图像差分的金属表面缺陷检测方法[J].表面技术,2018,47(06):277-283.DOI:10.16490/j.cnki.issn.1001-3660.2018.06.040.

[7] 王进峰,张兵宇,问丛川等.基于 HALCON 的四光源光度立体法金属表面缺陷检测方法[J].制造技术与机床,2022(03):157-161.DOI:10.19287/j.cnki.1005-2402.2022.03.027.

[8] 厉荣宣,沈希忠,张树行等.基于图像处理的轴类零件表面裂纹检测[J].图学学报,2015,36(01):62-67.

[9] 黄梦涛,连一鑫.基于改进 Canny 算子的锂电池极片表面缺陷检测[J].仪器仪表学报,2021,42(10):199-209.DOI:10.19650/j.cnki.cjsi.J2107914.

[10] 马忠平.一种基于机器视觉的轴承环形表面缺陷检测[J].中国科技信息,2023(19):129-132.

[11] 崔焱,彭可,杨玉娥等.基于机器视觉的手机盖板表面缺陷检测系统设计[J].制造业自动化,2023,45(07):75-79+96.

[12] 刘飞飞,窦祥飞,薛亚鑫等.基于机器视觉的铜箔表面缺陷检测方法研究[J].机电工程技术,2023,52(03):206-209+214.

[13] RUSSAKOVSKY O, DENG J, SU H, et al., 2014. ImageNet Large Scale Visual Recognition Challenge[Z/OL]//arXiv [cs.CV]. (2014)[2024-03-08]. http://arxiv.org/abs/1409.0575.

[14] ALOM M Z, TAHA T M, YAKOPCIC C, et al., 2018. The history began from AlexNet: A comprehensive survey on Deep Learning approaches[Z/OL]//arXiv [cs.CV]. (2018)[2024-03-08]. http://arxiv.org/abs/1803.01164.

[15] GIRSHICK R, DONAHUE J, DARRELL T, et al., 2013. Rich feature hierarchies for accurate object detection and semantic segmentation[Z/OL]//arXiv [cs.CV]. (2013)[2024-03-08]. http://arxiv.org/abs/1311.2524.

[16] GIRSHICK R, 2015. Fast R-CNN[Z/OL]//arXiv [cs.CV]. (2015)[2024-03-08]. http://arxiv.org/abs/1504.08083.

[17] REN S, HE K, GIRSHICK R, et al., 2015. Faster R-CNN: Towards real-time object detection with region proposal networks[Z/OL]//arXiv [cs.CV]. (2015)[2024-03-08]. http://arxiv.org/abs/1506.01497.

[18] HE K, GKIOXARI G, DOLLÁR P, et al., 2017. Mask R-CNN[Z/OL]//arXiv [cs.CV]. (2017)[2024-03-08]. http://arxiv.org/abs/1703.06870.

[19] CAI Z, VASCONCELOS N, 2017. Cascade R-CNN: Delving into high quality object detection[Z/OL]//arXiv [cs.CV]. (2017)[2024-03-08]. http://arxiv.org/abs/1712.00726.

[20] 孔思曼,周晨阳,王家华等.基于优化 Faster R-CNN 算法的金属板材表面缺陷检测[J].制造技术与机床,2024(01):171-178.DOI:10.19287/j.mtmt.1005-2402.2024.01.024.

[21] 杜志虎,韩亮,薛彦宇等.基于改进 Mask RCNN 算法的管道焊缝缺陷检测[J].电脑知识与技术,2023,19(30):16-18+24.DOI:10.14004/j.cnki.ckt.2023.1618.

[22] 陆尧,薛林,王云森等.基于 Cascade RCNN 的热轧带钢表面缺陷检测[J].仪表技术与传感器,2023(08):101-106+126.

[23] LIU W, ANGUELOV D, ERHAN D, et al., 2015. SSD: Single Shot MultiBox Detector[Z/OL]//arXiv [cs.CV]. (2015)[2024-03-08]. http://arxiv.org/abs/1512.02325.

[24] REDMON J, DIVVALA S, GIRSHICK R, et al., 2015. You only look once: Unified, real-time object detection[Z/OL]//arXiv [cs.CV]. (2015)[2024-03-08]. http://arxiv.org/abs/1506.02640.

[25] REDMON J, FARHADI A, 2016. YOLO9000: Better, faster, stronger[Z/OL]//arXiv [cs.CV]. (2016)[2024-03-08]. http://arxiv.org/abs/1612.08242.

[26] REDMON J, FARHADI A, 2018. YOLOv3: An Incremental Improvement[Z/OL]//arXiv [cs.CV]. (2018)[2024-03-08]. http://arxiv.org/abs/1804.02767.

[27] BOCHKOVSKIY A, WANG C Y, LIAO H Y M, 2020. YOLOv4: Optimal speed and accuracy of object detection[Z/OL]//arXiv [cs.CV]. (2020)[2024-03-08]. http://arxiv.org/abs/2004.10934.

[28] GE Z, LIU S, WANG F, et al., 2021. YOLOX: Exceeding YOLO Series in 2021[Z/OL]//arXiv [cs.CV]. (2021)[2024-03-08]. http://arxiv.org/abs/2107.08430.

[29] BENJUMEA A, TEETI I, CUZZOLIN F, et al., 2021. YOLO-Z: Improving small object detection in YOLOv5 for autonomous vehicles[Z/OL]//arXiv [cs.CV]. (2021)[2024-03-08]. http://arxiv.org/abs/2112.11798.

[30] LI C, LI L, JIANG H, et al., 2022. YOLOv6: A single-stage object detection framework for industrial applications[Z/OL]//arXiv [cs.CV]. (2022)[2024-03-09].

http://arxiv.org/abs/2209.02976.

[31] WANG C Y, BOCHKOVSKIY A, LIAO H Y M, 2022. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[Z/OL]//arXiv [cs.CV]. (2022)[2024-03-09]. http://arxiv.org/abs/2207.02696.

[32] REIS D, KUPEC J, HONG J, et al., 2023. Real-time flying object detection with YOLOv8[Z/OL]//arXiv [cs.CV]. (2023)[2024-03-09]. http://arxiv.org/abs/2305.09972.

[33] WANG C Y, YEH I H, LIAO H Y M, 2024. YOLOv9: Learning what you want to learn using programmable gradient information[Z/OL]//arXiv [cs.CV]. (2024)[2024-03-09]. http://arxiv.org/abs/2402.13616.

[34] 王勇强,周学明,张政等.基于 LSD 与深度学习的轻量化导地线缺陷检测算法[J].光学与光电技术,2024,22(01):60-66.DOI:10.19519/j.cnki.1672-3392.2024.01.005.

[35] 谢昆,方凯,陈娟等.基于改进 YOLOv5s 的铝材表面缺陷检测方法[J].制造技术与机床,2024(01):179-184.DOI:10.19287/j.mtmt.1005-2402.2024.01.025.

[36] 杨景崙,辛巍,刘全等.基于自监督学习的输电线路螺栓螺母异常检测技术[J].计算机测量与控制,2023,31(05):87-93.DOI:10.16526/j.cnki.11-4762/tp.2023.05.013.

[37] 刘华锋,韩翊,茅耀斌.基于自监督学习的变电站缺陷检测[J].计算机系统应用,2023,32(05):112-122.DOI:10.15888/j.cnki.csa.009088.

[38] SIMONYAN K, ZISSERMAN A, 2014. Very deep convolutional networks for large-scale image recognition[Z/OL]//arXiv [cs.CV]. (2014)[2024-03-08]. http://arxiv.org/abs/1409.1556.

[39] SZEGEDY C, LIU W, JIA Y, et al., 2014. Going deeper with convolutions[Z/OL]//arXiv [cs.CV]. (2014)[2024-03-08]. http://arxiv.org/abs/1409.4842.

[40] HUANG G, LIU Z, VAN DER MAATEN L, et al., 2016. Densely connected convolutional networks[Z/OL]//arXiv [cs.CV]. (2016)[2024-03-08]. http://arxiv.org/abs/1608.06993.

[41] HOWARD A G, ZHU M, CHEN B, et al., 2017. MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications[Z/OL]//arXiv [cs.CV]. (2017)[2024-03-08]. http://arxiv.org/abs/1704.04861.

[42] ZHANG X, ZHOU X, LIN M, et al., 2017. ShuffleNet: An extremely efficient convolutional neural network for mobile devices[Z/OL]//arXiv [cs.CV]. (2017)[2024-03-08]. http://arxiv.org/abs/1707.01083.

[43] IANDOLA F N, HAN S, MOSKEWICZ M W, et al., 2016. SqueezeNet: AlexNet-level accuracy with 50x fewer parameters and <0.5MB model size[Z/OL]//arXiv [cs.CV]. (2016)[2024-03-09]. http://arxiv.org/abs/1602.07360.

[44] HE K, ZHANG X, REN S, et al., 2015. Deep residual learning for image recognition[Z/OL]//arXiv [cs.CV]. (2015)[2024-03-08]. http://arxiv.org/abs/1512.03385.

[45] HU J, SHEN L, ALBANIE S, et al., 2017. Squeeze-and-Excitation Networks[Z/OL]//arXiv [cs.CV]. (2017)[2024-03-08]. http://arxiv.org/abs/1709.01507.

[46] 赵雅阁,马骏,孙晓强等.工业储罐缺陷检测模糊分类器研究[J].仪表技术,2023(05):51-53.DOI:10.19432/j.cnki.issn1006-2394.2023.05.013.

[47] 徐红牛,余华云.基于改进 YOLO 模型的工业铝片缺陷检测[J].组合机床与自动化加工技术,2023(09):106-111.DOI:10.13462/j.cnki.mmtamt.2023.09.023.

[48] 姜媛媛,蔡梦南.轻量化的印刷电路板缺陷检测网络 Multi-CR YOLO[J].电子测量与仪器学报,2023,37(11):217-224.DOI:10.13382/j.jemi.B2306738.

[49] 朱德平,程光,姚景丽.改进 YOLOv5 的汽车齿轮配件表面缺陷检测[J/OL].计算机工程与应用:1-9[2024-03-09].http://kns.cnki.net/kcms/detail/11.2127.TP.20231130.1415.014.html.

[50] 梁滨,宋雪峰,高嘉等.基于 YOLO 算法框架的曳引钢丝绳缺陷检测方法[J].无损探伤,2023,47(06):1-4+8.DOI:10.13689/j.cnki.cn21-1230/th.2023.06.011.

[51] 张嘉琪,徐啟蕾.基于 NAM-YOLO 网络的苹果缺陷检测算法[J].计算机与现代化,2023(10):53-58+64.

[52] 孔松涛,徐甄泽,林星宇等.基于改进 YOLO v5 算法的光伏组件红外热成像缺陷检测[J].红外技术,2023,45(09):974-981.

[53] 罗怡辰,张鹏鹏,单帅迪等.基于 YOLOX-S 模型的塑胶跑道缺陷检测系统[J].工业控制计算机,2023,36(08):116-117+121.

[54] 何彦弘,李俊峰,潘海鹏. 基于 MobileNet-YOLO 的轻量级布匹缺陷检测方法研究[C]//中国自动化学会过程控制专业委员会,中国自动化学会.第 34 届中国过程控制会议论文集.[出版者不详],2023:1.DOI:10.26914/c.cnkihy.2023.039770.

[55] 高文俊,张海峰.基于改进 YOLOv4 风机叶片缺陷检测方法[J].农业装备与车辆工程,2023,61(08):94-98.

[56] 贾伟萍,褚玮,刘文婷等.基于 YOLO v3 的卷烟用瓦楞纸箱表面缺陷检测方法[J].中国造纸,2023,42(06):126-133.

[57] 高小伟,吴合风,谭启昀等.基于 YOLO 框架的无锚框输电线多种缺陷检测[J].测控技术,2023,42(03):24-31.DOI:10.19708/j.ckjs.2023.03.004.

[58] 龙凌,陈浩,梁昊等.基于轻量化 YOLO 网络的实时 X 射线焊缝缺陷检测[J].网络新媒体技术,2023,12(02):30-38.DOI:10.20064/j.cnki.2095-347X.2023.02.004.

[59] WOO S, PARK J, LEE J Y, et al., 2018. CBAM: Convolutional Block Attention Module[Z/OL]//arXiv [cs.CV]. (2018)[2024-03-08]. http://arxiv.org/abs/1807.06521.

[60] LIN T Y, DOLLÁR P, GIRSHICK R, et al., 2016. Feature pyramid networks for object detection[Z/OL]//arXiv [cs.CV]. (2016)[2024-03-08]. http://arxiv.org/abs/1612.03144.

[61] LIU S, QI L, QIN H, et al., 2018. Path Aggregation Network for instance

segmentation[Z/OL]//arXiv [cs.CV]. (2018)[2024-03-08]. http://arxiv.org/abs/1803.01534.

[62] LIU S, HUANG D, WANG Y, 2019. Learning spatial fusion for single-shot object detection[Z/OL]//arXiv [cs.CV]. (2019)[2024-03-08]. http://arxiv.org/abs/1911.09516.

附 录

致 谢

感谢我的导师和实验室的朋友们对论文工作提供的帮助，感谢相关单位的工作支持，感谢我的家人、朋友们在论文完成期间给我的鼓励。

攻读学位期间取得的“创新成果”目录