北京郵電大學

硕士学位论文(学术学位)

题目：基于机器视觉的电解镍板表面缺陷检测算法研究

学　　号：2022111284

姓　　名：任逸为

学科专业：控制科学与工程

培养方式：全日制

导　　师：杨辉华

学　　院：智能工程与自动化学院

2025 年 3 月 14 日



BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Master Thesis

Machine Vision-Based Algorithm for Suface Defect Detection in Electrolytic Nickel Plates

Student ID: 2022111284

Candidate: Ren Yiwei

Subject: Control Science and Engineering

Supervisor: Yang Huihua

Institute: School of Intelligent Engineering and Automation

答辩委员会名单

职务	姓　名	职　称	工　作　单　位
主席			
委员			
委员			
委员			
秘书			
答辩日期			

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

摘　要

镍，作为一种过渡金属元素，凭借其出色的耐腐蚀性、铁磁性与良好的加工性能，在现代工业领域应用广泛。电解镍是借助电解工艺获取的高纯度镍产品，镍含量可达到99.9%以上，常用于电子、航空航天、电镀等领域。电解镍由于生产工艺复杂、操作要求高等因素，生产出的成品镍板表面会存在水渍、烧灼等不同种类缺陷污染，影响产品物理化学性质，进而影响产品性能。因此，根据成品电解镍板表面污染情况，给出不同的处理方案是其在出厂前必不可少的一步。

当前，在电解镍板处理环节，镍板生产厂商主要依赖肉眼进行操作。这种传统方式存在诸多弊端，具体表现为：对镍板下表面的检测往往缺失，检测标准缺乏统一规范，检测准确率较低，且分类效率不高。为实现电解镍板表面缺陷的精准检测，各领域专家已尝试运用一系列机器学习方法。然而，这些方法也存在明显的局限性，例如可检测的缺陷种类有限，或者检测准确率欠佳，因而难以完全取代人工操作。因此，为实现电解镍板的全自动分类，本文根据电解镍板表面特性，设计一套高质量电解镍板图像采集系统，引入基于深度的图像分类算法对电解镍板进行A、B、C三分类，针对处理方案模糊的B类镍板，引入目标检测算法计算其表面缺陷种类和面积，实现电解镍板的准确处理，全程自动化。

首先，本文设计了一套高质量镍板图像采集系统，有效解决了图像采集系统长期存在的光污染、过曝、成像不清晰等问题，实现了镍板图像的高质量采集。为本文后续算法的准确处理打下基础。

之后，本文从采集的若干张图像中挑选2123张，建立了电解镍板表面分类数据集，提出Nickel-Classifier分类模型。Nickel-Classifier基于ResNet18，在头部使用自主设计的Light-head特征粗提取结构以解决局部信息丢失和高分辨率输入造成的较高计算量问题；针对数据集镍板颜色信息丰富、通道特征区分性较大的情况，使用引入SE注意力机制的改进ResNet18作为主干网络提取特征；模型末端针对全连接分类器降维过程造成特征丢失、模型过拟合问题，设计CascadeCls分类器替换全连接分类器。在电解镍板分类数据集上测试数据显示，相比于使用ResNet18做分类，Nickel-Classifier模型验证集准确率提高4.26%，测试集准确率提高15.67%，并且解决了训练过拟合问题。此外，与其他经典分类方法相比，Nickel-Classifier也有明显优势。

然后，本文从采集的若干张图像中挑选 1195 张，建立电解镍板表面缺陷数据集。针对数据集小目标和大长宽比目标缺陷较多的问题提出了 YOLO-NP 检测模型，其基于 YOLO11 架构，引入为本数据集订制的锚框、PPA 注意力机制、SPDConv、可学习权重的 LW 特征融合模块和基于 Wasserstein 距离的 NWD 损失函数，提升模型检测性能。实验表明，与一阶段检测模型 YOLO 系列及其变体、二阶段检测模型 Faster-RCNN、基于 Transformer 架构的 RT-DETR 检测模型相比，YOLO-NP 有更高的检测精度和较低的参数量。

经过现场生产测试，本文的图像采集系统能够稳定、高效的采集图像，分类和检测算法能够满足并超出厂家需求。算法和 PLC、机械臂相配合，本文实现了电解镍板的准确处理，全程自动化，解决了人工分类效率低下、准确率低的问题，提高企业生产效率和效益，缺陷信息的全自动化统计也为企业改进生产工艺流程提供指导。

关键词：图像分类；目标检测；电解镍

ABSTRACT

Nickel, as a transition metal element, is widely applied in modern industrial fields due to its excellent corrosion resistance, ferromagnetism, and good workability. Electrolytic nickel is a high-purity nickel product obtained through the electrolysis process, with a nickel content of over 99.9%. It is commonly used in fields such as electronics, aerospace, electroplating, etc. Due to factors such as the complex production process and high operation requirements of electrolytic nickel, the surface of the finished nickel plates may be contaminated by various defects like water stains and burns. These defects affect the physical and chemical properties of the products, and further influence the product performance. Therefore, according to the surface contamination situation of the finished electrolytic nickel plates, providing different treatment schemes is an essential step before the products leave the factory.

Currently, in the processing of electrolytic nickel plates, nickel plate manufacturers mainly rely on visual inspection. This traditional method has many drawbacks, specifically: the inspection of the lower surface of the nickel plates is often lacking, the inspection standards lack uniformity and standardization, the inspection accuracy is relatively low, and the classification efficiency is not high. To achieve accurate detection of surface defects of electrolytic nickel plates, experts from various fields have attempted to use a series of machine learning methods. However, these methods also have obvious limitations. For example, the types of defects that can be detected are limited, or the detection accuracy is not satisfactory, so it is difficult to completely replace manual operation. Therefore, to achieve the full automation of the classification of electrolytic nickel plates, based on the surface characteristics of electrolytic nickel plates, this paper designs a high-quality image acquisition system for electrolytic nickel plates, introduces a deep-based image classification algorithm to classify electrolytic nickel plates into three categories, namely A, B, and C. For type B nickel plates with ambiguous treatment schemes, a target detection algorithm is introduced to calculate the types and areas of surface defects, so as to achieve accurate processing of electrolytic

nickel plates in a fully automated manner throughout the process.

Firstly, this paper designs a high-quality nickel plate image acquisition system, which effectively solves the long-standing problems of light pollution, overexposure, and unclear imaging in the image acquisition system, and realizes the high-quality acquisition of nickel plate images, laying a foundation for the accurate processing of subsequent algorithms in this paper.

After that, this paper selects 2,123 images from the collected images to establish a surface classification dataset of electrolytic nickel plates and proposes the Nickel-Classifier classification model. The Nickel-Classifier is based on ResNet18. At the head part, a self-designed Light-head feature rough extraction structure is used to address the issues of local information loss and high computational cost caused by high-resolution input. In view of the fact that the nickel plates in the dataset have rich color information and significant channel feature discrimination, an improved ResNet18 with the introduction of the SE attention mechanism is employed as the backbone network to extract features. At the end of the model, to tackle the problems of feature loss and model overfitting caused by the dimensionality reduction process of the fully connected classifier, a CascadeCls classifier is designed to replace the fully connected classifier. The test data on the classification dataset of electrolytic nickel plates show that, compared with using ResNet18 for classification, the verification set accuracy of the Nickel-Classifier model increases by 4.26%, the test set accuracy increases by 15.67%, and the problem of training overfitting is solved. Moreover, compared with other classic classification methods, the Nickel-Classifier also has obvious advantages.

Then, this paper selects 1,195 images from the collected images to establish a surface defect dataset of electrolytic nickel plates. To address the issues of a large number of small targets and targets with large aspect ratios in the dataset, the YOLO-NP detection model is proposed. It is based on the YOLO11 architecture and introduces customized anchor boxes for this dataset, the PPA attention mechanism, SPDConv, the LW feature fusion module with learnable weights, and the NWD loss function based on the Wasserstein distance to improve the detection performance of the

model. Experiments show that, compared with one-stage detection models in the YOLO series and their variants, two-stage detection model Faster-RCNN, and the RT-DETR detection model based on the Transformer architecture, the YOLO-NP has higher detection accuracy and a lower number of parameters.

Through on-site production tests, the image acquisition system in this paper can stably and efficiently acquire images, and the classification and detection algorithms can meet and exceed the requirements of the manufacturer. By coordinating the algorithms with PLC and robotic arms, this paper has achieved accurate processing of electrolytic nickel plates in a fully automated manner throughout the process, solving the problems of low efficiency and low accuracy of manual classification, improving the production efficiency and benefits of enterprises. The fully automated statistics of defect information also provide guidance for enterprises to improve the production process.

KEY WORDS: Image classification; Object detection; Electrolytic nickel plate

目 录

摘 要.....I
ABSTRACT.....III
第一章 绪论.....1
1.1 研究背景.....1
1.2 国内外研究现状.....2
1.2.1 基于机器学习与图像处理方法的工业产品图像分类.....2
1.2.2 基于深度学习的工业产品图像分类.....2
1.2.3 基于图像处理方法的工业制品表面缺陷检测.....4
1.2.4 基于深度学习的工业制品表面缺陷检测.....5
1.3 研究意义.....6
1.4 主要工作.....6
1.5 论文结构.....8
第二章 相关技术.....9
2.1 深度学习起源与发展.....9
2.2 基于深度学习的图像分类算法.....10
2.3 基于深度学习的目标检测算法.....11
2.4 图像采集系统.....11
2.4.1 镍板表面研究.....12
2.4.2 现有图像采集系统.....18
2.4.3 高质量图像采集系统.....19
第三章 基于 Nickel-Classifier 的电解镍板表面分类.....23
3.1 电解镍板表面等级分类数据集.....23
3.2 Nickel-Classifier 分类模型.....24
3.2.1 ResNet18 分类模型.....25
3.2.2 Nickel-Classifier 分类模型.....26
3.2.3 SE 注意力机制和 SE-ResBlock.....26
3.2.4 Light-head 特征粗提取结构.....27
3.2.5 CascadeCls 分类头.....29
3.3 实验和结果分析.....30
3.3.1 实验环境.....30
3.3.2 评价指标.....30
3.3.3 对比实验.....31

3.3.4 消融实验.....34
3.4 本章小结.....36
第四章 基于改进 YOLO11s 的电解镍板表面缺陷检测.....37
4.1 电解镍板表面缺陷数据集.....37
4.2 YOLO-NP 目标检测网络.....38
4.2.1 YOLO11 目标检测模型.....39
4.2.2 YOLO-NP 目标检测模型.....41
4.2.3 基于 K-means 聚类算法的锚框生成.....42
4.2.4 并行补丁感知注意力机制.....43
4.2.5 LW 特征融合模块.....44
4.2.6 空间深度转换卷积.....45
4.2.7 改进的 NWD 损失函数.....46
4.3 实验和结果分析.....48
4.3.1 实验环境.....48
4.3.2 评价指标.....48
4.3.3 对比实验.....48
4.3.4 消融实验.....52
4.4 检测结果可视化对比.....53
4.5 本章小结.....55
第五章 总结与展望.....57
5.1 总结.....57
5.2 展望.....57
参考文献.....59
致 谢.....67
攻读学位期间取得的创新成果目录.....69
作者学习经历.....71

第一章　绪论

本章节介绍电解镍板表面缺陷检测任务相关的研究背景与内容，包括研究背景、当前研究现状、研究意义、论文的主要工作内容和贡献。

1.1　研究背景

镍金属外观呈现银白色且带有光泽，凭借出色的硬度、耐腐蚀性与延展性，在建筑、军工、电镀、航空航天、电化学电池等多个产业广泛应用。在电解镍板的生产和保存过程中，因电解液成分复杂、工件处理不当、添加剂配比或运输、贮存、人为操作等因素导致电解镍板容易出现表面缺陷，影响产品外观和物理化学性质，进而影响产品性能，若用于关键领域还可能带来安全隐患，所以在电解镍产品出厂前，厂方技术人员会根据其表面特征，对其划分等级并处理不合格电解镍板。



图 1-1 人工剪板作业

Figure 1-1 Manual operation

一张标准电解镍板的尺寸为约 88cm 边长的正方形，重量相对较大，通常为 80kg 左右。目前，国内外镍制品生产企业在电解镍板处理方式上均采用人工搬运、分类、机组剪切方式，传统手工加工机组与自动化加工机组并存。国内还没有企业实现智能化、数字化剪切操作，对于电解镍板的剪切依据仍然依赖人眼检测。具体对单张电解镍板的剪切流程为：一摞电解镍板（约 2.25 吨左右）由叉车或天车移动至剪板机组边合适位置，由三到四人抬单张电解镍板至剪板机处，之后由一名经验丰富的工人用人眼对镍板表面缺陷进行判断，给出剪切位置后由三到四人移动镍板至剪切处进行剪切。此流程存在较多问题，最重要的是缺少了对镍板下表面的判断，厂房内光照不足，镍板下表面缺乏光照，对下表面的观察较

为费时费力，因此通常负责给出剪切方案的工程师不会低头观察镍板下表面信息；其次，整个流程需要较多人员配合（约八到十人），根据统计，每人每天搬运量达 110 吨左右，工人劳动强度高、身体损耗大，存在噪音污染；最后，随着时间持续，精力下降导致工作人员判断出现错误或偏差、标准不一致的问题。这些问题导致不能准确给出合理的电解镍处理结果，无法确保产品价值最大化。因此，寻找出一种准确高效的方法替代镍板手工分拣是很必要的。

1.2 国内外研究现状

目前，学术界和工业界还没有针对镍板的图像分类相关研究，但是，面向其他工业制品的分类任务已经有了大量研究与应用。在镍金属领域，图像分类相关研究以及针对镍板表面缺陷检测的研究均较为匮乏。目前，研究方向主要聚焦于运用传统方法开展镍板表面缺陷检测工作，而基于深度学习技术在该领域的应用则极为稀少。因此本节着重介绍前人基于传统机器学习方法和基于深度学习方法的工业品分类和缺陷检测研究，为电解镍板的分类和检测任务提供参考和理论支撑。

1.2.1 基于机器学习与图像处理方法的工业产品图像分类

传统图像分类方法通常采用图像处理技术和机器学习技术相结合。具体的，采用图像处理方法将图像统一调整为合适尺寸、引入如高斯滤波、中值滤波等各种滤波、降噪技术去除图像噪点；膨胀与侵蚀、Canny、Sobel 边缘算子等形态学计算提取图像特征；对于特征，采用基于机器学习的方法如 KNN 邻近算法、SVM（支持向量机）、BP 神经网络、MLP 多层感知器等方法实现图像分类。

目前，还未找到采用传统分类方法进行镍板及其衍生制品的研究文献，但是采用传统分类方法进行工业品分类已有较多研究。黄乐清等人针对工程机械项圈问题，构建由 500 个钢圈图像的数据集，采用灰度共生矩阵和 Canny 边缘检测方法提取钢圈图像的纹理和边缘信息特征，采用 SVM 作为分类器，最终实现了工程机械项圈的准确分类[1]。叶飞等人针对市面上常用人工鉴别法无法对多种类纤维进行识别分类的问题，使用传统方法提取 10 类纤维图像的灰度直方图、局部二值模式（LBP）、方向梯度直方图（HOG）、Hu 不变矩和灰度共生矩阵（GLCM）特征，将上述特征融合，然后使用 SVM 分类，最终对十类纤维实现了 85.8%分类准确率[2]。Pernkopf 等人针对鳞片覆盖的钢块上具有三维特征的表面缺陷，将钢块图像恢复深度图后，利用贝叶斯网络分类器针对提取缺陷的特征进行分类[3]。Ravikumar 等人面对不同背景下的机械零件表面图像，提出用直方图法提取特征、用改进决策树法进行分类的方法[4]。

1.2.2 基于深度学习的工业产品图像分类

在计算机科学领域，卷积神经网络呈现出迅猛的发展态势。在此背景下，基

于深度学习的图像分类方法凭借其卓越的性能，正逐步替代传统的图像分类方式。其在特征提取、分类精度以及处理复杂图像场景的能力上优势显著，推动图像分类技术革新。

在工业和制造业领域，胡坤等人针对工业生产中金属表面缺陷分类存在人力消耗大、效率不高等问题，提出改进的 VGG16 分类模型，以 VGG16 网络为基础，引入注意力机制 CBAM 和 Inception 网络结构，在 GC10-DET 和 NEU-CLS 两数据集上，相比其他经典分类网络实现了更优的分类性能[5]。王玲等人针对工业场景环境变化较大导致分类困难的问题，改进 CMT 架构和 Transformer 架构，在自制灌装桶数据集和公开的车辆零件数据集实现了更高的分类准确率[6]。王洪栋等人针对石油焦和冶金焦显微图像分类准确率低和小样本的问题，提出基于 ResNet 的石油焦与冶金焦图像分类模型，模型能够准确区分 2 种焦炭类型，且鲁棒性较好[7]。张瑞面向贴片元器件机器视觉质检挑战大的问题，使用动态模糊、旋转等方法做图像增强，融入多尺度特征融合方法改进 Swin Transformer 模型，对六类缺陷实现分类，分类准确率高达 82.83%[8]。于晓亮等人面对航空机载成附件检测性能较低的问题，引入分类算法，提出基于空间注意力的改进 WS-DAN 细粒度图像分类算法对航空机载成附件进行错漏装识别[9]。陈晓雷等人针对半导体制造中，混合型晶圆缺陷分类准确性不足的问题，提出一种改进的分类网络 MLG-Net，通过融合晶圆缺陷图像的全局语义信息与局部细节特征，提升分类精度，在包含 38 种混合类型缺陷的数据集上进行实验，分类准确度达到 98.84%[10]。王前等人针对铝材表面缺陷不明显、尺度差异大导致类别难识别的问题，运用多尺度特征聚合强化浅深层特征交互融合和 GAM 注意力机制加强对全局特征信息关注，相较于 ResNet 有更强的分类性能[11]。云晗等人针对常规涡流检测阻抗平面分析法无法识别不锈钢焊管缺陷种类的问题，对获取的涡流信号做短时傅里叶变换，转化为二维时频图，然后使用 SIFT 对时频图做特征提取，再把时频图输入 VGG-16 和 GoogleLeNet 两种神经网络训练模型做对比，得出 VGG-16 分类性能更优的结论，实现了焊管缺陷的分类识别[12]。余光海等人针对废旧电路板表面缺陷，提出一种基于改进 ResNet34 的深度学习分类方法，在 ResNet34 模型基础上引入 CBAM 注意力机制，提高了废旧电路板表面 5 种缺陷的分类准确率[13]。熊政等人面对热轧钢带缺陷分类问题，在 MobilenetV3 网络上剪枝、引入置换注意力机制、更换激活函数等改进，使模型参数量、训练时间有所降低，并且在 NEU–CLS 数据集上分类准确率更高[14]。福建商学院的陈晓桐构建了 50000 张铝制品表面缺陷数据集，并用 AlexNet 实现特征提取与准确分类[15]。

遥感图像领域，西安工程大学的刘宝宝等人针对遥感图像类间差异小的问题，提出一种基于注意力的深度可分离多尺度扩张特征融合网络的遥感图像场景分

类模型，实现了较高的分类准确率同时具有较低的参数量[16]。长安大学的刘怡等人设计一种多尺度异构跨模态注意力网络，实现了单源遥感数据和多源遥感数据联合分类[17]。军事科学院的刘勇等人提出一种改进 YOLOv5 算法，实现对多光谱卫星遥感图像地物分类[18]。

医学图像领域，吉林大学的崔宇琛等人将 ViT-B 模型引入至口腔良性和恶性病变图像分类中，实现 91%的分类准确率[19]。南方医科大学的刘沐然等人提出基于多视角投影和 Transformer 的牙齿分类方法，实现对全年龄层 CBCT 牙齿图像的 52 分类[20]。冯敬文等人将 VGG19、EfficientNet 和 CeiT 模型引入中药饮片分类中，实现对 248 个不同品牌饮片的准确分类[21]。江苏科技大学的陈诺等人设计了结合鲸鱼优化算法和 GC 注意力模块的 EfficientNet 分类模型，解决了乳腺癌超声图像中恶性肿瘤和良性肿瘤难以区分的二分类问题[22]。安徽理工大学的方燕燕等人提出一种基于多尺度特征提取与融合和多层感知机的 Resnet18 模型，实现对胸部 X 光图像的分类[23]。

在其他领域，也有诸多专家学者对多种模态图像分类进行研究，Yang 等人以道路实时拍摄图像为主，辅助结合气象和温度数据，实现多模态输入对道路冰雪覆盖情况准确分类[24]；Ullah 等人的综述文章中，基于高光谱图像分类已应用于大气、农业生产、地下水、生物等多个领域[25]；Ai 等人针对 SAR 采集图像数据，将中央坐标注意力模块引入卷积神经网络中，实现 SAR 目标的分类[26]；Lei 等人针对侧扫声纳图像，引入基于图的分类网络实现声纳图像分类[27]。

1.2.3 基于图像处理方法的工业制品表面缺陷检测

随着成像设备硬件素质的提升、计算机处理硬件的发展和软件算法的逐步研究，基于图像处理的检测技术逐步取代人工检测。通常，基于机器学习的检测技术依赖人工设计的特征提取，通常经过图像预处理、边缘提取、形态学运算和基于缺陷性质的特征提取器设计等步骤。

针对电解镍产品的缺陷检测问题，2024 年兰州理工大学的李建华等人基于传统的图像处理方法，设计了自适应阈值的 Ostu-Canny，利用双边滤波使图像去噪保边，设计一种增强梯度的掩模和 Sobel 算子组合以增强边缘梯度，提升了镍板缺陷检测的效果[28]。同年，昆明理工大学的朱正云等人基于机器视觉搭建了一种镍板表面缺陷检测装置，使用机器学习的方法，通过分段线性灰度变换抑制不感兴趣区域，其次对 G 通道分量进行自适应阈值分割、形态学处理等提取气孔区域，然后图像作差提取出极小值标记，以极小值标记的质心计算距离图并分水岭分割，获得更准确的气孔分割效果[29]。

在其他工业制品的检测领域，张新娜等人设计一套凸轮轴表面检测系统，使用最大类间方差法（otsu）提取凸轮轴感兴趣区域，结合形态学梯度的 Canny 算

子实现凸轮轴缺陷检测，实现了最低 98.11%的检测准确率[30]。李鑫等人针对焊缝表面缺陷检测问题，采用统计滤波、改进分割方法、二次聚类等传统机器学习算法。实现 97.48%的缺陷识别准确率[31]。仓传跃等人面对注塑制品熔接线缺陷，提出一种利用骨架提取和斜率判断的熔接线检测方法，用形态学运算、高斯滤波和二值化预处理，然后进行模板匹配、骨架提取和仿射变换的方式分割出缺陷区域，最后用 Canny 算子提取边缘，利用直线斜率判断的方式检测缺陷区域，算法实现 97.8%的检测准确率[32]。王艺斌等人针对卷烟包装纸缺陷问题，设计一种结合图像差分、图像梯度、灰度信息融合及自适应阈值分割等图像处理技术的检测算法，在噪声和光照变化下具有较高检测精度[33]。钱厚亮等人为解决传统人工检测不同规格纽扣准确率低、效率低的问题，采用双边滤波、OTSU 阈值分割、Canny-Otsu 边缘检测预处理图像，再对阈值分割图像检测内孔数量，用 Hu 不变矩检测外轮廓瑕疵并匹配类型。实现 96.85%的检测准确率[34]。潘盛辉等人设计一种基于机器视觉的铝巴表面缺陷检测系统，通过阈值分割、形态学处理、选取合适特征值和特征向量进行特征提取，检测铝巴缺陷，实现 0%误检率且相比人工处理省时 26min[35]。

1.2.4　基于深度学习的工业制品表面缺陷检测

传统机器学习方法依赖图像色彩或纹理特征，需要针对特定特征设计特定的特征提取流程，泛化性较差，对于特征复杂、形状、尺度差异较大的检测任务时检测性能较差。近年来，深度学习技术持续迭代，取得了一系列突破性进展。基于深度学习的目标检测技术在这一浪潮中展现出极为突出的优势，其泛化性能卓越，能够在不同场景和数据分布下保持良好的检测效果；同时，适应性也极为强大，可灵活应对各类复杂多变的检测任务。在此推动下，基于深度学习的工业检测领域涌现出大量的研究成果，并在实际生产中得到了广泛应用，极大地提升了工业检测的准确性、效率与智能化水平。

将深度学习方法引入镍板缺陷检测的相关文献仅有一篇。2024 年，长沙矿山研究院的潭沁源等人将 YOLOv5 引入镍板缺陷检测，构建带有大片结粒、烧板、水印三种缺陷的数据集，引入 K-means++锚框聚类算法、CBAM 注意力机制和 EIoU 损失函数提升模型检测性能[36]。

在工业检测领域，林永春等人针对彩涂钢板表面缺陷检测的问题，使用图像增强、高斯滤波和直方图均衡化等传统图像处理方法提取缺陷感兴趣区域构成数据集，然后使用 VGG 分类模型训练，实现了彩涂钢板表面三种缺陷的检测[37]。宋涛等人专注于钢板缺陷检测，采用卷积神经网络（CNN）在每个阶段生成特征图，然后设计多级特征融合网络进行多级特征融合，在自建数据集上 mAP 达到 84.6%、在单个 GPU 上检测速度达到 31 英尺/秒[38]。张耕培等人设计了一种高效

的石油管具内螺纹缺陷检测图像采集系统，引入 YOLOv8 检测石油管具内螺纹缺陷，解决了狭小空间、光线不足的条件下检测困难的问题[39]。张茹等人面对木材加工过程中的表面缺陷问题，引入并改进 YOLOv5s 算法，利用 ShuffleNetV2 轻量化模块降低计算成本和参数量；主干网络插入 SimAM 注意力增强语义联系；采用 DIoU 损失函数提升鲁棒性，改进后的网络在模型参数量大幅下降的条件下实现更优异的检测性能[40]。刘国民等人针对铝型材表面缺陷检测精度和效率低的问题，引入提出基于 Yolox 深度学习的检测方法，达到 90%的检测准确率[41]。王大维针对汽车冲压工艺中，经常会出现开裂、毛边等多种缺陷，设计了自适应预训练的特征块分布建模缺陷检测网络，在 ImageNet 预训练模型上设计了自监督任务仅使用正常样本对预训练的网络模型进行微调，并基于提取特征计算多元高斯分布，计算其与正常样本多元高斯分布的距离，以实现缺陷检测，解决了项目初期因缺乏缺陷数据，无法充分训练有监督的网络模型进行缺陷检测的问题，在冲压件数据集和公开数据集 Kolektor SDD 都表现了良好的检测效果[42]。张玉对管道缺陷进行识别检测时，引入可变形卷积网络至 RetinaNet 主干网络，在模型颈部和主干之间引入空间和通道注意力自适应地选择需要关注的特征，最后在基于 CPU 的算力支持下实现了较高的检测精度[43]。

1.3 研究意义

在镍板制造领域中，传统的人工检查、手动分拣方式由于效率低下、分拣无标准、标准不一致等问题，非常影响企业效益。另外，根据本文对国内外基于工业制品的图像分类和缺陷检测的研究现状，有关镍板图像分类的研究几乎为零，镍板表面缺陷检测和识别的研究也集中在用传统基于图像处理方法来识别镍板表面一种或几种缺陷，而基于深度学习的方法也仅能识别大面积结粒、烧板、水印这三种缺陷。

因此，镍板处理领域仍有很大研究空间，本研究将深度学习的方法引入至镍板分类和检测当中，将完全替代镍板处理的人工操作，联合 PLC、机械臂实现全过程自动化，本研究是工业检测、分类领域的又一重要应用，填补深度学习和计算机视觉在镍板领域应用和研究的空缺。本研究能够帮助企业提升生产效率，为企业后续的智能化、自动化升级提供参考依据和宝贵经验，解放人工重体力劳动、释放了生产力。

1.4 主要工作

本文针对电解镍板处理问题，同厂方专家探讨，设计自动化方案处理电解镍板，与 PLC、机械臂联动，实现高质量数据采集，高准确性镍板图像分类和表面

缺陷识别，最终实现了电解镍板的准确处理。具体算法方案如图 1-2 所示

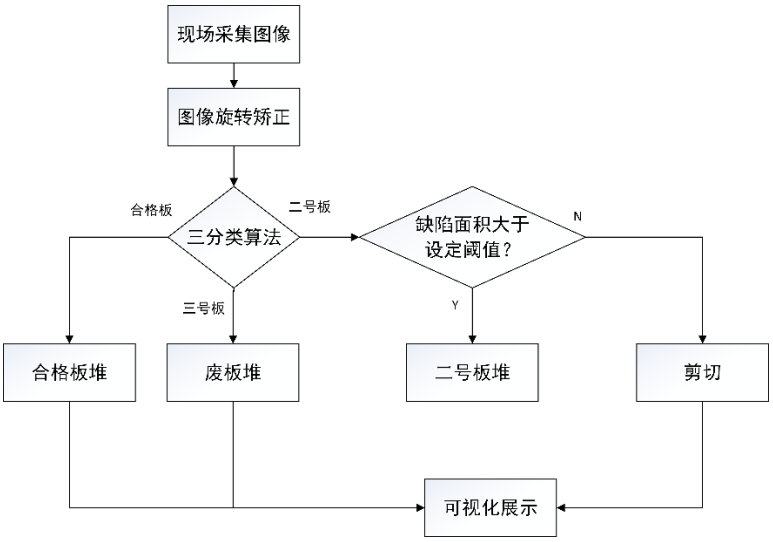


图 1-2 镍板处理流程图

Figure 1-2 Flow chart of nickel plate operation

本文主要工作分为如下四部分：设计高质量镍板图像采集系统；构建电解镍板等级分类和表面缺陷两个数据集；引入基于深度学习的 Resnet18 分类网络并改进；引入 YOLO11 一阶段目标检测算法并改进。主要工作具体如下：

设计高质量镍板图像采集系统：本文根据镍板表面亮度差异大、缺陷形态多样、色彩丰富的特点，引入合适的线扫相机和线光源，使用接近式传感器作为成像触发装置、线扫相机和线光源打光相配合，实现高质量、稳定的电解镍板图像采集。此图像采集系统解决了厂里其它系统存在的光学污染、过曝、成像不全等问题，在高效获取高质量图像数据的同时，还有较小的内存占用。

构建数据集：本文将高质量镍板图像采集系统安装在金川集团产品配送中心，采集来自于各种生产车间的高质量镍板图像数据共 5376 张，本文从中挑选出 2331 张典型镍板图片，同厂方技术专家探讨，分类，构建电解镍板表面等级分类数据集；本文从所有图片中选出 1195 张，同专家共同标注，构建含有 13 种类别、16650 个缺陷框的电解镍板缺陷数据集。

电解镍板表面等级分类：本文首次将基于深度学习的分类方法引入电解镍板分类任务中，本文设计了 Nickel-Classifier 分类模型，其基于 ResNet18，引入 SE 注意力机制、全新设计的 Light-head 模块和 CascadeCls 分类头，实现电解镍板的准确分类。

电解镍板表面缺陷检测：本文针对电解镍板表面缺陷尺度差异大、复杂度高、色彩丰富的特点，提出 YOLO-NP 一阶段目标检测模型，其模型结构基于 YOLO11，引入基于本研究数据集的锚框，主干网络中引入 PPA 注意力机制，模型颈部引入全新设计的 LW 特征融合模块与 SPD 卷积，损失函数改进为包含 Wasserstein

距离信息的损失函数，大幅度提高模型对电解镍板表面细小缺陷和高长宽比缺陷的检测效果。

1.5 论文结构

本论文分为以下五章节进行，各章节内容安排如下：

第一章节介绍电解镍板表面缺陷检测任务相关的研究背景与内容，包括镍板处理背景、基于传统图像处理和深度学习方法的图像分类和检测的研究现状、研究意义、论文研究内容和论文的结构。

第二章节介绍本文后续算法研究的背景知识和算法基础、镍板表面缺陷研究和高质量镍板图像采集系统的搭建。

第三章节介绍电解镍板分类任务、分类模型的算法优化。首先介绍电解镍板分类数据集，然后介绍 Nickel-Classifier 分类网络，与其他经典分类算法相比较，实现了优异的分类性能。

第四章节介绍电解镍板表面缺陷检测任务、检测模型的算法优化。首先介绍电解镍板缺陷检测数据集，然后介绍针对此数据集设计的 YOLO-NP 检测模型，与原始 YOLO11 模型、其他基于锚框的经典检测模型和 Transformer 架构模型相比，有更高的检测精度。

第五章节对本文的研究内容和贡献做出总结，对未来可优化问题做出展望。

第二章　相关技术

本章介绍本文研究使用的基础理论和图像采集系统。基础理论包括深度学习起源与发展、基于深度学习的图像分类和目标检测算法。图像系统采集部分包括镍板表面缺陷介绍、工厂现有图像采集系统分析和本文图像采集系统结构和采集过程。

2.1　深度学习起源与发展

深度学习作为机器学习的一个重要分支，其起源与发展是一个充满创新和突破的过程，最早可以追溯到 20 世纪 40 年代。1943 年，McCulloch 等人提出了 MP 神经元模型，这是一种模仿生物神经元的简单数学模型，标志着神经网络研究的开端[44]。20 世纪 50 年代，神经网络研究取得了新进展，1958 年，Rosenblatt 提出了感知机模型，它是一种简单的线性分类器，可以通过学习来调整权重以实现对数据的分类，被认为是最早的神经网络学习算法之一[45]。然而，1960 年代末到 1980 年代中期，深度学习发展受到限制。1969 年，Minsky 等人指出感知机只能处理线性可分问题[46]，这一观点对当时的神经网络研究造成了重大打击，使得神经网络的研究进入了低谷期。同时，当时计算机性能有限，无法满足神经网络对计算资源的需求，也在一定程度上限制了相关研究的进展。

到了 20 世纪 80 年代开始，深度学习迎来了复苏与发展。1986 年，Rumelhart 等人提出了反向传播（Backpropagation）算法，解决了多层神经网络的训练问题，使得神经网络能够学习更复杂的函数，引发了神经网络研究的第二次高速发展[47]。这一时期，还出现了多种神经网络模型，如双向联想记忆网络（BAM）[48]、卷积神经网络的早期雏形[49]、递归神经网络（RNN）[50]等，在语音识别、图像识别等领域取得了一定的成果。

1990 年代至 21 世纪初期，深度学习研究较为缓慢。随着支持向量机（SVM）等[51]机器学习方法的兴起，在一些基准数据集上表现出了比神经网络更好的性能，使得神经网络的研究热度再次有所下降。这一阶段，神经网络的研究主要集中在对现有模型的改进和优化上，如引入正则化方法、改进训练算法等，为后续的突破奠定了基础。

2006 年至今，深度学习实现了爆发式增长与突破。2006 年，Hinton 等人提出了深度信念网络（DBN）[52]，并提出了无监督的预训练方法，为训练深度神经网络提供了一种有效的策略，开启了深度学习的新时代。2012 年，Krizhevsky 等人提出的 AlexNet 在 ImageNet[53]图像分类竞赛中取得了巨大成功，证明了深度学习在处理大规模图像数据方面的强大能力，引发了深度学习的爆发式增长[54]。

此后，各种深度学习模型和算法不断涌现，卷积神经网络在图像识别领域不断刷新精度记录；基于 LSTM[55]、GRU[56]的改进的递归神经网络在自然语言处理、语音识别等序列数据处理任务中表现出色；生成对抗网络（GAN）[57]、变分自编码器（VAE）[58]等无监督学习模型为图像生成、数据降维等任务提供了新的思路和方法。

在执行复杂任务过程中，深度学习模型往往需要处理海量的数据信息。而注意力机制在此发挥着关键作用，它能够引导模型自动将关注点聚焦于输入数据里的核心部分，有效筛选并忽略那些无关紧要或相对次要的信息。通过这种方式，模型得以在复杂数据环境中精准提取关键特征，从而显著提升处理复杂任务的效率与准确性。注意力机制最早可追溯到计算机视觉领域，旨在让模型聚焦于图像的重要区域[59]。在自然语言处理中，早期的注意力机制主要用于机器翻译等任务，2014 年 Bahdanau 等人提出的注意力机制，使得机器翻译模型在生成目标语言时能够动态地关注源语言的不同部分，提高了翻译质量[60]。2017 年，Vaswani 等人提出了 Transformer 架构，其摒弃了传统的循环神经网络和卷积神经网络，完全基于注意力机制，为自然语言处理任务带来了新的思路和方法，大大提高了并行计算能力和长序列处理能力[61]。随着 Transformer 的提出，注意力机制得到了更广泛的关注和深入研究。Transformer 中的自注意力机制（Self-Attention）能够并行计算文本序列中每个位置与其他位置的依赖关系，大大提高了模型的效率和性能。此后，注意力机制不断发展，出现了多头注意力机制（Multi-Head Attention）、全局注意力机制[62]、图注意力机制[63]等多种变体，以适应不同任务和数据的特点，在自然语言处理、计算机视觉、语音识别等多个领域都取得了巨大成功。

2.2 基于深度学习的图像分类算法

近年来伴随着深度学习的兴起，计算机视觉所涵盖的众多领域逐步进入人们的视野并广泛应用于实际场景。其中，图像识别技术的相关研究与应用取得了尤为突出的进展。自 2 世纪中叶起，图像分类技术在计算机视觉领域便踏上了快速发展的征程，历经多年的技术迭代与创新，不断拓展其应用边界，如今已在众多行业中发挥着不可或缺的重要作用[65]。近几年人工智能网络和算力设备的快速发展，图像分类技术被专家学者研究并广泛应用。基于深度学习的图像分类算法可被分为基于 CNN 和基于 Transformer 架构两种。

随着深度学习技术的快速发展，基于卷积神经网络（CNN）的图像分类算法取得了巨大的成功。LeNet-5[64]是最早的成功的卷积神经网络之一，网络通过两组卷积、池化层和三个全连接层组成，在手写数字识别（MNIST 数据集）上取得了很好的效果，验证了卷积神经网络在图像识别领域的可行性。

后来又相继出现 AlexNet[54]、VGG[66]、ResNet[67]、EfficientNet[68]等模型，它

们被广泛应用于遥感、医疗、工业制造和日常场景的分类任务中。

Transformer 架构首先被应用于自然语言处理任务并展现出巨大优势。2020 年 10 月，Dosovitskiy[69]等人提出一种完全基于自注意力的模型 ViT,首次将纯 Transformer 架构应用于图像分类任务，取得当年最优分类效果。但是，纯 Transformer 模型存在数据需求大、局部信息缺失、计算复杂度高、位置编码方式灵活性差等问题。根据模型机制与结构特点，将基于 Transformer 的图像分类方法划分为结合 CNN 的混合 Transformer、局部性增强的 Transformer、多尺度序列交互的 Transformer、融合深层思想的 Transformer 网络与改进位置编码的 Transformer 网络 5 类算法[70]，如在编码器引入前馈神经网络的 DeiT[71]，卷积增强的 CeiT[72]，借鉴了 CNN 架构设计思想的 T2T-ViT[73]，引入移动窗口和层次特征提取结构的 Swin-T[13]，设计全新的交叉注意力和双分支结构的 Cross-ViT[74]。

2.3　基于深度学习的目标检测算法

目前，基于深度学习的目标检测算法可以分为 CNN 架构和 Transformer 架构，基于 CNN 架构的检测器可分为一阶段和二阶段两大类。一阶段检测器通过一个单一的神经网络直接预测图像中的目标类别和位置，代表算法有 YOLO[75-85]系列和 SSD[86]。二二阶段检测算法一般分两个阶段，先生成可能含目标的候选区域，再对候选区域精确分类与定位，检测精度高但速度相对较慢。代表算法有 R-CNN[87-90]系列。相比二阶段检测器，一阶段方法不需要额外的区域提案步骤，因而在速度上更有优势。一阶段检测器结构简单，易于部署，适用于对实时性要求较高的场景，例如无人驾驶、实时监控、视频分析等。二阶段方法由于在候选区域生成后再进行分类和回归，能够更精确地定位目标，同时候选框生成器可以针对小物体进行专门的处理，因此在检测小目标时比一阶段检测器具有优势，但是相应的优势是以牺牲了检测速度的代价换来。基于 Transformer 的检测器利用自注意力机制来自动学习图像中不同区域的重要性，无需像传统方法那样依赖手工设计的特征提取器。它可以直接处理图像的序列表示，通过编码器-解码器结构对图像中的目标进行定位和分类。这种检测器在处理复杂场景下的目标检测任务时表现出色，能够更好地处理遮挡、多尺度目标等问题，具有较高的检测精度和鲁棒性，为目标检测技术的发展提供了新的思路和方法。

2.4　图像采集系统

在设计视觉成像系统前，本文观察若干张不同品级的电解镍板实物，也研究了工厂现有图像采集系统，然后设计高质量镍板图像采集系统，在满足成像质量的同时，解决了工厂现有图像采集系统的成像痛点。

2.4.1 镍板表面研究

本文研究数千张不同品级的电解镍板样品，电解镍板缺陷种类多，形态学和色彩信息复杂，前人研究经验较少，为电解镍板缺陷检测任务带来巨大挑战。电解镍板表面缺陷介绍如下：

（1）污渍缺陷

污渍缺陷包含划痕、油墨油污和脚印手印缺陷。划痕缺陷产生原因是在镍板从生产车间运输到生产车间中摩擦碰撞导致的，缺陷形状不一，既有面积较大的长条状划痕、也有面积较小的块状和点状划痕，颜色呈现亮银白色或黑色。油墨与油污缺陷是在镍板传送及运输过程中，因操作不当或设备老化，导致镍板与生产设备发生不当接触，而表面产生油墨及油污。油墨污渍为黑色，呈长条状或散点状。油污污渍为深灰色，常呈散点状出现，少数情况下会出现较大面积的油污点。手印和脚印为工人操作不当导致的。



图 2-1 污渍缺陷样例图

Figure 2-1 Samples of the Stain Defect

（2）水渍缺陷

水渍缺陷是由于在镍板的电解后中会有酸液残留或者运输中水滴污染，风干后在镍板表面留下印记，该缺陷形状和大小不一，主要表现是在镍板表面上留下线状、片状和环状灰黑色条纹，按严重程度分为普通水渍和严重水渍。



图 2-2 水渍缺陷样例图

Figure 2-2 Samples of the Waterstain Defect

（3）边部结瘤缺陷

结瘤缺陷是发生在镍板边缘处的缺陷，由于在制造过程中压力不均匀或有一侧压力过大导致，或快速加热、冷却镍板时，镍板边缘加热或冷却速度与中心部分速度不一致而导致。边部结瘤缺陷表现为镍板边部出现凸起、膨胀或突起的现象。



图 2-3 边部结瘤缺陷样例图

Figure 2-3 Samples of the Nodule Defect

（4）气孔缺陷

气孔缺陷的产生主要是由于在电解的过程中，电解液中的气泡附着在阴极板的表面无法脱离，新生长出来的金属镍会将气泡整个包裹进去，形成一个中空的金属泡，气泡的表面外形近似为圆形，大小不一分布不均，小的气孔直径会在0.1mm 左右，大的直径在 1mm 上下，一般正常气孔是成片并较密集出现，颜色与镍板正常区域基本一致。但是气孔缺陷也会伴随着烧灼缺陷存在，气孔缺陷与烧灼缺陷交错融合在一起，致使气孔缺陷颜色也变成了灰黑色。

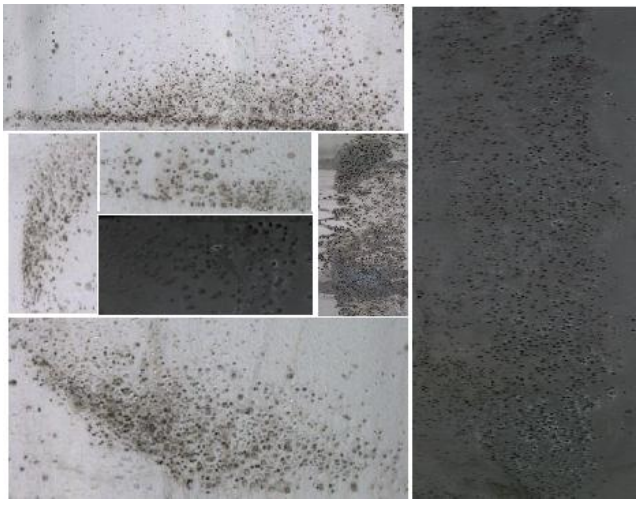


图 2-4 气孔缺陷样例图

Figure 2-4 Samples of the Airhole Defect

（5）结粒缺陷

结粒缺陷产生于电解作业阶段。电解作业时，空气中的尘埃、灰渣等杂质，会通过各种途径落入阴极室并吸附在阴极板表面。随着电解反应持续进行，当电解完成后，在吸附了尘埃、灰渣的阴极板位置，会逐渐覆盖上一层金属镍，外观表现为结粒。凸起的表面外形近似圆形，其内部实心，凸起的大小不一，凸起直径在 2-10mm 之间，既有聚集分布又有个别单独存在，正常凸起缺陷颜色与镍板正常区域颜色是差不多的，但是会在运输过程中经过挤压等原因，部分结粒顶部颜色也变为灰黑色。



图 2-5 结粒缺陷样例图

Figure 2-5 Samples of the Bubble Defect

（6）疙瘩缺陷

疙瘩缺陷的产生原因与结粒相似。但是，疙瘩的形状与结粒不同，疙瘩大小不一，表面积通常比结粒大，且形状各异，通常为近似圆形或近似椭圆形。疙瘩的颜色通常为黑色。

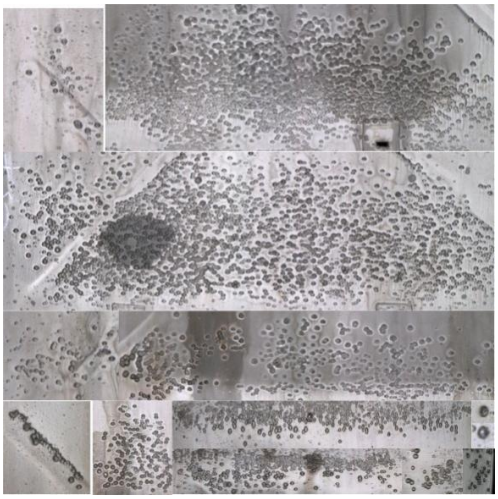


图 2-6 疙瘩缺陷样例图

Figure 2-6 Samples of the Bump Defect

（7）烧灼缺陷

烧灼缺陷的形成，主要归因于电解过程中的电流异常现象。当电解作业进行时，若出现电流过大的状况，大量电能会迅速转化为热能，导致热量在阴极板局部区域急剧聚集。这种过度集中的热量对阴极板表面产生灼烧效应，进而形成烧灼缺陷。该缺陷的位置呈现出随机性，并无固定规律可循，既可能出现在镍板边缘，也有同等可能性分布于镍板中心区域。从外观特征来看，灼烧缺陷区域与正常区域有着显著区别，正常区域呈现银灰色，而灼烧区域则为灰黑色或青灰色，灼烧区域的形状主要片状，形状和大小不固定，且尺寸差异大，可以只有很小的区域，也可以占到整个板面面积的 80%以上。

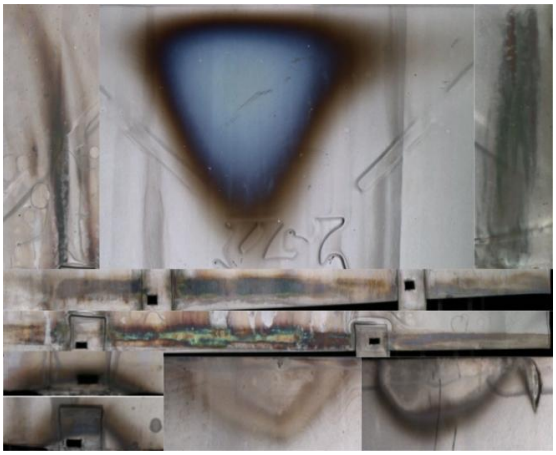


图 2-7 烧灼缺陷样例图

Figure 2-7 Samples of the Overfire Defect

（8）绿色结晶缺陷

绿色结晶是镍板中铜元素析出，产生这种缺陷的原因是粗镍处理的不彻底，其中含铜元素较多，导致在电极的过程中，铜元素在阴极板析出，形成中间是绿色的铜结晶，周围呈灰色的铜析出缺陷。

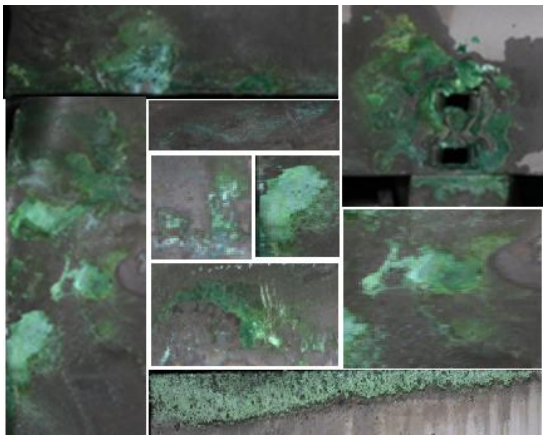


图 2-8 绿色结晶缺陷样例图

Figure 2-8 Samples of the Greenstain Defect

（9）酸污染缺陷

酸污染缺陷是镍板在电解或酸洗工艺后，若清洗不彻底（如冲洗水量不足、时间过短），残留的硫酸、盐酸等酸性物质会继续腐蚀镍板表面造成的缺陷。亦或是酸洗后若未使用碱性溶液（如碳酸钠溶液）充分中和，残留酸液会在干燥过程中浓缩，导致局部腐蚀。酸污染缺陷通常有较为丰富的颜色，缺陷面积占比较大。



图 2-9 酸污染缺陷样例图

Figure 2-9 Samples of the Acid Pollution Defect

（10）缺角缺陷

缺角缺陷常出现在镍板四周，通常和镍板制作过程中电流密度、电解液流动等工艺流程有关。



图 2-10 缺角缺陷样例图

Figure 2-10 Samples of the Miscorner Defect

（11）严重水渍缺陷

严重水渍和一般水渍以缺陷表面颜色区分，严重水渍颜色较深，呈黄褐色、五彩色或黑色，严重水渍颜色与烧灼缺陷相近，不同之处在于水渍缺陷大多数是线状或环状、且有明显的边界。



图 2-11 严重水渍缺陷样例图

Figure 2-11 Samples of the Watermark Defect

总体而言，如图 2-12 所示，同一品级的电解镍板表面亮度之间差异较大，缺陷在形态学和颜色上有所不同。从颜色角度分析，有些缺陷是绿色或黄色，有些是暗黑色，有些镍板整体发白，有些颜色偏暗；从缺陷形态学分析，不同缺陷相互叠加、一些缺陷表现为密集小点，颜色表现为与其周围区域无差异。

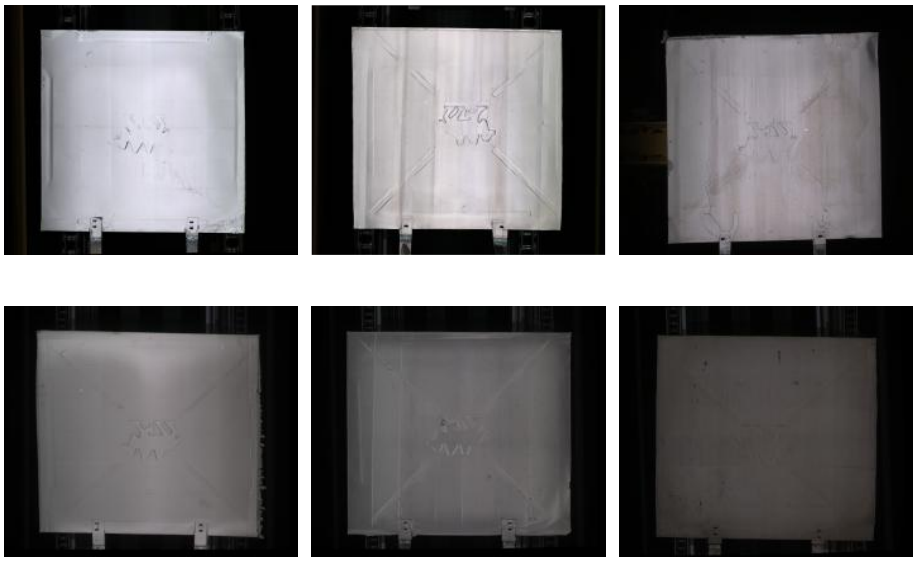


图 2-12 A 品级样例图

Figure 2-12 Samples of the grade A nickel plates

经过此研究，本文对不同品级电解镍板表面的颜色和形状特征有较深的理解，对厂方技术人员对电解镍板的分类依据已有大致掌握，也对成像设备的硬件条件有所明晰。

2.4.2 现有图像采集系统

图 2-13 展示了工厂当前使用的一套视觉成像系统。该系统由一个机械臂、PLC、面阵相机和光源组成。机械臂负责吸取镍板并移动，当机械臂移动至相机上方时，PLC 发送触发信号以激活光源，照亮镍板，随后相机拍摄图像。接下来，捕获的图像通过算法进行处理，提供边部结瘤缺陷的分析结果。机械臂的移动距离和速度通过软件控制，移动特定单位后停止移动。

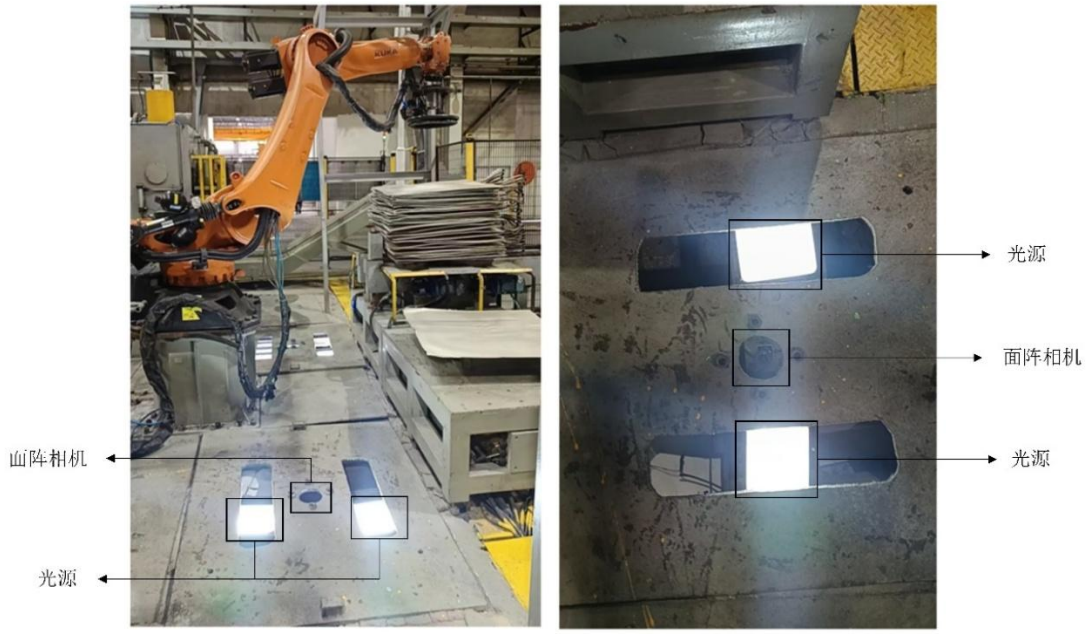


图 2-13 现有成像系统和其相机

Figure 2-13 Existing Visual System and Its Camera



图 2-14 现有视觉成像系统采集样品图

Figure 2-14 Samples Collected by the Existing Visual System

图 2-14 展示了视觉成像系统采集的样本。针对此系统，本文发现系统存在

六个问题，按严重程度排序如下：

（1）光学污染：所有捕获的镍板图像都受到来自厂房天花板大灯的光学污染影响。

（2）不均匀照明：由于合格电解镍板表面光洁，反光度较高，不均匀的照明导致镍板表面亮度不一致，导致过度曝光和图像失真。

（3）触发机制缺陷：由于机械臂的移动距离通过软件控制，当电解镍板上料位置和预期上料位置差别较大时会导致此图像采集系统未能捕获或仅能捕捉部分电解镍板图像。

（4）背景干扰：此采集系统背景干扰因素过多，可能会影响算法准确性，进而对成像系统的可扩展性和适应性产生了负面影响。

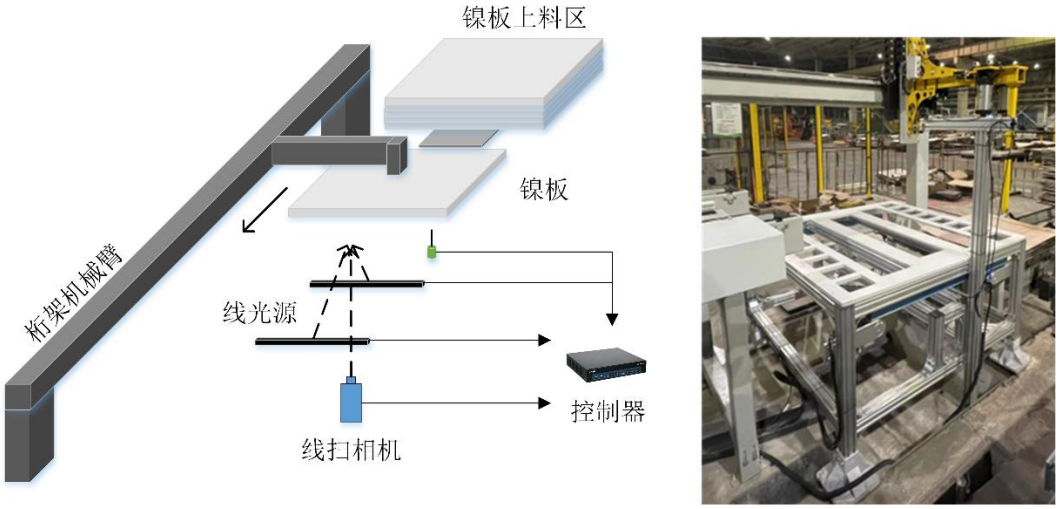
（5）效率低：机械臂在图像采集过程中经过运动-停止-运动的状态，不能保证整体流畅，这对生产效率产生了负面影响。

（6）可扩展性有限：捕获图像的质量是算法工程开展的关键。图像质量较低，阻碍了对镍板的准确分类，也无法进行未来电解镍板表面缺陷的检测。因此，采集系统难以与其他生产线进行集成。

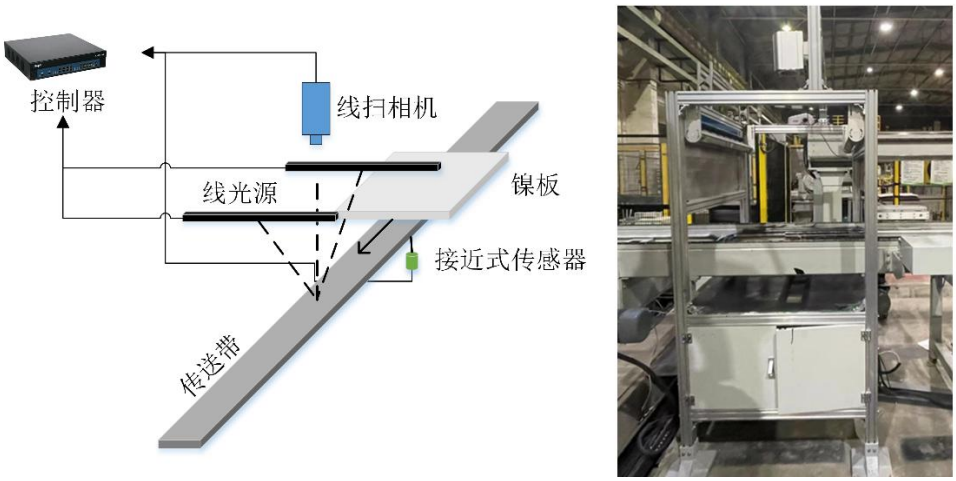
高质量的镍板图像影响表面电解镍板表面缺陷检测任务的下限，按照图 2-13 所示采集的样本无法进行算法开发和模型调试工作，因此设计一套高质量图像采集系统有很高必要性。

2.4.3　高质量图像采集系统

基于电解镍板表面特性研究和现有视觉系统的不足，本文设计了以线扫相机为核心采集设备的高质量镍板图像采集系统。此面向工业镍板检测场景的高质量镍板图像采集系统采用线扫相机与接近式传感器的协同架构，实现高效动态成像。



(a) 下表面图像采集系统



(b) 上表面图像采集系统

图 2-15 高质量图像采集系统

Figure 2-15 Structure of the high quality nickel plate image acquisition system

注：下表面采集系统的线扫相机被安装在坑里，上表面的传感器安装在传送带之间，两台控制器放置在传送带下方的柜中。以上所说的四个设备在图中未能标出。

高质量镍板图像采集系统分为下表面采集平台和上表面采集平台。数据采集流程为：电解镍板从上料区传送带运送至桁架机械臂抓取范围，机械臂吸取镍板，伺服电机控制桁架机械臂水平方向以 350mm/s 匀速移动，经过下表检检测平台上方触发接近式传感器给出一高电平信号，灯光被触发开启，并激活线扫相机拍摄图像，桁架机械臂持续水平匀速运动，将电解镍板放置在下表面采集平台末端的传送带末端，至此下表面检测结束。随后，传送带末端气泵运行，通过硬件方式将镍板转正，之后传送带以 320mm/s 匀速移动，经过上表检检测平台上方，触发接近式传感器拍摄镍板图片，镍板运动至传送带另一端，等待机械臂抓取，至此，镍板上下表面采集结束。

下表面检测平台搭建：在地面下挖一 600mm 深坑，将线扫相机及其支架、保护罩放于坑中，镜头垂直于地面向上，镜头距离镍板运动路径垂直距离为 1600mm，在坑上方搭建相机和光源防砸架。接近式传感器则通过支架支于镍板运动轨迹上方 200mm 处。下表面检测平台简易图和实物图如图 2-14 所示。

上表面检测平台搭建：在传送带上方合适位置搭建支架，镜头位于支架顶端，镜头垂直于地面向下，镜头距离镍板运动轨迹为 1100mm，传感器安装于传送带下方合适位置，上表面检测平台不需要相机和光源防砸架表面检测平台简易图和实物图如图 2-15 所示。

电解镍板的图像采集通过线扫相机、接近传感器和线光源的协作来实现。线扫相机的核心是由一行像素组成的传感器，它一次只捕获一行像素数据。为了获得完整的图像，线扫相机需要与电解镍板协调移动。当相机固定不动，镍板在一

个方向上连续移动时，线扫相机会以高频率捕获多行像素数据，然后将这些数据合成形成完整的 2D 图像。与面阵相机相比，线扫相机通过适当调整采集时间可以避免图像采集不完整的问题。线光源提供均匀明亮的光束，匹配线扫相机的成像区域，确保高均匀性和亮度，特别适合电解镍板等高反射率物体。

电解镍板的准确分类依赖于颜色细节和缺陷的局部特征，这需要高分辨率和高色深的图像。因此，本文部署了 Teledyne DALSA CC-04K05 线扫相机和 Omron E3FA-DP22 接近传感器。线扫相机的行频设为 889Hz，图像分辨率为 4096×10662，色深为 16 位。当电解镍板在输送带上移动到接近传感器下方时，光线变化触发传感器发送高电平信号，从而触发线扫相机拍摄图像。

与原有视觉成像系统相比，本文设计的高质量图像采集系统有效解决了光学污染问题。基于接近式传感器的触发机制能更精准地把握图像采集时机，同时对拍摄时机的控制也更加灵活，例如当接近式传感器由于外界因素发生偏移时，只需在人机交互界面根据图像采集结果，随后手动微调传感器位置即可，在确保系统鲁棒性的同时，显著降低了对传统机械复位的依赖度，运维复杂度明显降低。此外，本系统采用的线扫相机在高质量硬件素质的同时，图像采集过程中无需降低或暂停生产线运行速度，保障生产连续性，提高镍板生产效率。

表 2-1 两台图像采集系统采集图像属性对比

Table 2-1 Comparison of the Attributes of the Images Collected by Two System

	高质量图像采集系统	原有系统
分辨率	4098×3554	5470×3648
色深	24	24
存储占用	9.24MB - 12.5MB	55.5 - 58.0MB

从图像采集质量角度，表 2-1 对比展示了本文设计的高质量图像采集系统与工厂原有系统所获图像的属性特征。结果表明，新系统能以相对较低的分辨率获取更高质量的图像，且单幅图像的存储需求更小。

第三章　基于 Nickel-Classifier 的电解镍板表面分类

企业生产的电解镍板，按照其表面缺陷情况分为三种，合格板、缺陷板和三号板。目前行业内对电解镍板分类完全依赖人工，自动化或智能化尚未完全实现。人工检测不仅效率低下，而且检测结果会受到多种因素影响而不稳定，例如人的状态、光线影响、不同检测人员的标准不同等因素。此外，人工判断会导致检测员用眼过度，脑力和体力工作强度大，导致分类结果出现错误。

本章针对以上问题，将基于深度学习的分类方法引入电解镍板表面分类任务中。具体的，本章建立了由 2123 张高质量电解镍板表面图像构成的电解镍板表面分类数据集；以 ResNet18 为基础，设计一种面对电解镍板表面分类任务的分类网络 Nickel-Classifier。针对数据集中镍板图像色彩信息和局部细节信息丰富的情况，将 SE 注意力机制引入 ResNet18 主干提取网络；面对 7×7 的卷积计算暴露出的较大计算量和内存占用问题，设计全新的 Light-head 模块，在降低计算量的同时实现更强的局部特征提取能力；面对 ResNet18 全连接分类器将维度由 512 暴力降至 3 维的分类方法，设计由标准卷积、全局平均池化和全连接层组成的串级分类头 CascadeCls，实现特征维度由 512-256，256-128，128-64 的平缓降维，最后由全连接分类器将 64 维特征向量降至 3 维输出，大幅缓解模型过拟合的问题。

对比实验显示，Nickel-Classifier 分类网络可以实现高准确率的镍板表面等级分类，与其他经典分类网络相比，Nickel-Classifier 有更优异的性能。

3.1　电解镍板表面等级分类数据集

电解镍板品级分类数据集采集自某集团产品配送中心，涵盖实时产线、封装区、返工区等各个工位的产品，可以涵盖电解镍板分类中遇到的全部场景。采集系统共采集到分辨率为 4096×3554、色深为 24 位的超高清晰度镍板图像 5076 张。从所有收集到的数据中，本文选出 2123 张典型的镍板图像，在工厂技术专家指导下分类标注镍板等级。这 2123 张图像根据表面污染程度分为三类：A 类（合格板），B 类（缺陷板）和 C 类（三号板）。随后，将镍板每一等级均按照 7:2:1 比例，随机分成训练集、验证集和测试集。

A 类板表面光洁，只存在较少的缺陷，总计有 758 个数据；B 类板表面缺陷较多，存在烧灼、较大面积或程度较深的水渍、污渍等缺陷，总计有 808 个数据；C 类板表面污染严重，缺陷面积占比大于 50%，缺陷种类多、污染程度最深，总计有 557 个数据。每个品级镍板数据样例图如图 3-1 所示。

表 3-1 电解镍板品级分类数据集统计表

Table 3-1 The Electrolytic Nickel Plate Grading Dataset Statistical Table

	训练集	验证集	测试集	总计
A 类板	530	151	77	758
B 类板	566	161	81	808
C 类板	387	111	59	557



(a) A 等级镍板样品



(b) B 等级镍板样品



(c) C 等级镍板样品

图 3-1 电解镍板表面分类数据集

Figure 3-1 Sample Images of the Electrolytic Nickel Plate Surface Classification Dataset

3.2 Nickel-Classifier 分类模型

本文的 Nickel-Classifier 分类模型架构如图 7 所示。Nickel-Classifier 基于 ResNet18 网络架构，并结合以下三个关键改进，提高其对电解镍板分类任务的分类性能：

（1） ResNet18 骨干网络中引入 SE 注意力机制，显著提升了骨干网络对特征通道间依赖关系的捕捉能力。通过自适应地重新校准特征映射，这种改进有助

于网络关注与镍板缺陷相关的更多信息特征。

（2） Light-head，专为镍板分类任务设计的新型轻量级特征提取模块，取代了 ResNet18 中标准的 7×7 卷积层。这个新模块提高了特征提取效率，同时降低了计算量和计算复杂度。

（3） 受 YOLO11 分类模型的启发，设计一全新的 CascadeCls 分类头来取代全连接分类器。CascadeCls 有效解决了全连接分类器暴力降维导致的特征丢失和模型过拟合问题。

在本章节后续开展的消融实验中，实验结果清晰地表明，上述三项改进措施共同发挥作用，显著增强了 Nickel-Classifier 对电解镍板的准确分类能力。

3.2.1　ResNet18 分类模型

基于电解镍板表面分类数据集，本研究对比使用 AlexNet、VGG-16、ResNet18 和 ViT 四种经典分类网络，后采用 ResNet18 作为本研究的基准模型，详细对比过程见 3.2 节。ResNet 残差网络结构由何凯明等[67]于 2015 年提出，残差网络有效解决了深度学习网络层数变深导致梯度消失的问题，使得之后的网络能够相对轻松地达到更深的深度，提取更为抽象的特征。ResNet 按照层数分为多个版本，包括 ResNet18、ResNet34、ResNet50 和 ResNet101 等。在电解镍板表面分类实验中，采用的基础模型是 ResNet18，其参数量大约为 11.7M，这种参数规模适合用于自建的小规模电解镍板质量等级分类数据集。

本研究采用 ResNet18 作为基础模型，ResNet18 网络架构涵盖 17 个卷积层、1 个最大池化层以及 1 个全连接分类器。其中，包含训练参数的部分包括 1 个卷积层、位于末端的全连接层，还有穿插于中间环节的批量归一化层，该网络也正由此而得名。

输入层：ResNet18 采用卷积和最大池化进行特征粗提取，其核心作用在于对输入图像进行尺寸压缩，并初步提取图像的特征信息。紧接着的第二层为最大池化层，其池化核设定为 3×3，步长同样为 2，通过这一操作能够有效降低特征图的尺寸大小，拓宽网络的感受野范围。

主干网络：主干网络结构由四个 ResBlock 残差结构依次排列组合而成，每个 ResBlock 均由两个残差块以堆叠的形式构建。考虑到输入特征图存在深度不变和深度变深两种情况，因此残差块存在两种结构，第一种结构直接痛过跳跃连接，将底层特征图和高层特征图相加；第二种结构引入卷积和归一化层，用于处理跳跃连接深度不一致的问题。

在第一个阶段当中，所涉及的两个残差块统一采用 ResBlock1 变体形式，以此对上一环节获取的特征加以提取与精细处理。而从第二个阶段直至第四个阶段，由于通道数量增加，每个阶段起始的残差块运用 ResBlock2；该阶段内的第二个

残差块则回归第一种残差块模式，保持特征图的尺寸与通道数稳定不变，从而实现更为多元、深入的特征挖掘。如此这般，这四个阶段层层堆叠，累计形成 8 个残差块、共计 16 个卷积层，共同构筑起 ResNet18 的主体架构。在此之后，引入一个全局平均池化层，针对最后一个阶段所输出的特征图执行全局平均池化处理，使得特征图尺寸精准降至 1×1，进而大幅削减参数总量。

最终，将尺寸为 1×1 且具备 512 个通道的特征图展平为 512 维的特征向量，再经过线性映射至 3 维实现图像分类等相关任务的高效处理。

ResNet18 的网络结构如图 3-2 所示：

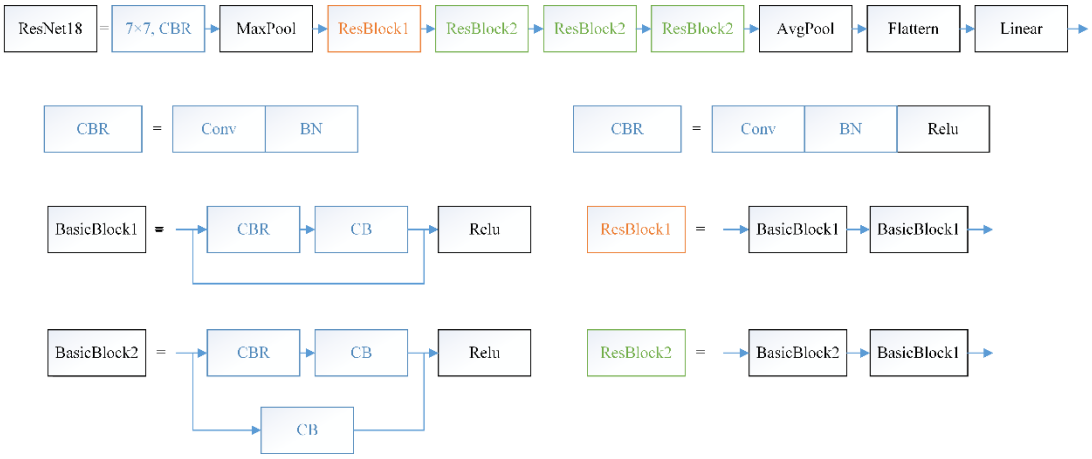


图 3-2 ResNet18 网络结构图

Figure 3-2 ResNet18 Network Architecture

3.2.2 Nickel-Classifier 分类模型

基于 ResNet18 网络结构，本研究做出以下三点改进以提高模型在电解镍板分类任务中的分类性能：

1.主干网络引入 SE 注意力机制；

2.引入全新设计的特征粗提取模块替换初始的 7×7 卷积；

3.引入分类头替换 ResNet18 末尾全连接分类器。

改进的 Nickel-Classifier 分类网络结构如图 3-3 所示：

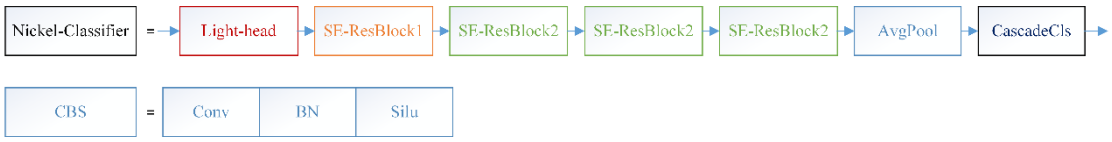


图 3-3 Nickel-Classifier 网络结构图

Figure 3-3 Nickel-Classifier Network Architecture

3.2.3 SE 注意力机制和 SE-ResBlock

电解镍板表面缺陷种类较多、存在缺陷尺度差异大、相互叠加的情况，很难单独依赖 ResNet18 提取出有效的特征来实现镍板分类，根据计算机视觉领域以

往的研究和实践结果证明，注意力机制可以突出图像中的重要区域，弱化非特征区域对模型的影响。

SE 通道注意力[91]将每个通道视作一种特征，通过 Squeeze 和 Excitation 操作去除作用较小的通道，对不同通道赋予不同的权重。具体的，SE 注意力机制实现步骤如下：

（1） Squeeze 操作，是在特征图的处理过程中，针对每个通道分别进行的一种运算。具体在特征图的 H（高度）和 W（宽度）维度上执行自适应全局平均池化操作。通过这一操作，原本每个通道的二维特征图会被压缩，整合为一个单一数值，进而生成一个通道描述符，它代表了整个特征图在该通道维度上的全局信息，能够有效将特征图在空间维度的信息进行凝练，为后续的特征分析与处理提供更为简洁且具代表性的依据。

（2） Excitation 操作，通过构建一个包含两个全连接层的网络结构，对通道维度的信息进行深度挖掘，以此学习通道间的相关性。

（3） Scale 操作，在完成对输入特征图各通道权重的生成后，通过特定机制，把先前经 Excitation 操作得到的权重，逐通道地应用于原始输入特征图之上。通过 Scale 操作，能够根据不同通道的重要程度，对特征图进行自适应调整，使模型更加关注关键通道所携带的信息，从而提升模型对复杂特征的提取与表达能力。

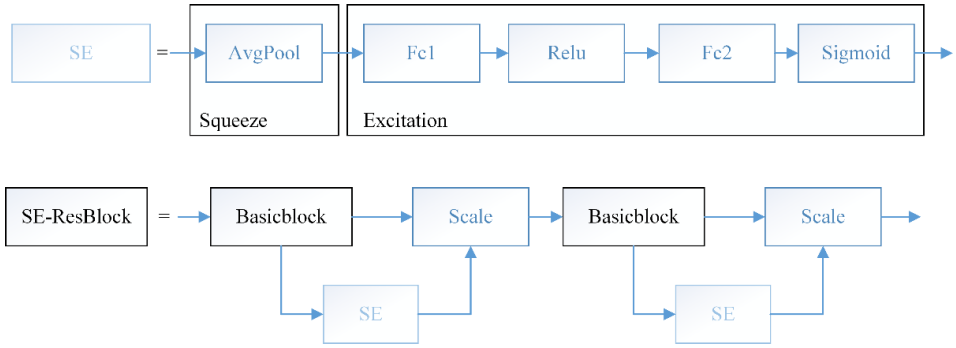


图 3-4 SE 注意力机制结构图

Figure 3-4 Squeeze and Excitation attention mechanism architecture

在电解镍板的分类任务中，不同的等级的电解镍板表面颜色差异较大，在通道特征上具有更显著的区分性。SE 的机制有助于模型聚焦于真正对分类有价值的特征信息，提高分类的准确性，此外 SE 通道注意力的结构相对简单，计算量和复杂度相对较小。将 SE 注意力添加至每个残差结构的末尾，在残差单元的输出与恒等映射相加之前进行处理，可以增强特征表达能力。图 3-4 展示了 SE 注意力机制结构及其在残差结构中的作用。

3.2.4　Light-head 特征粗提取结构

在 ResNet18 网络中，在输入阶段使用 7×7 卷积来初始提取特征，这有助于

降低特征图的分辨率，增加特征图的深度，为后续骨干网络提供更丰富的特征表示。

在本项目实验阶段，考虑到电解镍板图像分辨率为 4096×3554，将其缩放至[224,224,3]会导致丢失细节问题，因此缩放至[512,512,3]尺寸投入训练。在提高输入图像分辨率后，特征粗提取存在一些问题。

1.计算量上涨。7×7 卷积为[224,224,3]格式的输入设计，由于卷积计算量与输入分辨率正相关，在提高输入数据尺寸后，7×7 卷积粗提取计算量大的问题凸显。由公式 3-1、3-2、3-3 可知，在卷积核尺寸不变的情况下，输出特征图的宽和高和输入特征图近似成正比，因此卷积的计算量与输入分辨率成正比，512x512 的图像分辨率是 224x224 的约 5.2 倍，这导致计算量增加 5.2 倍。

$$H_{out}=\left[\frac{H_{in}+2P-K}{S}\right]+1 \tag{0-1}$$

$$W_{out}=\left[\frac{W_{in}+2P-K}{S}\right]+1 \tag{0-2}$$

$$FLOPs=H_{out}\times W_{out}\times C_{in}\times C_{out}\times K\times K\times 2 \tag{0-3}$$

式中：C_{in} 为输入通道数；C_{out} 为输出通道数；S 为步长；P 为填充；H_{out} 和 W_{out} 为输出特征图尺寸；K 为卷积核尺寸；$FLOPs$ 为计算量。

2. 感受野相对过大：虽然大的感受野有助于捕捉图像中的长距离依赖关系，但对于一些细节信息丰富的图像，7×7 的感受野可能过于粗糙，会丢失一些局部的细节信息，不利于对精细结构的建模。

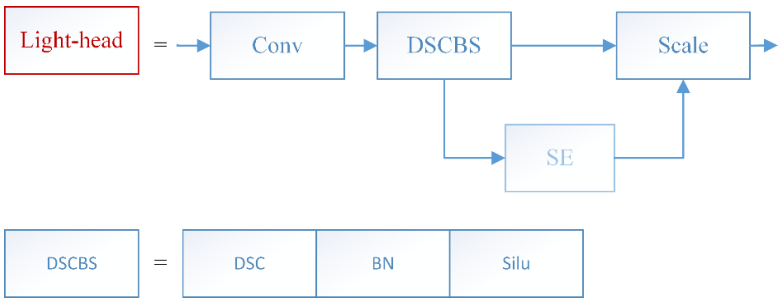


图 3-5 Light-head 结构图

Figure 3-5 Light-head network architecture

基于以上原因，本研究设计了 Light-head 特征粗提取结构，如图 3-5 所示。本文将电解镍板图像变换至[512,512,3]尺寸，输入至 Light-head 结构，依次经过 3×3 标准卷积升维至 32 层，3×3 深度可分离卷积[92]升维至 64 层，最后经过 SE 注意力机制输出。

深度可分离卷积（Depthwise Separable Convolutions, DSC）计算可以分为两个步骤：深度卷积和点卷积。在深度卷积步骤中，特征映射的每个通道独立进行卷积，消除了标准卷积中复杂的通道间计算。

$$FLOPs_{DWC} = H_{out} \times W_{out} \times C_{in} \times K \times K \times 2 \tag{0-4}$$

$$FLOPs_{PWC} = H_{out} \times W_{out} \times C_{in} \times C_{out} \times 2 \tag{0-5}$$

$$FLOPs_{DSC} = FLOPs_{DWC} + FLOPs_{PSC} \tag{0-6}$$

式中：$FLOPs_{DWC}$ 为深度卷积计算量；$FLOPs_{PSC}$ 为深度卷积计算量；$FLOPs_{DSC}$ 为深度可分离卷积计算量。

公式 3-4、3-5、3-6 展示了深度卷积、逐点卷积和深度可分离卷积的计算量。可知，深度卷积的计算量与输出通道数无关，当模型网络变深时，深度卷积可大幅降低计算量。

对比公式 3-3 和 3-6 可知，深度可分离卷积相比标准卷积大大降低了模型计算量。电解镍板的分类高度依赖于缺陷的空间特征，包括它们的位置、形状和大小。这些特征固有地包含在特征图的空间信息中。由于深度卷积对每个通道进行独立的空间滤波，因此可以更好地保留对缺陷分类至关重要的空间细节。随后的 1×1 逐点卷积促进了跨通道的信息交互，并将输出通道的数量调整到所需的维度。然而，DSC 固有地缺乏通道间交互，这降低了网络捕获跨通道复杂特征依赖的能力。因此，本文增加了 SE 注意机制，通过动态重新校准频道权重来增强频道注意。这种适应允许模型更好地从输入数据中捕获重要特征。

通过结合 DSC 降低计算成本和 FLOPs 与 SE 注意机制增强特征表示，Light-head 结构实现了高效的初始特征提取过程。

3.2.5　CascadeCls 分类头

在 ResNet18 网络的末尾，模型使用一个全连接层将 512 维的特征向量压缩为 3（代表类别数量），从而实现了电解镍板的三分类。这 512 维的特征图包含了丰富的信息，包括镍板图像的纹理、颜色以及其他细粒度的细节。直接降低维度可能会导致这些细节的丢失，进而阻碍模型对图像关键特征的准确捕获，从而影响分类精度。

尽管 ResNet 在 2015 年的 ImageNet 分类任务中获胜，但需要注意的是，本文的镍板数据集相对较小，仅有 1483 张电解镍板图像，远小于 ImageNet 的数据集规模。在电解镍板分类任务中，参数数量与数据集大小之间存在不匹配的问题。全连接分类器需要学习的权重参数数量很大，而如果训练数据相对较少，模型容易通过过度拟合训练数据中的噪声和无关细节来学习，而不是学习实际有意义的模式。因此，全连接分类器并不是电解镍板表面分类的理想选择。

检测任务通常比分类任务更复杂，因为它们不仅涉及目标定位，还涉及分类。本文受到目标检测模型中分类头的启发，在本研究中为电解镍板分类任务设计了一个全新的串级连接的分类头 CascadeCls，如图 3-6 所示。



图 3-6 CascadeCls 结构图

Figure 3-6 CascadeCls network architecture

CascadeCls 从上一层接收[1, 512, 1, 1]格式的输入。首先通过标准卷积将特征维度从 512 降低到 256，然后降低到 128，最后降低到 64。为了防止过拟合，在卷积层之间使用了自适应平均池化和随机 Dropout 层。最后，全连接层将特征维度从 64 降低到 3，从而实现电解镍板图像的三分类。

3.3 实验和结果分析

3.3.1 实验环境

本实验在台式工控机上进行，其硬件和软件设置见下表 3-2：

表 3-2 实验环境配置表

Table 3-2 Experimental Environment Configuration

模块	配置
操作系统	Windows10 64 位家庭版
运行内存	64GB
GPU	NVIDIA GeForce RTX A4000 16 GB
Python 版本	3.9.16
CUDA 版本	11.7
CUDNN 版本	8.9.2
Pytorch 版本	1.13.1
Batch_size	32
优化器	SGD
学习率	0.01
训练轮数	60

3.3.2 评价指标

分类结果可通过混淆矩阵表示，如表 3-2 所示，所有预测结果可被分为表 2 中的四类：真实值和预测值均为正例，标记为 TP（True Positive）；真实值为正例，但是预测为反例，标记为 FN（False Negative）；真实值为反例，但是预测为正例，标记为 FP（False Positive）；真实值和预测值均为反例，标记为 TN（True

Negative）。

表 3-3 混淆矩阵

Table 3-3 Confusion Matrix

	预测值	
真实值	正	反
正	TP	FN
反	FP	TN

本研究的评价指标均通过对以上四类运算而来，本研究采用准确率（*Accuracy*）、精准率（*Precision*）、召回率（*Recall*）作为模型性能主要评价指标。但是，在进行对比实验和消融实验时，不同模型在上述三类指标的表现上互有优劣，因此本文引入 F1-Score 作为辅助评价指标。

准确率为预测正确的样本占总样本的比例，计算公式如 3-7：

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN} \tag{0-7}$$

精准率为预测正确的个数占此类别所有样本的比例，计算公式如 3-8：

$$Precision = \frac{TP}{TP + FP} \tag{0-8}$$

召回率为预测正确的个数占所有被预测为此类别样本的比例，计算公式如 3-9：

$$Recall = \frac{TP}{TP + FN} \tag{0-9}$$

精确率（*Precision*）和召回率（*Recall*）是一对相互矛盾的指标。通常情况下，当精确率较高时，召回率往往相对较低；反之，当精确率较低时，召回率通常较高。因此，当仅凭精确率和召回率不足以评估模型的分类性能时，便引入 F_1 分数（F_1-*Score*）作为辅助评价指标，如公式 3-10 所示。

$$F_1\text{-}Score = \frac{2 \times Precision \times Recall}{Precision + Recall} \tag{0-10}$$

评价指标是衡量电解镍板表面分类模型性能优劣的重要依据，本研究的对比试验和消融试验均采用测试集和测试集准确率、测试集三类电解镍板的精准率和召回率作为评价指标。

3.3.3　对比实验

为验证 Nickel-Classifier 分类模型性能，本文围绕主干网络、注意力机制和分类头开展了三组对比实验。在每组对比实验的表格中，本文使用 A-valid 代表验证集准确率；A-test 代表测试集准确率；P-A 和 R-A 代表测试集中等级为 A 类镍板的准确率与召回率；P-B 和 R-B 代表测试集中等级为 B 类镍板的准确率与召回率；P-C 和 R-C 代表测试集中等级为 C 类镍板的准确率与召回率。针对准

确率和召回率互有高低的情况，本文引入 F_1 评价指标来辅助评价模型的分类性能。表 3-4 和表 3-5 展示了主流不同分类网络的分类性能。

表 3-4 不同模型分类性能对比

Table 3-4 Comparison of Classification Capabilities Across Different Models

模型	A-valid	A-test	P-A	R-A	P-B	R-B	P-C	R-C
ResNet18	337/423	147/247	50/63	50/77	51/91	51/81	46/68	46/59
	79.66%	67.74%	79.37%	64.9%	56.04%	62.96%	67.65%	77.97%
DenseNet	332/423	141/247	50/64	50/77	47/87	47/81	45/66	45/59
	78.49%	64.98%	78.13%	64.9%	54.02%	58.02%	68.18%	76.27%
AlexNet	326/423	140/247	48/63	48/77	55/95	55/81	45/70	45/59
	77.06%	64.52%	76.19%	62.34%	57.58%	67.9%	61.43%	76.27%
ViT-B-16	319/423	147/247	52/79	52/77	53/88	53/81	42/49	42/59
	75.41%	67.74%	65.82%	67.53%	60.23%	65.43%	85.71%	69.49%
Ours	373/423	190/247	67/77	67/77	72/81	72/81	51/59	51/59
	88.18%	87.56%	87.01%	87.01%	88.89%	88.89%	86.44%	86.44%

表 3-5 不同模型 F_1 指标对比

Table 3-5 Comparison of *F_1-score* Across Different Models

模型	ResNet18	DenseNet	AlexNet	ViT-B-16	Ours
F_1-A	0.714	0.709	0.686	0.667	0.87
F_1-B	0.593	0.559	0.625	0.686	0.889
F_1-C	0.724	0.72	0.698	0.778	0.864

根据实验结果的对比分析，在多个经典分类网络中，ResNet18 和 ViT-B-16 在验证集上都表现出较高的分类精度，且两种模型在测试集上取得了相同的准确率。在针对不同等级镍板的分类性能评估中，各模型呈现差异化的优劣势。此外，观察到模型在验证集与测试集上的准确率存在明显差异，经过对数据分布的调查分析，得出结论认为模型存在过拟合现象。

对比完所有模型的验证集和测试集准确率，在 ResNet18 与 ViT_B_16 之间选定基线模型。之后，进一步统计了各模型的 F_1 值（如表 3-6 所示）。鉴于实际工业生产过程中合格镍板（A 类镍板）占比较高，优先选择在该类别检测中表现最优的模型。由于 ViT-B-16 对合格镍板的精确度仅为 65.82%，显著低于其他模型，且发现其训练耗时较长、收敛速度较慢。训练中，ResNet 在 24 个训练轮次后即已收敛，而 ViT-B-16 在 60 轮次后仍未收敛，最终不得不增加训练轮次至 79 轮次才完成收敛。综合上述原因，选择 ResNet18 作为 Nickel-Classifier 模型的主干网络。

为验证在主干网络引入 SE 注意力机制的优势，本文将其与另外几种经典注意力机制进行对比分析，包括关系感知全局注意力（RGA）[93]和卷积块注意力模块（CBAM）[94]，具体见表 3-6、3-7。

表 3-6 基于 ResNet18 不同注意力机制分类性能对比

Table 3-6 Comparison of Different Attention Mechanisms Based On ResNet18

注意力机制	A-valid	A-test	P-A	R-A	P-B	R-B	P-C	R-C
Baseline	337/423	147/247	50/63	50/77	51/91	51/81	46/68	46/59
	79.66%	67.74%	79.37%	64.9%	56.04%	62.96%	67.65%	77.97%
RGA	350/423	163/247	57/68	57/77	70/111	70/81	36/43	36/59
	82.74%	75.11%	78.13%	74.03%	63.06%	86.42%	63.24%	61.62%
CBAM	353/423	163/247	60/84	60/77	59/85	59/81	44/48	44/59
	83.45%	75.11%	71.43%	77.92%	69.41%	72.84%	91.67%	74.58%
SE	352/423	163/247	63/82	63/77	57/84	57/81	43/51	43/69
	83.22%	75.11%	76.83	81.82	67.86	70.37%	84.31%	72.88%

表 3-7 不同注意力机制 F_1 指标对比

Table 3-7 Comparison of F_1-$Score$ On Different Attention Mechanisms

模型	Baseline	RGA	CBAM	SE
F_1-A	0.714	0.709	0.686	0.667
F_1-B	0.593	0.559	0.625	0.686
F_1-C	0.724	0.72	0.698	0.778

从表 3-6 可看出，从准确率方面：在不同镍板类别上，引入注意力机制后的模型相比基准模型在各类别的准确率（P-A、P-B、P-C）上有不同程度的变化。RGA 注意力在 A 类板上的准确率有一定提升；CBAM 注意力在 C 类上的准确率达到了 91.67%，表现突出；SE 注意力在多个类别上的准确率也较为可观，例如在 A 类和 C 类上有较好的表现。召回率方面：各注意力机制在不同类别的召回率（R-A、R-B、R-C）也有差异。SE 注意力在 A 类板上的召回率相对较高，说明其对 A 类样本的识别召回能力较好。F_1 指标方面：从表 3-7 可知，不同注意力机制在不同 F_1 指标（F_1-A、F_1-B、F_1-C）下各有优劣。基准模型和 RGA 注意力的 F_1 值相对较接近，CBAM 在不同指标下表现有波动，SE 注意力在 C 类板 F_1 指标下达到了 0.778，是所有模型在该指标下的最高值。

虽然不同注意力机制在个别类别或指标上有突出表现，但 SE 注意力在多个类别上的准确率和召回率表现较为均衡，且在 F_1 指标上也有不错的表现，尤其是 F_1-C 指标相对较高，说明其综合性能较优，能够在分类任务中达到较好的平

衡，也意味 SE 注意力机制可能具有更好的泛化能力，更适合应用于三分类模型的主干网络中。

为了证明本文所提出的 CascadeCls 分类头的优越性，本文将其与 ResNet18 中使用的 Softmax 全连接分类器、Multilayer Perceptron (MLP)多层感知机分类器和 YOLO11 分类头进行了比较。比较结果列在表 3-8 中。

表 3-8 基于 ResNet18 不同分类头性能对比

Table 3-8 Comparison of Different Classification Head Based On ResNet18

分类头	A-valid	A-test	P-A	R-A	P-B	R-B	P-C	R-C
Softmax	337/423	147/247	50/63	50/77	51/91	51/81	46/68	46/59
	79.66%	67.74%	79.37%	64.9%	56.04%	62.96%	67.65%	77.97%
MLP	350/423	162/247	68/99	68/77	49/68	49/81	45/50	45/59
	82.74%	74.65%	68.69%	74.03%	88.31%	60.49%	90%	76.27%
YOLO11	326/423	168/247	62/82	62/77	57/80	57/81	49/55	49/59
	77.06%	77.42%	75.61%	80.52%	71.25%	70.37%	89.09%	83.05%
CascadeCls	348/423	174/247	63/83	63/77	61/72	61/81	50/62	50/59
	82.27%	80.18%	75.09%	81.82%	84.72%	75.31%	80.65%	84.75%

如表 3-8 中所示，Softmax 在验证集和测试集上的准确率最低。MLP 在 B 类板上的召回率达到了 88.31%，显著优于其他模型。然而，它在 A 类板和 B 类板的召回率相对较弱。YOLO11 在所有三类中都表现出了较高的召回率，尤其是在 A 类和 C 类板类别中，显示出其在保持高召回率方面的优势。然而，它的总体精度略低于 MLP，特别是在 B 类板上。CascadeCls 在所有分类头中，在测试集上的准确率达到了 80.18%，表现出其强大的泛化能力。对于 B 类缺陷板，CascadeCls 的分类能力明显领先于其他模型。尽管其在板上的精度相对较低（80.65%），但其召回率是最高的，表明它能够有效识别更多的缺陷板样本，即使可能会出现一些误判。因此，选择 CascadeCls 作为 ResNet18 的分类头是基于其在多个评估指标上的优越表现，特别是其在准确率、精度和召回率方面表现平衡。

在本文最终改进的 Nickel-Classifier 分类模型中，模型在所有三类电解镍板的分类性能上表现达到最优。模型不仅在测试集和验证集上的准确率显著提高并达到最优，两者之间的差距也达到最小，表明模型过拟合问题得到了有效解决。因此，Nickel-Classifier 模型在电解镍板表面分类任务中具有更大的优势。

3.3.4 消融实验

为了进一步探讨模型中每项改进的影响，本文逐步将新提出的模块添加到基准模型 ResNet18 模型中。为了确保消融实验的公平性，实验环境和分类网络超参数配置保持表 3-1 中设置不变，同时每个实验逐步添加相应的模块。具体实验

结果见表 3-9。

表 3-9 消融实验结果

Table 3-9 Results of The Ablation Experiments

模型	A-valid	A-test	P-A	R-A	P-B	R-B	P-C	R-C
-	337/423	147/247	50/63	50/77	51/91	51/81	43/68	43/59
	79.66%	67.74%	79.37%	64.9%	56.04%	62.96%	63.24%	72.88%
SE	352/423	163/247	63/82	63/77	57/84	57/81	43/51	43/59
	83.22%	75.11%	76.83	81.82	67.86%	70.37%	84.31%	72.88%
Light-head	345/423	171/247	63/79	63/77	64/87	64/81	44/51	44/59
	81.56%	78.8%	79.75%	81.81%	73.56%	79.01%	86.27%	74.57%
CascadeCls	348/423	174/247	63/83	63/77	61/72	61/81	50/62	50/59
	82.27%	80.18%	75.09%	81.82%	84.72%	75.31%	80.65%	84.75%
SE+	359/423	177/247	65/78	65/77	67/86	67/81	45/52	45/59
Light-head	84.87%	81.57%	83.33%	84.42%	77.91%	82.72%	86.54%	76.27%
SE+	370/423	181/247	64/77	64/77	68/78	68/81	49/62	49/59
CascadeCls	87.47%	83.41%	83.12%	83.12%	87.18%	83.95%	79.03%	76.24%
Light-head+	364/423	177/247	64/81	64/77	62/77	62/81	51/59	51/59
CascadeCls	86.05%	81.57%	79.01%	83.12%	80.52%	76.54%	86.44%	86.44%
Ours	373/423	190/247	67/77	67/77	72/81	72/81	51/59	51/59
	88.18%	87.56%	87.01%	87.01%	88.89%	88.89%	86.44%	86.44%

由表 3-9 可知，基准模型在验证集上的准确率为 79.66%，在测试集上的准确率为 67.74%；表 3-13 显示三号板的准确率（63.24%）和召回率（72.88%）存在显著差异，表明模型对三号板的预测效果不平衡。

首先，分别将单个模块引入基线模型，结果表明，每个模块都能独立提高模型性能。在主干网络中引入 SE 模块，它可以通过动态调整通道权重显著提升特征捕捉能力。模型对三种类型镍板的分类能力大幅提高，具体的，验证集准确率和测试机准确率分别提高 3.56%和 7.37%；合格镍板和二号板的召回率分别提高 16.88%和 7.41%，但是合格板的检测精准率略有降低 2.54%，三号板的检测精准率大幅提高 21.07%。Light-head 模块在减少计算成本和 FLOPs 的同时，测试集准确率跃升至 78.80%，提高了 16.05%。该模块对缺陷板板的召回率提高最为显著，增加了 16.05%。CascadeCls 模块将测试集准确率提高了 12.44%，该模块在缺陷板准确率达到 84.72%，三号板召回率达到 84.75%，分类方面表现优异。

为了进一步探索各模块之间的互补性，本文设计了多组双模块联合配置的消融实验。SE + Light-head 组合在测试集上的准确率达到了 81.57%，比单独引入

Light-head 提高了 2.77%。值得注意的是，A 类板的准确率为 83.33%，召回率为 84.42%，表现出较好的平衡。SE + CascadeCls 组合表现出双模块联合下的最强的分类能力，测试集准确率达到了 83.41%，比单个模块平均提高了约 5%。其中，缺陷板的准确率（87.18%）和三号板的召回率（76.24%）均达到了新的阶段性高点，证明 SE 的局部特征增强和 CascadeCls 的分类头能够有效地提取并传递复杂的颜色特征。尽管 Light-head + CascadeCls 组合在测试集准确率（81.57%）上与 SE + Light-head 持平，但其在三号板的准确率（86.44）和召回率（86.44%）完美平衡。轻量化结构与上下文信息的结合有助于提升模型对三号板的鲁棒性。

最终， Nickel-Classifier 在三分类任务中达到了最佳性能，测试集的准确率达到了 87.56%，相比基线模型绝对提高了 19.82%，此结果验证了多模块联合作用的必要性。此外，所有类型的指标都呈现出高精度和高召回率的平衡状态。

实验结果表明，模块组合不仅提高了整体准确率，还增强了模型的泛化能力和鲁棒性。基准模型验证集和测试集之间的准确率差为 11.92%，表明了模型存在过拟合问题。在验证集和测试集之间的准确率差降低到 0.62%，证明了改进后的模型缓解了过拟合问题，并且具有更强的泛化能力。

3.4 本章小结

本章聚焦于电解镍板的等级分类任务，引入基于深度学习的分类方法，介绍了由 2331 张电解镍板图片组成的电解镍板表面分类数据集；然后，本文介绍了基准模型 ResNet18 的网络结构；之后，本文基于 ResNet18，提出 Nickel-Classifier 分类模型，具体做出三点改进：第一，提出 Light-head 模块改进模型头部的特征粗提取层；第二，将 SE 注意力机制引入主干网络中每个残差结构；第三，设计一种卷积层串级连接的分类头，CascadeCls 替换全连接分类头。在本文的实验部分，本文将 Nickel-Classifier 分类模型与 ResNet18、AlexNet、DenseNet、ViT-B-16 进行对比，实验结果表明，所提出的 Nickel-Classifier 在各项指标上显著优于其他经典分类模型，也解决了模型过拟合的证明其在电解镍板表面分类任务中的优越适用性。

第四章　基于改进 YOLO11s 的电解镍板表面缺陷检测

目前，针对电解镍板的处理全程依赖人眼判断和人力手工抬板至剪板机处剪切，此过程缺乏对电解镍板下表面信息的判断，此外还存在人员判断标准不一致、漏判、误判等问题，手工处理过程劳动力消耗大、存在人员健康和安全隐患。

为了解决此行业痛点，本文将基于深度学习的目标检测方法引入电解镍板表面缺陷检测任务中。针对 YOLO11 检测性能较差和 YOLOv5 针对小目标缺陷和高长宽比缺陷检测性能较低的问题，设计了改进的 YOLO-NP 目标检测网络。具体的，基于本文设计的高质量镍板图像采集系统建立了由 1195 张镍板图片组成的电解镍板缺陷数据集，并针对镍板缺陷中小目标和大长宽比目标缺陷较多的问题，结合 YOLOv5 的锚框机制锚框和 YOLO11 模型架构，提出了 YOLO-NP 检测模型，实现对电解镍板表面缺陷的准确检测，使电解镍板处理更高效、准确。在自建的电解镍板数据集上测试结果显示，mAP50 和 mAP50-95 分别为 54%和 44.3%，较原始 YOLOv5s 算法提高了 6.1%和 4.7%。此外，与二阶段经典目标检测算法和基于 Transformer 的目标检测算法相比，YOLO-NP 在性能和计算量上都有明显优势。

4.1　电解镍板表面缺陷数据集

电解镍板样品来源于 96 成品镍板生产线、镍板室外贮存处、9950 镍板、上游车间的缺陷板和降号板，涵盖了厂家电解镍板生产中的所有品种。其中，96 镍板是镍含量 99.6%的镍板，是最高等级的镍板，表面光洁，没有或有很少的缺陷；9950 镍板是镍含量 99.5%的电解镍板，表面有较大或较深的水渍、污渍等；室外贮存的镍板由于受到雨雪、沙尘等恶劣天气或捆绑轧带长时间捆绑挤压的影响，表面会产生些许印记，这些印记不影响镍板等级，但由于其性状和缺陷相似，会对镍板缺陷检测造成一些影响；对于缺陷较多的镍板，需要返回上游车间重新烫洗，缺陷更严重的板子直接降号。

在第三章节中，本文将 96 镍板和缺陷严重的降号板分别按照等级为 A 类和 C 类挑选出来，剩余的 9950 镍板和缺陷相对较轻的降号板则难以通过专家人眼区分，存在不同专家判断标准不一致的情况。基于以上原因，本文将剩余的镍板都按照 B 类进行分类，随后通过目标检测的技术，检测出镍板表面缺陷种类和面积的精确信息，以此信息作为依据进行后续处理。

本文从高质量镍板图像采集系统采集的 5376 张镍板图像中筛选出 1195 张含有各种缺陷的镍板图片组成电解镍板表面缺陷数据集，之后对这批图像转正，将 1195 张图片划分为训练集（832 张）和验证集（363 张），使用 LabelImg 软

件批量标注，构成由 15973 组成的电解镍板表面缺陷数据集。标注的缺陷总共分为 11 种，污渍、水渍、边部结瘤、气孔、结粒、疙瘩、烧灼、绿色结晶，酸污染，缺角和严重水渍训练集和验证集的总缺陷个数如表 4-1 所示：

表 4-1 电解镍板表面缺陷数据集统计表

Table 4-1 The Electrolytic Nickel Plate Defect Dataset Statistical Table

缺陷	训练集	验证集	总计
污渍	2074	920	2994
水渍	5602	3226	8828
边部结瘤	71	33	104
气孔	396	171	567
结粒	217	82	299
疙瘩	216	79	295
烧灼	129	69	198
绿色结晶	252	129	381
酸污染	20	21	41
缺角	37	9	46
严重水渍	1536	674	2210
所有	10550	5423	15973

4.2 YOLO-NP 目标检测网络

在本文进行模型选型时，对 YOLO 系列模型从 v5 至 v11 版本（除 v7）都进行了实验，实验结果表明 v5、v6 版本准确率、召回率和 mAP 指标均比其余最新发布的版本高出很多。因此，本文对 Ultralytics 发布的 YOLOv5、v8 和 v11 模型系列结构做出分析，三者模型架构虽然有一些改动，但是不会产生相差巨大的检测结果。最主要的，v5 和后两者在锚框（Anchor）设计上存在显著差异。

YOLOv5 中，Anchor-Base 锚框基于 K-means 聚类算法，对 COCO 数据集真实框进行多尺度聚类，采用 9 个预定义锚框，对应 P3/P4/P5（小尺寸、中尺寸、大尺寸目标）三个特征层，锚框尺寸静态固定；YOLOv8 和 v11 版本的 Anchor-Free 机制在训练中直接学习各种目标框尺寸。预测阶段不依靠锚框，而是根据学习到的边框距离和关键点位置，直接预测目标中心点的热力图（Heatmap），Anchor-Free 机制需要较少超参数调优；更适合复杂多变场景，如自动驾驶。

事实证明，YOLOv8 和 v11 的 Anchor-Free 机制在 COCO 公开数据集表现优异， PASCAL VOC、COCO、ImageNet Detection 等公开通用目标检测数据集目标框以数十万、上百万量级，而本文镍板数据集训练集目标框仅为 10665 个，此外，镍板数据集场景单一，但缺陷颜色、尺度变化多样，其中小目标、极小目标缺陷占比较高，对缺陷的检测造成不小挑战。

在本文的电解镍板缺陷检测任务中，如果使用基于 anchor-free 的目标检测模型且想取得较好的检测效果，需要较大的数据量作为支撑。因为 Anchor-free 模型不依赖于预定义的锚框，模型需要在整个图像空间内进行密集的预测，这意味着模型需要从零开始学习目标的尺度、形状和位置等特征。在数据量较小、目标框尺度差异较大的情况下，模型可能难以捕捉到这些复杂的特征，从而影响检测性能。

因此，本文结合 YOLOv5 锚框和 YOLO11 的模型结构并改进，提出了适用于电解镍板检测任务的一阶段目标检测模型 YOLO-NP。

4.2.1　YOLO11 目标检测模型

YOLO11 是由 Ultralytics 于 2024 年 9 月 30 日发布的一个开源的目标检测算法，相比于同为 Ultralytics 发布的 YOLOv8 模型， YOLO11 在 COCO 数据集上实现了更高的平均精度（mAP），同时参数量比 YOLOv8m 减少了 22%，单张图片推理时间也从 234.7ms 缩短至 183ms。YOLO11 提供了从低到高的五个不同参数量的目标检测网络版本:YOLO11n、YOLO11s、YOLO11m、YOLO11l 和 YOLO11x。通过改变配置文件中的深度和宽度系数，可以快速调整模型参数，从而修改卷积单元中的层数和卷积核的通道数。图 4-1 是 YOLO11 的详细网络结构图，这是本文改进的基础。

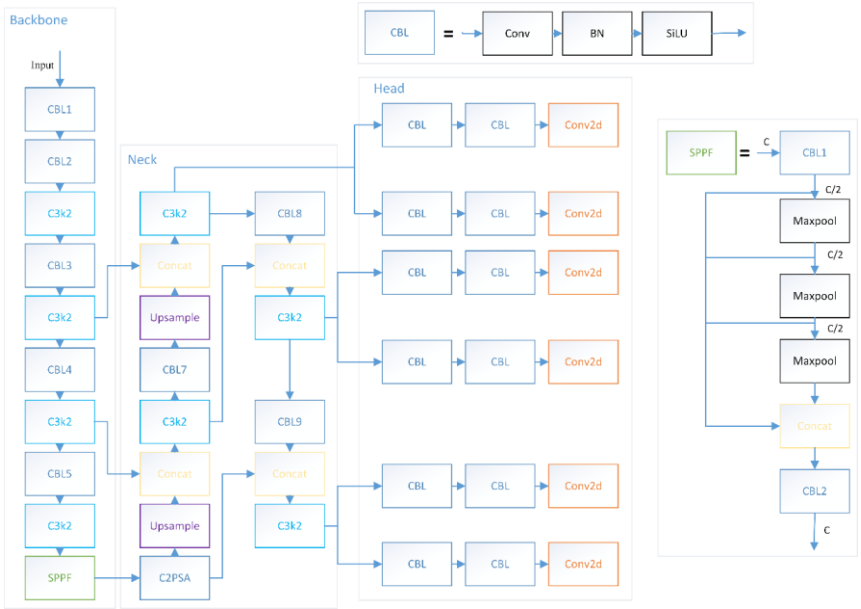


图 4-1 YOLO11 结构图

Figure 4-1 YOLO11 Network Architecture

YOLO11 网络结构概述如下：

输入：YOLO11 单样本增强策略包括翻转、旋转、平移、随机尺度裁剪、HSV 增强。其多样本数据增强策略包括 Mosaic[78]和 Mixup[95]。其中，Mosaic 数据增强方法尤为有效。它通过将四个原始图像拼接，组成一个新的样本，新样本使原始样本的数据尺寸缩小，增强了模型对小目标对象的检测能力。

主干网络：主干网络的作用是提取图像特征。相比 YOLOv8，YOLO11 将 C2f 模块改进为 C3k2 模块，新增加 C2PSA 模块。Bottleneck 结构是 C3k2 的基础，它包换两个卷积层和残差连接，在实际使用中根据用户的需要和输入输出参数来决定是否使用残差链接。Bottleneck 的结构可以减少计算量并提取特征，残差连接的引入使其有更好的梯度传播效果。C3 是基于 Bottleneck 的特征提取模块，通过一系列 Bottleneck 模块提取复杂特征，一条带有一个卷积的 shortcut 提取表层特征，最后将二者拼接后输出，这种结构能够高效提取特征；C3k 是 C3 模块的改良，主要在于其允许用户自定义卷积核的尺寸，以此适应不同尺寸的目标框。C2f 在 YOLOv8 中提出，相比于 C3，C2f 将输入拆分为两部分，一部分传递至 Concat 处，另一部分传递到多个 Bottleneck 块，每个 Bottleneck 的结果也传递至 Concat 处，最后拼接经过卷积后输出。相比于 C3，C2f 梯度流信息更丰富，其可以将来自不同层级的特征图进行融合，形成的特征图语义信息更丰富。YOLO11 中的 C3k2 更为灵活，其结合了 C2f 速度优势和 C3k 可定义卷积核的灵活性。具体的，C3k2 通过布尔型变量 C3k 控制 C3k2 结构，当 C3k 为 True 时，C3k2 通过若干层 C3k 模块堆叠提取特征；当 C3k 为 False 时，C3k2 可视为 C2f。

C3k2 相比于 C2f 的优势是，对于不同的数据集，目标框信息相差较大，C3k2 可灵活控制是否使用 C3k 模块，也可灵活改变 C3k 中可变卷积核尺寸，进而实现更简便的调参。图 4-2 展示了 C3\C3k、C2f、C3k2 模块结构。

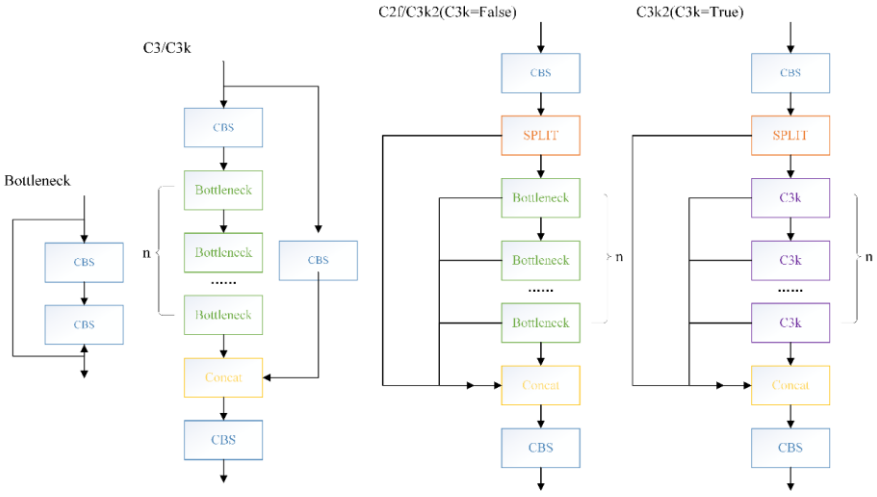


图 4-2 C3、C3k、C2f、C3k2 结构图

Figure 4-2 C3、C3k、C2f、C3k2 Module Architecture

C2PSA 模块基于 C2f，引入金字塔切片 PSA（Pointwise Spatial Attention）注意力机制，提高模型对重要特征的捕捉能力。

Neck：Neck 层的作用是对主干网络提取出的特征做进一步处理，充分利用主干网络提取出的信息，YOLO11 采用 PAN[96]+FPN[97]融合深、浅层，通过通道维度叠加改进不同层特征之间的融合。

Head：YOLO11 头部分为检测头和分类头，检测头采用两次普通卷积和一次单独卷积计算构成；分类头采用两次深度卷积、两次普通卷积和单独卷积计算构成，引入深度卷积以大幅减少参数量和计算量。在损失函数方面，检测损失采用 CIoU 损失函数，引入重叠区域、宽高比和中心点距离，全面衡量预测框和真实框之间差异；采用 BCE 二元交叉熵损失作为分类损失。

输出：在本项目中，以 json 格式输出缺陷框坐标信息和种类信息，以此作为镍板剪切的依据。

4.2.2　YOLO-NP 目标检测模型

基于 YOLO11 网络结构，本文提出的 YOLO-NP 网络结构如图 4-3 所示：

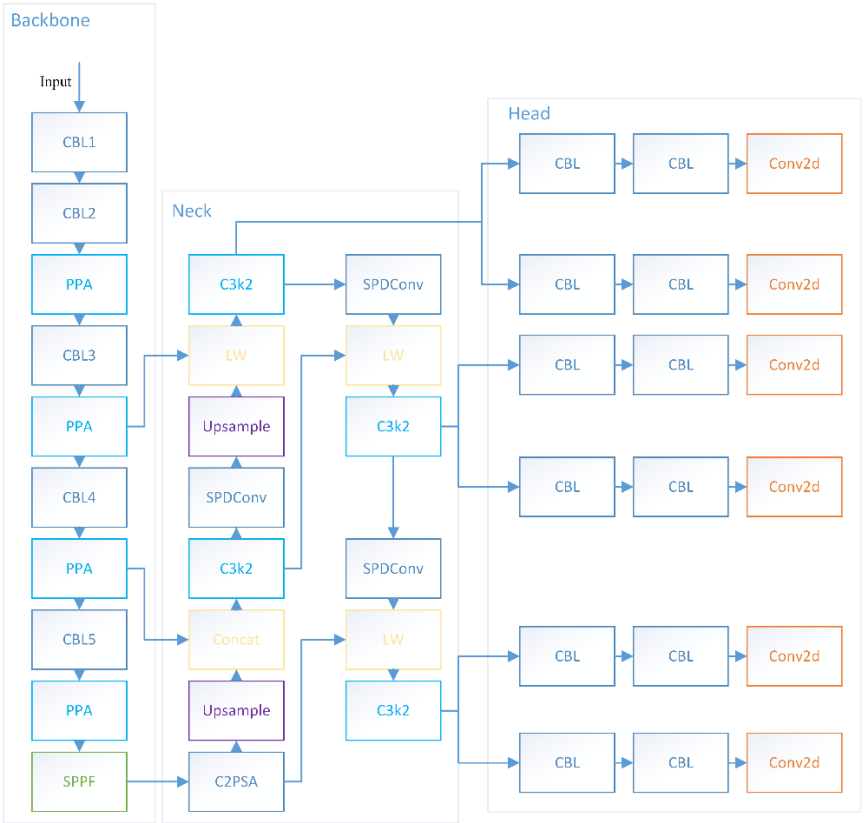


图 4-3 YOLO-NP 结构图

Figure 4-3 YOLO-NP Network Architecture

具体的，第一，基于 K-means 聚类算法生成适用于电解镍板缺陷数据集的锚框；第二，引入并行补丁感知 PPA 注意力机制至模型的主干网络；第三，本文提

出了 LW 模块，将其添加到颈部网络中替换掉 Concat 结构，用以提高对各种尺度目标的特征融合能力；第四，本文在模型颈部引入空间深度转换卷积 SPDConv；最后，在模型的后处理阶段引入基于归一化 Wasserstein 距离的回归损失函数 NWD，用 Wasserstein 距离来度量边界框之间的相似性，提升模型对小目标的检测性能。

4.2.3 基于 K-means 聚类算法的锚框生成

在目标检测任务中，由于目标的大小、尺寸多样，因此需要一个框来预测目标的大概形状。基于深度学习的目标检测常见的方法是：将整张图分多个区域，判断每个区域有无目标、目标尺寸。这些多个区域被称为即锚框，用以锚定实际的预测框。

在 NP-YOLO 模型中，锚框是预定义的三组边界框，锚框覆盖不同的尺度和宽高比，可以为模型提供先验知识，锚框通过预先定义的尺寸（如小、中、大）和宽高比（如 1:1、1:2、2:1），为模型提供目标的可能形状和位置的假设。例如，部分水渍、污渍通常宽高比比较大；而烧灼缺陷更近似于正方形。

在 YOLOv5、v6 和 v7 官方算法中，已经使用 K-means 聚类方法根据 COCO 数据集的特征设置了一组预设的锚框。然而，在镍板表面缺陷检测的实际应用中，由于不同缺陷的尺度差异巨大，预设的锚框与具体数据集的适应性较差，因此需要对这些锚框进行重新聚类优化。

具体的，本文使用 K-means 聚类算法生成适用于镍板缺陷检测的锚框。K-means 算法是一种基于划分的迭代聚类方法[98]，旨在将 n 个数据点分为 k 个簇，并根据相似度将每个数据点归类到其最近的质心所代表的簇中，从而使得每个簇内部的数据点之间的平方误差达到最小。通常，欧氏距离被用作衡量样本相似度的指标，通过不断迭代来更新每个簇的质心位置，更新方式是将簇内所有数据点的平均值作为新的质心，直到质心不再发生变化或达到预定的迭代次数为止。

平方误差准则函数，也称为误差平方和函数(sum of squared errors, SSE)，用于衡量聚类效果，其公式如下：

$$\min J = \sum_{i=1}^{K}\sum_{m=1}^{N} d_{mi} \left\| x_m - c_i \right\|^2 \tag{0-11}$$

$$d_{mi} = \begin{cases} 1, x_m \in R_i \\ 0, x_m \notin R_i \end{cases} \tag{0-12}$$

式中：J 为误差准则函数；K 为聚类簇数；R_i 为第 i 类；c_i 为 R_i 的质心；m 为样本编号；N 为样本数；x_m 为第 m 个样本，即待聚类目的相关因素构成的向量；d_{mi} 表示第 m 个样本是否属于 R_i。

基于 K-means 算法，本文针对镍板表面缺陷数据集进行了锚框的聚类优化，从而得到了适合该数据集的锚框尺寸，显著提高了检测效果。

4.2.4　并行补丁感知注意力机制

并行补丁感知注意力机制（Parallelized Patch-Aware Attention Module，PPA）由 Zheng 宸等人于 2024 年 HCF-Net 网络结构中提出，作者将 PPA 注意力机制与维度感知选择性融合（DASI）模块和多稀释通道细化器（MDCR）模块相结合，缓解了红外小目标检测任务中小目标背景丢失和背景区分度较低的问题[99]。

在镍板缺陷检测任务中，局部特征非常重要。在 10650 个缺陷框组成的训练集中，极小目标有 86 个，小目标缺陷有 10532 个，占比极大的小目标意味着模型需要对局部信息有较高的关注度，如边缘、纹理、斑块等信息。在对电解镍板表面缺陷进行检测时，其中包含的小目标缺陷在多次下采样过程中可能会丢失信息。

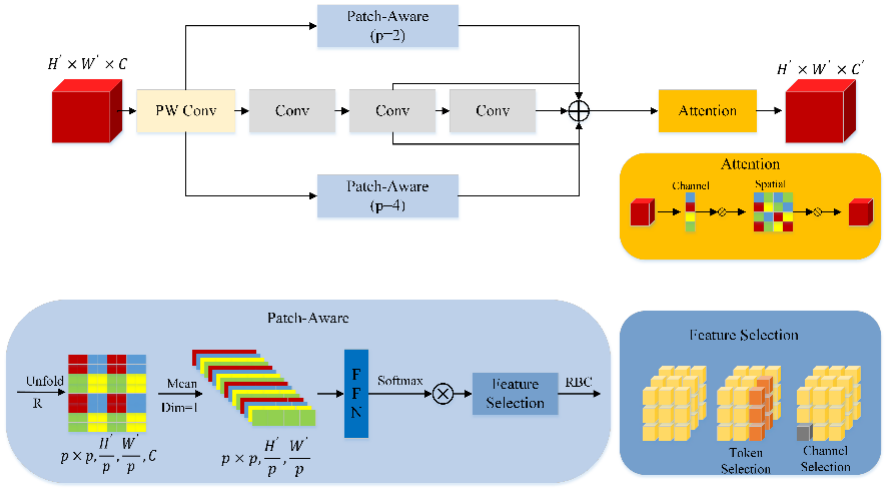


图 4-4 并行补丁感知注意力机制原理结构图

Figure 4-4 Parallelized Patch-Aware Attention Module Architecture

PPA 是一种结合了局部特征感知与并行化计算的注意力机制，其结构图如图 4-4 所示。主要用于提升计算机视觉任务中对多尺度局部特征的建模能力。其核心设计思想是将输入特征图划分为不同尺度的局部斑块（如 4×4、8×8、16×16），每个尺度的斑块通过独立的卷积层提取特征，形成层级化表示，以此捕获不同粒度的局部信息，之后引入注意力，自适应地分配通道和空间权重，增强模型对关键区域的敏感度。具体过程可分为多尺度特征提取和注意力机制两部分组成。

多尺度特征提取部分通过两组 Patch-Aware 和串联卷积并行完成，具体的：首先对于给定输入特征图通过点卷积调整尺寸，随后通过三个并行分支分别计算出局部特征图$F_{local} \in \mathbb{R}^{H' \times W' \times C'}$，全局特征图$F_{global} \in \mathbb{R}^{H' \times W' \times C'}$和卷积特征图$F_{conv} \in \mathbb{R}^{H' \times W' \times C'}$。对于局部和全局特征图，首先通过展开（Unfold）操作将特征图划分为空间上连续的块($p \times p$, $H^{'} / p$, $W^{'} / p$, C)，此操作能够聚焦于细粒度特征（如边缘、纹理），同时减少全局注意力计算的开销，同时不会造成信息丢

失；随后对特征图按通道进行展平，得到形状为($H^{'}/p \times W^{'}/p, p \times p$)张量；然后，对每个切块的每个通道展开取平均值，得到($p \times p, H^{'}/p \times W^{'}/p$)尺寸特征图，然后进行 FFN 线性计算；之后，应用 Softmax 函数获得特征在空间维度上的概率分布，并相应地赋予它们权重。在特征选择阶段，从标记（tokens）和通道（Channels）两个角度选择与镍板缺陷目标相似的特征

经过 Patch-Aware 后，对最后的特征图$\tilde{F}$依次通过通道注意力和二维空间注意力处理进行自适应特征增强，具体过程如下：

$$F_{Channel} = M_C(F) \otimes F \tag{0-13}$$

$$F_{Spatial} = M_S(F_{Channel}) \otimes F_C \tag{0-14}$$

$$F^{''} = \mathrm{Re}lu(BatchNorm(Dropout(F_{Spatial}))) \tag{0-15}$$

式中：$\otimes$为逐元素相乘

本文做出以下两种改进。第一种是直接引入 PPA 注意力机制替换 C3k2 模块；第二种是基于 PPA 机制，设计了改进的 C3k2-PPA 模块，初始 C3k2 只是一个标准的 CSP Bottleneck 模块，通过多个卷积层和 C3k 或 Bottleneck 模块来提取特征；改进的 C3k2-PPA 中，PPA 注意力机制被应用于 Concat 后卷积输出的特征图，使得模型能够在特征融合后对不同空间区域的特征进行加权，从而更好地聚焦于重要区域，进一步提升了模型的性能和表示能力。图 4-5 分别展示了 C3k2-PPA 结构在参数 C3k 为 True 和 False 时模块的结构。

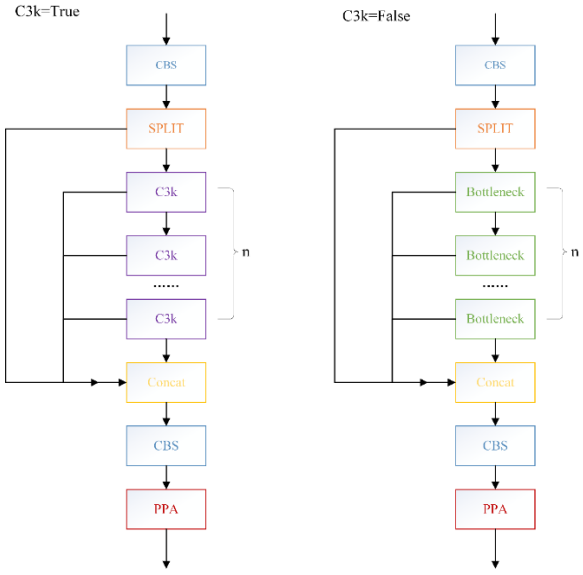


图 4-5 C3k2-PPA 原理结构图

Figure 4-5 C3k2-PPA Module Architecture

4.2.5 LW 特征融合模块

YOLO11 的 neck 层部分，FPN 和 PAN 通过 Concat 操作将来自不同尺度的特征图在通道维度进行拼接，它只是简单地将多个特征图在通道维度上堆叠，没有进行额外的权重调整或特征选择。这就意味着每个特征图在拼接过程中对最终

的输出影响是均等的，而没有考虑各个特征图之间的相对重要性。而对尺寸较小的缺陷的准确检测更依赖于细节信息，这些信息较多的位于底层，在高层和低层特征图均等的融合操作下，可能导致低层特征图上的信息被污染，影响小尺寸缺陷的识别效果。此外，直接拼接可能导致特征图中存在冗余信息，增加计算量且影响模型的泛化能力。

基于以上原因，本文设计了 LW 模块。引入了 SE 通道注意力和可学习的权重，SE 通道注意力[91]将每个通道视作一种特征，去除作用不大的通道，对不同通道赋予不同的权重。在电解镍板的缺陷检测任务中，不同的缺陷类别颜色、尺寸差异较大，在通道特征上具有更显著的区分性。SE 的机制有助于模型聚焦于真正对分类有价值的特征信息，提高分类的准确性，此外 SE 通道注意力的结构相对简单，计算量和复杂度相对较小。可学习的权重可以根据输入特征图的特性动态调整每张特征图的影响力。最后，通过残差连接简化反向传播中链式法则的计算，避免了因为梯度过小导致计算后梯度消失的问题，有助于梯度的流动；此外，残差层使得特征信息可以直接传播，这有助于特征的重用，提高了特征融合的学习效率和性能，尤其是易被忽略的小目标缺陷。LW 模块的结构图分别如图 4-6 所示。

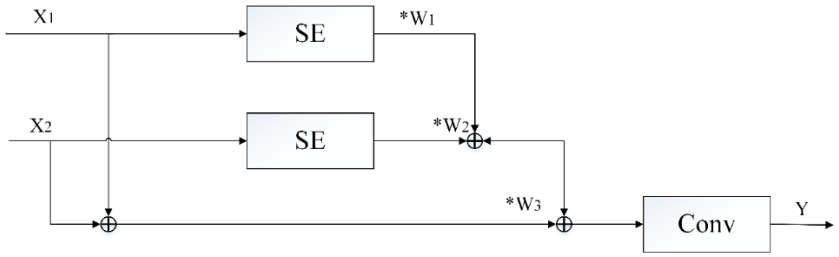


图 4-6 LW 模块原理结构图

Figure 4-6 LW Module Architecture

4.2.6　空间深度转换卷积

标准卷积中，步长的变化会改变卷积核的感受野大小。当使用大于 1 的步长时，卷积核在滑动过程中会跳过一些像素位置，这意味着部分空间信息没有被卷积核处理到，直接被丢弃。随着网络层数的增加，感受野会逐渐变大，这使得每个神经元所对应的输入图像区域变大，它对局部细节的敏感度就会降低。神经元更多地关注较大区域内的整体特征，而难以捕捉到精细的局部特征差异。在对一幅包含多个缺陷框的镍板图像进行特征提取时，较深层的跨步卷积可能会将多个物体的局部特征混合在一起，导致难以区分每个物体的精细细节。

基于以上原因，空间深度转换卷积 SPDConv[100]被设计以替代标准卷积。SPDConv 由空间到深度（Space to Depth，SPD）层和非步长卷积层组成。SPD 卷积具体过程如图 4-7 所示：

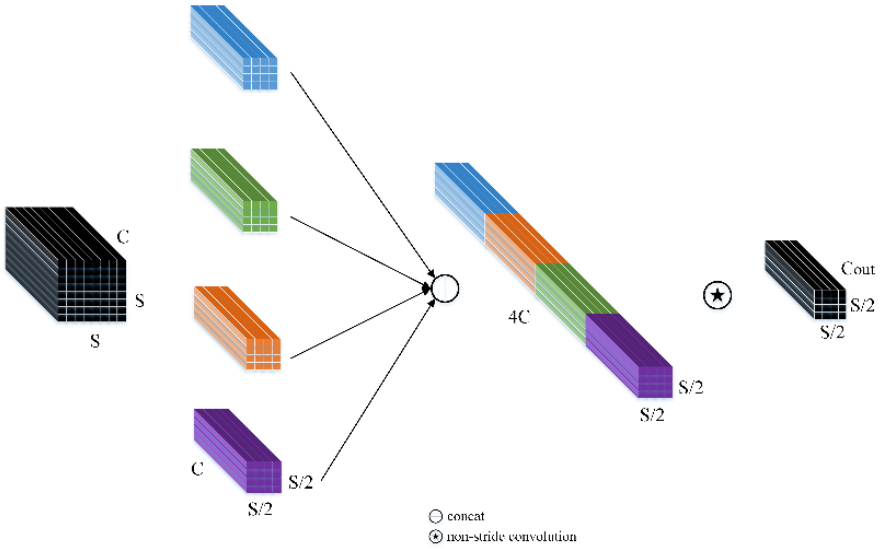


图 4-7 比例因子为 2 时空间深度转换卷积结构图

Figure 4-7 Illustration of SPDConv with scale factor of 2

SPD 层：该层通过重排特征图的元素，将空间信息转换到深度（通道）维度，从而实现下采样而不损失信息。对于输入特征图 X[0, S, S, C]，按比例因子 scale=2 进行下采样，得到 $scale^2$=4 个尺寸为[0, S/2, S/2, C]的子特征图，从通道维度拼接，得到尺寸为[0, S/2, S/2, 4C]的中间特征图。

非步长卷积层：在 SPD 层之后，SPDConv 使用非步长（即步长为 1）的卷积层进一步处理中间特征图。这种设计允许网络在不丢失空间信息的前提下，通过可学习的参数精细调整特征表示，有助于提高模型对小物体和低分辨率图像的处理能力。

本文对 YOLO11 模型的颈部结构进行了改进，采用 SPDConv 模块替代标准卷积单元，SPD 转换通过张量重组而非信息丢弃的方式压缩空间维度，能更完整地保留特征图的细粒度信息；这种方法通过增加通道深度来保留更多的信息，而非过减少像素点数来损失信息，尤其适用于小目标检测。后续的实验结果表明，引入 SPDConv 后模型对于小目标的特征提取能力得到了有效提升。

4.2.7 改进的 NWD 损失函数

NMS（Non-Maximum Suppression，非极大值抑制）是目标检测算法中的一个重要后处理步骤，用于去除冗余的检测框，保留具有最高得分的检测框作为最终的检测结果[101]。NMS 对所有的检测框按照目标类别的置信度从高到低排序，选择得分最高的检测框，将其保留作为最终的预测框。如公式 4-6 所示。

$$Score_i = \begin{cases} 0, IoU(M, b_i) \geq N_t \\ K_i, IoU(M, b_i) < N_t \end{cases} \tag{0-16}$$

在公式(4-6)中，$Score_i$ 为算法所生成的第 i 个检测框得分；K_i 表示各个目标边界框的置信度得分；N_t 表示预先设定的阈值，M 表示所有检测框中置信度最

大的检测框；b_i 表示第 i 个检测框。将 b_i 和 M 的交并比进行比较，若大于阈值，则认为它们检测的是同一个目标，之后为避免框冗余则直接删除 b_i。NMS 的主要目的是在多个相互重叠的检测框中，保留最优的检测框，删除其他冗余的检测框，以减少重复检测。

在电解镍板表面缺陷数据集中，水渍、污渍和绿色夹层这三种缺陷尺度差异大，以水渍为例，有小而密集的水点，也有跨度整板的长条状水渍。在检测电解镍板上的小水点和绿色结晶时，多个水点聚在一起，彼此之间距离接近，有些水点之间相互重叠。在此条件下，检测框可能高度重叠，NMS 可能会认为这些检测框是同一目标的重复检测框，进而错误地将某些真正的小目标检测框抑制掉。此外，针对不同尺度缺陷的 IoU 阈值难以调整，小目标缺陷的检测框往往较小，缺陷框的大小和位置轻微变化就会显著改变其 IoU 值，因此小目标缺陷对 IoU 敏感性较强。适用于大目标的 IoU 阈值，可能不适用于小目标。另外，小目标缺陷的检测置信度通常较低，边界框的回归往往不够精确，这些因素都会影响 NMS 的效果。

针对以上这些问题，本文引入 NWD[102]（Normalized Wasserstein Distance，归一化 Wasserstein 距离），在处理小目标时表现出显著的优势。相比于计算两个目标框之间的 IoU，NWD 通过将边界框视为二维高斯分布，计算检测框和参考框之间的 Wasserstein 距离来评估框的相似度，这样，在两个小目标缺陷有高度重叠的情况下，NWD 可以通过空间位置和形状的微小差异，更精确地将两个小目标区分出来，提高模型的召回率。

具体的，首先将预测框和真实框建模为高斯分布，这一操作的核心意义在于，将传统预测框与真实框之间的交并比计算，巧妙地转化为对高斯分布中两条等值线之间距离的计算；之后使用 Wasserstein 距离计算两个高斯分布距离,假设边界框 $A=(cx_a,cy_a,w_a,h_a)$ 和真实框 $B=(cx_b,cy_b,w_b,h_b)$ 建模的高斯分布为 N_a 和 N_b，那么 A 和 B 的 Wasserstein 距离为公式 4-7 所示。

$$W_2^2(N_a,N_b)=\left\|\left([cx_a,cy_a,\frac{w_a}{2},\frac{h_a}{2}]^T,[cx_b,cy_b,\frac{w_b}{2},\frac{h_b}{2}]^T\right)\right\|_2^2 \tag{0-17}$$

Wasserstein 距离是一种距离度量，IoU 取值范围在[0,1]，因此需要对 $W_2^2(N_a,N_b)$ 归一化后才可用作相似度度量。归一化后的 Wasserstein 距离如公式 4-8 所示。

$$NWD(N_a,N_b)=e^{-\frac{\sqrt{W_2^2(N_a,N_b)}}{c}} \tag{0-18}$$

其中，C 为常数，通常设为目标类别数。基于 NWD 的损失函数如公式 4-9

所示。

$$\begin{aligned} Loss_{NWD} &= 1 - NWD(N_a, N_b) \\ Loss &= \partial \times Loss_{NWD} + (1-\partial) \times Loss_{CIoU} \end{aligned} \tag{0-19}$$

本研究将 NWD 损失和 CIoU 通用损失函数以一特定权重∂相结合，组成的新损失函数相比于 NMS，NWD 不仅仅依赖于固定的 IoU 阈值，而是通过 Wasserstein 距离度量自适应地决定是否抑制一个检测框，这相比于 NMS 更加灵活，解决了小尺寸目标的检测任务中 IoU 阈值难以选择的问题。相比传统的 NMS，NWD 通过引入更加细致的 Wasserstein 距离度量，它能够更准确地区分相邻的小目标，减少误抑制，提升模型检测的鲁棒性和召回率。

4.3 实验和结果分析

4.3.1 实验环境

本实验在台式工控机上进行，实验平台硬件参数、Python 版本、CUDA 版本和 Cudnn 版本同表 3-2，其他参数设置见下表 4-2：

表 4-2 实验环境配置表

Table 4-2 Experimental Environment Configuration

模块	配置
学习率	0.01
随机种子	1
权重衰减系数	0.0005
训练轮数	600

4.3.2 评价指标

本文选择平均类别准确度（mean Average Precision，mAP）作为对比实验的评估标准。以 mAP50 为例，其指标计算过程如下：对于数据集中的每个类别，将模型检测出的目标框按置信度得分降序排列，以 IoU 阈值 0.5 为标准，依次计算每个目标框的精确率和召回率，据此绘制 Precision - Recall 曲线，通过插值法等计算该曲线下的面积，得到每个类别的 AP 值；最后，将所有类别的 AP 值求平均，得到的平均值即为 mAP50，其数值越高代表模型检测性能越好。

4.3.3 对比实验

为了体现出 YOLO-NP 模型的性能，本文将本研究与其他经典 YOLO 模型及其改进模型都进行全面比较，包括 YOLOv5s、YOLOv6s、YOLOv8s、YOLOv10s、YOLO11S 等基础 YOLO 模型，通过收集-分发机制实现特征提取和融合的 Gold-YOLO[103]以及经典的二阶段目标检测模型和基于 Transfomer 架构的目标检测模

型 RT-DETR[104]。结果如表 4-3 所示。

表 4-3 不同模型分类性能对比

Table 4-3 Comparison of detection capabilities across different models

模型	P	R	mAP50	mAP95	Params
YOLOv5	0.619	0.484	0.505	0.443	7.03M
YOLOv6	0.48	0.549	0.507	0.421	18.68M
YOLOv8	0.524	0.326	0.387	0.231	11.17M
YOLOv10	0.517	0.386	0.396	0.246	8.13M
YOLO11	0.538	0.439	0.423	0.24	9.42M
GOLD-YOLO	0.478	0.455	0.497	0.407	22.8M
Faster-RCNN	0.507	0.511	0.507	0.452	25.1M
RT-DETR	0.327	0.154	0.137	0.0975	32.97M
YOLO-NP	0.614	0.523	0.563	0.505	20.12M

通过表 4-3 的对比实验可知，从检测准确率、漏检率和精度角度，YOLO-NP 分别达到 0.614、0.523、0.559 和 0.491，在所有对比模型中处于领先位置，说明其在不同 IoU 阈值下对目标的检测精度较高，能更准确地识别出目标物体。各个模型对比中发现，YOLOv8、YOLOv10 和 YOLO11 模型检测精度较低，尤其 mAP95 指标比 mAP50 平均低 0.16，说明检测框定位精度不足，模型虽然能大致找到目标所在位置，但在更精准定位目标边界方面表现欠佳，检测框与真实目标框难以达到高度重合。镍板表面缺陷数据集普遍存在各种缺陷相互叠加的情况，在这种复杂的镍板表面场景下模型难以精确确定目标的准确范围。另外，本文测试时发现，Faster-RCNN 虽然有较高的检测精度和较为均衡的性能，但是检测 FPS 仅为 8，并不能达到实际生产需求。基于 Transformer 的 RT-DETR 模型训练时间极长，且在 batchsize 设置为 32 时，存在显存溢出的问题。

表 4-4 展示了各个模型对污渍、水渍和绿色结晶这三种缺陷的检测能力，表中的值依次为 mAP50 和 mAP95。这三种缺陷小尺寸目标占比较高，结果表明，基于锚框的 YOLO-NP 对小目标缺陷的检测能力更强。因此，本文认为改进后的 YOLO-NP 在镍板缺陷检测任务中更有优势。

表 4-4 不同模型检测小目标缺陷的性能对比实验结果

Table 4-4 Comparison of different algorithms detecting small targets

模型	污渍	水渍	绿色结晶
YOLOv5	0.414/0.329	0.552/0.509	0.359/0.298
YOLOv6	0.357/0.295	0.529/0.477	0.283/0.233
YOLOv8	0.265/0.121	0.481/0.275	0.087/0.0254

续表 4-4 不同模型检测小目标缺陷的性能对比实验结果

Table 4-4 Comparison of different algorithms detecting small targets (continued)

YOLOv10	0.228/0.0968	0.427/0.213	0.0905/0.0316
YOLO11	0.256/0.105	0.411/0.227	0.0455/0.0155
GOLD-YOLO	0.417/0.32	0.527/0.473	0.3/0.217
Faster-RCNN	0.209/0.0919	0.469/0.257	0.153/0.0491
RT-DETR	0.154/0.0287	0.357/0.185	0.0802/0.012
YOLO-NP	0.41/0.332	0.58/0.531	0.403/0.317

本文在设计 YOLO-NP 时发现：基于 anchor-free 架构的 YOLOv8、YOLOv10 和 YOLO11 模型检测性能大幅落后于较早版本的 YOLOv5 和 YOLOv6，尤其是小目标缺陷的检测性能（表 4-4）。YOLO11 模型相对 YOLOv8 和 YOLOv10 有更高的检测性能，因此本文选择 YOLO11 模型结构结合锚框作为模型的改进基础。

根据本文电解镍板缺陷数据集中各类缺陷尺度差异较大、部分缺陷样本较少的情况，本文认为无锚框模型并不适用于本文数据集。为了证明锚框在本任务中的必要性，选取表 4-3 中检测性能相对较好的无锚框模型 YOLO11 结构结合针对 COCO 数据集采用 K-means 方法聚类得到的锚框 anchors1、针对电解镍板表面缺陷数据集采用 K-means 方法聚类得到的锚框 anchors2、采用 DBSCAN 算法聚类得到的锚框 anchor3 和 YOLOv5、YOLO11 基础模型相比较。DBSCAN 是一种基于密度的空间聚类算法，该算法通过样本点的密度来进行聚类，如果一个区域内的点密度超过某个阈值，就将这些点划分为一个聚类[105]。对比实验中锚框信息如表 4-5 所示，对比实验结果如表 4-6 所示。

表 4-5 锚框信息

Table 4-5 Anchors information

锚框	数据集	方法	小	中	大
Anchors1	COCO	K-means	10,13 16,30 33,23	30,61 62,45 59,119	116,90 156,198 373,326
Anchors2	镍板	K-means	6.3,7.4 9.7,12.3 15.9,22.4	44.5,29.8 23.7,65.8 31.7,181.3	75.5,84.6 186,63.8 351.6,352.3
Anchors3	镍板	DBSCAN	9.8,40.7 50.3,75.6 85.8,113.6	151.5,193.5 224.1,240.1 251.7,292.8	329.2,393.7 406.5,457.9 511.6,577

表 4-6 引入不同锚框模型检测性能对比

Table 4-6 Comparison of detection capabilities across different anchors

模型结构	锚框	P	R	mAP50	mAP95
YOLOv5	Anchors1	0.619	0.484	0.505	0.443
YOLO11	无	0.538	0.439	0.423	0.24
YOLO11	Anchors1	0.639	0.484	0.5	0.45
YOLO11	Anchors2	0.631	0.493	0.517	0.458
YOLO11	Anchors3	0.601	0.513	0.503	0.449

根据表 4-6 可知，不同锚框设置对 YOLO 模型性能影响较大，对于 YOLO11 模型结构，使用锚框比无锚框设置性能提升很大，部分指标甚至超过 YOLOv5 使用基于 COCO 数据集锚框的表现。引入基于电解镍板表面缺陷数据集的锚框结合 YOLO11 模型结构，可以取得更优异的检测结果。K-means 和 DBSCAN 聚类算法对检测性能也有影响，基于 K-means 聚类得到的锚框检测性能比基于 DBSCAN 的锚框在 mAP50 指标稍高 1%，mAP95 指标稍高 0.1%，因此，本文选择 K-means 作为锚框生成算法。基于锚框的 YOLO11 模型记为 YOLO-Anchors1，之后的对比实验全部在 YOLO-Anchors1 下进行。

4.2.4 节中，本文基于 PPA 注意力机制，设计了改进的 C3k2-PPA 结构。本文将 PPA 模块和 C3k2-PPA 分别替换 YOLO-Anchors1 主干网络中全部 C3k2 模块，对比实验如表 4-7 所示。

表 4-7 引入 PPA 模块及其变体后模型检测性能对比

Table 4-7 Comparison of detection capabilities after introducing the PPA module and its variants

模型	P	R	mAP50	mAP95
YOLO-Anchors1	0.639	0.484	0.5	0.45
YOLO-Anchors1 + PPA	0.628	0.52	0.518	0.463
YOLO-Anchors1 + C3k2-PPA	0.586	0.547	0.52	0.454

由表 4-7 可知，PPA 和 C3k2-PPA 均可提升模型检测性能。PPA 注意力可将 mAP50 提升 1.8%，mAP95 提升 1.3%；C3k2-PPA 注意力将 mAP50 提升 2%，mAP95 提升 0.04%。此外，引入 PPA 注意力后 mAP50 指标和 mAP95 指标差值更小，这意味着模型对小目标缺陷的定位能力更加精确。因此，针对本文任务，最终选择 PPA 模块替换原结构中 C3k2。

为了体现出提出 LW 模块的性能，本文将 LW 与其他经典特征融合模块在 YOLO11 和 YOLO-Anchors1 模型中进行全面比较，其他经典特征融合模块包括引入加权策略 BiFPN[106]，引入自适应空间特征融合的 ASFF[107]。比较结果见表 4-8 和表 4-9。

表 4-8 YOLO11 引入不同特征融合后模型检测性能对比

Table 4-8 Comparison of detection capabilities after introducing different feature fusion modules to YOLO11

模型	P	R	mAP50	mAP95
YOLO11	0.538	0.439	0.423	0.24
YOLO11 + BiFPN	0.567	0.351	0.375	0.201
YOLO11 + ASFF	0.582	0.403	0.416	0.238
YOLO11 + LW	0.492	0.42	0.42	0.258

表 4-9 YOLO-Anchors1 引入不同特征融合后模型检测性能对比

Table 4-9 Comparison of detection capabilities after introducing different feature fusion modules to YOLO-Anchors1

模型	P	R	mAP50	mAP95
YOLO-Anchors1	0.639	0.484	0.5	0.45
YOLO-Anchors1 + BiFPN	0.501	0.531	0.509	0.437
YOLO-Anchors1 + ASFF	0.57	0.514	0.511	0.452
YOLO-Anchors1 + LW	0.596	0.557	0.515	0.464

基于表 4-8 和表 4-9 可知，LW 模块在 YOLO11 和 YOLO-Anchors1 中都有一定优势。BiFPN 和 ASFF 引入至 YOLO11 后，模型性能下降，尤其 BiFPN 下降最为明显，mAP50 下降 4.8%，mAP95 下降 3.9%；而引入至 YOLO-Anchors1 后模型性能变化很小，本文认为：镍板表面缺陷数据集特征复杂，基础模型性能较低表现了模型学习特征不到位的问题，主干网络提取的低维和高维特征质量较低，融合低质量的特征反而对模型有更差的影响；LW 模块中的 SE 注意力机制通过增强通道层面的关注，可以有效挖掘特征之间内在联系，进一步提升特征质量。

4.3.4 消融实验

为了进一步探讨模型中各改进的影响，在 YOLO11 基准模型的基础上引入 Anchors2 锚框，随后引入改进方法开展消融实验。为保障实验的公正性，实验环境和分类网络超参数配置保持表 4-2 中设置不变，同时在不同的实验进程中仅增添对应的模块。

表 4-10 消融实验结果

Table 4-10 Results of The Ablation Experiments

算法	锚框	PPA	LW	SPDConv	NWD	mAP50	mAP95
算法 1	-	-	-	-	-	0.423	0.24
算法 2	√	-	-	-	-	0.517	0.458

续表 4-10 消融实验结果

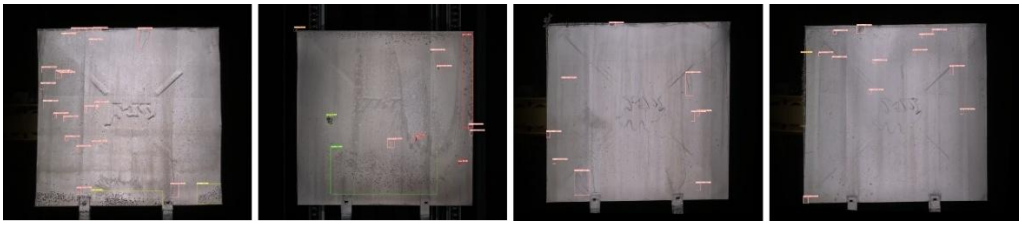
Table 4-10 Results of The Ablation Experiments (continued)

算法 3	√	√	-	-	-	0.524	0.467
算法 4	√	-	√	-	-	0.527	0.474
算法 5	√	-	-	√	-	0.531	0.481
算法 6	√	-	-	-	√	0.538	0.473
算法 7	√	√	√	-	√	0.548	0.48
算法 8	√	√	-	√	√	0.55	0.486
YOLO-NP	√	√	√	√	√	0.563	0.511

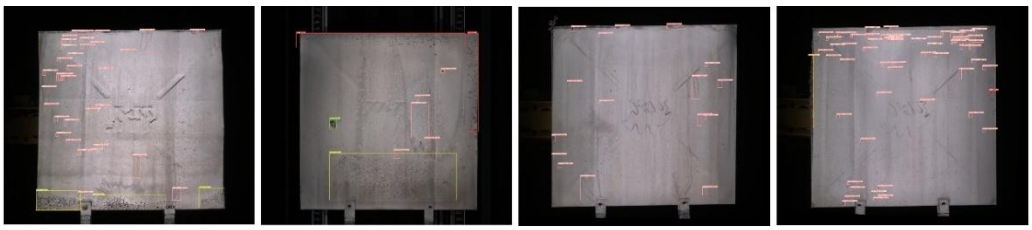
从表 4-10 结果可见，随着逐步加入改进的模块，模型性能显著提升。仅使用 YOLO11 时，mAP50 为 0.423，模型检测性能较低。YOLO11 引入了基于本文数据集的锚框后，mAP50 提升至 0.517，mAP95 提升至 0.458，表明锚框对模型性能有明显提升作用。后续算法 3、4、5、6 在基于锚框的 YOLO11 模型基础上分别引入 PPA、SPDConv、LW 和 NWD 损失函数，模型性能都有所提升，体现了各组件对模型检测能力的积极作用。算法 7、8 在引入锚框、PPA 注意力机制和 NWD 损失函数的基础上，分别引入 LW 模块和 SPDConv 卷积，模型性能均有提升。最终的 YOLO-NP 算法，融合了上述所有组件，mAP50 达到 0.563，mAP95 达到 0.501，相比 YOLO11，mAP50 和 mAP95 分别提升 14%和 27.1%，在所有算法中表现最佳，也验证了各改进模块的有效性。

4.4　检测结果可视化对比

4.3 节中，YOLO-NP 数值指标虽然能定量衡量模型性能，但无法直观展示模型具体检测电解镍板表面缺陷中的表现差异。通过可视化对比，可以清晰呈现不同模型对同一张镍板的检测效果。考虑到 YOLO11 模型在本文电解镍板表面缺陷数据集上性能较差，本段图 4-6、图 4-7 和图 4-8 展示 YOLO-Anchors2 和 YOLO-NP 对相同镍板的检测性能对比。



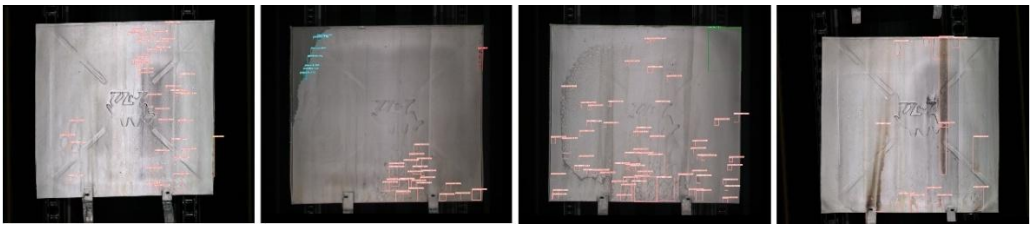
(a) YOLO-Anchors2 检测



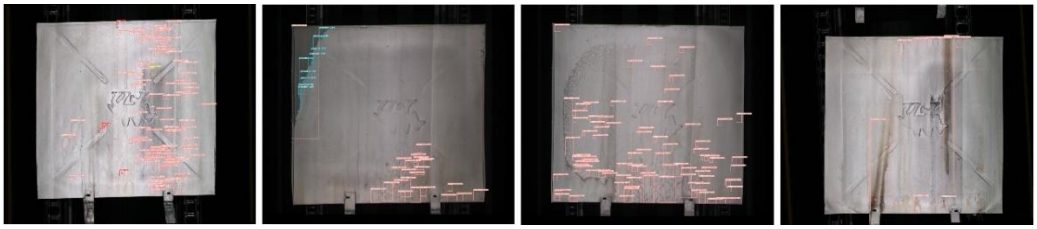
(b) YOLO-NP 检测

图 4-6 YOLO-Anchors2 和 YOLO-NP 检测效果对比 1

Figure 4-6 Comparison between YOLO-Anchors2 and YOLO-NP 1



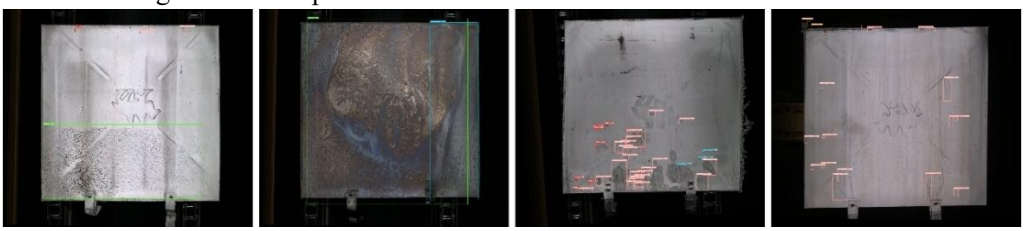
(a) YOLO-Anchors2 检测



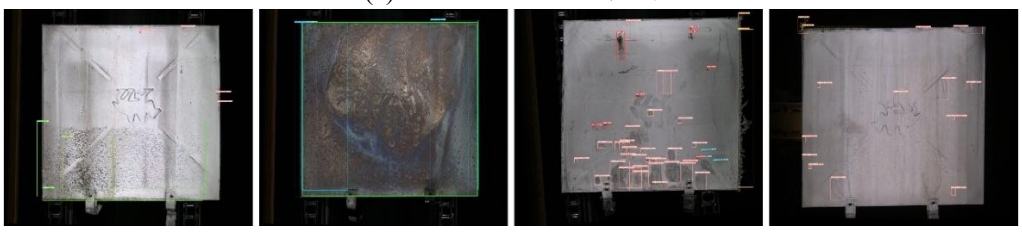
(b) YOLO-NP 检测

图 4-7 YOLO-Anchors2 和 YOLO-NP 检测效果对比 2

Figure 4-7 Comparison between YOLO-Anchors2 and YOLO-NP 2



(a) YOLO-Anchors2 检测



(b) YOLO-NP 检测

图 4-8 YOLO-Anchors2 和 YOLO-NP 检测效果对比 3

Figure 4-8 Comparison between YOLO-Anchors2 and YOLO-NP 3

YOLO-NP 能检测出更多小水渍，同时对同一个缺陷检测的置信度更高；在

检测渐变型水渍缺陷时，YOLO-NP 对正常区域和水渍区域的分界更为明晰，模型对不同颜色之间细微的差异学习能力更强；此外，在图 4-7 组对比可知，YOLO-NP 对于叠加缺陷的识别能力也有所提升，当绿色结晶和水渍叠加时，YOLO-NP 可在准确检测微小绿色结晶缺陷时仍能检测出底部的水渍缺陷；另外，结粒和疙瘩缺陷之间的差异由单个缺陷的面积决定，凸起较大为疙瘩，较小为结粒。由图 4-8 可知 YOLO-Anchors2 较难学习到结粒和疙瘩之间的差异，YOLO-NP 则在此两种缺陷相互叠加时仍可分清，并且有较高的置信度（被结粒包围的疙瘩置信度为 0.81）。针对结粒和酸污染相互叠加状态时，电解镍板表面颜色信息复杂，此时 YOLO-Anchors2 对酸污染的检测能力下降，而 YOLO-NP 仍可以准确检测到酸污染缺陷的区域。

4.5　本章小结

针对电解镍板表面缺陷检测的问题，本章首先构建了由 1195 张电解镍板、15973 组成的电解镍板表面缺陷检测数据集，针对电解镍板表面小目标缺陷多、颜色信息丰富、部分缺陷差异较小的问题，设计 YOLO-NP 目标检测模型，其基于 YOLO11，从锚框、主干网络引入注意力机制、模型颈部的卷积计算和特征融合、损失函数角度改进。

为充分验证 YOLO-NP 模型的性能，本文开展了一系列对比实验。将 YOLO-NP 与其他经典目标检测算法在本章所采用的数据集上进行性能对比；基于不同锚框检测性能对比；比较不同特征融合机制对模型性能的影响；探究损失函数不同参数设置下模型的表现；进行 12 组算法检测结果的可视化对比。经多维度对比分析，最终证实了在镍板场景中，相较于 YOLO11 原始算法和基于锚框和 YOLO11 结构的 YOLO-Anchors2，YOLO-NP 能够识别出那些尺度更细小、长宽比更大、细节差异更细微、颜色差异不明显、缺陷之间相互叠加的缺陷，改进后的算法可以满足电解镍板表面缺陷检测任务。

第五章　总结与展望

5.1　总结

本文针对镍板生产行业的现状，面对具体的电解镍板处理问题，设计了一套高质量镍板图像采集系统，实现高质量、稳定、快速的镍板图像采集；基于图像采集系统采集的电解镍板图像，构建由 2331 张电解镍板组成的电解镍板表面分类数据集和由 1195 张电解镍板、15973 的电解镍板表面缺陷数据集；基于 Resnet18 模型，设计 Nickel-Classifier 分类网络，实现电解镍板等级的准确分类；基于 YOLO11 模型和锚框，设计 YOLO-NP 一阶段目标检测网络实现电解镍板表面缺陷的准确检测。结合高质量镍板图像采集系统和算法，与厂方 PLC、机械臂联动，本文实现了电解镍板的全自动化处理。

5.2　展望

尽管目前已经实现稳定高效的电解镍板图像采集、分类和检测，且在现场生产中已经取得不错的效果，但仍然存在一些问题值得进一步研究和改善：

（1）电解镍板的表面缺陷生成机制与生产工艺密切相关。随着工业生产技术的迭代发展，后期工艺不断升级优化，原本相同类型的缺陷在表现形态上可能会呈现出显著差异。例如，早期因特定工艺环节导致的某类缺陷，在工艺改进后，其纹理、形状、尺寸等特征可能发生明显变化。这种因工艺升级引发的缺陷特征演变，对基于既有数据训练的目标检测模型构成了严峻挑战。由于模型未曾在训练过程中接触到此类特征，可能无法准确识别和判断，导致检测精度大幅下降。如何提升模型对这类未见过形态学缺陷的准确检测能力，非常值得研究。

（2）数据集的样本分布不均衡是一个亟待解决的关键问题。以当前的电解镍板表面缺陷数据集为例，不同类型的缺陷样本数量呈现出显著的差异。其中，污渍和水渍缺陷的样本数量分别达到了 2877 和 9561 个，而发污缺陷由于在电解镍板实际生产过程中发生概率较低，其样本数量极为稀少，仅有 33 个。这种严重的样本不均衡分布，会对基于该数据集训练的目标检测模型产生诸多不利影响。在模型训练过程中，样本数量较多的类别会在梯度更新中占据主导地位，导致模型过度学习这些常见类别的特征，而对少数类别的特征学习不足，从而降低模型对罕见缺陷（如发污缺陷）的检测精度和泛化能力。为了有效缓解这一问题，有必要采取针对性的措施。一方面，可以继续采集特定的电解镍板图像，尤其是包含罕见缺陷的图像，以扩充少数类别的样本数量。另一方面，尝试引入先进的图像生成算法，如生成对抗网络（GAN）或变分自编码器（VAE）等，通过对现有样本进行数据增强，生成与少数类别相似的合成样本，从而平衡各类别之间的样

本数量差异。

（3）NWD 损失函数和 CIoU 损失函数的融合应用中，权重 α 的确定是一个关键问题。本文采用手动调参的方式，根据模型在训练和验证过程中的性能表现来寻找最优的 α 值。一方面，调参过程极为耗时，需要耗费大量的计算资源和时间成本；另一方面，由于不同的数据集在目标的分布、尺度、背景复杂度等方面存在差异，导致针对某一数据集所确定的最优 α 值，难以直接应用于其他数据集，即该方法的泛化性较差。这使得模型在不同数据集之间的迁移应用面临挑战，限制了其在更广泛场景中的有效使用。鉴于手动调参确定 α 值的上述弊端，后续针对 α 值的自动化、高效调参方法的研究显得尤为重要且极具价值。通过开发更智能、自适应的调参策略，有望提高模型在不同数据集上的性能优化效率，增强模型的泛化能力，推动目标检测技术在实际应用中的进一步发展和拓展。

参考文献

[1] 黄乐清.基于 SVM 的工程机械钢圈缺陷分类算法研究[J].今日制造与升级,2024,(12):7-9.

[2] 叶飞,刘伟红,杨娟亚,等.基于支持向量机的多特征融合纤维分类算法[J].毛纺科技,2024,52(09):104-110.DOI:10.19333/j.mfkj.20240306707.

[3] Pernkopf F .Detection of surface defects on raw steel blocks using Bayesian network classifiers[J].Pattern Analysis & Applications, 2004, 7(3):333-342.DOI:10.1007/BF02683998.

[4] Ravikumar S , Ramachandran K I , Sugumaran V .Machine learni-ng approach for automated visual inspection of machine components[J].Exp-ert Systemswith Applications, 2011, 38(4):3260-3266.DOI:10.1016/j.eswa.2010.09.012.

[5] 胡坤,吴国庆,胡祖辉,等.基于改进的 VGG16 网络金属表面缺陷图像分类研究[J].计算机应用与软件,2024,41(06):175-180.

[6] 王玲,崔志瑜,黄靖,等.融合局部和全局特征的改进 Transformer 工业图像分类算法[J/OL].计算机工程与应用,1-11[2025-02-27].http://kns.cnki.net/kcms/detail/11.2127.tp.20241017.1332.007.html.

[7] 王洪栋,储杰,高思念,等.基于 ResNet 的石油焦与冶金焦图像分类[J].江苏理工学院学报,2024,30(04):79-84.DOI:10.19831/j.cnki.2095-7394.2024.04.003.

[8] 张瑞.贴片元器件外观缺陷分类系统研究[D].西南科技大学,2024.DOI:10.27415/d.cnki.gxngc.2024.001584.

[9] 于晓亮,吴承亮,董武振,等.一种基于空间注意力优化的机载成附件紧固件缺陷分类算法[J].智能制造,2025,(01):124-128.

[10] 陈晓雷,李正成,杨富龙,等.全局与局部多尺度特征融合晶圆缺陷分类网络[J].电子测量与仪器学报,2024,38(10):159-169.DOI:10.13382/j.jemi.B2407559.

[11] 王前,包春梅,陈望,等.基于多尺度特征聚合的铝材表面缺陷分类[J].智能计算机与应用,2024,14(11):124-130.DOI:10.20169/j.issn.2095-2163.241119.

[12] 云晗,付红红,王宗仁,等.基于卷积神经网络焊管缺陷分类识别[J].理化检验-物理分册,2024,60(07):35-39.

[13] 余光海,盛光鸣,张元昊,等.基于深度学习的废旧电路板表面缺陷分类[J].现代计算机,2024,30(10):17-22.

[14] 熊政,车文刚,保永莉,等.基于改进的 MobilenetV3 热轧钢带表面缺陷分类[J].兰州大学学报(自然科学版),2024,60(02):182-186.DOI:10.13885/j.issn.0455-2059.2024.02.006.

[15]陈晓桐.基于机器学习的金属制品表面瑕疵检测研究[J].中国金属通报,2024,(10):92-94.

[16] 刘宝宝,杨菁菁,陶露,等.基于注意力的 DSMSC 的遥感图像场景分类[J].计算机与现代化,2024,(12):72-77.

[17] 刘怡,李渊,孙搏遥,等.多尺度异构与跨模态注意力的遥感图像分类[J/OL].空间电子技术,1-9[2025-01-03].http://kns.cnki.net/kcms/detail/61.1420.TN.20241227.1007.008.html.

[18] 刘勇,杨伟丽,郭鹏宇,等.基于改进 YOLOv5 的多光谱卫星遥感图像地物分类方法[J].航天返回与遥感,2024,45(06):113-123.

[19] 崔宇琛,谢元栋,吴聿淼,等.基于 ViT-B 深度学习模型的口腔良恶性病变图像分类研究[J].口腔医学研究,2025,41(01):16-20.DOI:10.13701/j.cnki.kqyxyj.2025.01.004.

[20] 刘沐然,谭敏慧,张煜.基于深度学习对 CBCT 图像采用多视角投影的牙齿分类[J].中国医学物理学杂志,2025,42(03):313-319.

[21] 冯敬文,叶永浓,杨梓玥,等.基于 VGGNet、EfficientNet 以及 CaiT 深度学习模型建立中药饮片快速识别方法研究[J].中国处方药,2024,22(12):36-40.

[22] 陈诺,朱琎,赵启程,等.基于鲸鱼优化算法的乳腺癌图像分类方法研究[J/OL].电子测量技术,1-11[2025-01-03].http://kns.cnki.net/kcms/detail/11.2175.TN.20241226.1619.028.html.

[23] 方燕燕,陈辉.基于改进 ResNet 的多标签胸部 X 光图像分类[J].山东理工大学学报(自然科学版),2025,39(02):1-9.DOI:10.13367/j.cnki.sdgc.2025.02.008.

[24] Yang S , Lei C .Research on the Classification Method of Complex Snow and Ice Cover on Highway Pavement Based on Image-Meteorology-Temperature Fusion[J].IEEE sensors journal, 2024, 24(2):1784-1791.DOI:10.1109/JSEN.2023.3336667.

[25] F. Ullah, I. Ullah, R. U. Khan, S. Khan, K. Khan and G. Pau .Conventional to Deep Ensemble Methods for Hyperspectral Image Classification: A Comprehensive Survey[J].IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, vol. 17, pp. 3878-3916, 2024, doi: 10.1109/JSTARS.2024.3353551.

[26] Ai J , Qu Z , Zhao Z ,et al.An SAR Target Classification Algorithm Based on the Central Coordinate Attention Module[J].IEEE sensors journal, 2024(2): 24.DOI:10.1109/JSEN.2023.3338218.

[27] Lei C , Wang H , Lei J .SI-GAT: Enhancing Side-Scan Sonar Image Classi-

fication Based on Graph Structure[J].IEEE sensors journal, 2024(15):24.DOI:10.1109/JSEN.2024.3416193.

[28] 李建华,刘广鹏,赵正天,等.基于机器视觉的镍板材表面缺陷检测研究[J].机械制造与自动化,2024,53(03):66-69+118.DOI:10.19344/j.cnki.issn1671-5276.2024.03.014.

[29] 朱正云,许平,陆迎东,等.基于机器视觉的镍板表面气孔分割算法研究[J].传感器与微系统,2024,43(05):19-22.DOI:10.13873/J.1000-9787(2024)05-0019-04.

[30] 张新娜,吴兆中,王栋,等.基于机器视觉的凸轮轴表面缺陷检测实验研究[J/OL].机电工程,1-12[2025-02-27].http://kns.cnki.net/kcms/detail/33.1088.TH.20241125.1137.002.html.

[31] 李鑫.基于机器视觉的焊缝表面缺陷检测方法研究[D].长春工业大学,2024.DOI:10.27805/d.cnki.gccgy.2024.000942.

[32] 仓传跃,徐志鹏,周彬.基于机器视觉的注塑件缺陷检测方法[J].塑料,2025,54(01):149-153+188.

[33] 王艺斌,袁新科,周学斌,等.基于机器视觉的卷烟包装纸缺陷检测算法研究[J].造纸装备及材料,2025,54(01):1-3.

[34] 钱厚亮,赵帅.基于机器视觉的多规格纽扣缺陷检测方法[J].信息技术与信息化,2024,(12):217-220.

[35] 潘盛辉,邱振武,赵伟鹏.基于机器视觉的铝巴表面缺陷检测系统设计[J].物联网技术,2024,14(09):15-19+24.DOI:10.16667/j.issn.2095-1302.2024.09.004.

[36] 谭沁源,唐勇,金岩,等.基于改进 YOLOv5 的镍板表面缺陷检测方法[J].矿冶工程,2024,44(02):160-166.

[37] 林永春,夏鹏飞,董森,等.基于彩涂钢板表面质量缺陷的检测算法[J].河北冶金,2025,(01):47-51.DOI:10.13630/j.cnki.13-1172.2025.0107.

[38] 宋涛,胡颖涛.融合多层次特征的钢材表面缺陷检测方法[J].现代计算机,2024,30(21):26-31.

[39] 张耕培,窦萧寒,李刚.基于机器视觉的石油管具螺纹缺陷检测系统[J].长江大学学报(自然科学版),2024,21(06):120-126.DOI:10.16772/j.cnki.1673-1409.2024.06.008.

[40] 张茹,杨昊,王钰圣,等.基于深度学习的轻量化木材表面缺陷检测系统研究[J/OL].林业工程学报,1-18[2025-03-04].https://doi.org/10.13360/j.issn.2096-1359.202406003.

[41] 刘国民,温秀兰,高华卿,等.基于深度学习的铝型材表面缺陷检测研究[J].计量与测试技术,2024,51(10):23-25.DOI:10.15988/j.cnki.1004-6941.2024.10.007.

[42] 王大维.基于深度学习的汽车冲压件开裂缺陷检测方法研究与应用[D].沈阳工业大学,2024.DOI:10.27322/d.cnki.gsgyu.2024.000745.

[43] 张玉.基于深度学习的管道漏磁缺陷智能检测方法[J].石油和化工设备,2024,27(08):17-21.

[44] Mcculloch W S , Pitts W .A Logical Calculus of the Ideas Immanent in Nervous Activity[J].biol math biophys, 1943.

[45] Rosenblatt, F .The perceptron: a probabilistic model for information storage and organization in the brain[J].Psychological Review, 1958, 65:386-408.DOI:10.1037/h0042519.

[46] Minsky M L , Papert S .Perceptrons : An Introduction to Compu-tational Geometry[J].The MIT Press, 1991.DOI:10.1097/00000542-199109001-00453.

[47] Rumelhart D E , Hinton G E , Williams R J .Learning Representations by Back Propagating Errors[J].Nature, 1986, 323(6088):533-536.DOI:10.1038/323533a0.

[48] Kosko, B .Bidirectional associative memories[J].Systems Man & Cy-bernetics IEEE Transactions on, 1988, 18(1):49-60.DOI:10.1109/21.87054.

[49] Lecun Y, Matan O , Boser B , et al .Handwritten zip code recognition with multilayer networks[C]//Proc. of the International Conference on Pattern Recognition.IEEE, 1990.DOI:10.1109/ICPR.1990.119325.

[50] Pollack J B .Recursive distributed representations[J].Artificial Intelligence, 1990, 46(1-2):77-105.DOI:10.1016/0004-3702(90)90005-K.

[51] Burges C J C .A Tutorial on Support Vector Machines for Pattern Recogniti on[J].Data Mining and Knowledge Discovery, 1998, 2(2):121-167.DOI:10.1023/A:1009715923555.

[52] Hinton G E , Osindero S , Teh Y W .A Fast Learning Algorithm for Deep Belief Nets[J].Neural Computation, 2006, 18(7):1527-1554.DOI:10.1162/neco.2006.18.7.1527.

[53] Deng J , Dong W , Socher R , et al .ImageNet: A large-scale hierarchical image database[J].Proc of IEEE Computer Vision & Pattern Recognition, 2009:248-255.DOI:10.1109/CVPR.2009.5206848.

[54] Krizhevsky A , Sutskever I , Hinton G .ImageNet Classification with Deep Convolutional Neural Networks[C]//NIPS.Curran Associates Inc. 2012.DOI:10.1145/3065386.

[55] Hochreiter S , Schmidhuber J .Long Short-Term Memory[J].Neural Computati

on, 1997, 9(8):1735-1780.DOI:10.1162/neco.1997.9.8.1735.

[56] Cho K , Van Merrienboer B , Gulcehre C ,et al .Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation[J].Computer Science, 2014.DOI:10.3115/v1/D14-1179.

[57] Chakraborty T , Ujjwal R K S , Naik S M ,et al .Ten years of generative adversarial nets (GANs): a survey of the state-of-the-art[J].IOP Publishing Ltd, 2024.DOI:10.1088/2632-2153/ad1f77.

[58] Kingma D P , Welling M .Auto-Encoding Variational Bayes[J].arXiv.org, 2014.DOI:10.48550/arXiv.1312.6114.

[59] Mnih V , Heess N , Graves A ,et al .Recurrent Models of Visual Attention [J].Advances in Neural Information Processing Systems, 2014, 3.DOI:10.48550/arXiv.1406.6247.

[60] Bahdanau D , Cho K , Bengio Y .Neural Machine Translation by Jointly Learning to Align and Translate[J].Computer Science, 2014.DOI:10.48550/arXiv.1409.0473.

[61] Vaswani A , Shazeer N , Parmar N ,et al .Attention Is All You Need[J].arXiv, 2017.DOI:10.48550/arXiv.1706.03762.

[62] Dai Z , Yang Z , Yang Y ,et al .Transformer-XL: Attentive Language Models beyond a Fixed-Length Context[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics.2019.DOI:10.18653/v1/P19-1285.

[63] Velikovi P , Cucurull G , Casanova A ,et al .Graph Attention Networks[J]. 2017.DOI:10.48550/arXiv.1710.10903.

[64] Lecun Y , Bottou L .Gradient-based learning applied to document recognition[J].Proceedings of the IEEE, 1998, 86(11):2278-2324.DOI:10.1109/5.726791.

[65] 季长清,高志勇,秦静,等.基于卷积神经网络的图像分类算法综述[J].计算机应用, 2022, 42(4):6.DOI:10.11772/j.issn.1001-9081.2021071273.

[66] Simonyan K , Zisserman A .Very Deep Convolutional Networks for Large-Scale Image Recognition[J].Computer Science, 2014.DOI:10.48550/arXiv.1409.1556.

[67] He K , Zhang X , Ren S ,et al .Deep Residual Learning for Image Recognition[J].IEEE, 2016.DOI:10.1109/CVPR.2016.90.

[68] Tan M , Le Q V .EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[J]. 2019.DOI:10.48550/arXiv.1905.11946.

[69] Dosovitskiy A , Beyer L , Kolesnikov A ,et al .An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C]//International Conference on Learning Representations.2021.

[70] 陈洛轩,林成创,郑招良,等.Transformer 在计算机视觉场景下的研究综述[J].计算机科学, 2023, 50(12):130-147.DOI:10.11896/jsjkx.221100076.

[71] Touvron H , Cord M , Douze M ,et al.Training data-efficient ima-ge transformers & distillation through attention[J]. 2020.DOI:10.48550/arXiv.2012.12877.

[72] Yuan K , Guo S , Liu Z ,et al .Incorporating Convolution Designs into Visual Transformers[J]. 2021.DOI:10.48550/arXiv.2103.11816.

[73] Yuan L , Chen Y , Wang T ,et al .Tokens-to-Token ViT: Training Vision Transformers from Scratch on ImageNet[J]. 2021.DOI:10.48550/arXiv.2101.11986.

[74] Chen C F , Fan Q , Panda R .CrossViT: Cross-Attention Multi-S-cale Vision Transformer for Image Classification[J]. 2021.DOI:10.48550/arXiv.2103.14899.

[75] Redmon J , Divvala S , Girshick R ,et al .You Only Look Once: Unified, Real-Time Object Detection[C]//Computer Vision & Pattern Recognition.IEEE, 2016.DOI:10.1109/CVPR.2016.91.

[76] Redmon J , Farhadi A .YOLO9000: Better, Faster, Stronger[J].IEEE, 2017:6517-6525.DOI:10.1109/CVPR.2017.690.

[77] Redmon J , Farhadi A .YOLOv3: An Incremental Improvement[J].arXiv e-prints, 2018.DOI:10.48550/arXiv.1804.02767.

[78] Bochkovskiy A , Wang C Y , Liao H Y M .YOLOv4: Optimal Speed and Accuracy of Object Detection[J]. 2020.DOI:10.48550/arXiv.2004.10934.

[79] Jocher G. Ultralytics YOLOv5 (Version 7.0) [EB/OL]. (2020)[2023-10-05]. https://github.com/ultralytics/yolov5. DOI:10.5281/zenodo.3908559.

[80] LI C Y, LI L L, GENG Y F, et al. YOLOv6 v3.0: A Full-Scale Reloading [EB/OL]. (2023)[2023-10-05]. https://arxiv.org/abs/2301.05586.

[81] Wang C Y , Bochkovskiy A , Liao H Y M .YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[J].arXiv e-prints, 2022.DOI:10.48550/arXiv.2207.02696.

[82] Jocher G, Chaurasia A, Qiu J, et al. Ultralytics YOLOv8 (Version 8.0.0): A real-time object detection framework [EB/OL]. (2023)[2023-10-05]. https://gith

ub.com/ultralytics/ultralytics.

[83] Wang C Y , Yeh I H , Mark Liao H Y .YOLOv9: Learning Wh-at You Want toLearn Using Programmable Gradient Information[C]//European Conference on Computer Vision.Springer, Cham, 2025.DOI:10.1007/978-3-031-72751-1_1.

[84] Wang A , Chen H , Liu L ,et al.YOLOv10: Real-Time End-to-End Object Detection[J]. 2024.

[85] Jocher G, Qiu J. Ultralytics YOLO11 (Version 11.0.0): A next-generation real-time object detection system [EB/OL]. (2024)[2023-10-05]. https://github.com/ultralytics/ultralytics.

[86] Wei L , Dragomir A , Dumitru E ,et al .SSD: Single Shot MultiBox Detector[J].Springer, Cham, 2016.DOI:10.1007/978-3-319-46448-0_2.

[87] Girshick R , Donahue J , Darrell T ,et al .Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation[J].IEEE Computer Society, 2014.DOI:10.1109/CVPR.2014.81.

[88] Girshick R .Fast R-CNN[C]//2015.DOI:10.1109/ICCV.2015.169.

[89] Ren S , He K , Girshick R ,et al .Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149.DOI:10.1109/TPAMI.2016.2577031.

[90] He K , Gkioxari G , Dollar P ,et al .Mask R-CNN[J].IEEE, 2020(2).DOI:10.1109/TPAMI.2018.2844175.

[91] Hu J , Shen L , Sun G ,et al .Squeeze-and-Excitation Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, PP(99).DOI:10.1109/TPAMI.2019.2913372.

[92] Chollet F .Xception: Deep Learning with Depthwise Separable Co-nvolutions [C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR).IEEE, 2017.DOI:10.1109/CVPR.2017.195.

[93] Zhang Z , Lan C , Zeng W ,et al .Relation-Aware Global Attention for Person Re-Identification[C]//Computer Vision and Pattern Recognition.IEEE, 2020.DOI:10.1109/CVPR42600.2020.00325.

[94] Woo S , Park J , Lee J Y ,et al .CBAM: Convolutional Block Attention Module[J].Springer, Cham, 2018.DOI:10.1007/978-3-030-01234-2_1.

[95] Zhang H , Cisse M , Dauphin Y N ,et al .mixup: Beyond Empirical Risk Minimization[J]. 2017.DOI:10.48550/arXiv.1710.09412.

[96] Liu S , Qi L , Qin H ,et al .Path Aggregation Network for Instance Segmentation[J].IEEE, 2018.DOI:10.1109/CVPR.2018.00913.

[97] Lin T Y , Dollar P , Girshick R ,et al .Feature Pyramid Networks for Object Detection[J].IEEE Computer Society, 2017.DOI:10.1109/CVPR.2017.106.

[98] Macqueen J .Some methods for classification and analysis of multivariate ob servation-s[J].Proc. Symp. Math. Statist. and Probability, 5th, 1967, 1.

[99] Xu S , Zheng S C , Xu W ,et al.HCF-Net: Hierarchical Context Fusion Net work for Infrared Small Object Detection[J]. 2024.DOI:10.1109/ICME57554.2024.10687431.

[100] Sunkara R, Luo T. No more strided convolutions or pooling: A new CNN building block for low-resolution images and small objects[C]//Joint European conference on machine learning and knowledge discovery in databases. Cham: Springer Nature Switzerland, 2022: 443-459.

[101] Felzenszwalb, Pedro, F, et al .Object Detection with Discriminatively Trained Part-Based Models[J].IEEE Transactions on Pattern Analysis & Machine Intelligence, 2010, 32(9):1627-1645.DOI:10.1109/TPAMI.2009.167.

[102] Wang J , Xu C , Yang W ,et al. A Normalized Gaussian Wasserstein Distance for Tiny Object Detection[J]. 2021.DOI:10.48550/arXiv.2110.13389.

[103] Wang C , He W , Nie Y ,et al .Gold-YOLO: Efficient Object Detector via Gather-and-Distribute Mechanism[J]. 2023.

[104] Zhao Y, Lv W, Xu S, et al. Detrs beat yolos on real-time object detection [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16965-16974.

[105] Ester M , Kriegel H P , Sander J ,et al .A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise[J].Proc.int.conf.knowledg Discovery & Data Mining, 1996.

[106] Liu S , Huang D , Wang Y .Learning Spatial Fusion for Single-Shot Object Detection[J]. 2019.DOI:10.48550/arXiv.1911.09516.

[107] Tan M , Pang R , Le Q V .EfficientDet: Scalable and Efficient Object Detection[C]//2020 IEEE/CVF Conference on Computer Vision and Patter-n Recognition (CVPR).IEEE, 2020.DOI:10.1109/CVPR42600.2020.01079.

致 谢

在我即将完成硕士学位论文时，我想向硕士三年学习生涯中所有帮助过我的人们致以最真诚的感谢和敬意。

我要感谢我的家人，感谢你们一直以来对我的鼓励和支持。

我要感谢我的导师杨辉华老师和赵文义老师。您们在项目上给予我支撑，在学术研究方向、方法上对我指导，熬夜帮助我修改论文，让我顺利毕业。您严谨的治学态度，深深影响着我，让我从一个对学术懵懂的学生，逐渐学会如何严谨地思考、研究。没有您的悉心指导，我绝不可能顺利完成这篇论文。

我要感谢金川集团产品配送中心的白翔主任，李有誉、魏维和严鹏，感谢你们的帮助和支持，你们的经验、技术和设备资源支持对我有巨大帮助，你们的支持不仅保障了项目的进度，更提升了项目的质量。

我要感谢长沙矿山研究院的唐勇高级工程师、周向荣、谭沁源工程师，感谢你们在项目中对我的帮助。

我要感谢实验室的任明金师兄、侍掠飞师兄和母征岩师弟，我们一起攻克难关，完成了镍板表面缺陷检测的项目。

我还要感谢我的舍友们，三年来朝夕相处，以宿舍为家，带给我太多珍贵且美好的回忆。感谢舍友们一直以来对我的支持，使我在研究生三年变成更好的自己。

思绪难平，感恩相遇，后会有期，毕业快乐！

攻读学位期间取得的创新成果目录

[1] 任逸为，白翔，金岩，等. 基于改进 YOLOv5 的电解镍板表面缺陷检测[EB/OL]. 北京：中国科技论文在线 [2025-03-27]. https://www.paper.edu.cn/releasepaper/content/202503-282.

作者学习经历

起止年月	类别	学习单位名称	学科/专业名称
2014.9-2017.7	高中	北京市第二中学	--
2017.9-2021.7	本科	重庆大学	自动化
2022.9-2025.7	硕士	北京邮电大学	控制科学与工程